



Salmon Ladder: Catching Recurring Unknowns

表 紘太郎¹ 尾崎 慶次郎²

概要

near-OOD の検知は難しく、OpenOOD v1.5 では VLM の最良の報告値でも AUROC は 82.65% である。本稿は、凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで、繰り返し現れる未知をグラフ上の両側のラベル伝播で捕まえる学習なしの枠組み Salmon Ladder を提案する。支持画像から伝播した質量を較正画像の中での順位（共形 p 値）で読み、BH 法で偽発見率を抑えて未知の種を自己ラベル付けし、種から伝播した質量の順位を掛ける。OpenOOD v1.5 で near-OOD AUROC 98.07%・FPR95 10.22%, far-OOD 99.03%・4.28%, Four-OOD で 99.06%・3.36% を達成し、公開の最良値を near-OOD で AUROC 3.02 ポイント、FPR95 19.18 ポイント更新した。コード：omotes24/SalmonLadder.

1. はじめに

OOD 検知は、学習時のクラス (ID) 以外の入力を見分ける問題である。CLIP [1] などの VLM は学習なしに OOD を検知でき [2]、負例ラベル [3] やテスト時の適応 [4], [5], [6], [7] により、ID から遠い far-OOD の AUROC は 97% に達した。しかし ID に近い near-OOD は依然として難しい。OpenOOD v1.5 [8] の ImageNet-1K では、VLM による最良の報告値でも near-OOD の AUROC は 82.65%, FPR95 は 57.88% にとどまり [7]、ImageNet-1K のラベルで学習した検出器 [9], [10] や教師なし生成モデルの DisCoPatch [11] でも FPR95 は 29–48% 残る (表 2)。

本研究は、テスト画像の集合に同じ未知クラスが繰り返し現れる (再来) ことを利用して、この残りを学習なしで減らす枠組み Salmon Ladder を提案する。凍結した特徴抽出器と、ID クラスあたり 16 枚のラベル付き画像だけを使い、支持画像・較正画像・テスト画像を節点とする 1 つのグラフ上で 2 つの質量を伝播させる。支持画像に置いた質量は、支持画像から遠く互いに近い未知の塊には届かない。届いた質量を、固定した較正画像の中での順位 (較正順位, 共形 p 値) で読み、多重検定の BH 法で偽発見率を抑

えながら「確かに未知」な画像を自己ラベル付けして種とし、種に置いた質量を同じグラフで伝播させて同じクラスの残りの未知を引き上げる。先に見つかった未知が後の未知の足場になる様子を魚道 (salmon ladder) に見立てた*¹。貢献は次の 3 点である。(1) 学習なし・16 枚のラベルだけで、OpenOOD v1.5 ImageNet-1K の near-OOD で AUROC 98.07%, FPR95 10.22% を達成し、公開されている最良値を AUROC で 3.02 ポイント、FPR95 で 19.18 ポイント更新した (表 2, 図 3)。far-OOD と Four-OOD [12] でも最良である。(2) データセット別でも、OpenOOD の 5 データセットと Four-OOD の 4 データセットのすべてで AUROC と FPR95 の両方が報告値の最良を上回る (表 3, 表 4)。(3) 較正順位は、尺度の違うビュー (特徴抽出器) の伝播の値を同じ物差しにそろえて掛け合わせることを可能にし、種の選択に偽発見率の保証を与える。種からの質量は near-OOD の FPR95 を 12.43% から 10.22% へ下げ、ビューとベース検出器は再学習なしに差し替えられる (表 5)。

2. 提案手法

2.1 問題設定と全体像

ID の各クラス c に 16 枚のラベル付き画像が与えられ、12 枚を支持画像 S_c 、4 枚を較正画像とする (全体を S , C , $n = |C| = 4,000$)。テスト画像の集合 (ストリーム) T は ID と OOD が混ざったラベルなしの画像からなり、各画像 $x \in T$ にスコア $s(x)$ (大きいほど ID らしい) を返す。スコアは T の全画像が届いた後に、 T 全体を見て付ける (transductive な設定)。特徴抽出器 f は凍結し、モデルは更新しない。Salmon Ladder は次の 3 つの部品からなる (図 1, 記号は表 1)。


- (1) **較正順位**: ID らしさの値を、固定した較正画像 C の中での順位に変えて読む (2.2 節)。すべての部品の共通の物差しであり、共形 p 値である。
- (2) **支持画像からの質量** u^+ : 支持画像・較正画像・テスト画像を節点とする 1 つのグラフ上で支持画像に置いた質量を伝播させ、届いた質量を較正順位 p^+ で読む (2.3 節)。支持画像から遠く、互いに近い未知の塊に

¹ 慶應義塾大学 総合政策学部 3 年
中澤・大越研究室 d-hacks 72402035


² 慶應義塾大学院 政策・メディア研究科

*¹ コード：<https://github.com/omotes24/SalmonLadder>

(a) 1つのグラフ：支持画像の質量 u^+ が辺を伝わる



(b) 校正順位 p^+ (C の中での u^+ の順位) に BH 法をかけて種を選ぶ



(c) 種の質量 u^- を同じグラフで伝播させ, 校正順位の積で読む




図 1 Salmon Ladder の概要. (a) 支持画像 S ・校正画像 C ・テスト画像 T を節点とする 1つの k_g 近傍グラフで, 支持画像に置いた質量 u^+ を伝播させる. 校正画像もテスト画像と同じ節点として u^+ を受け取る. (b) テスト画像の u^+ を C の中での順位 p^+ (共形 p 値) に変え, BH 法で棄却された画像を種 $\hat{Q}$ とする. (c) 種に置いた質量 u^- を同じグラフで伝播させ, 順位 p^- に変える. スコアはビューごとの $p^+ p^-$ の積に任意のベース検出器 s_0 を掛けたものである.

表 1 記号.

記号	意味
S, C	支持画像 (クラスあたり 12 枚), 校正画像 (4 枚, $n= C $)
T, N	テスト画像, 節点数 $ S + C + T $
$f(x)$	凍結した特徴抽出器の出力 (L_2 正規化)
W, δ_i, D, S	重み行列, 次数, 次数行列, $D^{-1/2} W D^{-1/2}$
y^+, u^+	支持画像で 1 の初期質量と伝播した質量 (式 (3))
$p^+(x)$	u^+ の校正順位 (小さいほど未知, 式 (5))
$\hat{Q}, q, \hat{\pi}_0$	種 (自己ラベル付けした未知), BH 法の水準, ID の割合
y^-, u^-	種で 1 の初期質量と伝播した質量
$p^-(x)$	u^- の校正順位 (小さいほど未知, 式 (9))
k_g, λ	近傍数 10, 減衰 0.9
$\omega, w(Q, \hat{Q})$	$D^{1/2} \mathbf{1}$, Q から外へ出る辺の重みの和
$s_0(x), v$	ベース検出器のスコア (任意), ビュー (特徴抽出器)

は質量が届かない.

- (3) 未知からの質量 u^- (魚道): p^+ に多重検定 (BH 法) をかけて, 誤り率を抑えながら「確かに未知」な画像の集合 $\hat{Q}$ (種) を自己ラベル付けし, 種に置いた質量を同じグラフで伝播させて校正順位 p^- で読む (2.4 節). 先に見つかった未知が, 同じクラスの残りの未知を引き上げる.

スコアは $s(x) = s_0(x) \prod_v p_v^+(x) p_v^-(x)$ で, v は特徴抽出器 (ビュー), s_0 は任意のベース検出器である (2.5 節). 同じ未知クラスの画像が互いを足場にして段を上るように見つかっていく様子を魚道 (salmon ladder) に見立てた.

2.2 校正順位：固定した校正画像の中での順位

ID らしさを表す値 $a(x)$ (小さいほど OOD らしい) が

あるとき, その値そのものではなく, 校正画像を同じ方法で採点した値の中での順位

$$p(x) = \frac{1 + |\{x' \in C : a(x') \leq a(x)\}|}{n+1} \in \left[\frac{1}{n+1}, 1 \right] \quad (1)$$

で読む. これを校正順位と呼ぶ. $p(x)$ が小さいほど, x は校正画像のどれよりも ID らしくない. 校正画像と ID のテスト画像が交換可能なら, これは $\Pr(p(x) \leq \alpha) \leq \alpha$ を満たす共形 p 値 [13] であり, 閾値 α で OOD と判定したときの ID の誤警報率は α 以下になる. 大きいほど OOD らしい値 $b(x)$ は, 不等号を逆にした $p(x) = (1 + |\{x' \in C : b(x') \geq b(x)\}|)/(n+1)$ で読む. Salmon Ladder では, 伝播した 2 つの質量をどちらもこの順位で読む. 値の尺度がビューやストリームごとに違っても (2.3.4 節), 校正画像を同じグラフで同じ反復にかけける限り, 順位は同じ意味を保つ. 順位は $[0, 1]$ の共形 p 値なので, ビューどうしの積が取れ (2.5 節), 多重検定にもそのまま使える (2.4 節).

2.3 支持画像からの質量：ラベル伝播のグラフ

2.3.1 グラフの構成

支持画像 S , 校正画像 C , テスト画像 T のすべてを節点とする (節点数 $N = |S| + |C| + |T|$). 各節点 i から, コサイン類似度 $f(x_i)^T f(x_j)$ が上位 $k_g=10$ の節点 j へ向かう辺を張り, 重みを $a_{ij} = \max(f(x_i)^T f(x_j), 0)$ とする (行列 A). 向きのない辺にするために $W = \max(A, A^T)$ (成分ごとの最大) とし, 次数 $\delta_i = \sum_j W_{ij}$, $D = \text{diag}(\delta_i)$, 正規化した行列

$$S = D^{-1/2} W D^{-1/2} \quad (2)$$

を作る [14]. S は対称で, 固有値はすべて $[-1, 1]$ にある. 辺の数は高々 $N k_g$ 本なので S は疎で, 非零成分は $O(N k_g)$ である. 校正画像とテスト画像はどちらもラベルを持たない節点として全く同じ扱いを受ける (図 2a). グラフはビューごとに 1 つ作り, 以下の 2 つの質量を同じグラフで伝播させる.

2.3.2 伝播の反復と酔歩としての意味

支持画像の節点で 1, 他で 0 のベクトル $y^+ \in \{0, 1\}^N$ と $\lambda=0.9$ で

$$u^{(\ell+1)} = \lambda S u^{(\ell)} + (1 - \lambda) y^+ \quad (3)$$

を収束するまで反復する ($u^{(0)} = \mathbf{0}$). これは局所・大域一貫性 [14] の反復で, $\lambda < 1$ かつ $\|S\|_2 \leq 1$ なので縮小写像であり, 収束解 $u^+ = (1 - \lambda)(I - \lambda S)^{-1} y^+ = (1 - \lambda) \sum_{\ell \geq 0} \lambda^\ell S^\ell y^+$ を持つ. $(S^\ell y^+)_i$ は節点 i と支持画像を結ぶ長さ ℓ の歩道の重みの和 (次数で正規化したもの) なので, u_i^+ は「短い歩道で支持画像とつながる節点ほど大きい」量である. 酔歩で言えば, $P = D^{-1} W$ を遷移確率とし, 各ステップで確率 $1 - \lambda$ で止まる酔歩を節点 i から始めたとき,




図 2 ラベル伝播のグラフ. (a) 節点は支持画像・校正画像・テスト画像で、各節点をコサイン類似度の上位 k_g 個と結ぶ. 支持画像に置いた質量 y^+ が辺を伝わり (式 (3)), 支持画像に近い ID 画像には多く、互いに近い同じ未知クラスの画像には少ししか届かない. 種に置いた質量 y^- も同じ辺を伝わる. (b) 初期質量を置いた節点を含まない集合 Q に届く質量は、 Q から外へ出る辺の重みの和 $w(Q, \bar{Q})$ で上から抑えられる (命題 2). 同じ未知クラスが r 枚そろって互いが近傍の上位を占め、外へ出る辺が減る. (c) 質量の総和は支持画像の度数だけで決まるので (命題 1), u の尺度はビューやストリームごとに違う. 校正画像の u も同じ尺度で動くので、校正順位で読めば閾値もビューの積も同じ物差しに乗る.

$$\frac{u_i^+}{\sqrt{\delta_i}} = \mathbb{E}_i \left[\frac{\mathbf{1}[X_T \in S]}{\sqrt{\delta_{X_T}}} \right] \quad (4)$$

である (X_T は止まった節点. $S^\ell = D^{1/2} P^\ell D^{-1/2}$ から従う). 次数がそろっていれば u_i^+ は「 i から出た酔歩が支持画像で止まる確率」そのものである. 支持画像に近い ID 画像からは数歩で支持画像に着くので u^+ は大きく、互いに近い未知クラスの画像の塊からは支持画像へ出る辺が少ないので u^+ は小さい (図 2a).

2.3.3 校正順位による読み出し

校正画像はグラフの節点であり ($y^+ = 0$), 同じ反復で u^+ を受け取るので,

$$p^+(x) = \frac{1 + |\{x' \in C : u^+(x') \leq u^+(x)\}|}{n+1} \quad (5)$$

とする. u^+ は校正画像とテスト画像を同じ $y^+ = 0$ の節点として扱う対称な関数なので、校正画像と ID のテスト画像が交換可能なら p^+ は 2.2 節の共形 p 値である. すなわち $p^+(x) \leq \alpha$ で OOD と判定したときの ID の誤警報率は α 以下で、この性質はグラフの形やストリームの構成に依らない.

2.3.4 質量の保存

命題 1 (質量の保存). $\omega = D^{1/2} \mathbf{1}$ とすると、式 (3) を $\mathbf{u}^{(0)} = \mathbf{0}$ から L 回反復した値は

$$\omega^\top \mathbf{u}^{(L)} = (1 - \lambda^L) \omega^\top \mathbf{y}^+ = (1 - \lambda^L) \sum_{j \in S} \sqrt{\delta_j} \quad (6)$$

を満たし、収束解では $\omega^\top \mathbf{u}^+ = \sum_{j \in S} \sqrt{\delta_j}$ である. 証明. $S\omega = D^{-1/2} W D^{-1/2} D^{1/2} \mathbf{1} = D^{-1/2} W \mathbf{1} = D^{-1/2} D \mathbf{1} = \omega$ であり、 S は対称なので $\omega^\top S = \omega^\top$. よって $\omega^\top \mathbf{u}^{(\ell+1)} = \lambda \omega^\top \mathbf{u}^{(\ell)} + (1 - \lambda) \omega^\top \mathbf{y}^+$ となり、 $\mathbf{u}^{(0)} = \mathbf{0}$ から解けば式

(6) を得る. □

右辺は支持画像の度数だけで決まる. $\sqrt{\delta_i}$ で重みづけた質量の総和がテスト画像の枚数 $|T|$ に依らず一定なので、1 節点あたりの u^+ の尺度はストリームの大きさや構成、そしてビューごとに変わる (図 2c). したがって u^+ の値をそのまま閾値にかけたり、ビューどうして掛け合わせたりすることはできない. 校正順位式 (5) はこの尺度を取り除き、どのビュー・どのストリームでも同じ $[0, 1]$ の物差しにそろえる.

2.3.5 再来が効く理由 (カットの上界)

命題 2 (カットの上界). 初期質量を置いた節点を含まない節点の集合 Q について、 Q から外へ出る辺の重みの和を $w(Q, \bar{Q}) = \sum_{i \in Q, j \notin Q} W_{ij}$ とすると、初期質量 $\mathbf{y}$ (1 を置いた集合を Y とする) からの収束解 $\mathbf{u}$ は

$$\sum_{i \in Q} \sqrt{\delta_i} u_i \leq \frac{\lambda}{1-\lambda} \cdot \frac{w(Q, \bar{Q})}{\min_{j \in Y} \sqrt{\delta_j}} \quad (7)$$

を満たす. 証明. $i \in Q$ では $y_i = 0$ なので $u_i = \lambda \sum_j W_{ij} u_j / \sqrt{\delta_i \delta_j}$. 両辺に $\sqrt{\delta_i}$ を掛けて Q で足すと、 Q の内側の辺からの寄与は $\sum_{j \in Q} (u_j / \sqrt{\delta_j}) \sum_{i \in Q} W_{ij} \leq \sum_{j \in Q} \sqrt{\delta_j} u_j$ で抑えられ、外側の辺からの寄与は $w(Q, \bar{Q}) \max_j u_j / \sqrt{\delta_j}$ で抑えられる. 式 (4) と同じ酔歩の表現より $u_j / \sqrt{\delta_j} \leq 1 / \min_{s \in Y} \sqrt{\delta_s}$ なので、移項して式 (7) を得る. □

$Y = S$, Q を同じ未知クラスの r 枚とする. それらが互いの近傍の上位を占めるなら、 Q の各節点が自ら張る k_g 本の辺のうち外へ出るのは $(k_g - r + 1)_+$ 本で、 r が k_g に近づくほど $w(Q, \bar{Q})$ は減り、 Q に届く質量 u^+ の上界は下がる (図 2b). すなわち、同じ未知クラスが繰り返し現れるほど、その画像の u^+ は小さく読まれ、OOD として見つ

けやすくなる。これが伝播が**再来**に効く理由である。上界は値そのものを保証しないが、 $r \approx k_g$ で外への辺が尽きることを示している。

2.4 未知からの質量：自己ラベル付けと負の伝播（魚道）

2.4.1 BH 法による種を選択

p^+ は、ID のテスト画像について一様分布に従う（かそれより大きい）共形 p 値である。そこで「 x は ID である」を帰無仮説とする $|T|$ 個の検定とみなし、Benjamini–Hochberg (BH) 法 [15] で棄却する画像の集合 $\hat{Q}$ を選ぶ。 $p_{(1)} \leq \dots \leq p_{(|T|)}$ を p^+ の昇順、 $\hat{\pi}_0 = \min\{1, (1 + |\{x : p^+(x) > 1/2\}|)/(|T|/2)\}$ を ID の割合の推定値 [16] として、

$$\hat{k} = \max \left\{ i : p_{(i)} \leq \frac{q_i}{\hat{\pi}_0 |T|} \right\} \quad (8)$$

とし、 p^+ が小さい方から $\hat{k}$ 枚の画像の集合を $\hat{Q}$ とする ($q=0.1$)。 $\hat{Q}$ を**種**と呼ぶ。選ぶ枚数 $\hat{k}$ は固定せず、ストリームに含まれる未知の量と p^+ の分布から決まる。未知が多いストリームでは種も多く、未知がほとんどないストリームでは種はほとんど選ばれない。

命題 3（偽発見率）。 較正画像と ID のテスト画像が交換可能なら、 $\hat{\pi}_0 = 1$ とした BH 法で選んだ $\hat{Q}$ に混じる ID の割合の期待値（偽発見率）は $q|T_{ID}|/|T| \leq q$ 以下である。これは、同じ較正画像から作った共形 p 値が正の回帰従属性 (PRDS) を持ち、BH 法が偽発見率を制御するという Bates ら [13] の定理による (p^+ はグラフを通してテスト画像どうしにも依存を持つが、較正画像とテスト画像を対称に扱うので、各 p^+ は周辺的に有効な共形 p 値である)。 $\hat{\pi}_0$ による補正 [16] は、ID の割合が 1 より小さいときに上界の余りを使って種を増やす標準的な手続きである。種は後述の伝播の初期質量として使うだけで、種そのものを最終判定にはしないので、少数の誤った種が混じっても、その影響はごく近くの節点に限られる。

2.4.2 負の質量とその読み出し

種で 1、他で 0 のベクトル $\mathbf{y}^- = \mathbf{1}_{\hat{Q}}$ を初期質量とし、同じグラフ・同じ λ で式 (3) を収束まで反復した値を $\mathbf{u}^-$ とする。式 (4) と同様に、 $u_i^-/\sqrt{\delta_i}$ は節点 i から出た酔歩が種で止まる確率である。種は未知なので、 $\mathbf{u}^-$ は**大きいほど未知らしい**。較正画像も同じ反復で $\mathbf{u}^-$ を受け取るので、不等号を逆にした較正順位

$$p^-(x) = \frac{1 + |\{x' \in C : u^-(x') \geq u^-(x)\}|}{n + 1} \quad (9)$$

で読む。命題 2 を $Y = \hat{Q}$ 、 Q を種を含まない ID の画像の集合として適用すると、ID の画像に届く負の質量の総和は、ID と種を隔てるカット $w(Q, \hat{Q})$ で上から抑えられる。ID の画像どうしは支持画像を介して密につながり、種とは疎にしかつながらないので、 $\mathbf{u}^-$ は ID には小さく、種のまわりに集まる同じ未知クラスの画像には大きい（図 2a）。

2.4.3 魚道：二つの質量が補い合う

p^+ だけでは、未知のうち支持画像に比較的近い画像 (ID の兄弟クラスなど) が取り逃される。しかしそのクラスの画像のうち確かに未知なものは、BH 法で種として選ばれる。種に置いた質量は、支持画像の質量が届きにくかった同じクラスの残りの画像へ、クラス内の密な辺を通して流れる（図 1）。先に見つかった未知が同じクラスの後の未知を引き上げる、この段構えが魚道 (salmon ladder) の名の由来である。読み出しはどちらも較正順位なので、二つを掛けた p^+p^- も $[0, 1]$ の値であり、ID の画像では両方が大きく、未知では少なくとも一方が小さい。

2.5 スコアと枠組み

$s(x) = s_0(x) \prod_v p_v^+(x) p_v^-(x)$ を返す。特徴抽出器ごとの値を**ビュー v** と呼び、ビューごとにグラフと種を持つ。 s_0 はベース検出器で、 $s_0=1$ を**単体**と呼ぶ。ビューとベース検出器は差し替え可能で、ビューの読み出しはビューごとに独立に計算されるので、ビューを加えることは積に因子を加えることに等しい。本稿の構成は、DINOv3 [17] ViT-L/16 のビューと、DINOv2 [18] ViT-L/14 と DINOv3 ViT-L/16 の L_2 正規化した特徴を連結して再び正規化した**連結ビュー**（コサイン類似度は 2 つの特徴抽出器のコサイン類似度の平均になる）の 2 ビューに、TINS [7] (CLIP ViT-B/16) のスコアを掛けたものである。VLM はベース検出器にだけ使い、グラフも種も VLM には依らない。計算は、ビューごとに N 節点の厳密な k_g 近傍探索 (GPU でブロックごとの内積) と、疎行列と密ベクトルの積 $O(Nk_g)$ の反復 2 回 ($\mathbf{u}^+$ と $\mathbf{u}^-$ 、各数百回以内で収束) で、OpenOOD の 1 本のストリーム ($N \approx 6\text{--}11$ 万) に対して 1 枚の GPU で 1 分以内である。

2.6 実験設定

評価は OpenOOD v1.5 [8] の ImageNet-1K ベンチマークに従う。ID は ImageNet-1K の検証画像 45,000 枚、near-OOD は SSB-hard と NINCO, far-OOD は iNaturalist, Textures, OpenImage-O である。各 OOD データセットについて ID と混ぜたストリームを到着順の種を変えて 5 本作り、平均する。Four-OOD [12] (ImageNet-1K の検証画像 50,000 枚に対する iNaturalist, SUN, Places, Textures) は到着順 3 本の平均である。16 枚のラベル付き画像は ImageNet-1K の学習画像から取る。本手法は各ストリームの全画像が届いた後にスコアを付ける。 k_g と λ は学習画像だけから作った開発用分割で決めて凍結し、ビューの組、 q 、ベース検出器は表 5 の比較から選んだ。比較手法のうち公開されている値は報告値 (†) を用い、公式実装が公開されている MCM, NegLabel, AdaNeg, TANL, TINS は同じストリームで実測した (学習なし)。評価指標は AUROC (高いほど良い) と、ID の 95% を受け入れる閾

値での OOD の誤受理率 FPR95 (低いほど良い) である。

3. 結果

3.1 OpenOOD v1.5 ImageNet-1K (表 2, 図 3)

Salmon Ladder は, 表 2 の 6 列すべてで最良である. near-OOD では AUROC 98.07%, FPR95 10.22%で, 報告値の最良である DisCoPatch (95.05%, 29.40%) を AUROC で 3.02 ポイント上回り, FPR95 を 19.18 ポイント下げた. 誤受理率で見れば 3 分の 1 である. VLM の手法の最良 (TINS, 82.65% / 57.88%) に対しては AUROC で 15 ポイント, FPR95 で 48 ポイントの差がある. far-OOD でも AUROC 99.03%, FPR95 4.28%で, ラベルで学習した検出器の最良 (NNGuide, 97.80%, 9.87%) を FPR95 で 5.58 ポイント下回る. Four-OOD では AUROC 99.06%, FPR95 3.36%で, 報告値の最良である TINS (98.51%, 6.72%) の FPR95 を半分にした. ベース検出器を使わない単体でも near-OOD は 97.95% / 11.02%, far-OOD は 98.78% / 5.23%, Four-OOD は 98.78% / 4.39%で, いずれも報告値のすべてを上回る. 優位は VLM の力ではなく, 16 枚のラベル付き画像と凍結した特徴, そして未知の再来を使う枠組みそのものによる. 同じストリームで実測した TINS (81.48% / 56.37%) に本手法を掛けると, near-OOD の FPR95 は 56.37%から 10.22%へ 46.15 ポイント下がる. 図 3 では, 本手法だけが両ベンチマークの右上の隅にあり, 近づく手法はない.

3.2 データセット別 (表 3)

表 3 の 10 列のすべてで本手法が最良である. SSB-hard (ID の兄弟クラス) では AUROC 96.43%, FPR95 19.62%で, 報告値の最良である DisCoPatch (95.8% / 19.8%) を両指標で上回る. NINCO (ImageNet と重ならない 64 クラス) では AUROC 99.71%, FPR95 0.81%で, DisCoPatch (94.3% / 39.0%) を FPR95 で 38.19 ポイント, NNGuide (93.7% / 28.9%) を 28.09 ポイント下回り, 誤受理はほぼ消える. SSB-hard と NINCO のどちらでも, 報告値の VLM の手法 (TINS は 61.68%と 54.09%) を FPR95 で 40 ポイント以上引き離す. far-OOD の 3 データセットでは iNaturalist 99.96% / 0.08%, Textures 99.29% / 2.45%, OpenImage-O 97.84% / 10.32%で, AUROC・FPR95 とも 3 データセットすべてで最良である.

3.3 Four-OOD (表 4)

Four-OOD では TINS の報告値 (98.51% / 6.72%) が最良であった. Salmon Ladder×TINS は iNaturalist 99.96% / 0.09%, SUN 99.65% / 0.97%, Places 97.48% / 9.57%, Textures 99.17% / 2.83%で, 表 4 の 10 列のすべてで最良であり, 平均の FPR95 は 3.36%と TINS の報告値より 3.36 ポイント低い. Textures では FPR95 を 10.09%から

2.83%へ, SUN では 3.84%から 0.97%へ下げた.

3.4 枠組みの部品の寄与 (表 5)

ビュー. DINOv3 L/16 を 1 ビューで使うと near-OOD の FPR95 は 10.92%で, DINOv2 L/14 の 1 ビュー (12.50%) より低い. DINOv2 L/14 と DINOv3 L/16 の 2 ビューで 10.46%, DINOv2 L/14 を DINOv3 L/16 との連結ビューに替えた本稿の構成で 10.22%になる. 連結ビューのコサイン類似度は 2 つの特徴抽出器の類似度の平均なので, 2 つの抽出器が共に近いと認める画像だけが近傍になり, near-OOD の FPR95 は DINOv2 L/14 + DINOv3 L/16 の 2 ビューより 0.24 [0.14, 0.35] ポイント低い (到着順を単位とする対応のある 95% t 区間. 区間は 0 を含まない). ビューを 3 つ・4 つに増やしても改善せず, 2 ビューで十分である. **読み出し**. 支持画像の質量 p^+ だけでは near-OOD の FPR95 は 12.43%だが, 種からの質量 p^- を掛けると 10.22%になり (差は 2.21 [2.11, 2.31] ポイント), far-OOD と Four-OOD の FPR95 も 4.70%から 4.28%へ, 3.78%から 3.36%へ下がる. 種の水準 q は 0.05 でも 0.2 でも near-OOD の FPR95 は 10.59%, 10.61%で, q に敏感ではない. 近傍数 k_g を 20 にすると far-OOD と Four-OOD の FPR95 は 3.95%, 2.96%へ下がり, near-OOD は 10.87%になる. 種への最近傍距離の較正順位をさらに掛けると far-OOD の FPR95 は 4.13%になる. **ベース検出器**. 単体 (near-OOD 11.02%) に対し, TANL を掛けると 10.70%, TINS を掛けると 10.22%で, far-OOD と Four-OOD の FPR95 もどちらを掛けても下がる. ベース検出器の差 (near-OOD で実測の FPR95 が 56.37%と 56.80%, far-OOD で 12.23%と 15.91%) に比べて積の差は 1 ポイント以下に収まり, 枠組みがベース検出器の弱さを吸収する.

4. 結論

支持画像・較正画像・テスト画像を 1 つのグラフに置き, 支持画像からの質量と, BH 法で自己ラベル付けした未知の種からの質量を, 固定した較正画像の中での順位で読んで掛け合わせる枠組み Salmon Ladder を提案した. 凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで, OpenOOD v1.5 ImageNet-1K の near-OOD (AUROC 98.07%, FPR95 10.22%), far-OOD (99.03%, 4.28%), Four-OOD (99.06%, 3.36%) のすべてで公開されている最良値を更新し, near-OOD では FPR95 を 3 分の 1 にした. 較正順位は伝播の値の尺度を取り除き, ビューの積と偽発見率の保証を同時に可能にする. ビューとベース検出器はそれぞれ寄与し, より強い部品が現れれば再学習なしに差し替えられる. コードと設定は <https://github.com/omotes24/SalmonLadder> で公開している.




図 3 OpenOOD v1.5 ImageNet-1K での AUROC と FPR95 (表 2 の全手法. 右上ほど良い). 大きな星が本稿の構成 (×TINS), 小さな星はベース検出器を使わない単体の構成である. 比較手法は報告値 (TANL のみ実測).

表 2 OpenOOD v1.5 ImageNet-1K と Four-OOD ([%]). † は原論文の報告値 (近/遠の平均はデータセット別の報告値から本稿で計算). 実測値は同じストリーム (OpenOOD は到着順 5 本, Four-OOD は 3 本) の平均. ★ は列の最良値, 青 は比較手法のすべてを上回る値, 括弧の行は最良の比較手法との差 (正は本手法が良い).

手法	OpenOOD near-OOD		OpenOOD far-OOD		Four-OOD	
	AUROC↑	FPR95↓	AUROC↑	FPR95↓	AUROC↑	FPR95↓
<i>ImageNet-1K</i> のラベルで学習した検出器 (報告値 †, 近/遠の平均は本稿で計算)						
MOODv2 [10] (BEiTv2)	88.85	48.15	97.10	13.37	—	—
NNGuide [9] (RegNet)	89.20	41.80	97.80	9.87	—	—
RankFeat [19] (ResNetv2-101)	89.70	43.60	94.47	23.90	—	—
SCALE [20] (ResNet-50)	81.40	59.75	96.53	16.53	—	—
ASH [21] (ResNet-50)	78.55	72.40	96.10	18.70	—	—
教師なし (報告値 †)						
DisCoPatch [11] (教師なし生成)	95.05	29.40	96.63	17.40	—	—
VLM (CLIP ViT-B/16, 報告値 †)						
MCM [2] (CLIP B/16, ゼロショット)	60.11	79.02	84.77	68.54	90.82	43.93
NegLabel [3] (CLIP B/16, ゼロショット)	75.18	69.45	94.85	23.73	94.21	25.40
LAPT [22] (CLIP B/16, 学習あり)	82.63	58.94	94.26	24.86	—	—
AdaNeg [4] (CLIP B/16, テスト時適応)	76.70	67.51	96.43	17.31	96.66	18.92
InterNeg [6] (CLIP B/16, テスト時適応)	82.20	65.43	96.71	16.96	97.43	14.04
TINS [7] (CLIP B/16, テスト時適応)	82.65	57.88	96.92	12.99	98.51	6.72
同じストリームでの実測 (公式実装, 学習なし)						
MCM [2]	66.86	85.92	88.91	53.24	89.07	49.93
NegLabel [3]	74.64	75.90	94.67	24.61	94.38	24.55
AdaNeg [4]	76.60	72.00	96.18	17.56	96.34	14.38
TANL [5]	82.85	56.80	96.19	15.91	97.55	8.91
TINS [7]	81.48	56.37	97.04	12.23	98.52	6.85
Salmon Ladder (Ours, 学習なし, クラスあたり 16 枚)						
Salmon Ladder, 単体	97.95	11.02	98.78	5.23	98.78	4.39
Salmon Ladder × TINS	98.07★	10.22★	99.03★	4.28★	99.06★	3.36★
最良の比較手法との差	(+3.02)	(+19.18)	(+1.23)	(+5.58)	(+0.54)	(+3.36)

表 3 OpenOOD v1.5 ImageNet-1K のデータセット別の結果 ([%, AUROC↑ / FPR95↓]). 記法は表 2 と同じ.

手法	near-OOD				far-OOD					
	SSB-hard		NINCO		iNaturalist		Textures		OpenImage-O	
	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MOODv2 [10]†	85.00	58.10	92.70	38.20	99.60	1.80	94.30	24.70	97.40	13.60
NNGuide [9]†	84.70	54.70	93.70	28.90	99.90	1.80	95.80	17.00	97.70	10.80
RankFeat [19]†	89.40	47.90	90.00	39.30	96.00	13.00	95.00	25.40	92.40	33.30
SCALE [20]†	77.40	67.70	85.40	51.80	98.00	9.50	97.60	11.90	94.00	28.20
DisCoPatch [11]†	95.80	19.80	94.30	39.00	99.10	3.60	96.40	18.90	94.40	29.70
TINS [7]†	81.38	61.68	83.91	54.09	99.93	0.21	97.83	10.09	92.99	28.68
TINS [7] (実測)	82.22	56.65	80.74	56.09	99.93	0.17	98.11	8.31	93.09	28.20
Salmon Ladder, 単体	96.22	20.96	99.68	1.09	99.92	0.12	98.88	4.22	97.55	11.34
Salmon Ladder × TINS	96.43★	19.62★	99.71★	0.81★	99.96★	0.08★	99.29★	2.45★	97.84★	10.32★
最良の比較手法との差	(+0.63)	(+0.18)	(+5.41)	(+28.09)	(+0.03)	(+0.09)	(+1.18)	(+5.86)	(+0.14)	(+0.48)

参考文献

- [1] A. Radford et al.: Learning transferable visual models from natural language supervision. *ICML*, 2021.
- [2] Y. Ming et al.: Delving into out-of-distribution detection with vision-language representations. *NeurIPS*, 2022.
- [3] X. Jiang et al.: Negative label guided OOD detection with pretrained vision-language models. *ICLR*, 2024.
- [4] Y. Zhang and L. Zhang: AdaNeg: Adaptive negative

表 4 Four-OOD (ImageNet-1K に対する iNaturalist, SUN, Places, Textures, [%]). 比較手法はすべて CLIP ViT-B/16 による報告値† (TINS は実測も併記). 記法は表 2 と同じ.

手法	iNaturalist		SUN		Places		Textures		平均	
	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MCM [2]†	94.59	32.20	92.25	38.80	90.31	46.20	86.12	58.50	90.82	43.93
NegLabel [3]†	99.49	1.91	95.49	20.53	91.64	35.59	90.22	43.56	94.21	25.40
CSP [23]†	99.60	1.54	96.66	13.66	92.90	29.32	93.86	25.52	95.76	17.51
OODD [24]†	99.79	0.85	97.17	12.94	92.51	30.68	94.51	30.67	96.00	18.79
AdaNeg [4]†	99.71	0.59	97.44	9.50	94.55	34.34	94.93	31.27	96.66	18.92
InterNeg [6]†	99.79	0.40	98.68	6.78	95.01	27.11	96.26	21.85	97.43	14.04
TINS [7]†	99.93	0.21	99.14	3.84	97.14	12.73	97.83	10.09	98.51	6.72
TINS [7] (実測)	99.93	0.22	99.12	4.35	97.12	12.98	97.94	9.83	98.52	6.85
Salmon Ladder, 単体	99.92	0.15	99.48	1.57	97.01	11.24	98.73	4.59	98.78	4.39
Salmon Ladder × TINS	99.96★	0.09★	99.65★	0.97★	97.48★	9.57★	99.17★	2.83★	99.06★	3.36★
最良の比較手法との差	(+0.03)	(+0.12)	(+0.51)	(+2.87)	(+0.34)	(+3.16)	(+1.24)	(+7.00)	(+0.54)	(+3.36)

表 5 Salmon Ladder の部品を替えたときの結果 ([%]). ビュー: B/14 · L/14 は DINOv2, B/16 · L/16 は DINOv3, 連結ビューは DINOv2 L/14 と DINOv3 L/16 の L_2 正規化した特徴の連結. 読み出し: p^+ は支持画像の質量の較正順位, p^- は種の質量の較正順位, q は BH 法の水準, k_g は近傍数. ★ は列の最良値.

構成	OpenOOD near-OOD		OpenOOD far-OOD		Four-OOD	
	AUROC↑	FPR95↓	AUROC↑	FPR95↓	AUROC↑	FPR95↓
ビューを替える ($p^+ \times p^-$, $q=0.1$, $k_g=10$, × TINS)						
DINOv2 L/14	97.57	12.50	98.87	5.15	99.00	3.85
DINOv3 L/16	97.89	10.92	99.04	4.18	99.14	3.07
連結ビュー (DINOv2 L/14 ⊕ DINOv3 L/16)	97.87	11.02	99.00	4.29	99.08	3.32
DINOv2 L/14 + DINOv3 L/16	98.04	10.46	99.04	4.36	99.08	3.40
DINOv3 B/16 + L/16	97.91	11.10	99.07	4.23	99.15	3.02
連結ビュー + DINOv3 L/16 (本稿の構成)	98.07	10.22★	99.03	4.28	99.06	3.36
DINOv2 L/14 + DINOv3 B/16 + L/16	98.01	10.66	99.08	4.22	99.11	3.25
DINOv2 B/14 + L/14 + DINOv3 L/16	97.98	10.84	99.04	4.42	99.07	3.45
4 つの特徴抽出器すべて	97.96	11.03	99.06	4.42	99.09	3.32
読み出しを替える (本稿の 2 ビュー, × TINS)						
p^+ のみ (種なし)	97.48	12.43	98.90	4.70	98.91	3.78
$p^+ \times p^-$, $q=0.05$	97.91	10.59	99.03	4.12	99.06	3.15
$p^+ \times p^-$, $q=0.1$ (本稿の構成)	98.07	10.22★	99.03	4.28	99.06	3.36
$p^+ \times p^-$, $q=0.2$	98.06	10.61	98.96	4.58	99.01	3.72
$p^+ \times p^-$, $k_g=20$	97.96	10.87	99.10	3.95★	99.15★	2.96★
$p^+ \times p^- \times$ 種への最近傍距離の較正順位	98.08★	10.39	99.11★	4.13	99.05	3.49
ベース検出器 s_0 を替える (本稿の 2 ビュー, $p^+ \times p^-$)						
なし (単体)	97.95	11.02	98.78	5.23	98.78	4.39
TANL [5]	97.97	10.70	98.89	4.94	98.92	3.84
TINS [7] (本稿の構成)	98.07	10.22★	99.03	4.28	99.06	3.36

proxy guided OOD detection with vision-language models. *NeurIPS*, 2024.

- [5] Y. Zhang et al.: Activation matters: Test-time activated negative labels for OOD detection with vision-language models. *CVPR*, 2026.
- [6] Z. Xu et al.: Mind the way you select negative texts: Pursuing the distance consistency in OOD detection with VLMs. *CVPR*, 2026.
- [7] Y. Yang et al.: TINS: Test-time ID-prototype-separated negative semantics learning for OOD detection. arXiv:2605.10756, 2026.
- [8] J. Zhang et al.: OpenOOD v1.5: Enhanced benchmark for out-of-distribution detection. *DMLR*, 2024.
- [9] J. Park, Y. G. Jung, and A. B. J. Teoh: Nearest neighbor guidance for out-of-distribution detection. *ICCV*, 2023.
- [10] J. Li et al.: MOODv2: Masked image modeling for out-of-distribution detection. *IEEE TPAMI*, 2024.
- [11] F. Caetano et al.: DisCoPatch: Taming adversarially-driven batch statistics for improved out-of-distribution detection. *ICCV*, 2025.
- [12] R. Huang and Y. Li: MOS: Towards scaling out-of-distribution detection for large semantic space. *CVPR*, 2021.
- [13] S. Bates et al.: Testing for outliers with conformal p-values. *Ann. Stat.*, 2023.
- [14] D. Zhou et al.: Learning with local and global consistency. *NIPS*, 2004.

- [15] Y. Benjamini and Y. Hochberg: Controlling the false discovery rate: A practical and powerful approach to multiple testing. *J. R. Stat. Soc. B*, 1995.
- [16] J. D. Storey: A direct approach to false discovery rates. *J. R. Stat. Soc. B*, 2002.
- [17] O. Siméoni et al.: DINOv3. arXiv:2508.10104, 2025.
- [18] M. Oquab et al.: DINOv2: Learning robust visual features without supervision. *TMLR*, 2024.
- [19] Y. Song, N. Sebe, and W. Wang: RankFeat: Rank-1 feature removal for out-of-distribution detection. *NeurIPS*, 2022.
- [20] K. Xu et al.: Scaling for training time and post-hoc out-of-distribution detection enhancement. *ICLR*, 2024.
- [21] A. Djurisic et al.: Extremely simple activation shaping for out-of-distribution detection. *ICLR*, 2023.
- [22] Y. Zhang et al.: LAPT: Label-driven automated prompt tuning for OOD detection with vision-language models. *ECCV*, 2024.
- [23] M. Chen, J. Gao, and C. Xu: Conjugated semantic pool improves OOD detection with pre-trained vision-language models. *NeurIPS*, 2024.
- [24] Y. Yang et al.: OODD: Test-time out-of-distribution detection with dynamic dictionary. *CVPR*, 2025.