Salmon Ladder: Conformal Label Propagation for OOD Detection

表 紘太朗[1]　尾崎 慶次郎[2]

概要

OpenOOD v1.5 の near-OOD では，VLM の最良の報告値でも AUROC は 82.65%にとどまる．凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで，支持画像からの質量を 1 つのグラフで伝播させ，ラベル付き画像の中での順位（共形 p 値）で読む転導的な検知器 Salmon Ladder を提案する．学習なしの単体で near-OOD AUROC 97.98%・FPR95 11.26%，far-OOD 98.81%・5.14%，Four-OOD 98.81%・4.55%に達し，ImageNet-200 と CIFAR-100 でも公開の最良値を上回った．再出現する未知は偽発見率を制御する検定で自己ラベル付けした種から引き上げ，種の選択と読み出しを参照画像で行い，折なしで読み出しも共形 p 値にする．1 枚だけの未知と描画への共変量シフトには弱い．コード：omotes24/SalmonLadder

1. はじめに

OOD 検知は, 学習時のクラス（ID）以外の入力を見分ける問題である．CLIP [1] などの VLM は学習なしに OOD を検知でき [2]，負例ラベル [3] やテスト時の適応 [4], [5], [6], [7] で far-OOD の AUROC は 97%に達したが, ID に近い near-OOD は難しい．OpenOOD v1.5 [8] の ImageNet-1K では，VLM による最良の報告値でも near-OOD の AUROC は 82.65%，FPR95 は 57.88%にとどまり [7]，ImageNet-1K のラベルで学習した検出器 [9], [10] や教師なし生成モデルの DisCoPatch [11] でも FPR95 は 29–48%残る（**表 1**）．

本研究は，凍結した特徴抽出器と ID クラスあたり 16 枚のラベル付き画像だけで，この残りを学習なしで減らす転導的な枠組み **Salmon Ladder** を提案する．支持画像・ラベル付きの参照画像と較正画像・テスト画像を節点とする 1 つのグラフの上で，支持画像に置いた質量を伝播させ，届いた質量をラベル付き画像の中での順位（**較正順位**）で読む．支持画像から遠く互いに近い未知の塊には質量が届かず，較正順位は AdaDetect [12] の意味での共形 p 値になる．この伝播だけで見出しの数字の大半が得られる（**表 2**）．その上で，テスト集合に同じ未知クラスの画像が複数枚含まれる（**再出現**）ときの拡張として，偽発見率を制御する多重検定で未知の側に偏った画像を自己ラベル付けして**種**にし，種に置いた質量を同じグラフで伝播させて同じクラスの残りの未知を引き上げる[*1]．種の選択と読み出しの順位を参照画像に対して取ることで，テスト画像を折に分けずに，種を含む読み出しの較正順位そのものが共形 p 値になる．

主たる設定はテスト集合全体を見て採点する**事後採点**（transductive）で，**到着時採点**も示す（付録 A.11）．貢献は 4 点である．(1) **共形ラベル伝播**：グラフ上のラベル伝播を共形 p 値として読む検知器（命題 1–3）．学習なし・16 枚のラベルだけで，OpenOOD v1.5 ImageNet-1K の near-OOD で AUROC 97.98%，FPR95 11.26%（6 通りの抽出の平均，単体）を達成し，公開の最良値を AUROC で 2.93 ポイント，FPR95 で 18.14 ポイント更新した（**表 1**）．far-OOD と Four-OOD [13] でも最良で，構成を固定したまま評価した ImageNet-200 と CIFAR-100 でも報告値の最良を上回る（4.6 節）．$u^+ = \sqrt{\delta}\times$（確率）の分解で，確率の因子が検知の大半を担い，密度の因子は単独では手がかりにならず確率の因子と組んで効く（向きはデータセットに依る）ことを示す（4.2 節）．(2) **種と参照画像**：種は再出現（クラスあたり 10 枚以上）のときの拡張で，ImageNet-1K の near-OOD で FPR95 を 1.10（単体）／1.92（×TINS）ポイント下げるが，未知が大半を占める ImageNet-200 と CIFAR-100 では効かない．参照画像による読み出し σ_{ref} は折なしで共形 p 値になり（命題 4），較正画像とテスト画像が交換可能なら，利用者は閾値を「ID の誤警報率 α」として直接指定できる．同じ未知クラスの画像に小さな p 値を保証する分離の上界（系 2）を導き，格子で実測する（4.3 節）．(3) **比較と限界**：同じ特徴の静的な検出器，同じグラフ上のクラスラベル伝播，全学習画像を使う基線，ゼロショットの手法と比べて利得の出どころを切り分け（**表 2**，4.6 節），1 枚だけ現れる未知には静的な検出器より

[1] 慶應義塾大学　総合政策学部 3 年
中澤・大越研究室 d-hacks　72402035
[2] 慶應義塾大学院　政策・メディア研究科

[*1] コード：https://github.com/omotes24/SalmonLadder

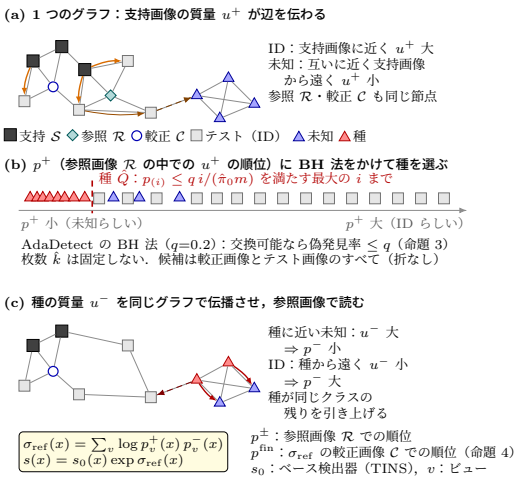


図 1 Salmon Ladder の概要．(a) 支持画像 $\mathcal{S}$・参照画像 $\mathcal{R}$・較正画像 $\mathcal{C}$・テスト画像 $\mathcal{T}$ を節点とする 1 つの k_g 近傍グラフで，支持画像に置いた質量 u^+ を伝播させる．(b) u^+ を $\mathcal{R}$ の中での順位 p^+（共形 p 値）に変え，偽発見率を制御する BH 法で棄却された画像を種 $\hat{Q}$ とする（候補は $\mathcal{C} \cup \mathcal{T}$）．(c) 種に置いた質量 u^- を同じグラフで伝播させ，$\mathcal{R}$ の中での逆順位に変えて足した統計量 σ_{ref} を，$\mathcal{C}$ の中での順位 p^{fin} で読む．スコアは $s_0 \exp \sigma_{\mathrm{ref}}$（$s_0$ はベース検出器）．

弱く，描画への共変量シフト（ImageNet-R）を ID として受け入れないことを示す（4.3 節，4.5 節）．(4) **選択手続きと逸脱の開示**：構成は開発用分割の事前登録した規則で選び，登録からの逸脱 2 件（いずれもテスト集合の値を見た後）と，開発用分割が構成の細部（q や種の規則）の差を予測しないことを開示する（3 節）．

2. 提案手法

2.1 問題設定と全体像

ID の各クラス c に 16 枚のラベル付き画像が与えられ，12 枚を支持画像 $\mathcal{S}_c$，2 枚を参照画像 $\mathcal{R}_c$，2 枚を較正画像 $\mathcal{C}_c$ とする（クラスごとの並びの位置で固定；全体を $\mathcal{S}$，$\mathcal{R}$，$\mathcal{C}$，$|\mathcal{R}| = |\mathcal{C}| = 2{,}000$）．テスト集合 $\mathcal{T}$ は ID と OOD が混ざったラベルなしの画像の集合で，各画像 $x \in \mathcal{T}$ にスコア $s(x)$（大きいほど ID らしい）を返す．主たる設定は $\mathcal{T}$ の全画像が揃ってから採点する**事後採点**（transductive）で，画像が届くたびに採点する**到着時採点**は付録 A.11 で扱う．特徴抽出器 f は凍結し，モデルは更新しない．Salmon Ladder は次の 4 つの部品からなる（**図 1**）．

(1) **較正順位**：ID らしさの値を，固定したラベル付き画像の中での順位に変えて読む（2.2 節）．すべての部品の共通の物差しで，共形 p 値である．

(2) **支持画像からの質量** u^+：支持画像・参照画像・較正画像・テスト画像を節点とする 1 つのグラフ上で支持画像に置いた質量を伝播させ，参照画像の中での順位 p^+ で読む（2.3 節）．

(3) **未知からの質量** u^-：p^+ に偽発見率を制御する多重検定（AdaDetect [12] の意味での BH 法）をかけ，較正画像とテスト画像の全体から未知の側に偏った画像の集合 $\hat{Q}$（種）を自己ラベル付けし，種の質量を同じグラフで伝播させる（2.4 節）．

(4) **参照画像による読み出し**：2 つの質量の参照画像での順位を足した統計量 σ_{ref} を，較正画像の中での順位 p^{fin} で読む（2.5 節）．p^{fin} は折に分けずに共形 p 値になり，ID の誤警報率と BH 法の偽発見率が保証される（命題 4）．

スコアは $s(x) = s_0(x) \exp \sigma_{\mathrm{ref}}(x)$ で，s_0 は任意のベース検出器である（2.6 節）．判定には p^{fin} を使う．

2.2 較正順位：固定したラベル付き画像の中での順位

ID らしさを表す値 $a(x)$（小さいほど OOD らしい）を，ラベル付き画像の集合 $\mathcal{C}'$（$n' = |\mathcal{C}'|$）を同じ方法で採点した値の中での順位

$$p(x) = \frac{1 + |\{x' \in \mathcal{C}' : a(x') \le a(x)\}|}{n' + 1} \in \left[\frac{1}{n'+1}, 1\right] \tag{1}$$

で読む（**較正順位**）．$\mathcal{C}'$ と ID のテスト画像が交換可能で，a が両者を対称に扱うなら，これは $\Pr(p(x) \le \alpha) \le \alpha$ を満たす共形 p 値 [12], [14] であり，閾値 α で OOD と判定したときの ID の誤警報率は α 以下になる．大きいほど OOD らしい値は不等号を逆にして読む（式 (9)）．順位は $[0, 1]$ の値なので尺度の違うビューどうしの積が取れる．

2.3 支持画像からの質量：ラベル伝播のグラフ

2.3.1 グラフの構成

支持画像 $\mathcal{S}$，参照画像 $\mathcal{R}$，較正画像 $\mathcal{C}$，テスト画像 $\mathcal{T}$ のすべてを節点とする（節点数 N）．各節点 i から，コサイン類似度 $f(x_i)^\top f(x_j)$ が上位 k_g=10 の節点 j へ向かう辺を張り，重みを $a_{ij} = \max(f(x_i)^\top f(x_j), 0)$ とする（行列 A）．向きのない辺にするために $W = \max(A, A^\top)$（成分ごとの最大）とし，次数 $\delta_i = \sum_j W_{ij}$，$D = \mathrm{diag}(\delta_i)$，正規化した行列

$$S = D^{-1/2} W D^{-1/2} \tag{2}$$

を作る [15]．S は対称で固有値は $[-1, 1]$ にあり，非零成分は $O(Nk_g)$ の疎行列である．参照画像・較正画像・テスト画像はどれもラベルを持たない節点として全く同じ扱いを受け，グラフは節点の順序や名札に依らない（付録の**図 A·1**a）．グラフはビューごとに 1 つ作り，2 つの質量を同じグラフで伝播させる．

2.3.2 伝播の反復とランダムウォークとしての意味

支持画像の節点で 1，他で 0 のベクトル $\mathbf{y}^+ \in \{0, 1\}^N$ と λ=0.9 で

$$\mathbf{u}^{(\ell+1)} = \lambda S \mathbf{u}^{(\ell)} + (1 - \lambda)\mathbf{y}^+ \tag{3}$$

を収束するまで反復する（$\mathbf{u}^{(0)} = \mathbf{0}$；局所・大域一貫性 [15] の反復）．$\lambda < 1$ かつ $\|S\|_2 \le 1$ なので縮小写像であり，収束解 $\mathbf{u}^+ = (1 - \lambda) \sum_{\ell \ge 0} \lambda^\ell S^\ell \mathbf{y}^+$ を持つ．ランダムウォー

クで言えば，$P = D^{-1}W$ を遷移確率とし，各ステップで確率 $1-\lambda$ で止まるランダムウォークを節点 i から始めたとき，

$$u_i^{+} = \sqrt{\delta_i}\, q_i, \qquad q_i = \mathbb{E}_i\Big[\frac{\mathbf{1}[X_T \in \mathcal{S}]}{\sqrt{\delta_{X_T}}}\Big] \tag{4}$$

である（X_T は止まった節点．$S^{\ell} = D^{1/2}P^{\ell}D^{-1/2}$ から従う）．u^{+} は，次数（密度）の因子 $\sqrt{\delta_i}$ と，支持画像で止まる確率（止まった支持画像の $1/\sqrt{\delta}$ で重みづけたもの）の因子 q_i の積である．支持画像に近い ID 画像からは数歩で支持画像に着くので q は大きく，互いに近い未知の塊からは支持画像へ出る辺が少ないので q は小さい（**図 A·1**a；どちらの因子が near と far に効くかは 4.2 節）．

2.3.3 参照画像での順位による読み出し

参照画像はグラフの節点であり（$y^{+}=0$），同じ反復で u^{+} を受け取るので，

$$p^{+}(x) = \frac{1 + |\{r \in \mathcal{R} : u^{+}(r) \le u^{+}(x)\}|}{|\mathcal{R}| + 1} \tag{5}$$

とする．u^{+} は支持画像の特徴と「参照画像・較正画像・テスト画像を合わせた集合」だけで決まり，その集合の中の節点を入れ替えても各画像の値は変わらない（置換不変性）．したがって参照画像と ID のテスト画像が交換可能なら，p^{+} は AdaDetect [12] の経験 p 値で，ID のテスト画像について超一様である．p^{+} だけでも検知器として完結し（**表 2** の「p^{+} のみ」），以下の種は再出現する未知のための拡張である．

2.3.4 質量の保存とカットの上界

命題 1（質量の保存）． $\boldsymbol{\omega} = D^{1/2}\mathbf{1}$ とすると，式 (3) を $\mathbf{u}^{(0)} = \mathbf{0}$ から L 回反復した値は $\boldsymbol{\omega}^{\top}\mathbf{u}^{(L)} = (1-\lambda^{L})\sum_{j\in\mathcal{S}}\sqrt{\delta_j}$ を満たし，収束解では $\boldsymbol{\omega}^{\top}\mathbf{u}^{+} = \sum_{j\in\mathcal{S}}\sqrt{\delta_j}$ である（証明は付録 A.1）．重みづけた質量の総和は支持画像の次数だけで決まり，テスト画像の枚数に比例しては増えないので，1 節点あたりの u^{+} の尺度はテスト集合やビューごとに変わり（**図 A·1**c），値をそのまま閾値にかけたりビューどうしで掛けたりはできない．順位式 (5) がこの尺度を取り除く．**命題 2（カットの上界）．** 初期質量を置いた節点の集合 Y を含まない節点の集合 Q について，Q と外とを結ぶ辺の重みの和を $w(Q,\bar{Q}) = \sum_{i\in Q,\, j\notin Q} W_{ij}$ とすると，収束解 $\mathbf{u}$ は

$$\sum_{i\in Q}\sqrt{\delta_i}\, u_i \le \frac{\lambda}{1-\lambda}\cdot\frac{w(Q,\bar{Q})}{\min_{j\in Y}\sqrt{\delta_j}} \tag{6}$$

を満たす（証明は付録 A.1）．$W = \max(A, A^{\top})$ なので，$w(Q,\bar{Q})$ には Q **の節点が自ら張る辺**と**外の節点が** Q **へ張る辺**の両方が入る（**図 A·1**b）．$Y = \mathcal{S}$，Q を同じ未知クラスの r 枚とし，それらが互いの近傍の上位を占めるなら，前者は節点あたり $(k_g - r + 1)_{+}$ 本に減り，$r \ge k_g + 1$ で尽きる．後者は外の節点が Q の画像を近傍に選ぶかどうかで決まる．

系 1（逃げる確率）． Q の節点 i から出たランダムウォークが止まる前に Q の外へ出る確率を π_i とすると，$\boldsymbol{\pi} = \lambda(I - \lambda P_{QQ})^{-1}\mathbf{e}$（$P_{QQ}$ は P の Q への制限，$e_i = \sum_{j\notin Q} W_{ij}/\delta_i$）で，$\pi_i \le \psi(\bar{e}_Q)$，$\bar{e}_Q = \max_{i\in Q} e_i$，$\psi(e) = \lambda e/(1-\lambda+\lambda e)$ である．∂Q を Q に隣接する外の節点の集合とすると，Q の各節点 i で

$$u_i \le b_i := \pi_i\sqrt{\delta_i}\max_{j\in\partial Q}\frac{u_j}{\sqrt{\delta_j}} \tag{7}$$

が成り立つ．特に $\bar{e}_Q = 0$ なら $u_i^{+} = 0$ で，$p^{+}(i)$ は床 $1/(|\mathcal{R}|+1)$ に落ちる（参照画像の u^{+} がすべて正のとき；証明は付録 A.1）．

2.4 未知からの質量：自己ラベル付けと負の伝播

2.4.1 種の選択：AdaDetect の意味での BH 法

p^{+} は，ID の画像について超一様な p 値である．そこで較正画像とテスト画像を合わせた**プール** $\mathcal{U} = \mathcal{C}\cup\mathcal{T}$（$m = |\mathcal{U}|$）の各画像に「$x$ は ID である」を帰無仮説とする検定を当て，偽発見率（FDR：選んだ集合に混じる ID の割合の期待値）を水準 q に抑える選び方で未知の集合 $\hat{Q}$ を選ぶ．Benjamini–Hochberg（BH）法 [16] は，$p_{(1)} \le \cdots \le p_{(m)}$ を p^{+} の昇順として $p_{(i)} \le q\, i/m$ を満たす最大の i まで棄却する．本稿は ID の割合 π_0 を推定して水準を $q/\hat{\pi}_0$ に上げる Storey 型 [17] を用い，$\lambda_{\mathrm{S}} = K/(|\mathcal{R}|+1)$（$K = \lfloor |\mathcal{R}|/2 \rfloor$）として

$$\hat{\pi}_0 = \frac{1 + |\{x : p^{+}(x) \ge \lambda_{\mathrm{S}}\}|}{m\,(1-\lambda_{\mathrm{S}})}, \quad \hat{k} = \max\{i : p_{(i)} \le \tfrac{q\,i}{\hat{\pi}_0 m}\} \tag{8}$$

とし，p^{+} が小さい方から $\hat{k}$ 枚の画像の集合 $\hat{Q}$ を**種**と呼ぶ（ビューごと）．本稿の構成は q=0.2 である．較正画像も候補に入れるのは，種の選び方を較正画像とテスト画像について対称にするためである（命題 4）．

命題 3（偽発見率，AdaDetect [12]）． 参照画像とプールの ID の画像が交換可能なら，(i) 水準 q の BH 法（$\hat{\pi}_0 = 1$）で選んだ $\hat{Q}$ の FDR は $q\, m_0/m \le q$ 以下，(ii) 式 (8) の Storey 型で選んだ $\hat{Q}$ の FDR は q 以下である（m_0 はプールの ID の画像の数）．**証明．** u^{+} は支持画像を学習標本とし，参照画像とプールを合わせた集合の中での置換に不変なので AdaDetect の条件 (8) を満たし，式 (5) は同論文の経験 p 値 (10) である．同論文の定理 3.3 と系 3.5・3.7 による．□

較正画像（学習画像）と ID のテスト画像（検証画像）は厳密には交換可能ではなく，実際に混じる ID の割合は 4.3 節，4.4 節で報告する．**順位の粒度．** p^{+} の最小値は $1/(|\mathcal{R}|+1)$ なので，種が 1 枚でも選ばれるには最小値を取る画像が $\hat{\pi}_0 m/(q(|\mathcal{R}|+1))$ 枚以上要る（q=0.2 ならプールの約 0.25%）．未知がそれより少なければ種は選ばれず，p^{+} だけの読み出しに戻る（4.3 節）．種の閾値に上限 τ を

付けた規則も登録して評価した（付録 A.16）．

2.5 参照画像による読み出し

種で 1，他で 0 のベクトル $\mathbf{y}^- = \mathbf{1}_{\hat{Q}}$ を初期質量とし，同じグラフ・同じ λ で式 (3) を収束まで反復した値を $\mathbf{u}^-$ とする．$u^-/\sqrt{\delta}$ は種で止まる確率の因子で，種は未知なので，u^- は**大きいほど未知らしい**．種は自分に注入した質量 $1-\lambda$ を持つので，それを除いた $\tilde{\mathbf{u}}^- = \mathbf{u}^- - (1-\lambda)\mathbf{1}_{\hat{Q}} = \lambda S\mathbf{u}^-$ を使い，プールのどの画像も同じ規則で採点する．参照画像の中での逆順位

$$p^-(x) = \frac{1 + |\{r \in \mathcal{R} : \tilde{u}^-(r) \geq \tilde{u}^-(x)\}|}{|\mathcal{R}| + 1} \tag{9}$$

で読み（種が選ばれなければ $p^- \equiv 1$），ビュー v ごとの値を足して

$$\begin{aligned} \sigma_{\mathrm{ref}}(x) &= \textstyle\sum_v \left[\log p_v^+(x) + \log p_v^-(x)\right], \\ p^{\mathrm{fin}}(x) &= \frac{1 + |\{c \in \mathcal{C} : \sigma_{\mathrm{ref}}(c) \leq \sigma_{\mathrm{ref}}(x)\}|}{|\mathcal{C}| + 1} \end{aligned} \tag{10}$$

とする．命題 2 を $Y = \hat{Q}$，Q を種を含まない ID の画像の集合として適用すると，ID に届く負の質量は ID と種を隔てるカットで上から抑えられる．種は同じ未知クラスのうち支持画像から遠い画像として命題 3 の意味で誤りを抑えながら選ばれ，その質量がクラス内の密な辺を通って残りへ流れる．

命題 4（最終読み出しの保証）．較正画像 $\mathcal{C}$ と $\mathcal{T}$ の ID の画像が，支持画像・参照画像・未知の画像を所与として交換可能なら，(i) $\mathcal{T}$ の各 ID 画像 x について $\Pr(p^{\mathrm{fin}}(x) \leq \alpha) \leq \alpha$，すなわち閾値 α で OOD と判定したときの ID の誤警報率は α 以下である．(ii) $\{p^{\mathrm{fin}}(x) : x \in \mathcal{T}\}$ は ID の画像の上で PRDS であり，水準 q の BH 法で選んだ集合の FDR は $q|\mathcal{T}_0|/|\mathcal{T}| \leq q$ 以下（$\mathcal{T}_0$ は $\mathcal{T}$ の ID の画像），Storey 型（$\lambda_{\mathrm{S}} = \lfloor|\mathcal{C}|/2\rfloor/(|\mathcal{C}|+1)$）では q 以下である．**証明の要点．** σ_{ref} は，$\mathcal{S}$，$\mathcal{R}$ と「$\mathcal{U}$ という節点の集合」だけで決まり，$\mathcal{U}$ の中でどの節点を較正画像と呼ぶかを入れ替えても変わらない（グラフと $\mathbf{u}^{\pm}$ は名札に依らず，種はプールの p^+ の多重集合から対称に決まり，読み出しの順位は固定した $\mathcal{R}$ に対して取る）．これは AdaDetect の条件 (8) であり，p^{fin} は同論文の経験 p 値 (10) なので，定理 3.3 と系 3.5・3.7 が従う（付録 A.1）．

p^{fin} は有効な共形 p 値なので，利用者は「ID の誤警報率 α」という閾値を調整なしに直接指定できる．順位付け（AUROC，FPR95）には σ_{ref} を使う．p^{fin} は $1/(|\mathcal{C}|+1)$ 刻みで，σ_{ref} が較正画像の最小値を下回る画像はすべて同じ最小値になる（床）．比較に用いる読み出し σ は，ラベル付きの 4 枚（クラスあたり）とテスト画像を 2 つの**折**に分け，一方の折の種と較正画像で他方の折を採点する**交差適合**で同じ保証を得る（付録 A.2）．σ_{ref} は折を使わずに保証を得て，種を較正画像とテスト画像の全体から選ぶ．参照する枚数（$|\mathcal{R}| = |\mathcal{C}| = 2{,}000$）は折の較正画像と同じで，折の乱数による値の揺れ（開発用分割で，折の割り当てを 4 通りに変えたときの 1 抽出あたりの範囲が平均 0.64，最大 1.13 ポイント）もない．

系 2（分離の上界）．同じ未知クラスのテスト画像の集合を Q（種を含んでよい）とし，系 1 の $b_v(y)$（$Y = \mathcal{S}$）と

$$c_v(y) = \lambda(1-\lambda) \sum_{j \in \hat{Q}_v} \frac{W_v(y,j)}{\sqrt{\delta_v(y)\,\delta_v(j)}} \tag{11}$$

を使うと，Q の各画像 y で $u_v^+(y) \leq b_v(y)$，$\tilde{u}_v^-(y) \geq c_v(y)$ なので

$$\begin{aligned} &\sigma_{\mathrm{ref}}(y) \leq B(y) := \textstyle\sum_v \left[\log p_v^+[b_v(y)] + \log p_v^-[c_v(y)]\right], \\ &p^{\mathrm{fin}}(y) \leq \bar{p}(y) := \frac{1 + |\{c \in \mathcal{C} : \sigma_{\mathrm{ref}}(c) \leq B(y)\}|}{|\mathcal{C}| + 1} \end{aligned} \tag{12}$$

が成り立つ（$p_v^+[b]$，$p_v^-[c]$ は値 b，c の参照画像の中での順位と逆順位；証明は付録 A.1）．b_v は同じクラスの画像が外へ張る辺が少ないほど小さく，c_v は種と結ぶ辺が多いほど大きい．囲まれた未知と種に囲まれた未知には，y 自身のスコアを見ずに，クラスの境界の質量と種への辺から小さな p^{fin} が保証される（実測は 4.3 節）．

2.6 スコアと枠組み

$s(x) = s_0(x) \exp \sigma_{\mathrm{ref}}(x)$ を返す．特徴抽出器ごとの値を**ビュー** v と呼び，ビューごとにグラフと種を持ち，式 (10) の和で合わせる．s_0 はベース検出器で，s_0=1 を**単体**と呼ぶ．ベース検出器は較正画像のスコアを持たない（テスト画像にしか付かない）ので較正順位に変えられず，σ_{ref} との積で合わせる．命題 4 が及ぶのは単体の p^{fin} までで，$s_0 \exp \sigma_{\mathrm{ref}}$ は順位付けのためのスコアであり保証の外にある．p^{fin} との積では，床の上でベース検出器の対数スコアが未知の順序を決めてしまう（4.2 節）．本稿の構成は，DINOv2 [18] ViT-L/14 と DINOv3 [19] ViT-L/16 の 2 ビュー，Storey 型の種，q=0.2 で，3 節の手続きで開発用分割から選んだ．ベース検出器には TINS [7]（CLIP ViT-B/16）を用い，NegLabel，AdaNeg，TANL に差し替えた値も示す．計算は，ビューごとに厳密な k_g 近傍探索と疎行列と密ベクトルの積 $O(Nk_g)$ の反復で，OpenOOD の 1 つのテスト集合（$N \approx$ 6–11 万）に 1 枚の GPU で 1 分以内である．

2.7 関連する枠組みとの関係

共形 p 値と半教師あり新奇性検知．ラベル付きの ID 標本と未知が混じったラベルなし標本から未知を見分ける設定は Scott と Blanchard [20], [21] が定式化した．固定したスコアの較正順位による共形 p 値と FDR 制御 [14], [22], [23] に対し，AdaDetect [12] は混合標本から学んだ置換不変なスコアに同じ保証を与え，本稿の p^+ と p^{fin} はその特別な

場合である．本稿のスコアは 16 枚のラベルで動くグラフ上の伝播で，棄却集合（種）から第 2 段の伝播を起こし，その読み出しを再び共形 p 値にする．**ラベル伝播とテスト時適応．**局所・大域一貫性 [15] や TPN [24] は閉集合を仮定してクラスへ割り当てるが，本稿は「ID である」質量と「未知である」質量だけを伝播させる（LGC-max との比較は 4.2 節）．AdaNeg [4]，OODD [25]，TANL [5]，TINS [7] はテスト画像の特徴や負例を蓄えて適応し，RTL [26] はテストバッチ上の回帰でスコアを補正し，AUTO [27] はモデルを更新するが，いずれも誤警報率や FDR の保証を持たない．テスト集合全体を見られる分の有利は，同条件の静的検出器と LGC-max，全学習画像を使う基線，到着時採点モードで埋める．

3. 実験設定

ベンチマーク．評価は OpenOOD v1.5 [8] の ImageNet-1K ベンチマークに従う．ID は ImageNet-1K の検証画像 45,000 枚，near-OOD は SSB-hard と NINCO，far-OOD は iNaturalist，Textures，OpenImage-O である．Four-OOD [13] は検証画像 50,000 枚に対する iNaturalist, SUN, Places，Textures である．OOD データセットごとに ID と混ぜた集合を 1 つのテスト集合とし, 指標は AUROC と, ID の 95%を受け入れる閾値での OOD の誤受理率 FPR95 である．ImageNet-200（ID は 200 クラスの検証画像 9,000 枚；OOD は同じ 5 データセット）と CIFAR-100（near-OOD は CIFAR-10 と Tiny ImageNet, far-OOD は MNIST, SVHN, Textures，Places365）の OpenOOD v1.5 ベンチマークでも，構成を固定したまま単体で評価する（4.6 節）．

ラベル付き画像とその抽出．クラスあたり 16 枚（支持 12 枚，参照 2 枚，較正 2 枚）を ID の学習画像から取る．抽出は 6 通り（ベース検出器の 16 枚と同じ 1 通りと，重ならない 5 通り）で，表の値はその平均，本文の区間は抽出を単位とする対応のある 95% t 区間である．事後採点のスコアは画像の順序に依らない．ベース検出器は到着順に依存するので，× ベース検出器の値はさらに OpenOOD で 5 通り，Four-OOD で 3 通りの順序の平均である．

構成の選び方と逸脱．k_g=10，λ=0.9 は，ImageNet-1K の学習画像だけから作った開発用分割（900 クラスを ID，残りを未知とする 2 つの分割 dev1，dev2）で以前に決めた値である．v16 までの版では，これらを含む構成をテスト集合上でも探索したうえで第 1 段の候補の集合を決めた（値は変えていない；付録 A.13）．その後の選択は「dev1 の near-OOD の FPR95 を最小にし, far-OOD の悪化を 0.5 ポイント未満に抑える」という事前登録した規則で行い，第 1 段でビュー（DINOv2 L/14 + DINOv3 L/16）と q=0.2 を折なしの p^+p^- について，第 2 段で種の規則（Storey 型），q=0.2，統計量 p^+p^- を折を使う読み出し σ について選んだ（付録 A.12）．σ_{ref} は σ の折を参照画像に置き換えた読み出しとして登録し，dev2 で「$\sigma_{\mathrm{ref}} - \sigma$ の FPR95 の対応のある 95%区間の上端が near と far で+0.5 以下，p^{fin} の誤警報率が α=0.05 で 0.06 以下，0.2 で 0.21 以下」なら主構成にすると定めた（付録 A.2）．dev2 の差は near +0.02 [-0.18, +0.21], far -0.08 [-0.50, +0.34], 誤警報率は α=0.05 で 0.052，0.2 で 0.204 で規則を満たし，テスト集合の値が出る前に σ_{ref} が主構成になった．登録は評価の実行前に公開リポジトリに置き，公開されたことを確かめてから実行した（付録 A.17）．ベース検出器は報告値が最良の VLM 手法 TINS [7]（CLIP ViT-B/16）で，本稿の実験では選んでいない．

登録からの逸脱は 2 件あり，どちらもテスト集合の値を見た後に，数字の良い側へ倒した．(a) ベース検出器との積は，σ の登録では $p^{\mathrm{fin}} \times s_0$ だったが，テスト集合で near-OOD の FPR95 が悪化したのを見て $\exp\sigma$ との積に替えた（4.2 節）．σ_{ref} の登録はこの形を引き継いだ．(b) 付録の一つの量 h は，点推定（dev2 の差が+0.5 以下）による採否の規則では主構成になったが，テスト集合で σ に劣ったため変種にとどめた（付録 A.18）．区間の上端（+0.89，+1.54）で判定していれば h は採用されず，(b) は生じなかった．σ_{ref} の採否を区間で定めたのはこのためである．

開発用分割の予測力．σ の第 2 段の 18 候補では，dev2 とテスト集合の FPR95 の順位相関は near 0.64，far 0.61（dev1 と dev2 では 0.99，0.94）で，dev1 で選んだ候補はテストの near で 18 候補中 10 位，far で 18 位だった．Storey 型と単純 BH 法の差（near の FPR95，dev2 -0.31，テスト+0.50）も，q=0.2 と 0.1 の差（-1.24，+0.49）も符号が逆転した（付録 A.3）．q=0.05 は dev1 の near で 17.76%と q=0.2（13.54%）より 4 ポイント悪いが, テストでは 11.32%と 11.50%で逆に良い．再現したのは near-OOD での種の有無の向きと静的 p を加えたときの向きで，構成の細部の選択はテスト集合から見て偶然と区別できない．σ_{ref} と σ の差も dev2 の+0.02 に対し，テストでは-0.24 である．

比較手法．公開されている値は報告値（†）を用い，公式実装のある NegLabel，AdaNeg，TANL，TINS は同じテスト集合で実測した．さらに，同じ特徴と同じ 16 枚で動く静的な検出器（静的 p：支持画像 12 枚の平均を原型とした最大の余弦類似度の較正順位；kNN [28]：支持画像への k=10 近傍の類似度の較正順位），同じグラフ上でクラスラベルを伝播させ最大のクラス質量を較正順位で読む LGC-max [15], [24]，到着時採点モード（付録 A.11）を測る．ImageNet-200 と CIFAR-100 では，同じ 2 つの特徴で全学習画像を使う kNN（k=50）とクラス平均，CLIP ViT-B/16 のゼロショットの MCM [2] と NegLabel も測る．6 つの単一ビューの値は付録 A.10 に示す．

4. 結果

4.1 OpenOOD v1.5 ImageNet-1K（表 1）

単体（主結果）. ベース検出器を使わない Salmon Ladder は，**表 1** の 6 列すべてで報告値の最良を上回る．near-OOD では AUROC 97.98%，FPR95 11.26%（抽出を振った 95%区間 [11.00, 11.51]）で，報告値の最良である DisCoPatch（95.05%，29.40%）を AUROC で 2.93 ポイント上回り，FPR95 を 18.14 ポイント（2.6 分の 1 に）下げた．far-OOD では AUROC 98.81%，FPR95 5.14%，Four-OOD では 98.81%，4.55%である．**データセット別**（付録 A.8）では，9 データセットの 18 列のうち単体で 12 列，×TINS で 18 列で報告値の最良を上回る．単体が上回らない 6 列は，SSB-hard（ID の兄弟クラス）の FPR95（21.26%；DisCoPatch は 19.80%），OpenImage-O の 2 列，Places の AUROC と，小数 2 桁で同値の iNaturalist の AUROC（OpenOOD と Four-OOD）である．×TINS の SSB-hard の FPR95（19.42%）は DisCoPatch を下回るが，抽出による 95%区間 [18.90, 19.94] は 19.80%を含む．

ベース検出器との積. ベース検出器 s_0 は $s_0 \exp \sigma_{\text{ref}}$ の形で掛ける（逸脱 (a) の形）．TINS との積は near-OOD AUROC 98.13%, FPR95 10.21%, far-OOD 99.06%, 4.14%, Four-OOD 99.09%, 3.39%で，報告値の最良を near-OOD の FPR95 で 19.19 ポイント，Four-OOD の TINS の FPR95 をほぼ半分に下げる．NegLabel，AdaNeg，TANL との積もすべての列で報告値を上回り，同じテスト集合で実測した各ベース検出器の near-OOD の FPR95（56.37–75.90%）を 45.83–65.25 ポイント下げる．

4.2 利得の出どころ：同じ特徴での比較（表 2）

特徴とラベルの分. 同じ 2 つの特徴抽出器と同じ 16 枚で動く静的な検出器は，near-OOD の FPR95 が ×TINS で静的 p 47.27%，kNN 51.34%，単体で 54.36%，59.51%であり，報告値の最良（29.40%）に及ばない．**伝播の分.** p^+ だけで FPR95 は 12.36%（単体），12.13%（×TINS）になり，見出しの数字の大半はこの共形ラベル伝播による．同じグラフでクラスラベルを伝播させる LGC-max は 19.52%（単体），18.04%（×TINS）で，静的な検出器よりは良いが p^+ に遠く及ばない．閉集合を仮定する伝播は未知を近い ID クラスへ引き寄せる．**種の分.** 種からの質量を加えた σ_{ref} と p^+ だけとの差は，near-OOD で単体-1.10 [-1.21, -0.98]，×TINS -1.92 [-2.07, -1.76] ポイント，far-OOD で-0.90，Four-OOD で-1.18 ポイント（単体）である．**参照画像の代価はない.** σ_{ref} と σ の差は near-OOD で単体-0.24 [-0.34, -0.15]，×TINS -0.28 [-0.36, -0.20]，far-OOD と Four-OOD で絶対値 0.03 以下であり，読み出しの保証を持たない折なしの p^+p^-（11.39%）との差も-0.13 [-0.22, -0.04] である．p^{fin} **をスコアにした場合.** 単体では 11.26%と σ_{ref} と同じだが，TINS との積は 13.00%（2.78 ポイント悪化），Four-OOD では逆に 2.97%と良い．p^{fin} の床の上ではベース検出器が順序を決めるので，TINS が弱い near-OOD で悪化し強い Four-OOD で改善する．

二つの因子（表 3）. 式 (4) の $u^+ = \sqrt{\delta}\, q$ の因子を別々に較正順位で読むと，確率の因子 q だけで near-OOD 11.85%，far-OOD 8.69%に達し，密度の因子 $\sqrt{\delta}$ だけでは AUROC が 37.99%（near），50.40%（far）と無情報か逆向きである（未知の塊は ID より密なことが多い）．それでも積 u^+ は q だけより far-OOD で FPR95 を 2.66 ポイント下げ（Four-OOD 1.62，ImageNet-200 far 0.66，CIFAR-100 near 0.99），ImageNet-1K の near-OOD の平均では 0.49 ポイント上げる．後者は SSB-hard（ID の兄弟クラス；20.62% → 22.50%）によるもので，NINCO では下げる（3.09%→ 2.19%）．密度の因子は単独では手がかりにならず，確率の因子と組んで効き，その向きはデータセットに依る．種の側の分解は登録どおり σ でだけ行い，$u^{\pm}$ を $u^{\pm}/\sqrt{\delta}$ に置き換えると ImageNet-1K では near でも far でも悪化する．

4.3 再出現と混入率（図 2）

同じクラスが何枚あり，どの混入率から効くのかを，OpenOOD の ID の検証画像 45,000 枚に，NINCO（64 クラス）または SSB-hard（980 クラス，各 50 枚）から c 個の未知クラスを r 枚ずつ加えたテスト集合で実測した（**図 2**，全条件は付録 A.14）．

再出現しない未知には静的な検出器より劣る. $r \leq 5$ では，σ_{ref} は同じ特徴の静的 p より FPR95 が高く（30 条件中 27 条件），差の平均は r=1 で+23.6，r=2 で+16.9，r=5 で+12.3 ポイント，最大+40.0 ポイントである．NINCO の 64 クラス ×1 枚では σ_{ref} も p^+ だけも 75.0%に対し，静的 p は 44.3%である．1 枚だけの未知は k_g=10 本の辺をすべて外へ張るので，伝播はその画像を隣の ID に均す．付録の一つの量 h は $r \leq 2$ の 20 条件でさらに平均+14.1 ポイント悪い．$r \geq 10$ では逆転し（30 条件中 29 条件，差の平均-30.9），NINCO の 64 クラス ×10 枚で 31.0%，30 枚で 3.0%（静的 p は 46.0%）まで下がる．SSB-hard（兄弟クラス）は遅く，980 クラス ×10 枚で 32.7%，50 枚で 22.3%である．σ_{ref} と σ の差は 60 条件中 49 条件で 1 ポイント以内（最大 3.8）である．

混入率が低いときの種は ID が多い. 混入率 1%未満では，72 のセル × ビューのうち種が選ばれたのは 5 だけで，選ばれたときに種に混じる ID の割合は平均 0.43（0.39–0.51）と水準 q=0.2 を超える．種が選ばれない場合を 0 と数えた偽発見割合（命題 3 が期待値を抑える量）の平均は 0.02，混入率 1–10%で 0.21，10%以上で 0.28 で，混入率が高いと水準を超える（較正画像とテスト画像のずれ；4.4 節）．低

表 1 OpenOOD v1.5 ImageNet-1K と Four-OOD（[%]）．† は原論文の報告値（近／遠の平均は本稿で計算）．実測値は同じテスト集合での値（到着順の平均，3 節）．本手法は σ_{ref}，抽出 6 通りの平均（× ベース検出器の行は順序の平均も取る）．★ は列の最良値，青 は比較手法のすべてを上回る値，括弧の行は最良の比較手法との差（正は本手法が良い）．

手法	OpenOOD near-OOD AUROC↑	FPR95↓	OpenOOD far-OOD AUROC↑	FPR95↓	Four-OOD AUROC↑	FPR95↓
***ImageNet-1K* のラベルで学習した検出器（報告値 †，近／遠の平均は本稿で計算）**						
MOODv2 [10]（BEiTv2）	88.85	48.15	97.10	13.37	–	–
NNGuide [9]（RegNet）	89.20	41.80	97.80	9.87	–	–
SCALE [29]（ResNet-50）	81.40	59.75	96.53	16.53	–	–
教師なし（報告値 †）						
DisCoPatch [11]（教師なし生成）	95.05	29.40	96.63	17.40	–	–
***VLM*，到着時採点（*CLIP ViT-B/16*，報告値 †）**						
NegLabel [3]（CLIP B/16，ゼロショット）	75.18	69.45	94.85	23.73	94.21	25.40
AdaNeg [4]（CLIP B/16，テスト時適応）	76.70	67.51	96.43	17.31	96.66	18.92
InterNeg [6]（CLIP B/16，テスト時適応）	82.20	65.43	96.71	16.96	97.43	14.04
TINS [7]（CLIP B/16，テスト時適応）	82.65	57.88	96.92	12.99	98.51	6.72
同じテスト集合での実測（公式実装，到着時採点，学習なし）						
NegLabel [3]	74.64	75.90	94.67	24.61	94.38	24.55
AdaNeg [4]	76.60	72.00	96.18	17.56	96.34	14.38
TANL [5]	82.85	56.80	96.19	15.91	97.55	8.91
TINS [7]	81.48	56.37	97.04	12.23	98.52	6.85
***Salmon Ladder*（*Ours*，学習なし，クラスあたり *16* 枚，事後採点；*6* 通りの抽出の平均）**						
Salmon Ladder，単体	**97.98**	**11.26**	**98.81**	**5.14**	**98.81**	**4.55**
最良の比較手法との差	(+2.93)	(+18.14)	(+1.01)	(+4.73)	(+0.29)	(+2.17)
ベース検出器との積 $s_0 \exp \sigma_{\text{ref}}$（*2.6* 節）						
×NegLabel	**98.03**	**10.66**	**98.94**	**4.66**	**98.90**	**4.12**
×AdaNeg	**98.05**	**10.45**	**98.95**	**4.56**	**98.92**	**3.98**
×TANL	**98.01**	**10.97**	**98.91**	**4.81**	**98.95**	**3.95**
×TINS	**98.13**★	**10.21**★	**99.06**★	**4.14**★	**99.09**★	**3.39**★
最良の比較手法との差	(+3.08)	(+19.19)	(+1.26)	(+5.73)	(+0.57)	(+3.33)

表 2 同じ特徴での読み出しの比較（[%]，×TINS；単体は付録 A.13 の**表 A·16**）．静的 p と kNN はグラフを使わない検出器，LGC-max は同じグラフ上のクラスラベル伝播（いずれも較正順位で読む）．p^+ は支持画像からの伝播，p^- は種からの伝播．到着時採点は付録 A.11 のモード（抽出は 1 通り）．★ は列の最良値．

構成	OpenOOD near-OOD AUROC↑	FPR95↓	OpenOOD far-OOD AUROC↑	FPR95↓	Four-OOD AUROC↑	FPR95↓
同じ特徴（*DINOv2 L/14 + DINOv3 L/16*）での読み出し，×*TINS*（単体は付録 *A.13* の表 *A·16*）						
静的 p（原型への余弦の較正順位，グラフなし）	86.18	47.27	98.61	6.62	97.84	7.97
kNN [28]（支持画像への k=10 近傍の較正順位，グラフなし）	83.63	51.34	98.23	8.31	97.68	8.45
LGC-max（支持画像のクラスラベルを伝播，最大クラス質量の較正順位）	96.07	18.04	98.82	5.31	98.56	5.60
p^+ のみ（支持画像からの伝播，種なし；参照画像で読む）	97.59	12.13	99.01	4.33	98.99	3.51
p^+p^-，折も参照画像もなし（保証は種だけ）	98.12	10.26	99.05	4.21	99.07	3.50
σ：2 つの折で交差適合した p^+p^-	98.09	10.50	99.05	4.16	99.09	3.39
σ，上限付きの種（Storey 型）（付録 A.16）	97.88	10.69	99.07	4.05	99.09	3.38
σ，上限付きの種（単純 BH 法）（付録 A.16）	97.89	10.66	99.08★	4.02★	99.10	3.32
σ_{ref}：参照画像で種を選び読む p^+p^-（本稿）	98.13★	10.21★	99.06	4.14	99.09	3.39
σ_{ref} の較正順位 p^{fin} をそのままスコアにしたもの	97.50	13.00	99.03	4.40	99.17★	2.97★
p^+p^-，到着時採点，折なし（付録 A.11）	97.41	13.39	98.89	5.13	98.96	4.10
σ，到着時採点（付録 A.11）	97.35	13.83	98.87	5.25	98.97	4.00

表 3 $u^+ = \sqrt{\delta}\, q$ の二つの因子（単体，AUROC ／ FPR95 [%]，6 通りの抽出の平均）．上の 3 行はビューごとの値のラベル付き画像 4,000 枚（参照画像と較正画像）の中での順位の対数和（$\sqrt{\delta}$ と q はそれぞれ単独，u^+ は積），4 行目は交差適合した σ の読み出しの順位を $u^{\pm}/\sqrt{\delta}$ で取ったもの（種は同じ）．

読み出し（AUROC ／ FPR95）	ImageNet-1K（OpenOOD, Four-OOD） near	far	Four-OOD	ImageNet-200 near	far	CIFAR-100 near	far
$\sqrt{\delta}$ のみ（密度の因子）	37.99 ／ 97.97	50.40 ／ 93.60	48.84 ／ 95.75	40.85 ／ 97.84	52.90 ／ 93.34	50.82 ／ 93.06	33.35 ／ 96.72
$q = u^+/\sqrt{\delta}$ のみ（確率の因子）	97.49 ／ 11.85	97.13 ／ 8.69	97.57 ／ 7.36	98.61 ／ 7.09	99.21 ／ 1.89	98.74 ／ 3.82	99.49 ／ 1.51
$u^+ = \sqrt{\delta}\, q$（積；p^+，ラベル付き画像 4,000 枚）	97.54 ／ 12.35	98.46 ／ 6.03	98.27 ／ 5.74	98.49 ／ 7.47	99.44 ／ 1.22	99.19 ／ 2.83	99.62 ／ 1.17
σ の $u^{\pm}$ を $u^{\pm}/\sqrt{\delta}$ に置換	97.77 ／ 12.09	98.40 ／ 6.26	98.58 ／ 5.32	97.77 ／ 9.90	99.17 ／ 1.62	98.95 ／ 3.14	98.87 ／ 2.30
σ（交差適合）	97.94 ／ 11.50	98.79 ／ 5.17	98.80 ／ 4.56	98.17 ／ 9.07	99.35 ／ 2.15	99.18 ／ 2.90	99.37 ／ 2.34
σ_{ref}（本稿）	97.98 ／ 11.26	98.81 ／ 5.14	98.81 ／ 4.55	98.22 ／ 8.68	99.40 ／ 2.06	99.20 ／ 2.90	99.37 ／ 2.48

い混入率でまれに選ばれる種は半分近くが ID であり，種が効くのは同じクラスの未知がそれより多く再出現するときである．

分離の上界の実測． 系 2 の上界は格子の全条件・全未知画像で成り立ち（違反 0），上界だけから $p^{\text{fin}} \le 0.05$ が言える未知の割合は，NINCO の r=30 で 47–58%（実際に $p^{\text{fin}} \le 0.05$ の割合は 88–98%），$r \le 5$ では最大 14%，SSB-hard の r=50 では未知クラスの数とともに 38%（c=10）から 0.6%（c=980；実際は 81%）へ下がる（付録 A.5）．系 2 は，再出現が多く未知クラスの少ない条件で検知の半分程度をクラスの境界と種への辺から説明するが，未知クラスが多いとほとんど何も言わない．付録の h の系 A1 では，較正画像側の下界で保証される未知は全条件で 0 である．

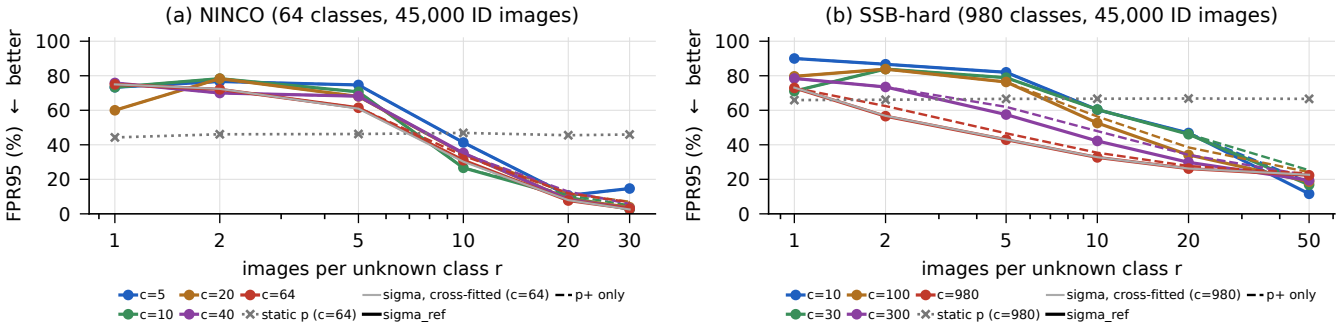


図 2 再出現と混入率（FPR95，単体，DINOv2 L/14 + DINOv3 L/16）．ID の検証画像 45,000 枚に，NINCO（a）または SSB-hard（b）から c 個の未知クラス $\times r$ 枚を加えたテスト集合（クラスと画像の選び方を変えた 3 回の平均）．実線は σ_{ref}，破線は p^{+} だけ（参照画像で読む），灰色の点線は静的 p，灰色の細い実線は交差適合した σ（後二者は c が最大の条件）．

4.4 最終スコアの保証の実測

命題 4 が仮定する較正画像と ID のテスト画像の交換可能性は，両者が ImageNet-1K の学習画像である開発用分割ではほぼ成り立ち（較正画像はクラスごとに 2 枚と層化されている），較正画像が学習画像，テスト画像が検証画像のベンチマークでは厳密には成り立たない．開発用分割での σ_{ref} の p^{fin} の誤警報率 $\Pr(p^{\mathrm{fin}} \le \alpha)$ は，α=0.05 で dev1 0.052，dev2 0.052，0.2 で 0.201，0.204，BH 法（q=0.2）の偽発見割合は 0.170，0.176 と水準どおりである．ベンチマークでは α=0.05 で 0.061（near），0.065（far），0.063（Four-OOD）と，学習画像と検証画像のずれの分だけ水準を超える（σ の p^{fin} も 0.058，0.064，0.062）．種に混じる ID の割合も，データセットとビューごとに 0.22–0.27 と水準 q=0.2 を超える．ベンチマークでの命題 3，4 の保証は近似である．σ については較正画像を検証画像から取った交換可能な設定でも，誤警報率が α=0.05 で 0.049–0.054 と水準どおりであることを確かめた（付録 A.7）．

4.5 共変量シフトした ID

ID のテスト画像 45,000 枚に，ImageNet-V2（同じ 1,000 クラスの新しい検証画像 10,000 枚）または ImageNet-R（200 クラスの絵・彫刻などの描画 30,000 枚）を ID として加えた（付録 A.6 の**表 A·5**）．ImageNet-V2 は ID と区別されず（ID と V2 の AUROC 54.4%），V2 も受け入れる全体の FPR95 は near-OOD で 11.61%，far-OOD で 5.78% と，同じ実行で ID だけを受け入れる場合（11.46%，5.55%）からほとんど変わらない（α=0.05 の誤警報率は V2 で 0.073）．ImageNet-R はほぼすべて未知と判定され（ID と R の AUROC 96.8%，誤警報率 0.847，種の 41%が R），全体の FPR95 は near-OOD で 64.67%，far-OOD で 58.82% に悪化する．同じ特徴の静的 p は R を ID により近く扱うので（AUROC 72.6%），far-OOD の全体では 26.33%と本手法より良い．Salmon Ladder は支持画像の分布からのずれを，意味のずれと共変量のずれの区別なく未知とみなすので，描画のような強い共変量シフトを ID として受け入れる運用にはそのままでは使えない．

4.6 ImageNet-200 と CIFAR-100

ImageNet-200．構成を固定したまま単体で評価した（6 通りの抽出の平均；付録 A.9 の**表 A·11**）．σ_{ref} は near-OOD で AUROC 98.22%，FPR95 8.68%，far-OOD で 99.40%，2.06%であり，OpenOOD v1.5 [8] の報告値の最良（near 84.84%／52.30%，far 95.01%／21.22%；ImageNet-200 で学習した ResNet-18）を大きく上回る．ラベルの数を揃えない基線として，全学習画像 258,951 枚の kNN（k=50）とクラス平均（同じ 2 つの特徴），CLIP ViT-B/16 のゼロショットの MCM と NegLabel も測った．kNN は FPR95 28.04%／4.40%，クラス平均は 24.69%／3.20%で 16 枚の静的 p（26.72%／3.71%）と同程度にとどまり，MCM と NegLabel は 57.89%／14.92%，56.16%／10.21%である．ラベル付き画像を約 80 倍使っても伝播の分（p^{+} だけで 7.44%／1.23%）は得られない．一方，種は効かない．σ_{ref} は p^{+} だけより near で+1.24 [+0.29, +2.19]，far で+0.83 ポイント悪く，LGC-max（7.99%／1.65%）にも及ばない．ID が 9,000 枚しかなく，SSB-hard では未知が全画像の 84.48%を占めるからである（付録 A.9）．

CIFAR-100．OpenOOD v1.5 の CIFAR-100 ベンチマーク（3 節）で，同じ凍結特徴と学習画像からの 16 枚（クラスあたり，重ならない 6 通りの抽出），同じ構成で単体の値を測った（**表 A·10**）．σ_{ref} は near-OOD で AUROC 99.20%，FPR95 2.90%，far-OOD で 99.37%，2.48%で，報告値（CIFAR-100 で学習した ResNet-18）の最良である OE（near 88.30%／30.73%，外れ値データで学習）と RotPred（far 88.40%／34.50%）を AUROC で 10 ポイント以上上回る．全学習画像 50,000 枚の kNN（16.35%／32.15%）とクラス平均（12.91%／28.05%）は 16 枚の静的 p（16.49%／29.19%）から数ポイント以内にとどまり，32 × 32 の画像ではゼロショットの MCM と NegLabel は弱い（94.06%

／ 89.10%，76.98%／ 64.84%）．ここでも利得は伝播にあり，種は効かない．p^+ だけで 2.87%／ 1.17%，σ_{ref} との差は far-OOD で+1.31 [+0.48, +2.13] ポイントで，未知が MNIST・SVHN・Places365 で全画像の 74–89%を占めると，割合 q の種が ID のほぼ全数になって p^- は情報を失う．交差適合した σ では，種の閾値に上限 τ=0.05 を付けた登録済みの規則がこの害をほぼ消した（ImageNet-200 near で FPR95 9.07%→ 6.91%，CIFAR-100 far で 2.34% → 1.46%；付録 A.16）．σ_{ref} との組合せは評価していない．

5. 結論

支持画像の質量をグラフで伝播させ順位（共形 p 値）で読む共形ラベル伝播，自己ラベル付けした種からの負の伝播，参照画像で種を選び読む読み出し σ_{ref} からなる枠組み Salmon Ladder を提案した．凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで，OpenOOD v1.5 ImageNet-1K の near-OOD（単体で AUROC 97.98%，FPR95 11.26%），far-OOD，Four-OOD で公開の最良値を更新し，ImageNet-200 と CIFAR-100 でも報告値の最良を上回った．利得の大半はグラフ上の伝播の確率の因子にあり，σ_{ref} は折なしに読み出しの保証を得て，同じ未知クラスの画像の検知の一部を系 2 でクラスの境界と種への辺から説明する．**推す構成．** σ_{ref}（ベース検出器があれば $s_0 \exp \sigma_{\text{ref}}$）を推す．ID のテスト画像が 1 万枚程度と少なく未知が多い集合を含む ImageNet-200 と CIFAR-100 では，種を使わない p^+ だけ（参照画像で読み，同じ保証を持つ）が σ_{ref} と同等以上だったので，そうした運用には p^+ だけを推す．45,000 枚の ID に未知を加えた格子では，混入率 10%以上の 6 条件（最大 52%）すべてで σ_{ref} が良く，混入率だけでは境目は決まらない．**限界．** 1 枚しか現れない未知には静的な検出器より劣り，描画への共変量シフトを未知とみなす．ベンチマークでは較正画像とテスト画像のずれのため保証は近似で，ベース検出器との積は命題 4 の外にある．開発用分割による構成の細部の選択はテスト集合に移らない．理論が扱うのは有効性と分離の上界で，検知力の全体ではない．

参考文献

[1] A. Radford et al.: Learning transferable visual models from natural language supervision. *ICML*, 2021.
[2] Y. Ming et al.: Delving into out-of-distribution detection with vision-language representations. *NeurIPS*, 2022.
[3] X. Jiang et al.: Negative label guided OOD detection with pretrained vision-language models. *ICLR*, 2024.
[4] Y. Zhang and L. Zhang: AdaNeg: Adaptive negative proxy guided OOD detection with vision-language models. *NeurIPS*, 2024.
[5] Y. Zhang et al.: Activation matters: Test-time activated negative labels for OOD detection with vision-language models. *CVPR*, 2026.
[6] Z. Xu et al.: Mind the way you select negative texts: Pursuing the distance consistency in OOD detection with VLMs. *CVPR*, 2026.
[7] Y. Yang et al.: TINS: Test-time ID-prototype-separated negative semantics learning for OOD detection. arXiv:2605.10756, 2026.
[8] J. Zhang et al.: OpenOOD v1.5: Enhanced benchmark for out-of-distribution detection. *DMLR*, 2024.
[9] J. Park, Y. G. Jung, and A. B. J. Teoh: Nearest neighbor guidance for out-of-distribution detection. *ICCV*, 2023.
[10] J. Li et al.: MOODv2: Masked image modeling for out-of-distribution detection. *IEEE TPAMI*, 2024.
[11] F. Caetano et al.: DisCoPatch: Taming adversarially-driven batch statistics for improved out-of-distribution detection. *ICCV*, 2025.
[12] A. Marandon, L. Lei, D. Mary, and E. Roquain: Adaptive novelty detection with false discovery rate guarantee. *Ann. Stat.*, 52(1), 2024.
[13] R. Huang and Y. Li: MOS: Towards scaling out-of-distribution detection for large semantic space. *CVPR*, 2021.
[14] S. Bates, E. Candès, L. Lei, Y. Romano, and M. Sesia: Testing for outliers with conformal p-values. *Ann. Stat.*, 51(1):149–178, 2023.
[15] D. Zhou et al.: Learning with local and global consistency. *NIPS*, 2004.
[16] Y. Benjamini and Y. Hochberg: Controlling the false discovery rate: A practical and powerful approach to multiple testing. *J. R. Stat. Soc. B*, 1995.
[17] J. D. Storey: A direct approach to false discovery rates. *J. R. Stat. Soc. B*, 2002.
[18] M. Oquab et al.: DINOv2: Learning robust visual features without supervision. *TMLR*, 2024.
[19] O. Siméoni et al.: DINOv3. arXiv:2508.10104, 2025.
[20] C. Scott and G. Blanchard: Novelty detection: Unlabeled data definitely help. *AISTATS*, pp. 464–471, 2009.
[21] G. Blanchard, G. Lee, and C. Scott: Semi-supervised novelty detection. *J. Mach. Learn. Res.*, 11:2973–3009, 2010.
[22] M. Haroush, T. Frostig, R. Heller, and D. Soudry: A statistical framework for efficient out of distribution detection in deep neural networks. *ICLR*, 2022.
[23] Z. Liang, M. Sesia, and W. Sun: Integrative conformal p-values for out-of-distribution testing with labelled outliers. *J. R. Stat. Soc. B*, 86(3):671–693, 2024.
[24] Y. Liu et al.: Learning to propagate labels: Transductive propagation network for few-shot learning. *ICLR*, 2019.
[25] Y. Yang et al.: OODD: Test-time out-of-distribution detection with dynamic dictionary. *CVPR*, 2025.
[26] K. Fan et al.: Test-time linear out-of-distribution detection. *CVPR*, pp. 23752–23761, 2024.
[27] P. Yang, J. Liang, J. Cao, and R. He: AUTO: Adaptive outlier optimization for test-time OOD detection. arXiv:2303.12267, 2023.
[28] Y. Sun, Y. Ming, X. Zhu, and Y. Li: Out-of-distribution detection with deep nearest neighbors. *ICML*, 2022.
[29] K. Xu et al.: Scaling for training time and post-hoc out-of-distribution detection enhancement. *ICLR*, 2024.

付　　録

A.1　命題 1，2，4 と系 1，2 の証明

図 A·1 に，本文 2.3 節のグラフと命題 1，2 の図を示す．

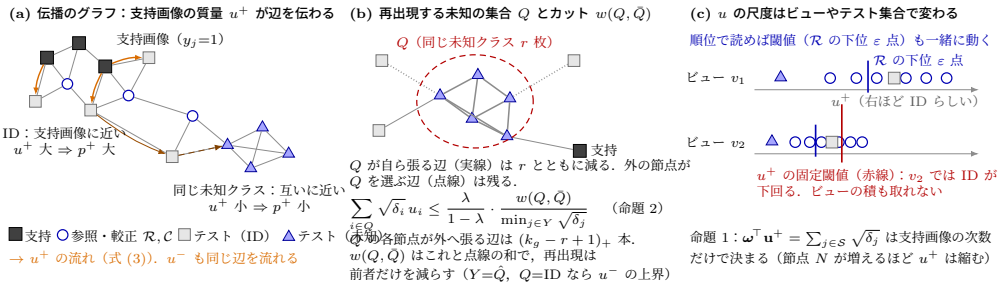


図 A·1　ラベル伝播のグラフ．(a) 節点は支持画像・ラベル付きの参照画像と較正画像・テスト画像で，各節点をコサイン類似度の上位 k_g 個と結ぶ．支持画像に置いた質量 $\mathbf{y}^+$ が辺を伝わり（式 (3)），支持画像に近い ID 画像には多く，互いに近い同じ未知クラスの画像には少ししか届かない．種に置いた質量 $\mathbf{y}^-$ も同じ辺を伝わる．(b) 初期質量を置いた節点を含まない集合 Q に届く質量は，Q と外とを結ぶ辺の重みの和 $w(Q,\bar{Q})$ で上から抑えられる（命題 2）．これには Q の節点が自ら張る辺（実線）と外の節点が Q へ張る辺（点線）が入り，同じ未知クラスが r 枚そろうと前者は減るが後者は残り得る．(c) 質量の総和は支持画像の次数だけで決まるので（命題 1）u の尺度はビューやテスト集合ごとに違うが，ラベル付き画像の u も同じ尺度で動くので，その中での順位で読めば閾値もビューの積も同じ物差しに乗る．

命題 1 の証明（主張は 2.3.4 節）．$\boldsymbol{\omega} = D^{1/2}\mathbf{1}$ について

$$S\boldsymbol{\omega} = D^{-1/2}WD^{-1/2}D^{1/2}\mathbf{1} = D^{-1/2}W\mathbf{1} = D^{-1/2}\boldsymbol{\delta} = \boldsymbol{\omega}$$

であり（$\boldsymbol{\delta} = W\mathbf{1}$ は次数のベクトル），S は対称なので $\boldsymbol{\omega}^\top S = \boldsymbol{\omega}^\top$ である．式 (3) に左から $\boldsymbol{\omega}^\top$ を掛けると

$$\boldsymbol{\omega}^\top\mathbf{u}^{(\ell+1)} = \lambda\,\boldsymbol{\omega}^\top S\,\mathbf{u}^{(\ell)} + (1-\lambda)\,\boldsymbol{\omega}^\top\mathbf{y}^+ = \lambda\,\boldsymbol{\omega}^\top\mathbf{u}^{(\ell)} + (1-\lambda)\,\boldsymbol{\omega}^\top\mathbf{y}^+$$

となり，$\mathbf{u}^{(0)} = \mathbf{0}$ からこの漸化式を解けば

$$\boldsymbol{\omega}^\top\mathbf{u}^{(L)} = (1-\lambda^L)\,\boldsymbol{\omega}^\top\mathbf{y}^+ = (1-\lambda^L)\sum_{j\in\mathcal{S}}\sqrt{\delta_j}$$

を得る．$L\to\infty$ とすれば収束解の式になる．□

命題 2 の証明（主張は 2.3.4 節）．収束解は $\mathbf{u} = \lambda S\mathbf{u} + (1-\lambda)\mathbf{1}_Y$ を満たし，$Q\cap Y = \emptyset$ なので

$$\sqrt{\delta_i}\,u_i = \lambda\sum_j W_{ij}\,\frac{u_j}{\sqrt{\delta_j}} \qquad (i\in Q)$$

である．$U = \sum_{i\in Q}\sqrt{\delta_i}\,u_i$，$\beta = \max_j u_j/\sqrt{\delta_j}$ とおく．$i\in Q$ で足して j が Q の内か外かで分けると，$u_j\ge 0$ と $\sum_{i\in Q}W_{ij}\le\delta_j$ から

$$\begin{aligned} U &= \lambda\sum_{j\in Q}\frac{u_j}{\sqrt{\delta_j}}\sum_{i\in Q}W_{ij} \;+\; \lambda\sum_{i\in Q,\,j\notin Q}W_{ij}\,\frac{u_j}{\sqrt{\delta_j}} \\ &\le \lambda\sum_{j\in Q}\sqrt{\delta_j}\,u_j \;+\; \lambda\,w(Q,\bar{Q})\,\beta \;=\; \lambda U + \lambda\,w(Q,\bar{Q})\,\beta \end{aligned}$$

を得る．式 (4) と同じランダムウォークの表現から

$$\frac{u_j}{\sqrt{\delta_j}} = \mathbb{E}_j\Big[\frac{\mathbf{1}[X_T\in Y]}{\sqrt{\delta_{X_T}}}\Big] \le \frac{1}{\min_{s\in Y}\sqrt{\delta_s}}$$

なので $\beta\le 1/\min_{s\in Y}\sqrt{\delta_s}$ であり，

$$(1-\lambda)\,U \le \lambda\,w(Q,\bar{Q})\,\beta \le \lambda\,\frac{w(Q,\bar{Q})}{\min_{s\in Y}\sqrt{\delta_s}}$$

を $1-\lambda$ で割れば式 (6) を得る．□

命題 4 の証明（主張は 2.5 節）．σ_{ref} をプール $\mathcal{U}=\mathcal{C}\cup\mathcal{T}$ の節点の上の関数とみる．

(1) それを定めるのは，支持画像 $\mathcal{S}$，参照画像 $\mathcal{R}$，および「$\mathcal{U}$ という節点の集合」だけである．グラフと $\mathbf{u}^{+}$ は節点の名札に依らない（2.3 節）．p^{+} は固定した $\mathcal{R}$ との比較なので各画像の u^{+} だけで決まる．種はプールの p^{+} の多重集合から式 (8) の閾値を決めて選ぶので，どの画像が種になるかは $\mathcal{U}$ の画像を対称に扱う．$\mathbf{u}^{-}$ と $\tilde{\mathbf{u}}^{-}=\lambda S\mathbf{u}^{-}$ も同様で，p^{-} は固定した $\mathcal{R}$ との比較である．

(2) したがって σ_{ref} は，$\mathcal{U}$ の中でどの節点を較正画像と呼ぶかを入れ替えても変わらない．これは AdaDetect の条件 (8) である（学習標本を $\mathcal{S}\cup\mathcal{R}$，帰無の較正標本を $\mathcal{C}$，テスト標本を $\mathcal{T}$ としたもの．同論文の証明は学習標本を所与とした置換の議論なので，その中身は問わない）．種の候補に較正画像を含めるのはこの対称性のためで，テスト画像だけから種を選ぶと，較正画像とテスト画像を入れ替えたときに種の集合が変わり得て条件 (8) が崩れる．

(3) 式 (10) の p^{fin} は同論文の経験 p 値 (10) である．よって定理 3.3 から (i) と (ii) の PRDS・超一様性が従い，系 3.5 と系 3.7 が FDR の上界を与える．□

系 1 の証明（主張は 2.3.4 節）．式 (4) のランダムウォーク（各ステップで確率 $1-\lambda$ で止まる）で，Q から初めて外へ出る時刻を τ とする．

式 *(7)* の上界． $Q\cap Y=\emptyset$ なので，$X_T\in Y$ となるには $\tau\le T$ が要る．止まる時刻 T は幾何分布で無記憶だから，強マルコフ性より（$X_\tau\in\partial Q$）

$$\frac{u_i}{\sqrt{\delta_i}}=\mathbb{E}_i\Big[\mathbf{1}[\tau\le T]\,\frac{u_{X_\tau}}{\sqrt{\delta_{X_\tau}}}\Big]\le \Pr_i(\tau\le T)\,\max_{j\in\partial Q}\frac{u_j}{\sqrt{\delta_j}}$$

である．$\pi_i=\Pr_i(\tau\le T)$ とおいて両辺に $\sqrt{\delta_i}$ を掛ければ $u_i\le b_i$ である．

逃げる確率． 最初の 1 歩で場合を分けると

$$\pi_i=\lambda\Big(e_i+\sum_{j\in Q}P_{ij}\,\pi_j\Big)\quad(i\in Q),\qquad\text{すなわち}\qquad\boldsymbol{\pi}=\lambda(I-\lambda P_{QQ})^{-1}\mathbf{e}$$

である（λP_{QQ} のスペクトル半径は 1 未満）．$\pi^{*}=\max_{x\in Q}\pi_x$ とおくと，$\sum_{j\in Q}P_{xj}=1-e_x$ と $e_x\le\bar e_Q$ から

$$\pi^{*}\le\lambda\big(\bar e_Q+(1-\bar e_Q)\,\pi^{*}\big),\qquad\text{すなわち}\qquad\pi^{*}\le\frac{\lambda\,\bar e_Q}{1-\lambda+\lambda\,\bar e_Q}=\psi(\bar e_Q)$$

を満たす．$\bar e_Q=0$ なら $\boldsymbol{\pi}=\mathbf{0}$ なので $u_i^{+}=0$ である．□

系 2 の証明（主張は 2.5 節）．Q は支持画像を含まないので，系 1（$Y=\mathcal{S}$）から $u_v^{+}(y)\le b_v(y)$ である．種の各節点 j では収束解が $u_v^{-}(j)=\lambda(S_vu_v^{-})(j)+(1-\lambda)\ge 1-\lambda$ を満たし，$\mathbf{u}_v^{-}\ge\mathbf{0}$ なので，y が種であってもなくても

$$\tilde u_v^{-}(y)=\lambda\sum_j S_v(y,j)\,u_v^{-}(j)\ge\lambda\sum_{j\in\hat Q_v}\frac{W_v(y,j)}{\sqrt{\delta_v(y)\,\delta_v(j)}}\,(1-\lambda)=c_v(y)$$

である．p_v^{+} は u^{+} について非減少，p_v^{-} は $\tilde u^{-}$ について非増加なので

$$\log p_v^{+}(y)\le\log p_v^{+}[b_v(y)],\qquad\log p_v^{-}(y)\le\log p_v^{-}[c_v(y)]$$

で，ビューで足せば $\sigma_{\mathrm{ref}}(y)\le B(y)$ を得る．p^{fin} は σ_{ref} について非減少なので $p^{\mathrm{fin}}(y)\le\bar p(y)$ である．交差適合した σ（付録 A.2）では，y の折 b に対して他方の折 $\bar b$ の較正画像と種で同じ議論をすれば（y は折 $\bar b$ の種ではない），$\sigma(y)\le B(y)$ と $p^{\mathrm{fin}}(y)\le(1+|\{c\in\mathcal{C}_b:\sigma(c)\le B(y)\}|)/(|\mathcal{C}_b|+1)$ を得る．□

A.2　参照画像による読み出しの登録と結果

交差適合した σ（v18–v21 の読み出し）． ラベル付きの 4 枚（クラスあたり；σ ではすべて較正画像として使う）とテスト画像を，画像とは独立に等確率で 2 つの折 $b\in\{1,2\}$ に分ける（$n_b=|\mathcal{C}_b|=2{,}000$）．折 b の種 $\hat Q_b$ は，$\mathcal{T}_b$ の画像の u^{+} の $\mathcal{C}_b$ の中での順位に式 (8) をかけて選ぶ．折 b の節点 $x\in\mathcal{C}_b\cup\mathcal{T}_b$ は，他方の折 $\bar b$ の較正画像と種で採点し，

$$\sigma(x)=\sum_v\big[\log\tilde p_v^{+}(x)+\log\tilde p_v^{-}(x)\big],\qquad p^{\mathrm{fin}}(x)=\frac{1+|\{x'\in\mathcal{C}_b:\sigma(x')\le\sigma(x)\}|}{n_b+1}$$

とする（$\tilde p_v^{+}$ は u_v^{+} の $\mathcal{C}_{\bar b}$ の中での順位，$\tilde p_v^{-}$ は $u_{\bar b,v}^{-}$ の $\mathcal{C}_{\bar b}$ の中での逆順位）．σ は $\mathcal{C}_b\cup\mathcal{T}_b$ の中の名札の入れ替えに不変なので（$\hat Q_{\bar b}$ と $\mathbf{u}_{\bar b}^{-}$ は折 $\bar b$ の画像から決まる），命題 4 と同じ保証が折ごとに成り立つ．局外関数を一方の標本で推定し他方で評価

する交差適合 [A1] と同じ構造である．付録の他の節の σ もこの読み出しで，折は乱数で決める．

登録． σ_{ref} は，σ の折を参照画像に置き換える読み出しとして，計算の内容・採否の規則・記述的な解析（**表 3** の分解，系 2 と系 A1 の格子での実測，共変量シフト）を登録文書（`experiments/phase17/prereg_p17.json`，SHA-256 `068dd4d9`$\cdots$）に記してから実行した．クラスあたりの 4 枚のうち並びの位置で最初の 2 枚を参照画像，残り 2 枚を較正画像とし（付録 A.18 の h と同じ分割），自由な値はない．登録の前に行ったのは，ImageNet-V2 と ImageNet-R の特徴抽出（スコアなし），動作確認（dev1 の 1 課題での σ の値の再現と σ_{ref} の種の数と $\hat{\pi}_0$，格子の 1 課題での上界の違反の数；σ_{ref} の指標は計算していない），既存の結果の解析（**表 A·3** と折の割り当ての確認）である．登録文書は 2026 年 10 月 11 日 15:21 UTC に計算サーバに置き，公開リポジトリのブランチ `phase12-15-registrations`（コミット `ee565d8`）で公開されたことを 15:25 UTC に確かめてから実行した（15:25–15:39 UTC）．登録した集計スクリプトはファイル名の解釈の誤り（`rep0` の先頭の `r` を r の値と読む）で出力の前に止まったので，その 1 行だけを直したもの（`ana17_fix.py`）で集計した．計算する量は同じで，それ以外の変更と登録からの逸脱はない（`experiments/phase17/prereg_p17_outcome.json`）．

採否と結果．表 A·1 に，採否の規則を当てた dev2，記述的に報告する dev1，ベンチマークでの σ_{ref} と σ を示す．dev2 で規則が成り立ったので σ_{ref} が主構成になり，ベンチマークの値は計算されたとおりに報告している．ベンチマークでは，σ_{ref} は ImageNet-1K の near-OOD で σ より良く（単体-0.24 [-0.34, -0.15]，×TINS -0.28），他の設定では区間が 0 を含む．開発用分割では dev1 の near でも-0.25 [-0.43, -0.07] と良い．

表 A·1 参照画像による読み出し σ_{ref} と交差適合した σ（単体，dev1 と dev2 は 5 通り，ベンチマークは 6 通りの抽出の平均；差は $\sigma_{\mathrm{ref}} - \sigma$，抽出を単位とする対応のある 95% t 区間）．dev2 の 2 行が登録した採否の規則の対象（区間の上端が+0.5 以下）．

	σ（交差適合）		σ_{ref}（本稿）		
設定	AUROC	FPR95	AUROC	FPR95	FPR95 の差 [95%区間]
dev2 near（採否の規則）	97.16	12.92	97.19	12.94	+0.02 [-0.18, +0.21]
dev2 far（採否の規則）	96.56	16.73	96.56	16.65	-0.08 [-0.50, +0.34]
dev1 near	97.08	13.75	97.11	13.50	-0.25 [-0.43, -0.07]
dev1 far	96.70	16.51	96.66	16.51	+0.00 [-0.86, +0.86]
ImageNet-1K near-OOD	97.94	11.50	97.98	11.26	-0.24 [-0.34, -0.15]
ImageNet-1K far-OOD	98.79	5.17	98.81	5.14	-0.03 [-0.08, +0.01]
Four-OOD	98.80	4.56	98.81	4.55	-0.01 [-0.07, +0.04]
ImageNet-200 near-OOD	98.17	9.07	98.22	8.68	-0.39 [-1.06, +0.29]
ImageNet-200 far-OOD	99.35	2.15	99.40	2.06	-0.09 [-0.23, +0.06]
CIFAR-100 near-OOD	99.18	2.90	99.20	2.90	+0.01 [-0.09, +0.10]
CIFAR-100 far-OOD	99.37	2.34	99.37	2.48	+0.14 [-0.69, +0.98]
ImageNet-1K near-OOD ×TINS	98.09	10.50	98.13	10.21	-0.28 [-0.36, -0.20]
ImageNet-1K far-OOD ×TINS	99.05	4.16	99.06	4.14	-0.02 [-0.07, +0.02]
Four-OOD ×TINS	99.09	3.39	99.09	3.39	-0.00 [-0.04, +0.04]

種．表 A·2 に，ベンチマークで σ_{ref} に選ばれた種（登録した記録；ビューごと，6 通りの抽出の平均）を示す．種に混じる ID の割合は 0.22–0.27 と水準 q=0.2 を超え，較正画像も種に選ばれる（SSB-hard では未知がプールの半分を占め，種がプールの 6 割を超える）．

表 A·2 学習画像の較正で σ_{ref} に選ばれた種（ビューごと，6 通りの抽出の平均）．種は種の数，プール%はプール $\mathcal{U} = \mathcal{C} \cup \mathcal{T}$ に占める割合，較正は種になった較正画像の数（2,000 枚中），ID 率は種に混じっていた ID の割合（実測の偽発見割合，水準 q=0.2）．

	DINOv2 L/14				DINOv3 L/16			
データセット	種	プール%	較正	ID 率	種	プール%	較正	ID 率
SSB-hard	60,412	62.9	522	0.216	61,744	64.3	552	0.228
NINCO	7,420	14.0	58	0.241	7,855	14.9	70	0.271
iNaturalist	13,191	23.1	113	0.243	13,515	23.7	124	0.261
Textures	5,995	11.5	47	0.237	6,488	12.4	60	0.272
OpenImage-O	18,511	29.4	153	0.226	19,594	31.2	171	0.250
iNat.（Four-OOD）	13,184	21.3	103	0.243	13,766	22.2	118	0.275
SUN	12,509	20.2	90	0.232	13,268	21.4	109	0.263
Places	10,879	17.5	81	0.234	11,867	19.1	100	0.259
Textures（Four-OOD）	6,369	11.0	44	0.230	6,939	12.0	56	0.270

σ の開発用分割の値が表ごとに違う理由． σ は折の乱数に依存する．**表 A·15**（第 2 段の選択）の σ は，各抽出で 3 通りの TINS の順序ごとに位置で折を割り当てた値の平均（dev1 13.54%／16.60%，dev2 13.09%／17.00%；near／far）で，**表 A·1** と付録 A.18 の**表 A·24** の値は画像の番号順に 1 通りの折を割り当てたもの（dev1 13.75%／16.51%，dev2 12.92%／16.73%）である．同じ抽出で折の割り当てを 4 通り（第 14 段階の 3 通りと番号順の 1 通り）に変えたときの値の範囲は 1 抽出あたり平均 0.64，最大 1.13 ポイント（番号順の値と 3 通りの平均の差は最大 0.98 ポイント）で，表どうしの違いはこの揺れに収まる．付録 A.18.4 の探索の段落の σ（dev1 13.69%／16.74%）は，探索時のコードでのさらに別の割り当ての値である．σ_{ref} は乱数を含まないので，この揺れはない．

A.3 開発用分割とテスト集合の一致

表 A·3 に，σ の第 2 段の 18 候補の開発用分割（dev1，dev2；5 通りの抽出，折は 3 通りの平均）とテスト集合（OpenOOD v1.5 ImageNet-1K，6 通りの抽出）での FPR95 を示す（単体；既存の結果の解析で，登録外）．dev1 と dev2 の順位相関

は near 0.99，far 0.94 と高いが，dev2 とテストでは near 0.64，far 0.61（dev1 とテストでは 0.69，0.50）に下がる．候補の対のうち差の符号が dev2 とテストで一致するのは near 0.74，far 0.69 で，選ばれた統計量 p^+p^- の 6 候補に限ると順位相関は near 0.37，far -0.43 である．静的 p を加えたときの向き（near で悪く far で良い）は再現するが，q の差は開発用分割で数ポイントあっても再現しない（q=0.05 は dev1 の near で q=0.2 より約 4 ポイント悪いが，テストでは良い）．種の規則の差も再現しない．dev1 で選んだ候補（Storey 型，q=0.2，p^+p^-）はテストの near で 18 候補中 10 位，far で 18 位である（dev1 の far で最良の候補はテストの far で 5 位）．dev1 と dev2 はどちらも ImageNet-1K の学習画像から作った分割で far-OOD の画像集合も共通であり，学習画像と検証画像のずれや OpenOOD の OOD 集合の性質を含まない．付録 A.18 の h が dev2 で非劣，テスト集合の ImageNet-1K で単体 2.14–2.44 ポイント，×TINS の near で 8.09 ポイント悪かったのも同じ限界の表れである．

表 A·3 σ の第 2 段の候補の開発用分割とテスト集合での FPR95（単体）．順位はテスト集合での順位（18 候補中）．行は dev1 near の昇順．

	near（FPR95[%]）				far（FPR95[%]）			
候補（σ，dev1 の順）	dev1	dev2	テスト	順位	dev1	dev2	テスト	順位
Storey 型，q=0.2，p^+p^-	13.54	13.09	11.50	10	16.60	17.00	5.17	18
Storey 型，q=0.2，$\min(\cdot)$	13.74	13.21	11.49	9	15.71	16.12	5.17	17
単純 BH，q=0.2，p^+p^-	13.82	13.40	11.00	1	16.79	16.99	4.96	14
単純 BH，q=0.2，$\min(\cdot)$	13.98	13.53	11.01	2	15.80	16.15	4.96	13
Storey 型，q=0.1，p^+p^-	14.60	14.33	11.01	4	18.03	17.75	4.78	11
Storey 型，q=0.1，$\min(\cdot)$	14.72	14.41	11.01	3	16.54	16.32	4.80	12
単純 BH，q=0.1，p^+p^-	15.15	15.22	11.40	7	18.98	17.81	4.70	7
単純 BH，q=0.1，$\min(\cdot)$	15.31	15.32	11.44	8	16.93	16.38	4.71	8
Storey 型，q=0.2，$p^+p^-\times$ 静的 p	16.31	15.30	12.57	13	11.26	11.46	4.48	5
単純 BH，q=0.2，$p^+p^-\times$ 静的 p	16.54	15.58	12.31	12	11.27	11.45	4.39	4
Storey 型，q=0.1，$p^+p^-\times$ 静的 p	17.44	16.46	12.30	11	11.79	11.78	4.30	2
Storey 型，q=0.05，p^+p^-	17.76	18.10	11.32	5	20.62	19.74	4.74	10
単純 BH，q=0.1，$p^+p^-\times$ 静的 p	17.98	17.23	12.96	17	12.08	11.84	4.28	1
Storey 型，q=0.05，$\min(\cdot)$	18.04	18.18	11.37	6	16.82	15.64	4.73	9
単純 BH，q=0.05，p^+p^-	19.71	19.98	12.84	14	19.60	19.47	5.06	16
単純 BH，q=0.05，$\min(\cdot)$	20.01	20.07	12.91	15	16.12	15.45	5.03	15
Storey 型，q=0.05，$p^+p^-\times$ 静的 p	20.97	19.65	12.94	16	12.55	12.50	4.34	3
単純 BH，q=0.05，$p^+p^-\times$ 静的 p	22.97	21.21	14.20	18	12.40	12.47	4.53	6

A.4 二つの因子の詳細

表 3 の因子を OpenOOD のデータセット別に見ると，密度の因子 $\sqrt{\delta}$ だけの AUROC は SSB-hard 40.3%，NINCO 35.7%，iNaturalist 39.6%，Textures 50.8%，OpenImage-O 60.8%で，SSB-hard，NINCO，iNaturalist では未知の方が密，Textures では差がなく，OpenImage-O では ID の方が密である．確率の因子 q だけの FPR95 と積 u^+ の FPR95 は，SSB-hard で 20.62%と 22.50%，NINCO で 3.09%と 2.19%，iNaturalist で 0.36%と 0.18%，Textures で 8.67%と 6.34%，OpenImage-O で 17.04%と 11.57%である．付録 A.18.4 の探索（dev1）では次数だけの AUROC が far-OOD で 80%を超えたが，テスト集合では再現しなかった．密度の因子は単独の手がかりとしてではなく，確率の因子と組んで未知の塊の内側の質量を薄める形で効くと解釈できる．σ の読み出しの順位を $u^{\pm}/\sqrt{\delta}$ で取ると（**表 3** の 4 行目），ImageNet-1K では near でも far でも σ より悪い．

A.5 分離の上界の実測

表 A·4 に，4.3 節の格子の各条件（3 回の平均）で，系 2 の上界から $p^{\mathrm{fin}} \le 0.05$ が言える未知の割合（保証），実際に $p^{\mathrm{fin}} \le 0.05$ の割合（実），σ_{ref} での上界の余裕 $B(y) - \sigma_{\mathrm{ref}}(y)$ の中央値（対数），付録の h の系 A1（定理 A4 の較正画像側の下界 $\ell = \rho\omega$ で読んだ割合（下界），実際の較正画像のスコア s で読んだ割合（実較正），実際に $p \le 0.05$ の割合（実），$\pi_Q/\bar{\phi}$ と較正画像での ℓ/s の中央値）を示す（登録した記述的な計算で，何も選ばない）．上界はすべての未知画像で成り立つ（系 2 の σ_{ref} と σ，系 A1 の $h \le \pi_Q$ と $\pi_Q \le \bar{\phi}$ のいずれも違反 0）．σ_{ref} の系 2 は NINCO の r=30 で実際の検知の約半分を保証し，$r \le 5$ ではほとんど保証しない．SSB-hard の r=50 では保証の割合は未知クラスの数とともに下がる（c=10 で 38%，c=980 で 0.6%）．余裕の中央値は 2.2–13.8 で，緩さの源は，系 1 が出口の質量を最大値で押さえること（b_v）と，種への辺だけを数えて種から 2 歩以上離れた質量を捨てること（c_v）である．h の系 A1 では，較正画像側の下界 ℓ が実際のスコア s の 0.31–0.42 倍（中央値）しかないので，下界で読むと保証される未知は全条件で 0 になり，実際のスコアで読めば最大 45%を保証する．

表 A·4 分離の上界の実測（格子の各条件，3 回の平均；[%]，余裕と比は中央値）．保証：上界だけから $p^{\mathrm{fin}} \le 0.05$（$h$ では $p \le 0.05$）が言える未知の割合，実：実際の割合．

			σ_{ref}（系 2）			σ（系 2）		h（系 A1）				
未知	c	r	保証	実	余裕	保証	実	下界	実較正	実	$\pi/\bar{\phi}$	ℓ/s
NINCO	5	1	0.0	33.3	3.2	0.0	33.3	0.0	0.0	20.0	1.00	0.31
NINCO	5	2	0.0	26.7	3.2	0.0	26.7	0.0	0.0	6.7	1.00	0.31
NINCO	5	5	0.0	28.0	4.0	0.0	28.0	0.0	0.0	36.0	0.97	0.31
NINCO	5	10	22.7	64.0	4.8	26.7	63.3	0.0	4.0	67.3	0.90	0.31
NINCO	5	20	40.3	91.0	5.6	43.3	91.7	0.0	39.2	83.3	0.63	0.31
NINCO	5	30	47.1	87.6	6.0	55.8	90.7	0.0	8.5	70.8	0.79	0.31
NINCO	10	1	0.0	40.0	3.7	0.0	36.7	0.0	0.0	20.0	1.00	0.31
NINCO	10	2	3.3	25.0	3.3	3.3	25.0	0.0	0.0	11.7	1.00	0.31
NINCO	10	5	0.0	33.3	4.1	0.0	32.7	0.0	0.0	33.3	0.97	0.31
NINCO	10	10	17.3	78.7	6.0	24.0	77.0	0.0	15.1	86.1	0.85	0.31
NINCO	10	20	48.5	92.3	7.0	55.7	92.8	0.0	30.6	61.5	0.81	0.31
NINCO	10	30	53.2	98.0	8.5	58.4	98.9	0.0	45.1	83.3	0.72	0.31
NINCO	20	1	5.0	48.3	3.8	5.0	48.3	0.0	0.0	20.0	1.00	0.31
NINCO	20	2	0.0	28.3	3.5	0.0	28.3	0.0	0.0	10.8	1.00	0.31
NINCO	20	5	0.0	41.0	4.1	0.0	39.0	0.0	0.0	45.7	0.97	0.31
NINCO	20	10	10.0	68.3	5.9	14.0	68.2	0.0	9.0	65.5	0.87	0.31
NINCO	20	20	44.2	93.3	7.7	48.8	93.3	0.0	27.3	72.4	0.82	0.31
NINCO	20	30	56.6	97.3	9.0	65.6	97.3	0.0	7.9	69.0	0.82	0.31
NINCO	40	1	5.8	28.3	3.2	5.0	27.5	0.0	0.0	9.2	1.00	0.31
NINCO	40	2	0.8	37.5	3.9	0.8	37.5	0.0	0.0	22.1	1.00	0.31
NINCO	40	5	1.3	40.2	4.2	1.2	39.2	0.0	0.0	39.5	0.96	0.31
NINCO	40	10	14.2	70.9	6.5	18.1	68.5	0.0	6.5	65.8	0.88	0.31
NINCO	40	20	44.5	94.5	9.1	49.8	93.0	0.0	22.3	70.4	0.81	0.31
NINCO	40	30	57.9	97.9	12.1	61.2	98.2	0.0	22.5	65.3	0.80	0.31
NINCO	64	1	3.6	27.6	3.3	3.6	27.1	0.0	0.0	12.5	1.00	0.31
NINCO	64	2	2.9	34.1	3.6	3.1	34.1	0.0	0.0	23.2	1.00	0.31
NINCO	64	5	3.3	44.4	4.4	4.2	44.6	0.0	0.0	46.7	0.97	0.31
NINCO	64	10	17.5	74.8	7.9	21.5	74.1	0.0	9.3	64.4	0.88	0.31
NINCO	64	20	46.2	94.8	11.1	49.7	94.6	0.0	18.6	71.7	0.83	0.31
NINCO	64	30	56.6	98.0	12.6	55.0	98.5	0.0	29.7	74.8	0.76	0.31
SSB-hard	10	1	0.0	10.0	2.2	0.0	10.0	0.0	0.0	0.0	1.00	0.31
SSB-hard	10	2	0.0	18.3	3.0	0.0	18.3	0.0	0.0	5.0	1.00	0.31
SSB-hard	10	5	0.0	24.7	3.8	0.0	24.0	0.0	0.0	22.7	0.96	0.31
SSB-hard	10	10	7.0	44.7	4.1	7.0	44.3	0.0	9.7	43.3	0.89	0.31
SSB-hard	10	20	16.3	56.3	3.9	21.8	57.0	0.0	13.8	48.5	0.88	0.31
SSB-hard	10	50	37.9	89.9	9.9	42.7	90.3	0.0	9.8	53.9	0.82	0.31
SSB-hard	30	1	1.1	37.8	2.9	1.1	36.7	0.0	0.0	15.6	1.00	0.31
SSB-hard	30	2	0.0	22.2	2.8	0.0	21.1	0.0	0.0	12.8	1.00	0.31
SSB-hard	30	5	2.0	24.0	2.8	2.2	23.6	0.0	0.0	26.4	0.97	0.31
SSB-hard	30	10	3.6	44.4	4.4	6.8	44.4	0.0	2.8	47.7	0.92	0.31
SSB-hard	30	20	22.3	57.1	5.8	23.3	59.7	0.0	5.0	40.7	0.89	0.31
SSB-hard	30	50	29.3	86.0	11.1	31.6	86.9	0.0	6.0	46.9	0.84	0.31
SSB-hard	100	1	2.0	23.3	2.5	2.0	23.7	0.0	0.0	11.7	1.00	0.31
SSB-hard	100	2	0.7	20.2	2.6	0.7	19.8	0.0	0.0	13.3	1.00	0.31
SSB-hard	100	5	1.7	29.9	3.3	2.4	29.3	0.0	0.0	28.2	0.97	0.31
SSB-hard	100	10	8.6	50.7	6.4	11.0	53.6	0.0	2.4	31.0	0.93	0.31
SSB-hard	100	20	22.5	70.2	10.1	24.7	71.4	0.0	6.0	35.8	0.90	0.31
SSB-hard	100	50	18.4	84.5	12.3	18.2	84.3	0.0	7.0	41.3	0.81	0.31
SSB-hard	300	1	2.6	26.8	2.4	2.3	26.4	0.0	0.0	15.8	1.00	0.31
SSB-hard	300	2	2.3	30.9	3.0	2.3	30.4	0.0	0.0	24.3	1.00	0.31
SSB-hard	300	5	10.2	46.3	5.8	9.5	45.5	0.0	1.2	33.2	0.96	0.31
SSB-hard	300	10	15.5	61.8	9.6	15.6	61.8	0.0	3.1	33.6	0.93	0.31
SSB-hard	300	20	11.9	74.1	11.6	12.1	74.5	0.0	2.1	25.1	0.89	0.31
SSB-hard	300	50	4.4	84.0	13.5	4.3	83.5	0.0	0.3	3.8	0.78	0.33
SSB-hard	980	1	5.9	32.5	2.8	5.7	32.0	0.0	0.6	24.9	1.00	0.31
SSB-hard	980	2	10.9	47.2	5.5	10.9	46.9	0.0	0.6	34.0	1.00	0.31
SSB-hard	980	5	14.0	61.8	9.5	13.8	61.8	0.0	1.6	30.8	0.96	0.31
SSB-hard	980	10	8.4	71.1	11.4	8.2	71.1	0.0	0.8	14.2	0.93	0.32
SSB-hard	980	20	3.8	78.3	13.2	3.9	77.8	0.0	0.0	0.1	0.86	0.33
SSB-hard	980	50	0.6	81.1	13.8	0.7	79.4	0.0	0.0	0.0	0.88	0.42

A.6 共変量シフトした ID

表 A·5 に 4.5 節の値を示す（登録した記述的な計算；6 通りの抽出の平均，単体，学習画像の較正）．テスト集合は ID の検証画像 45,000 枚，シフトした ID（ImageNet-V2 matched-frequency の 10,000 枚または ImageNet-R の 30,000 枚），OpenOOD の OOD 集合 1 つからなり，ベース検出器のスコアはこれらの画像にないので単体だけを測った．「全体」は ID とシフトした ID の両方を受け入れるときの AUROC と FPR95，「シフト対 OOD」はシフトした ID と OOD だけ，「ID 対 OOD」は同じ実行の ID と OOD だけ，「ID 対シフト」は ID とシフトした ID を見分ける AUROC（大きいほどシフトした ID を未知とみなす）である．σ_{ref} の p^{fin} の α=0.05 での誤警報率は，ID で 0.062 ／ 0.056（V2 ／ R，near-OOD の実行），シフトした ID で 0.073 ／ 0.847 である．ImageNet-R の描画は ID の写真と特徴の分布が離れて互いに近い塊をなすので，伝播では未知と同じ扱いを受ける（種の 41–57%が R）．

表 A·5　共変量シフトした ID を加えたテスト集合（[%]，単体，6 通りの抽出の平均）．

読み出し	OOD = near-OOD（SSB-hard, NINCO）				OOD = far-OOD（iNaturalist, Textures, OpenImage-O）			
	全体	シフト対 OOD	ID 対 OOD	ID 対シフト	全体	シフト対 OOD	ID 対 OOD	ID 対シフト
	AUROC ／ FPR95	AUROC ／ FPR95	FPR95	AUROC	AUROC ／ FPR95	AUROC ／ FPR95	FPR95	AUROC
ID に *ImageNet-V2* を加える（*10,000* 枚）								
σ_{ref}（本稿）	97.87 ／ 11.61	97.66 ／ 12.23	11.46	54.4	98.68 ／ 5.78	98.45 ／ 6.75	5.55	54.6
σ（交差適合）	97.83 ／ 11.80	97.62 ／ 12.58	11.60	54.3	98.65 ／ 5.87	98.43 ／ 6.75	5.63	54.5
p^+ のみ（交差適合）	97.26 ／ 13.13	96.74 ／ 15.31	12.65	55.9	98.18 ／ 7.15	97.75 ／ 8.69	6.78	56.2
静的 p	81.49 ／ 56.50	77.77 ／ 64.48	54.30	56.1	96.17 ／ 17.44	94.73 ／ 24.12	15.88	56.1
kNN	78.21 ／ 61.10	75.76 ／ 66.38	59.51	53.8	95.29 ／ 20.62	94.24 ／ 25.96	19.27	53.8
ID に *ImageNet-R* を加える（*30,000* 枚）								
σ_{ref}（本稿）	84.19 ／ 64.67	64.52 ／ 78.72	14.18	96.8	84.70 ／ 58.82	65.07 ／ 72.85	10.13	98.2
σ（交差適合）	83.72 ／ 65.52	63.47 ／ 78.68	14.59	96.8	84.17 ／ 61.04	63.81 ／ 74.33	10.13	98.2
p^+ のみ（交差適合）	83.07 ／ 62.05	62.45 ／ 69.46	15.45	96.4	84.95 ／ 55.50	65.67 ／ 63.97	9.27	97.5
静的 p	75.85 ／ 66.78	66.16 ／ 74.47	54.30	72.6	94.10 ／ 26.33	90.51 ／ 34.89	15.88	72.6
kNN	73.72 ／ 69.71	66.18 ／ 75.19	59.51	66.5	93.44 ／ 30.05	90.32 ／ 38.12	19.27	66.5

A.7　交差適合した σ の保証の実測と種に混じる ID の割合

本節の値は交差適合した σ のものである（σ_{ref} では交換可能な較正を実行していない；σ_{ref} の値は 4.4 節）．較正画像の取り方の異なる 2 つの設定を示す．

交換可能な較正（検証画像）．較正画像を ID の検証画像からクラスあたり 4 枚取り（残りの検証画像が ID のテスト集合），支持画像は学習画像のままにすると，較正画像と ID のテスト画像は交換可能になる．3 通りの抽出・9 データセットで，ID の誤警報率 $\Pr(p^{\text{fin}} \le \alpha)$ は α=0.01 で 0.009–0.011，0.05 で 0.049–0.054，0.1 で 0.097–0.103，0.2 で 0.197–0.203 とどの水準でも α のまわりに収まり，p^{fin} への BH 法（q=0.2）の偽発見割合は 0.091–0.191 で水準以下，その再現率（未知のうち棄却された割合）は 0.855–0.998 である．種に混じる ID の割合（折ごと，命題 3 の対象）も q=0.2 で 0.193–0.215（Storey 型）である．検知性能は学習画像の較正と変わらない（near-OOD の FPR95 は ×TINS で 10.60%，単体で 11.51%）．命題 4 の保証は実測でも成り立つ．

ベンチマークの較正（学習画像）．同じ量を**表 1** の設定（6 通りの抽出）で測ると，$\Pr(p^{\text{fin}} \le 0.05)$ は 0.052–0.067，BH 法の偽発見割合は 0.101–0.239，種の ID の割合は 0.219–0.281（単純 BH 法では 0.102–0.230）であり，学習画像と検証画像のずれの分だけ水準を超える（**表 A·7**）．ベンチマークの値（**表 1**）はその定めどおり学習画像の較正で報告する．

表 A·6 に，交換可能な較正での p^{fin} の実測の誤警報率と BH 法の偽発見割合をデータセット別に示す．**表 A·7** に，学習画像の較正（6 通りの抽出の平均）で折ごとに選ばれた種の数（2 つの折の平均）と，種に混じっていた ID の割合（実測の偽発見割合）を，Storey 型と単純 BH 法の両方について，データセット別・ビュー別に示す．

表 A·6　交差適合した σ の p^{fin} の保証の実測（交換可能な較正：ID の検証画像からクラスあたり 4 枚を較正画像とし，3 通りの抽出の平均，単体）．ID の誤警報率は $p^{\text{fin}} \le \alpha$ と判定された ID のテスト画像の割合（命題 4(i)：$\le \alpha$），偽発見割合は BH 法（q=0.2）で棄却された画像のうち ID の割合（命題 4(ii)：期待値 ≤ 0.2），再現率は未知のうち棄却された割合．

	ID の誤警報率 $\Pr(p^{\text{fin}} \le \alpha)$				BH 法（q=0.2）	
データセット	α=0.01	0.05	0.1	0.2	偽発見割合	再現率
SSB-hard	0.009	0.051	0.099	0.201	0.091	0.901
NINCO	0.011	0.052	0.100	0.197	0.183	0.983
iNaturalist	0.009	0.049	0.099	0.198	0.158	0.998
Textures	0.011	0.054	0.103	0.202	0.191	0.928
OpenImage-O	0.009	0.051	0.103	0.199	0.147	0.901
iNat. (Four-OOD)	0.009	0.050	0.101	0.203	0.165	0.998
SUN	0.010	0.051	0.097	0.200	0.168	0.981
Places	0.009	0.050	0.099	0.198	0.165	0.855
Textures (Four-OOD)	0.011	0.051	0.102	0.203	0.191	0.915

表 A·7　学習画像の較正で交差適合した σ に選ばれた種（折あたり，6 通りの抽出の平均）．種は種の数，ID 率は種に混じっていた ID の割合（実測の偽発見割合，水準 q=0.2）．

	DINOv2 L/14				DINOv3 L/16			
	Storey 型		単純 BH		Storey 型		単純 BH	
データセット	種	ID 率	種	ID 率	種	ID 率	種	ID 率
SSB-hard	30,383	0.219	23,993	0.102	31,030	0.230	24,227	0.103
NINCO	3,784	0.254	3,597	0.219	3,993	0.281	3,685	0.226
iNaturalist	6,642	0.249	6,197	0.196	6,808	0.266	6,240	0.200
Textures	3,064	0.248	2,892	0.213	3,277	0.278	3,030	0.230
OpenImage-O	9,433	0.235	8,281	0.167	9,932	0.256	8,584	0.174
iNat. (Four-OOD)	6,653	0.250	6,235	0.201	6,895	0.276	6,326	0.211
SUN	6,414	0.249	5,911	0.192	6,668	0.266	6,075	0.199
Places	5,587	0.246	5,071	0.196	5,960	0.260	5,313	0.196
Textures (Four-OOD)	3,325	0.255	3,103	0.214	3,492	0.272	3,253	0.230

A.8　データセット別の値と散布図

表 A·8 と**表 A·9** に**表 1** のデータセット別の値を示す（4.1 節；σ_{ref}）．括弧の行は単体と ×TINS のそれぞれと最良の比較手法との差である．**図 A·2** は**表 1** の全手法の AUROC と FPR95 の散布図である．

表 A·8 OpenOOD v1.5 ImageNet-1K のデータセット別の結果（[%]，AUROC↑ ／ FPR95↓）．記法は**表 1** と同じ．TINS の報告値は原論文の表 8 のとおりで，iNaturalist と Textures は同論文の Four-OOD の表 1 と同じ値が報告されている（**表 A·9**）．

	near-OOD				far-OOD					
	SSB-hard		NINCO		iNaturalist		Textures		OpenImage-O	
手法	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MOODv2 [10]†	85.00	58.10	92.70	38.20	99.60	1.80	94.30	24.70	97.40	13.60
NNGuide [9]†	84.70	54.70	93.70	28.90	99.90	1.80	95.80	17.00	97.70	10.80
RankFeat [A2]†	89.40	47.90	90.00	39.30	96.00	13.00	95.00	25.40	92.40	33.30
SCALE [29]†	77.40	67.70	85.40	51.80	98.00	9.50	97.60	11.90	94.00	28.20
DisCoPatch [11]†	95.80	19.80	94.30	39.00	99.10	3.60	96.40	18.90	94.40	29.70
TINS [7]†	81.38	61.68	83.91	54.09	99.93	0.21	97.83	10.09	92.99	28.68
TINS [7]（実測）	82.22	56.65	80.74	56.09	99.93	0.17	98.11	8.31	93.09	28.20
Salmon Ladder，単体	**96.31**	21.26	**99.66**	**1.26**	99.93	**0.15**	**98.93**	**4.34**	97.57	10.92
最良の比較手法との差	(+0.51)	(-1.46)	(+5.36)	(+27.64)	(+0.00)	(+0.02)	(+0.82)	(+3.97)	(-0.13)	(-0.12)
Salmon Ladder ×TINS	**96.57**★	**19.42**★	**99.68**★	**1.00**★	**99.96**★	**0.10**★	**99.32**★	**2.55**★	**97.89**★	**9.76**★
最良の比較手法との差	(+0.77)	(+0.38)	(+5.38)	(+27.90)	(+0.03)	(+0.07)	(+1.21)	(+5.76)	(+0.19)	(+1.04)

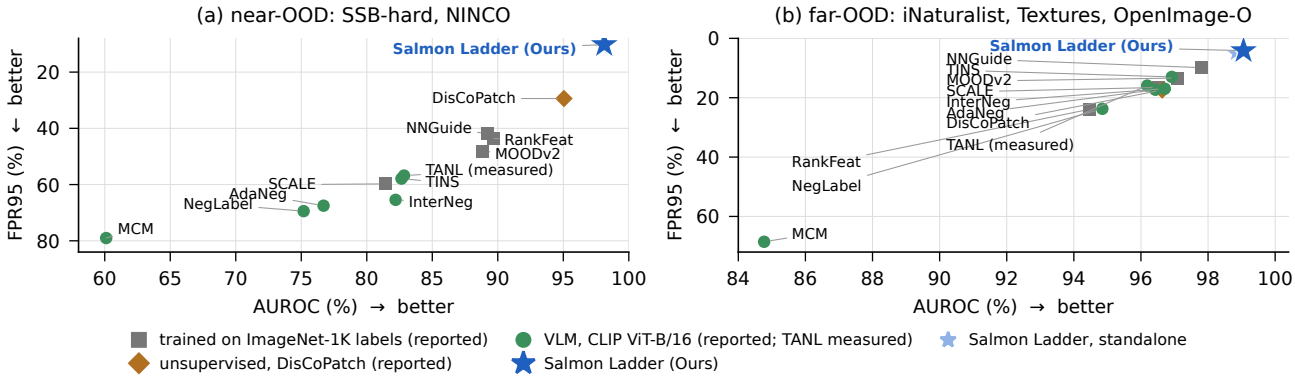


図 A·2 OpenOOD v1.5 ImageNet-1K での AUROC と FPR95（**表 1** と**表 A·8** の比較手法と MCM [2]，右上ほど良い）．大きな星が本稿の構成（σ_{ref}×TINS），小さな星は単体．比較手法は報告値（TANL のみ実測）．

表 A·9 Four-OOD（ImageNet-1K に対する iNaturalist，SUN，Places，Textures，[%]）．比較手法はすべて CLIP ViT-B/16 による報告値 †（TINS は実測も併記）．記法は**表 1** と同じ．

	iNaturalist		SUN		Places		Textures		平均	
手法	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MCM [2]†	94.59	32.20	92.25	38.80	90.31	46.20	86.12	58.50	90.82	43.93
NegLabel [3]†	99.49	1.91	95.49	20.53	91.64	35.59	90.22	43.56	94.21	25.40
CSP [A3]†	99.60	1.54	96.66	13.66	92.90	29.32	93.86	25.52	95.76	17.51
OODD [25]†	99.79	0.85	97.17	12.94	92.51	30.68	94.51	30.67	96.00	18.79
AdaNeg [4]†	99.71	0.59	97.44	9.50	94.55	34.34	94.93	31.27	96.66	18.92
InterNeg [6]†	99.79	0.40	98.68	6.78	95.01	27.11	96.26	21.85	97.43	14.04
TINS [7]†	99.93	0.21	99.14	3.84	97.14	12.73	97.83	10.09	98.51	6.72
TINS [7]（実測）	99.93	0.22	99.12	4.35	97.12	12.98	97.94	9.83	98.52	6.85
Salmon Ladder，単体	99.93	**0.16**	**99.51**	**1.64**	97.06	**11.32**	**98.75**	**5.07**	**98.81**	**4.55**
最良の比較手法との差	(+0.00)	(+0.05)	(+0.37)	(+2.20)	(-0.08)	(+1.41)	(+0.81)	(+4.76)	(+0.29)	(+2.17)
Salmon Ladder ×TINS	**99.96**★	**0.11**★	**99.66**★	**0.98**★	**97.56**★	**9.27**★	**99.19**★	**3.17**★	**99.09**★	**3.39**★
最良の比較手法との差	(+0.03)	(+0.10)	(+0.52)	(+2.86)	(+0.42)	(+3.46)	(+1.25)	(+6.66)	(+0.57)	(+3.33)

A.9 ImageNet-200 と CIFAR-100

表 A·11 と**表 A·10** に 4.6 節の ImageNet-200 と CIFAR-100 の値を示す（σ_{ref} と交差適合した σ の両方）．σ_{ref} の p^{fin} の α=0.05 での誤警報率は，ImageNet-200 で 0.064 ／ 0.069（near ／ far），CIFAR-100 で 0.057 ／ 0.050 である（学習画像の較正）．以下の種と誤警報率の値は σ のものである．CIFAR-100 の ID の誤警報率 $\Pr(p^{\text{fin}} \le 0.05)$ は 0.055（near）／ 0.051（far），BH 法の偽発見割合は 0.105 ／ 0.057 である．CIFAR-100 の 32 × 32 の画像は他と同じ前処理で拡大して入力し，Textures は ImageNet-1K ベンチマークと同じ画像ファイルなので特徴を共有する．CIFAR-100 の種は，Storey 型 q=0.2 で CIFAR-10・Tiny ImageNet では折の 50–64%，MNIST・SVHN・Places365 では 91–100%，Textures では 47% を占め，種に混じる ID の割合は 0.114–0.190 である（DINOv3 L/16 のビュー，2 つの折・6 通りの抽出の平均）．単純 BH 法の種は折の 43–91%，ID の割合 0.022–0.123 である．種に混じる ID の割合は命題 3 どおり q 以下でも，割合 q の種が ID のほぼ全数になって p^- は情報を失う（Places365：σ 8.40%，p^+ だけ 3.99%，単純 BH 法の種で 5.64%，上限付きの種で 5.04%）．ImageNet-200 の SSB-hard では未知が全画像の 84.48%を占めて Storey 型の $\hat{\pi}_0$ が 0.15 になり，水準 $q/\hat{\pi}_0$ が 1 を超えて折の全画像が種になる（単純 BH 法の種は折の 84%，上限付きの種は 75%，ID の割合 0.012）．

表 A·10 OpenOOD v1.5 CIFAR-100 ([%], 単体, 6 通りの抽出の平均). † は OpenOOD v1.5 [8] の報告値 (AUROC は論文の表 2, FPR95 は同論文の脚注 6 が指す公開の表). 全学習画像の kNN・クラス平均は本稿と同じ 2 つの特徴 (L2 正規化して連結), ゼロショットは CLIP ViT-B/16 (4.6 節). 上限付きの種は τ=0.05 の σ (付録 A.16). ★ は列の最良値, 青 は本手法以外の全行 (報告値, 全学習画像・ゼロショットの基線, 静的検出器, LGC-max) を上回る値.

	near-OOD		far-OOD	
手法	AUROC↑	FPR95↓	AUROC↑	FPR95↓
***CIFAR-100* で学習した *ResNet-18* (報告値 †)**				
MSP†	80.27	54.80	77.76	58.70
MLS†	81.05	55.47	79.67	56.73
RMDS†	80.15	55.46	82.92	52.81
VOS†	80.93	55.56	81.32	53.70
G-ODIN†	77.15	67.58	85.67	42.68
RotPred†	76.43	62.58	88.40	34.50
OE† (外れ値データで学習)	88.30	30.73	81.41	54.82
全学習画像 (*50,000* 枚) またはゼロショット (本稿で実測)				
kNN, 全学習画像 (k=50)	97.09	16.35	94.94	32.15
クラス平均, 全学習画像	97.61	12.91	95.38	28.05
MCM [2], ゼロショット	70.30	94.06	74.59	89.10
NegLabel [3], ゼロショット	72.98	76.98	80.25	64.84
凍結特徴, クラスあたり *16* 枚, 学習なし, 単体 (*6* 通りの抽出の平均)				
静的 p (同じ特徴, グラフなし)	96.94	16.49	94.88	29.19
kNN (同じ特徴, グラフなし)	92.35	39.22	88.47	49.80
LGC-max (同じグラフ)	98.80	5.39	99.42	2.21
p^+ のみ (種なし, 参照画像で読む)	**99.11**	**2.87**	**99.59**★	**1.17**★
p^+p^-, 折も参照画像もなし	**99.25**	**2.83**	99.35	2.58
σ (交差適合)	**99.18**	**2.90**	99.37	2.34
σ_{ref} (本稿の構成)	**99.20**	**2.90**	99.37	2.48
σ, 上限付きの種 (Storey 型)	**99.26**★	**2.55**★	**99.59**	**1.46**
σ, 上限付きの種 (単純 BH 法)	**99.26**★	**2.55**★	**99.59**	**1.46**

表 A·11 OpenOOD v1.5 ImageNet-200 ([%], 単体, 6 通りの抽出の平均). † は OpenOOD v1.5 [8] の報告値 (ImageNet-200 で学習した ResNet-18; リーダーボードと同論文の脚注 6 が指す公開の表). 全学習画像の kNN・クラス平均は本稿と同じ 2 つの特徴, ゼロショットは CLIP ViT-B/16 (4.6 節). 上限付きの種は τ=0.05 の σ (付録 A.16). ★ は列の最良値, 青 は本手法以外の全行 (報告値, 全学習画像・ゼロショットの基線, 静的検出器, LGC-max) を上回る値.

	near-OOD		far-OOD	
手法	AUROC↑	FPR95↓	AUROC↑	FPR95↓
***ImageNet-200* で学習した *ResNet-18* (報告値 †)**				
OE† (外れ値データで学習)	84.84	52.30	89.02	34.17
RegMixup + MSP†	84.13	53.78	90.81	33.88
TempScale† (事後手法の最良)	83.69	54.82	90.82	34.00
PixMix + ASH†	81.36	63.51	95.01	21.22
NPOS†	79.40	62.09	94.49	21.76
全学習画像 (*258,951* 枚) またはゼロショット (本稿で実測)				
kNN, 全学習画像 (k=50)	92.09	28.04	98.56	4.40
クラス平均, 全学習画像	92.88	24.69	98.96	3.20
MCM [2], ゼロショット	84.53	57.89	96.85	14.92
NegLabel [3], ゼロショット	86.82	56.16	97.90	10.21
凍結特徴, クラスあたり *16* 枚, 学習なし, 単体 (*6* 通りの抽出の平均)				
静的 p (同じ特徴, グラフなし)	92.25	26.72	98.71	3.71
kNN (同じ特徴, グラフなし)	89.20	38.95	97.84	7.62
LGC-max (同じグラフ)	98.31	7.99	99.41	1.65
p^+ のみ (種なし, 参照画像で読む)	**98.48**★	**7.44**	**99.42**	**1.23**★
p^+p^-, 折も参照画像もなし	98.11	9.26	99.37	2.45
σ (交差適合)	98.17	9.07	99.35	2.15
σ_{ref} (本稿の構成)	98.22	8.68	99.40	2.06
σ, 上限付きの種 (Storey 型)	**98.43**	**6.91**★	**99.49**★	**1.23**
σ, 上限付きの種 (単純 BH 法)	**98.43**	**6.91**★	**99.49**★	**1.23**

A.10 特徴抽出器の族

本節の値は交差適合した σ のものである (σ_{ref} では再計算していない). **表 A·12** に, ImageNet-1K のベンチマークで 6 つの特徴抽出器をそれぞれ単一のビューとして使った値を示す (抽出 1 通り). DINOv2 B/14・L/14, DINOv3 B/16・L/16, DINO (v1) ViT-B/16, CLIP ViT-B/16 の 6 ビューのすべてで, σ は near-OOD の FPR95 が静的 p (6/6), LGC-max (6/6), p^+ だけ (6/6) より低く, 交差適合なしの p^+p^- との差は-0.92–+0.19 ポイントである. たとえば CLIP ViT-B/16 (ベース検出器と同じ重み) では静的 p 93.64%から σ 13.43%へ, DINO (v1) では 80.38%から 26.22%へ下がる. 利得は自己教師あり学習の世代や VLM かどうかに依らず, 特徴空間で ID が支持画像のまわりに集まり未知が互いに近いという性質だけに依る. **CLIP の静的 p について.** CLIP ViT-B/16 の静的 p と kNN は near 93.64%, far 95.38%とほとんど分離しない. 特徴は TINS が使うのと同じ画像埋め込み (投影後, 単位ノルム) であり取り違えではなく, 同じ特徴でゼロショットの MCM は ImageNet-200 で動く (**表 A·11**). CLIP の画像埋め込みは狭い錐に集まり (支持画像の平均のノルムは 0.71, DINO 系では 0.10–0.27), 最も近い原型への余弦は ID で 0.847±0.068, Textures で 0.809±0.043 と平均は分かれるが, ID の下側の裾が Textures の全体を覆うので, ID の 95%を受け入れる閾値では Textures のほぼ全部が通る. 登録

時の仮説「支持画像の平均を引いてから余弦を取れば（中心化）DINO 系の範囲に入る」は否定された（付録 A.17）．中心化で静的 p は near 91.41%，far 78.46%，kNN は near 94.65%，far 88.81%になり，far は 16.96 ポイント改善するが near はほぼ変わらない（**表 A·12** の中心化の列；DINO 系の静的 p の変化は 8.97 ポイント以内）．中心化なしの同じ計算（交差適合なし）は表の静的 p と 0.43 ポイント以内で一致する．グラフは相対的な近傍だけを使うので，同じ特徴でも p^+ と σ はこの影響を受けない． CLIP ViT-B/16 はベース検出器 TINS が使う画像エンコーダと同じ重みで，DINO (v1) [A4] は ImageNet-1K の画像だけで自己教師あり学習した ViT-B/16 である．

表 A·12　6 つの特徴抽出器をそれぞれ単一のビューとした値（FPR95[%]，OpenOOD v1.5 ImageNet-1K，近= near-OOD，遠= far-OOD，抽出 1 通り）．

	静的 p		静的 p，中心化		kNN		kNN，中心化		LGC-max		p^+ のみ		p^+p^-（交差なし）		σ（交差適合）		$\sigma\times$TINS	
ビュー	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠
DINOv2 B/14（768 次元）	61.19	21.44	62.01	22.81	65.12	23.16	65.40	24.90	28.30	13.93	16.02	8.48	15.11	6.71	15.05	6.71	14.44	5.36
DINOv2 L/14（1024 次元）	55.43	20.22	55.94	21.66	59.37	25.81	59.47	27.57	24.56	13.71	14.62	8.77	14.18	7.83	14.18	7.61	13.42	5.33
DINOv3 B/16（768 次元）	76.08	25.38	76.78	28.34	82.67	34.96	83.12	38.70	29.17	13.72	17.65	7.63	14.48	5.67	14.44	5.60	13.88	4.97
DINOv3 L/16（1024 次元）	62.77	19.42	62.80	20.61	69.97	25.69	70.65	28.63	20.46	11.79	13.63	7.22	12.09	6.12	12.28	5.86	11.62	4.36
DINO (v1) ViT-B/16（768 次元）	80.38	40.72	83.33	49.60	86.11	52.80	88.76	63.71	46.45	19.86	30.08	10.20	27.14	8.56	26.22	8.26	24.42	7.01
CLIP ViT-B/16（画像埋め込み）（512 次元）	93.64	95.38	91.41	78.46	95.91	97.41	94.65	88.81	41.12	21.53	16.67	10.38	14.20	7.14	13.43	6.60	13.79	6.07

A.11　到着時採点モード

本節のモードは交差適合した σ で実装した（σ_{ref} では実行していない）．画像がバッチ（256 枚）で順に届く設定では，届いた画像を節点に加えてグラフを厳密な k_g 近傍グラフに保ち，画像の折は到着番号の偶奇で決める（較正画像の折は最初に 1 回決める）．各バッチで，$\mathbf{u}^+$ と各折の $\mathbf{u}_b^-$ をその時点のグラフ上で式 (3) の不動点まで反復し（前のバッチの値を初期値にして反復を減らすが，不動点は初期値に依らない．相対残差 10^{-8} まで平均 117 回），種はその時点までに届いた各折の画像に式 (8) をかけて毎バッチ選び直す．届いたバッチの画像は付録 A.2 の σ のとおり採点し，p^{fin} はその時点の自分の折の較正画像の σ の中での順位で確定して後のバッチで見直さない．到着順がランダムなら，各時点で折 b の較正画像とそれまでに届いた折 b の ID 画像は交換可能なので，命題 4 と同じ保証が各時点の判定に当てはまる．事後採点との違いは，各画像が「それより後に届く画像」を使えないことだけである．

表 A·13 に到着時採点モードのデータセット別の値を示す（本稿の 2 ビュー，Storey 型 q=0.2，折は到着番号の偶奇；OpenOOD は 5 通り，Four-OOD は 3 通りの到着順の平均，抽出は 1 通り）．交差適合なしの到着時採点（v16 までの読み出し）も併記する．このモード（near-OOD の FPR95 は単体 14.80%，×TINS 13.83%）は後に届く画像を使えない分だけ劣るが，報告値の最良は上回る．到着時の p^{fin} の ID の誤警報率 $\Pr(p^{\text{fin}} \le 0.05)$ は近 0.061，遠 0.064，Four-OOD 0.064 である（学習画像の較正）．

表 A·13　到着時採点モードのデータセット別の値（[%]，AUROC ／ FPR95）．

	SSB-hard		NINCO		iNat.		Textures		OImO		iNat.		SUN		Places		Textures	
$\sigma\times$TINS	95.71	23.44	98.98	4.22	99.95★	0.09★	99.10★	3.72★	97.56	11.94	99.95	0.12★	99.58★	1.38★	97.40★	10.04★	98.93★	4.44★
σ，単体	95.48	25.44	99.05	4.15	99.91	0.18	98.64	5.59	97.24	13.12	99.91	0.21	99.42	1.92	96.88	11.76	98.41	6.63
$p^+p^-\times$TINS，交差適合なし	95.79★	22.93★	99.04	3.85★	99.95	0.10	99.08	4.01	97.63★	11.26★	99.95★	0.13	99.57	1.52	97.38	10.14	98.92	4.60
p^+p^-，単体，交差適合なし	95.49	25.32	99.08★	3.87	99.92	0.20	98.61	6.13	97.30	12.61	99.91	0.22	99.41	2.27	96.85	12.27	98.39	7.07

A.12　開発用分割での構成の選択

表 A·14 に第 1 段（ビューと q，交差適合なしの p^+p^-），**表 A·15** に第 2 段（交差適合の種の規則・q・統計量）の，開発用分割 dev1（選択）と dev2（確認）での候補の値を示す（単体，5 通りの抽出の平均；各分割は near と far の 2 つの未知の集合を持つ）．第 2 段では，静的 p を統計量に含める候補は dev1 の far-OOD では最も良いが near-OOD で悪く（16.29%／11.33%），q=0.05 はどの組でも悪い．選ばれた Storey 型・q=0.2・p^+p^- は dev1 near で 13.55%（18 候補中 1 位），dev2 near で 13.01%であり，交差適合なしの参照（dev1 14.10%）より良い．LGC-max は dev1 near で 38.05%である．σ_{ref} はこの選択の後に，選ばれた σ の折を参照画像に置き換えるものとして登録した（付録 A.2）．

表 A·14　第 1 段の候補（ビューと q；[%]，交差適合なしの p^+p^-，単体，5 通りの抽出の平均）．★ は列の最良値．

	dev1（選択）				dev2（確認）			
	near		far		near		far	
構成（p^+p^-，単体）	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
DINOv2 L/14，q=0.05	94.95	21.50	95.29	22.03	94.84	22.59	95.18	23.19
DINOv2 L/14，q=0.1	95.69	18.43	95.36	22.19	95.66	18.40	95.35	22.34
DINOv2 L/14，q=0.2	95.94	19.26	95.68	20.12	96.11	18.12	95.56	20.92
DINOv3 L/16，q=0.05	95.69	20.80	95.59	20.54	95.86	18.71	95.55	20.00
DINOv3 L/16，q=0.1	96.57	16.38	95.87	19.57	96.73	15.52	95.85	18.62
DINOv3 L/16，q=0.2	96.81	16.86	96.28	17.19	96.94	15.65	96.12	17.40
連結ビュー，q=0.05	96.03	17.23	95.96	19.49	95.95	17.82	95.92	19.75
連結ビュー，q=0.1	96.66	15.34	96.09	18.94	96.57	14.62	96.11	18.87
連結ビュー，q=0.2	96.79	15.86	96.45	16.91	96.86	14.48	96.37	17.47
DINOv2 L/14 + DINOv3 L/16，q=0.05	96.34	17.15	96.36	17.84	96.25	17.27	96.32	17.73
DINOv2 L/14 + DINOv3 L/16，q=0.1	96.89	14.59	96.40	18.05	96.91	14.35	96.39	17.60
DINOv2 L/14 + DINOv3 L/16，q=0.2（選択）	97.06	14.10★	96.71	16.43	97.16	13.58	96.57	16.93
連結ビュー + DINOv3 L/16，q=0.05	96.39	17.17	96.17	18.03	96.35	16.46	96.09	18.49
連結ビュー + DINOv3 L/16，q=0.1	96.96	14.44	96.30	17.96	96.98	13.91	96.30	17.42
連結ビュー + DINOv3 L/16，q=0.2	97.10★	14.37	96.68	16.39★	97.18★	13.53★	96.54	16.78
DINOv3 B/16 + L/16，q=0.05	94.73	24.54	95.62	20.93	94.94	22.85	95.58	20.15
DINOv3 B/16 + L/16，q=0.1	95.92	20.30	95.96	19.30	96.03	19.12	95.89	18.89
DINOv3 B/16 + L/16，q=0.2	96.33	19.13	96.37	17.95	96.41	18.50	96.19	17.47
DINOv2 B/14 + L/14，q=0.05	94.80	23.72	95.73	21.20	94.62	23.77	95.72	21.01
DINOv2 B/14 + L/14，q=0.1	95.73	19.74	95.85	20.61	95.59	19.34	95.73	20.75
DINOv2 B/14 + L/14，q=0.2	96.03	19.06	96.15	19.08	96.11	18.11	95.98	19.77
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.05	95.95	19.30	96.30	18.30	95.72	19.52	96.27	18.01
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.1	96.64	16.11	96.40	18.18	96.54	16.38	96.36	17.48
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.2	96.87	15.52	96.74★	16.51	96.89	15.50	96.59★	16.46★

表 A·15　第 2 段の候補（交差適合の種の規則・q・統計量；[%]，p^{fin}，単体，5 通りの抽出の平均，折は 3 通りの割り当ての平均）と参照．★ は列の最良値．

	dev1（選択）				dev2（確認）			
	near		far		near		far	
候補（p^{fin}，単体）	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
Storey 型，q=0.2，p^+p^-（選択）	97.08	13.55	96.66	16.53	97.15	13.01★	96.54	16.97
Storey 型，q=0.2，$p^+p^-\times$ 静的 p	96.68	16.29	97.67★	11.33★	96.73	15.28	97.60★	11.50★
Storey 型，q=0.2，$\min(p^+p^-$，静的 $p)$	97.09	13.74	96.93	15.58	97.16	13.14	96.80	16.03
Storey 型，q=0.1，p^+p^-	96.84	14.59	96.48	17.39	96.84	14.39	96.36	17.69
Storey 型，q=0.1，$p^+p^-\times$ 静的 p	96.41	17.48	97.59	11.56	96.39	16.48	97.52	11.72
Storey 型，q=0.1，$\min(p^+p^-$，静的 $p)$	96.87	14.73	96.82	15.95	96.85	14.52	96.69	16.33
Storey 型，q=0.05，p^+p^-	96.23	17.74	96.40	17.47	96.08	18.16	96.38	17.36
Storey 型，q=0.05，$p^+p^-\times$ 静的 p	95.71	20.92	97.52	11.92	95.62	19.67	97.50	11.81
Storey 型，q=0.05，$\min(p^+p^-$，静的 $p)$	96.25	17.98	96.93	15.30	96.08	18.24	96.90	15.08
単純 BH，q=0.2，p^+p^-	97.03	13.77	96.64	16.65	97.07	13.37	96.52	16.99
単純 BH，q=0.2，$p^+p^-\times$ 静的 p	96.62	16.55	97.66	11.36	96.63	15.62	97.59	11.53
単純 BH，q=0.2，$\min(p^+p^-$，静的 $p)$	97.04	14.00	96.91	15.73	97.07	13.51	96.80	16.10
単純 BH，q=0.1，p^+p^-	96.72	15.19	96.45	17.52	96.65	15.30	96.35	17.72
単純 BH，q=0.1，$p^+p^-\times$ 静的 p	96.27	18.01	97.57	11.72	96.19	17.19	97.52	11.74
単純 BH，q=0.1，$\min(p^+p^-$，静的 $p)$	96.75	15.36	96.80	16.09	96.66	15.43	96.68	16.45
単純 BH，q=0.05，p^+p^-	95.89	19.70	96.43	17.13	95.72	19.95	96.40	17.28
単純 BH，q=0.05，$p^+p^-\times$ 静的 p	95.32	22.93	97.53	11.88	95.28	21.25	97.50	11.84
単純 BH，q=0.05，$\min(p^+p^-$，静的 $p)$	95.90	19.97	97.00	14.77	95.72	19.97	96.94	14.90
参照：p^+p^-，交差適合なし（Storey 型，q=0.2）	97.06	14.10	96.71	16.43	97.16	13.58	96.57	16.93
p^+ のみ	95.65	18.81	96.50	16.46	95.99	17.40	96.44	17.14
静的 p	84.84	58.45	97.12	13.30	85.36	57.77	97.19	13.16
kNN	80.13	68.20	96.00	19.05	79.42	66.82	95.95	19.08
LGC-max	91.80	38.05	94.04	29.53	93.24	32.97	94.32	28.38
選択した構成の σ（順位付けの統計量）	97.10★	13.54★	96.67	16.60	97.17★	13.09	96.54	17.00
選択した構成の $\sigma\times$TINS	97.09	13.80	96.85	15.94	97.12	13.44	96.71	16.44
選択した構成の $p^{\mathrm{fin}}\times$TINS	96.82	14.99	96.73	16.71	96.74	15.07	96.52	17.87

A.13　テスト集合での感度と選択の履歴

表 A·16 に，**表 2** の読み出しの単体での値と，σ の第 2 段の候補（種の規則，q，統計量）の一部のテスト集合での値を示す．テスト集合では単純 BH 法の種が Storey 型よりわずかに良く，q=0.1 が q=0.2 よりわずかに良いが，構成は開発用分割の規則で選んだものを変えない（3 節，付録 A.3）．**表 A·17** に，交差適合なしの p^+p^- について，ビューの組と q とベース検出器のすべての組合せのテスト集合での値（6 通りの抽出の平均）を示す．v16 までの版では，グラフの近傍数，相互近傍グラフ，λ，種の 2 巡目，種への最近傍項，重み，DINOv3 の採用，静的 p との積をテスト集合上で探索し，その上で第 1 段の候補の集合を決めた．本稿の構成はこの表からは選んでおらず（3 節），交差適合に関わる第 2 段の候補と規則，σ_{ref} とその採否の規則はテスト集合の計算前に登録した．探索の記録は `https://github.com/omotes24/SalmonLadder` に残している．

表 A·16　同じ特徴での読み出しの比較（単体）と σ の第 2 段の他の候補の値（[%]，6 通りの抽出の平均）．記法は**表 2** と同じ．

構成	OpenOOD near-OOD AUROC↑	near-OOD FPR95↓	OpenOOD far-OOD AUROC↑	far-OOD FPR95↓	Four-OOD AUROC↑	Four-OOD FPR95↓
同じ特徴での読み出し，単体						
静的 p	82.30	54.36	96.48	15.92	93.77	24.85
kNN [28]	78.75	59.51	95.52	19.27	92.71	28.55
LGC-max	95.69	19.52	97.70	10.13	96.98	11.38
p^+ のみ	97.54	12.36	98.46	6.04	98.26	5.73
p^+p^-，折も参照画像もなし	97.96	11.39	98.80	5.21	98.79	4.69
σ：2 つの折で交差適合した p^+p^-	97.94	11.50	98.79	5.17	98.80	4.56
σ，上限付きの種（Storey 型）	97.78	11.32	98.83	5.00	98.80	4.54
σ，上限付きの種（単純 BH 法）	97.79	11.29	98.84	4.94	98.83	4.43
σ_{ref}：参照画像で種を選び読む p^+p^-	97.98	11.26	98.81	5.14	98.81	4.55
σ_{ref} の較正順位 p^{fin} をそのままスコアにしたもの	97.97	11.26	98.79	5.14	98.80	4.55
p^+p^-，到着時採点，折なし	97.28	14.60	98.61	6.31	98.64	5.46
σ，到着時採点	97.26	14.80	98.60	6.29	98.65	5.13
σ の第 2 段の他の候補（表 A·15），$\times$ *TINS*						
σ（Storey 型，q=0.2）	98.09★	10.50	99.05	4.16	99.09	3.39
σ，種を単純 BH 法で選択	98.03	10.29	99.07	4.03	99.10	3.32
σ に静的 p を加える	97.72	12.16	99.19	3.69	99.00	3.75
$\min(\sigma, \log$ 静的 $p)$	98.06	10.54	99.08	4.14	99.09	3.36
単純 BH 法の種，静的 p を加える	97.63	11.94	99.20★	3.64★	99.01	3.72
σ，q=0.1	98.06	10.26	99.09	3.96	99.12★	3.20
σ，q=0.05	97.87	10.74	99.08	4.03	99.11	3.07★
単純 BH 法の種，q=0.1	97.84	10.82	99.10	3.95	99.12	3.15
p^+p^-，折なし，q=0.1	98.08	10.08★	99.09	4.00	99.11	3.25
p^+p^-，折なし，q=0.05	97.88	10.64	99.09	4.00	99.11	3.09

表 A·17　テスト集合での感度（[%]，交差適合なしの p^+p^-，6 通りの抽出の平均）．★ は列の最良値．

構成（交差適合なしの p^+p^-）	OpenOOD near-OOD AUROC↑	near-OOD FPR95↓	OpenOOD far-OOD AUROC↑	far-OOD FPR95↓	Four-OOD AUROC↑	Four-OOD FPR95↓
DINOv2 L/14，q=0.05，単体	97.36	13.01	98.54	6.04	98.53	5.28
DINOv2 L/14，q=0.05，×TINS	97.43	12.40	98.93	4.80	99.04	3.43
DINOv2 L/14，q=0.1，単体	97.54	12.81	98.50	6.43	98.50	5.74
DINOv2 L/14，q=0.1，×TINS	97.64	11.98	98.94	4.78	99.04	3.64
DINOv2 L/14，q=0.2，単体	97.47	13.69	98.38	7.02	98.37	6.52
DINOv2 L/14，q=0.2，×TINS	97.64	12.55	98.89	4.98	99.00	3.94
DINOv3 L/16，q=0.05，単体	97.72	11.69	98.79	4.91	98.83	4.04
DINOv3 L/16，q=0.05，×TINS	97.72	11.31	99.05	4.11	99.15	2.90★
DINOv3 L/16，q=0.1，単体	97.91	11.06	98.79	5.17	98.83	4.33
DINOv3 L/16，q=0.1，×TINS	97.93	10.56	99.07	4.02	99.17★	3.00
DINOv3 L/16，q=0.2，単体	97.91	11.62	98.71	5.55	98.75	4.88
DINOv3 L/16，q=0.2，×TINS	97.97	10.81	99.04	4.18	99.14	3.19
連結ビュー，q=0.05，単体	97.75	11.34	98.78	4.88	98.76	4.36
連結ビュー，q=0.05，×TINS	97.76	11.06	99.05	4.10	99.12	3.07
連結ビュー，q=0.1，単体	97.90	11.08	98.75	5.27	98.74	4.71
連結ビュー，q=0.1，×TINS	97.93	10.59	99.06	4.08	99.12	3.21
連結ビュー，q=0.2，単体	97.83	11.90	98.65	5.74	98.64	5.39
連結ビュー，q=0.2，×TINS	97.93	11.10	99.02	4.29	99.09	3.46
DINOv2 L/14 + DINOv3 L/16，q=0.05，単体	97.79	11.28	98.90	4.71	98.89	3.96
DINOv2 L/14 + DINOv3 L/16，q=0.05，×TINS	97.88	10.64	99.09	4.00	99.11	3.09
DINOv2 L/14 + DINOv3 L/16，q=0.1，単体	97.97	10.87	98.88	4.84	98.88	4.23
DINOv2 L/14 + DINOv3 L/16，q=0.1，×TINS	98.08	10.08	99.09★	4.00	99.11	3.25
DINOv2 L/14 + DINOv3 L/16，q=0.2，単体	97.96	11.39	98.80	5.21	98.79	4.69
DINOv2 L/14 + DINOv3 L/16，q=0.2，×TINS	98.12	10.26	99.05	4.21	99.07	3.50
連結ビュー + DINOv3 L/16，q=0.05，単体	97.84	11.15	98.88	4.61	98.88	3.93
連結ビュー + DINOv3 L/16，q=0.05，×TINS	97.93	10.45	99.08	3.91★	99.10	3.06
連結ビュー + DINOv3 L/16，q=0.1，単体	98.00	10.65	98.87	4.83	98.87	4.22
連結ビュー + DINOv3 L/16，q=0.1，×TINS	98.12	9.87★	99.08	4.02	99.11	3.23
連結ビュー + DINOv3 L/16，q=0.2，単体	97.97	11.24	98.78	5.18	98.78	4.71
連結ビュー + DINOv3 L/16，q=0.2，×TINS	98.14★	10.10	99.03	4.23	99.07	3.57

A.14　再出現と混入率の格子

表 A·18 と**表 A·19** に，4.3 節の格子の全条件での σ_{ref} の値を，静的 p，p^+ だけ（参照画像で読む），交差適合した σ と並べて示す（FPR95，単体と ×TINS，3 回の平均；種は σ_{ref} の DINOv3 L/16 のビューで選ばれた枚数とそのうち ID の割合（%））．**表 A·20** と**表 A·21** は交差適合した σ の詳細（v18–v21 の表）である．σ と交差適合なしの p^+p^- との FPR95 の差は 60 条件で-4.0–+2.2 ポイントの範囲にある．σ に静的 p を加えると，$r \le 5$ で静的 p に劣る条件は 23 に減り差も最大 14.2 ポイントになるが，64 クラス ×30 枚では 2.5%から 4.1%へ悪化する．c は未知クラスの数，r は各クラスの枚数，混入率は未知の枚数をテスト集合の枚数で割った値．σ の表の検出器の列は AUROC ／ FPR95（DINOv2 L/14 + DINOv3 L/16，ラベル付き画像は本稿の抽出 1 通り，クラスと画像の選び方を変えた 3 回の平均；学習画像の較正）．$\Pr(p^{\text{fin}} \le 0.05)$ は σ の p^{fin} の ID の誤警報率．種は DINOv3 L/16 のビューで Storey 型 q=0.2 のときに選ばれた枚数（2 つの折の合計），ID はそのうち ID だった割合（%），再現は未知のうち種に選ばれた割合（%）．

表 A·18　再出現と混入率の格子：NINCO，σ_{ref}（FPR95[%]）．

c	r	未知	混入率	静的 p	p^{+}（参照）	σ	σ_{ref}	$\sigma_{\mathrm{ref}}\times$TINS	種	ID
5	1	5	0.01	33.3	73.3	73.3	73.3	46.7	0	–
5	2	10	0.02	63.3	76.7	76.7	76.7	53.3	0	–
5	5	25	0.06	46.7	74.7	76.0	74.7	62.7	0	–
5	10	50	0.11	69.3	41.3	40.7	41.3	39.3	0	–
5	20	100	0.22	43.3	10.7	11.7	10.7	12.3	0	–
5	30	150	0.33	34.2	14.7	10.9	14.7	8.7	73	40
10	1	10	0.02	33.3	73.3	73.3	73.3	60.0	0	–
10	2	20	0.04	55.0	78.3	78.3	78.3	51.7	0	–
10	5	50	0.11	52.7	70.7	70.7	70.7	55.3	0	–
10	10	100	0.22	45.7	26.7	28.7	26.7	25.3	0	–
10	20	200	0.44	39.2	10.8	8.8	9.7	8.3	76	39
10	30	300	0.66	35.1	4.9	1.4	2.6	3.1	338	51
20	1	20	0.04	35.0	60.0	60.0	60.0	45.0	0	–
20	2	40	0.09	40.0	78.3	77.5	78.3	58.3	0	–
20	5	100	0.22	45.7	68.0	68.0	68.0	49.7	0	–
20	10	200	0.44	44.5	34.8	36.2	34.8	30.8	0	–
20	20	400	0.88	52.5	11.8	9.0	8.5	7.7	308	45
20	30	600	1.32	45.6	7.0	3.9	3.8	2.2	989	46
40	1	40	0.09	47.5	75.8	75.8	75.8	55.8	0	–
40	2	80	0.18	46.2	70.0	70.8	70.0	52.9	0	–
40	5	200	0.44	46.5	68.2	67.8	68.2	49.3	0	–
40	10	400	0.88	48.9	34.8	35.2	35.2	30.0	35	42
40	20	800	1.75	49.8	12.9	9.8	8.2	7.8	1,029	44
40	30	1,200	2.60	45.1	5.8	2.7	3.2	2.6	1,856	44
64	1	64	0.14	44.3	75.0	75.0	75.0	57.8	0	–
64	2	128	0.28	46.1	72.1	72.4	72.1	54.9	0	–
64	5	320	0.71	46.2	61.5	60.9	61.5	47.8	0	–
64	10	640	1.40	46.9	33.6	30.2	31.0	28.1	119	37
64	20	1,280	2.77	45.5	11.9	7.9	7.7	6.7	1,675	41
64	30	1,920	4.09	46.0	6.8	2.5	3.0	2.3	2,839	40

表 A·19　再出現と混入率の格子：SSB-hard，σ_{ref}（FPR95[%]）．

c	r	未知	混入率	静的 p	p^{+}（参照）	σ	σ_{ref}	$\sigma_{\mathrm{ref}}\times$TINS	種	ID
10	1	10	0.02	66.7	90.0	90.0	90.0	60.0	0	–
10	2	20	0.04	73.3	86.7	86.7	86.7	66.7	0	–
10	5	50	0.11	53.3	82.0	82.0	82.0	52.7	0	–
10	10	100	0.22	63.3	60.3	60.0	60.3	46.0	0	–
10	20	200	0.44	69.8	46.8	45.8	46.8	40.3	0	–
10	50	500	1.10	65.7	18.3	11.5	11.6	10.5	422	39
30	1	30	0.07	55.6	71.1	71.1	71.1	50.0	0	–
30	2	60	0.13	65.0	83.9	82.8	83.9	63.3	0	–
30	5	150	0.33	65.1	78.9	79.1	78.9	67.3	0	–
30	10	300	0.66	58.9	60.4	60.7	60.4	48.4	0	–
30	20	600	1.32	71.0	46.2	43.3	46.1	40.4	154	31
30	50	1,500	3.23	67.3	25.2	16.5	16.8	14.1	1,622	44
100	1	100	0.22	65.0	79.7	80.0	79.7	62.0	0	–
100	2	200	0.44	71.0	83.8	84.0	83.8	66.3	0	–
100	5	500	1.10	70.3	76.4	76.1	76.4	59.5	0	–
100	10	1,000	2.17	68.1	56.4	50.7	52.6	43.2	208	42
100	20	2,000	4.26	66.9	38.5	32.4	34.1	29.9	1,671	45
100	50	5,000	10.00	67.2	24.1	18.5	18.6	17.2	4,972	30
300	1	300	0.66	67.1	78.4	78.6	78.4	61.9	0	–
300	2	600	1.32	64.7	73.5	73.6	73.5	57.9	0	–
300	5	1,500	3.23	64.6	62.0	58.9	57.5	47.4	377	46
300	10	3,000	6.25	66.8	47.9	42.3	42.2	36.7	1,744	38
300	20	6,000	11.76	65.7	34.2	29.7	29.9	27.2	5,583	34
300	50	15,000	25.00	66.9	22.2	19.3	19.5	18.4	17,582	27
980	1	980	2.13	65.9	73.0	73.1	73.0	58.0	0	–
980	2	1,960	4.17	66.1	62.4	56.8	56.6	47.5	391	44
980	5	4,900	9.82	66.6	46.7	43.1	43.0	37.9	3,398	36
980	10	9,800	17.88	66.7	35.4	32.8	32.7	29.9	9,293	31
980	20	19,600	30.34	66.8	27.7	26.2	26.2	24.4	22,559	27
980	50	49,000	52.13	66.6	23.3	22.6	22.3	20.2	65,249	26

表 A·20　再出現と混入率の格子：NINCO，交差適合した σ（[%]）．

c	r	未知	混入率	静的 p	p^+	p^+p^-（交差なし）	σ（交差適合）	σ+静的 p	$\sigma\times$TINS	$\Pr(p^{\mathrm{fin}}\leq 0.05)$	種	ID	再現
5	1	5	0.01	94.2 ／ 33.3	76.6 ／ 73.3	76.7 ／ 73.3	76.6 ／ 73.3	90.0 ／ 40.0	83.7 ／ 46.7	0.065	0	–	0
5	2	10	0.02	83.8 ／ 63.3	78.4 ／ 76.7	78.4 ／ 76.7	78.4 ／ 76.7	83.2 ／ 63.3	81.6 ／ 53.3	0.066	0	–	0
5	5	25	0.06	85.9 ／ 46.7	83.7 ／ 76.0	83.7 ／ 74.7	83.7 ／ 76.0	87.5 ／ 53.3	86.5 ／ 62.7	0.066	0	–	0
5	10	50	0.11	81.4 ／ 69.3	89.6 ／ 40.7	89.4 ／ 41.3	89.5 ／ 40.7	89.2 ／ 44.7	91.4 ／ 40.0	0.066	35	82	13
5	20	100	0.22	89.3 ／ 43.3	97.8 ／ 10.7	98.1 ／ 11.0	97.8 ／ 11.7	96.7 ／ 20.3	97.7 ／ 12.0	0.067	91	71	26
5	30	150	0.33	94.8 ／ 34.2	96.7 ／ 14.4	98.0 ／ 10.4	97.7 ／ 10.9	99.0 ／ 5.6	98.9 ／ 6.7	0.065	189	59	52
10	1	10	0.02	90.5 ／ 33.3	83.4 ／ 73.3	83.4 ／ 73.3	83.4 ／ 73.3	89.8 ／ 43.3	84.9 ／ 60.0	0.066	0	–	0
10	2	20	0.04	84.4 ／ 55.0	80.4 ／ 78.3	80.5 ／ 78.3	80.4 ／ 78.3	86.1 ／ 58.3	84.4 ／ 51.7	0.066	0	–	0
10	5	50	0.11	83.7 ／ 52.7	81.3 ／ 70.7	81.2 ／ 70.7	81.3 ／ 70.7	87.1 ／ 58.0	85.7 ／ 54.7	0.066	0	–	0
10	10	100	0.22	89.4 ／ 45.7	94.4 ／ 26.7	94.2 ／ 27.0	93.8 ／ 28.7	95.0 ／ 25.3	94.5 ／ 29.3	0.066	70	79	15
10	20	200	0.44	92.6 ／ 39.2	97.1 ／ 10.7	98.4 ／ 7.7	98.2 ／ 8.8	98.1 ／ 10.7	98.5 ／ 8.0	0.066	232	54	54
10	30	300	0.66	91.4 ／ 35.1	98.9 ／ 4.9	99.6 ／ 1.0	99.5 ／ 1.4	99.2 ／ 4.0	99.5 ／ 1.8	0.064	436	50	72
20	1	20	0.04	91.4 ／ 35.0	86.5 ／ 60.0	86.5 ／ 60.0	86.5 ／ 60.0	92.6 ／ 41.7	92.1 ／ 43.3	0.067	0	–	0
20	2	40	0.09	90.9 ／ 40.0	81.3 ／ 77.5	81.3 ／ 78.3	81.3 ／ 77.5	90.3 ／ 54.2	86.4 ／ 56.7	0.066	0	–	0
20	5	100	0.22	89.5 ／ 45.7	86.4 ／ 68.0	86.4 ／ 67.3	86.4 ／ 68.0	90.8 ／ 46.0	89.0 ／ 50.0	0.066	0	–	0
20	10	200	0.44	89.0 ／ 44.5	91.8 ／ 34.7	91.5 ／ 35.7	91.6 ／ 36.2	92.4 ／ 34.5	92.7 ／ 31.2	0.067	35	72	5
20	20	400	0.88	87.6 ／ 52.5	97.4 ／ 11.8	98.2 ／ 8.2	98.1 ／ 9.0	97.7 ／ 13.1	98.4 ／ 8.6	0.067	415	46	56
20	30	600	1.32	88.3 ／ 45.6	98.5 ／ 6.9	99.3 ／ 3.4	99.2 ／ 3.9	99.1 ／ 5.1	99.4 ／ 2.3	0.065	955	49	82
40	1	40	0.09	86.8 ／ 47.5	79.6 ／ 75.8	79.6 ／ 75.8	79.6 ／ 75.8	87.0 ／ 53.3	84.4 ／ 55.8	0.067	0	–	0
40	2	80	0.18	88.8 ／ 46.2	84.0 ／ 70.8	84.0 ／ 70.4	84.0 ／ 70.8	89.3 ／ 49.6	86.7 ／ 53.3	0.067	0	–	0
40	5	200	0.44	87.9 ／ 46.5	84.7 ／ 67.8	84.7 ／ 68.0	84.7 ／ 67.8	89.4 ／ 47.2	88.0 ／ 49.0	0.067	0	–	0
40	10	400	0.88	86.9 ／ 48.9	92.9 ／ 34.5	93.6 ／ 34.4	92.9 ／ 35.2	92.9 ／ 32.1	93.4 ／ 32.5	0.066	175	58	18
40	20	800	1.75	87.6 ／ 49.8	96.9 ／ 12.9	98.4 ／ 7.8	98.1 ／ 9.8	97.8 ／ 12.3	98.2 ／ 9.4	0.064	1,081	48	71
40	30	1,200	2.60	88.6 ／ 45.1	98.6 ／ 5.9	99.3 ／ 2.7	99.3 ／ 2.7	99.3 ／ 3.4	99.5 ／ 1.7	0.069	1,766	42	86
64	1	64	0.14	88.0 ／ 44.3	81.6 ／ 75.0	81.6 ／ 75.0	81.6 ／ 75.0	88.2 ／ 53.6	85.4 ／ 57.8	0.067	0	–	0
64	2	128	0.28	87.8 ／ 46.1	82.1 ／ 72.4	82.1 ／ 72.4	82.1 ／ 72.4	88.4 ／ 49.0	85.8 ／ 54.4	0.067	0	–	0
64	5	320	0.71	88.3 ／ 46.2	85.7 ／ 61.6	87.0 ／ 60.2	85.4 ／ 60.9	90.0 ／ 44.2	88.2 ／ 47.4	0.068	33	74	3
64	10	640	1.40	88.1 ／ 46.9	93.2 ／ 33.7	94.5 ／ 29.5	94.5 ／ 30.2	94.2 ／ 29.9	94.8 ／ 27.3	0.064	296	46	25
64	20	1,280	2.77	88.1 ／ 45.5	97.3 ／ 11.7	98.5 ／ 7.7	98.5 ／ 7.9	98.3 ／ 9.6	98.6 ／ 6.5	0.067	1,689	41	77
64	30	1,920	4.09	88.2 ／ 46.0	98.4 ／ 6.7	99.2 ／ 3.1	99.3 ／ 2.5	99.2 ／ 4.1	99.3 ／ 2.2	0.070	2,664	37	88

表 A·21　再出現と混入率の格子：SSB-hard，交差適合した σ（[%]）．

c	r	未知	混入率	静的 p	p^+	p^+p^-（交差なし）	σ（交差適合）	σ+静的 p	$\sigma\times$TINS	$\Pr(p^{\mathrm{fin}}\leq 0.05)$	種	ID	再現
10	1	10	0.02	76.4 ／ 66.7	60.9 ／ 90.0	61.0 ／ 90.0	60.9 ／ 90.0	71.3 ／ 70.0	78.8 ／ 60.0	0.066	0	–	0
10	2	20	0.04	76.9 ／ 73.3	66.1 ／ 86.7	66.1 ／ 86.7	66.1 ／ 86.7	73.6 ／ 80.0	78.0 ／ 66.7	0.065	0	–	0
10	5	50	0.11	83.3 ／ 53.3	73.9 ／ 82.0	73.8 ／ 82.0	73.9 ／ 82.0	81.8 ／ 56.0	86.2 ／ 53.3	0.066	0	–	0
10	10	100	0.22	75.6 ／ 63.3	76.6 ／ 60.0	78.9 ／ 64.0	76.6 ／ 60.0	78.8 ／ 58.3	85.2 ／ 46.7	0.066	0	–	0
10	20	200	0.44	74.5 ／ 69.8	83.0 ／ 46.8	85.3 ／ 44.7	84.9 ／ 45.8	83.1 ／ 50.8	87.6 ／ 39.3	0.065	122	65	22
10	50	500	1.10	73.9 ／ 65.7	94.4 ／ 18.1	98.2 ／ 9.3	97.7 ／ 11.5	96.0 ／ 17.9	98.2 ／ 9.7	0.064	535	49	55
30	1	30	0.07	80.6 ／ 55.6	73.6 ／ 71.1	73.6 ／ 71.1	73.6 ／ 71.1	79.4 ／ 53.3	82.0 ／ 50.0	0.066	0	–	0
30	2	60	0.13	79.3 ／ 65.0	70.1 ／ 82.8	70.1 ／ 82.8	70.1 ／ 82.8	77.1 ／ 65.6	79.8 ／ 63.3	0.066	0	–	0
30	5	150	0.33	75.8 ／ 65.1	68.5 ／ 79.1	68.5 ／ 79.1	68.5 ／ 79.1	74.2 ／ 68.9	77.6 ／ 67.3	0.066	0	–	0
30	10	300	0.66	79.8 ／ 58.9	80.3 ／ 60.3	81.1 ／ 59.9	80.1 ／ 60.7	82.4 ／ 54.1	85.2 ／ 48.6	0.067	72	77	6
30	20	600	1.32	74.9 ／ 71.0	83.8 ／ 46.4	87.9 ／ 42.1	86.0 ／ 43.3	85.1 ／ 48.2	88.4 ／ 38.0	0.065	344	51	28
30	50	1,500	3.23	71.3 ／ 67.3	92.3 ／ 25.1	96.1 ／ 15.6	96.0 ／ 16.5	95.3 ／ 21.6	96.7 ／ 13.8	0.068	1,507	42	58
100	1	100	0.22	75.2 ／ 65.0	68.9 ／ 80.0	68.9 ／ 79.7	68.9 ／ 80.0	74.2 ／ 68.0	80.5 ／ 62.3	0.066	0	–	0
100	2	200	0.44	72.5 ／ 71.0	66.7 ／ 84.0	66.6 ／ 83.8	66.7 ／ 84.0	71.6 ／ 74.2	77.2 ／ 66.7	0.066	0	–	0
100	5	500	1.10	74.8 ／ 70.3	72.9 ／ 75.8	72.9 ／ 76.3	72.6 ／ 76.1	75.8 ／ 69.9	80.3 ／ 60.1	0.066	33	88	1
100	10	1,000	2.17	75.4 ／ 68.1	80.2 ／ 56.5	84.7 ／ 51.3	84.3 ／ 50.7	84.7 ／ 54.1	88.0 ／ 42.9	0.066	404	55	18
100	20	2,000	4.26	74.5 ／ 66.9	87.8 ／ 38.5	91.5 ／ 32.4	91.3 ／ 32.4	90.2 ／ 35.8	92.5 ／ 28.7	0.065	1,597	44	45
100	50	5,000	10.00	75.9 ／ 67.2	93.6 ／ 24.2	96.2 ／ 19.6	96.2 ／ 18.5	95.3 ／ 22.9	96.6 ／ 17.2	0.063	5,132	32	70
300	1	300	0.66	74.9 ／ 67.1	68.9 ／ 78.6	68.8 ／ 78.4	68.9 ／ 78.6	73.8 ／ 68.9	78.0 ／ 62.1	0.066	0	–	0
300	2	600	1.32	75.4 ／ 64.7	71.7 ／ 73.6	71.7 ／ 73.7	71.7 ／ 73.6	75.8 ／ 66.2	80.6 ／ 58.0	0.067	0	–	0
300	5	1,500	3.23	77.1 ／ 64.6	78.2 ／ 62.2	81.7 ／ 57.9	80.9 ／ 58.9	82.3 ／ 56.5	85.4 ／ 48.3	0.067	402	50	13
300	10	3,000	6.25	76.0 ／ 66.8	84.5 ／ 47.9	88.2 ／ 42.3	88.0 ／ 42.3	87.6 ／ 44.4	89.7 ／ 37.1	0.065	1,751	38	36
300	20	6,000	11.76	76.3 ／ 65.7	90.4 ／ 34.2	93.4 ／ 30.3	93.4 ／ 29.7	92.2 ／ 32.0	94.0 ／ 27.3	0.065	5,348	32	60
300	50	15,000	25.00	75.4 ／ 66.9	94.9 ／ 22.1	96.4 ／ 19.4	96.5 ／ 19.3	95.7 ／ 23.2	96.7 ／ 18.2	0.061	18,001	28	86
980	1	980	2.13	75.7 ／ 65.9	73.4 ／ 72.9	73.4 ／ 73.0	73.3 ／ 73.1	76.7 ／ 66.0	81.0 ／ 58.2	0.065	33	85	1
980	2	1,960	4.17	75.4 ／ 66.1	78.2 ／ 62.4	81.6 ／ 57.0	81.5 ／ 56.8	82.3 ／ 55.7	85.3 ／ 47.6	0.064	522	47	14
980	5	4,900	9.82	75.6 ／ 66.6	85.3 ／ 46.7	89.0 ／ 43.2	89.0 ／ 43.1	88.3 ／ 43.2	90.2 ／ 38.0	0.067	3,381	36	44
980	10	9,800	17.88	75.5 ／ 66.7	90.0 ／ 35.5	92.5 ／ 33.1	92.5 ／ 32.8	91.5 ／ 34.2	93.1 ／ 29.7	0.065	9,400	31	66
980	20	19,600	30.34	75.4 ／ 66.8	93.4 ／ 27.8	94.8 ／ 26.1	94.8 ／ 26.2	93.9 ／ 28.4	95.1 ／ 24.3	0.064	22,780	27	85
980	50	49,000	52.13	75.4 ／ 66.6	95.6 ／ 23.4	96.1 ／ 22.5	96.1 ／ 22.6	95.5 ／ 25.1	96.4 ／ 20.8	0.056	64,430	25	98

A.15　近傍数 k_g を変えた格子

図 A·3 に，同じ格子の NINCO（c=64）と SSB-hard（c=980）で，グラフの近傍数を $k_g \in \{3,5,10,20,40\}$ と変えた値を示す（交差適合した σ，単体，本稿の抽出 1 通り，3 回の平均；1 つのテスト集合につき上位 40 個の近傍リストを 1 回作り，全 k_g を同じリストで評価）．k_g が大きいほど再出現の少ない側で良く（NINCO 64 クラス ×1 枚：k_g=40 で 39.6%，k_g=10 で 75.0%），多い側で悪い（×30 枚：15.9%と 2.5%）．登録時の仮説「小さい k_g ほど小さい r で静的 p を下回る」は否定され（付録 A.17），k_g=10 は最大の r で NINCO の最良，SSB-hard で最良との差 0.3 ポイントである．

k_g を変えても較正順位の仕組みは同じで，変わるのはグラフの密さだけである．NINCO（a）では，k_g=40 の σ は r=1 から静的 p を下回る（39.6%対 44.3%）が r=30 でも 15.9%にとどまり，k_g=3 は r=1 で 91.1%と最も悪いが r=30 で 6.5%まで下がる．σ が静的 p を初めて下回る r は $k_g \in \{3,5,10,20\}$ で 10，k_g=40 で 1 である．SSB-hard（b）では $k_g \geq 20$ は r=1 から，$k_g \leq 10$ は r=2 から静的 p を下回り，r=50 では k_g=5（22.3%）と 10（22.6%）が最も良く，k_g=40 は 28.3%である．p^+ だけ（破線）も同じ順に並び，種の利得（実線と破線の差）は $r \geq 10$ で現れ，k_g=40 では小さい．密なグラフでは再出現する未知の塊の内側の辺の割合が下がり，塊が孤立しにくい（命題 2 のカット条件）と解釈できる．登録時の仮説 H5（付録 A.17）の前半（小さい k_g ほど小さい r で静的 p を下回る）は否定され，後半（大きい r での最良は $k_g \in \{10,20\}$）は $\{5,10\}$ として部分的に成り立つ．本稿の k_g=10 は登録どおり変えない．

系 1 の実測． 同じ格子（1 回目の反復，ラベル付き画像 4,000 枚，交差適合なし，DINOv3 L/16 のビュー）の各未知ク

ラス Q について，π_i，式 (7) の b_i，実際の p^+（ラベル付き画像 4,000 枚での順位）を計算した（**表 A·22**；登録外の記述的な計算で，何も選ばない）．$u_i \le b_i$ はクラス × ビュー × 条件の全 62640 組で成り立つ（u_i/b_i の最大は 1.0000005 で，$|\partial Q| = 1$ のときの等号が数値誤差の範囲で表れたもの）．NINCO 64 クラス ×30 枚では，逃げる確率 π の中央値は k_g=3 の 0.27 から k_g=40 の 0.75 へ増え，系 1 だけから $p^+ \le 0.05$ が言える未知の割合は 50%から 0%に下がる（実際に $p^+ \le 0.05$ の割合は 88–93%）．SSB-hard では π の中央値が 0.81 以上で（兄弟クラスの未知は ID 側へ辺を多く張る），系 1 は多くを言わない．系 1 が効くのは疎なグラフで未知が多数回再出現する条件であり，$r \le 2$（$\bar{e}_Q = 1$）では何も言わない．k_g とともに π が増える向きは，密なグラフが再出現の多い側で不利になる実測と一致する．緩さの源は，出口の節点の質量を最大で押さえることと，閉じた形 $\psi(\bar{e}_Q)$ がクラスで最も漏れる節点で決まることである（ψ で $p^+ \le 0.05$ が言える割合は k_g=3，r=30 で 16%）．系 1 に種からの下界を加えた系 2 の実測は付録 A.5 にある．

表 A·22　系 1 の実測（1 回目の反復，DINOv3 L/16，ラベル付き画像 4,000 枚）．π は逃げる確率の中央値（クラスの中央値のさらに中央値），「実」は実際に $p^+ \le 0.05$ となった未知の割合（%），「系」は系 1 の上界だけから $p^+ \le 0.05$ が言える割合（%）．

		k_g=3			k_g=5			k_g=10			k_g=20			k_g=40		
	r	π	実	系	π	実	系	π	実	系	π	実	系	π	実	系
NINCO	10	0.50	69	35	0.61	75	32	0.74	69	7	0.83	57	0	0.87	54	0
NINCO	20	0.35	83	45	0.43	86	42	0.53	86	25	0.69	83	7	0.82	61	0
NINCO	30	0.27	88	50	0.33	92	45	0.42	93	30	0.53	93	18	0.75	80	0
SSB-hard	10	0.86	60	17	0.87	63	12	0.87	67	7	0.88	66	3	0.89	63	1
SSB-hard	20	0.85	69	13	0.85	73	11	0.86	74	7	0.87	73	3	0.88	68	0
SSB-hard	50	0.81	74	10	0.82	78	8	0.84	79	6	0.85	76	2	0.86	72	0

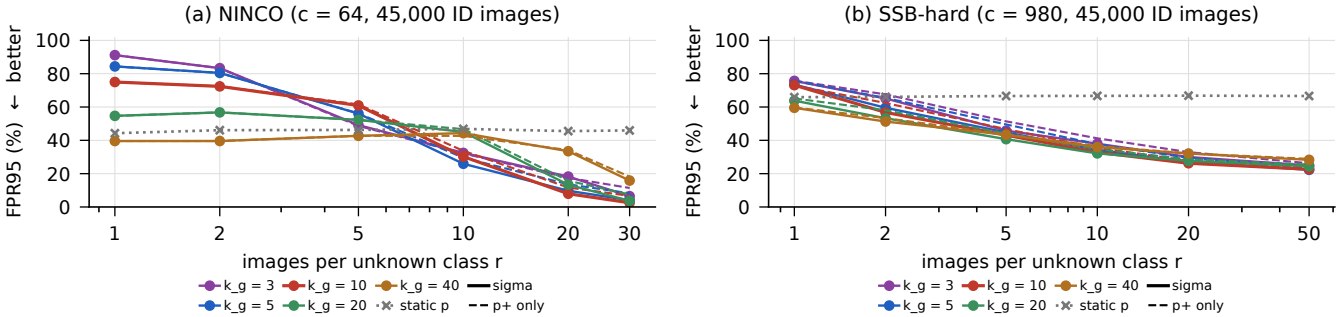


図 A·3　近傍数 k_g を変えた再出現の格子（FPR95，交差適合した σ，単体，DINOv2 L/14 + DINOv3 L/16）．実線は σ，破線は p^+ だけ，灰色の点線は静的 p（k_g に依らない）．

A.16　種の上限 τ

命題 3 が抑えるのは種に混じる ID の**割合**であり，未知が大半を占めるテスト集合では割合 q の種が ID のほぼ全数になる（4.6 節）．そこで，step-up の臨界値を $c_i = \min(q\,i/m, \tau)$（Storey 型では $q/\hat{\pi}_0$）に置き換えた規則も用意した．棄却された p はすべて τ 以下なので種に混じる ID の**数**の期待値は τm_0 以下であり，単純 BH 法では $p \le q\,i^*/m$（i^* は棄却数）も満たすので，PRDS のもとで自己整合な手続きとして FDR$\le q\,m_0/m$ が保たれる [A5]．τ=0.05 は選ばずに固定した．この規則（τ=0.05，q=0.2）は交差適合した σ について実行前に登録し，上限なしと同じ実行の中で評価した（付録 A.17）．σ_{ref} との組合せは評価していない．

ImageNet-1K では変わらない．上限が効くのは Storey 型の閾値が τ を超える SSB-hard と OpenImage-O（iNaturalist ではわずか）で，SSB-hard では種が折の 66.02%から 42.88%に減り，種に混じる ID の割合は 0.230 から 0.060 になる．near-OOD の FPR95 は単体で 11.32%（上限なし 11.50%，対応のある差-0.18），×TINS で 10.69%（+0.19），far-OOD と Four-OOD の単体は 5.00%，4.54%で，いずれも上限なしと 0.25 ポイント以内である．

混入率が高いベンチマークでは害がほぼ消える．ImageNet-200 の near-OOD では FPR95 が 9.07%から 6.91%へ下がり（差-2.16 [-2.79, -1.53]），交差適合した p^+ だけ（7.45%）より 0.53 ポイント低い（[-0.64, -0.43]）．far-OOD は 1.23%で交差適合した p^+ だけ（1.25%）と並ぶ．CIFAR-100 では near-OOD が 2.90%から 2.55%（交差適合した p^+ だけ 2.88%），far-OOD が 2.34%から 1.46%になり，交差適合した p^+ だけ（1.22%）との差は+1.11 から+0.24 [0.14, 0.33] ポイントに縮む．4.3 節の格子の 60 条件でも，上限付きの規則が p^+ だけより 1 ポイント以上悪い条件は混入率 30%以上の 2 条件で 0，$r \ge 10$・混入率 30%未満の 28 条件では上限なしとの差が最大 0.3 ポイントと利得を保つ．

位置づけ．v18–v21 では，上限付きの種が ImageNet-1K で上限なしと変わらず，混入率の高いベンチマークで p^+ だけと同等以上になることから，混入率が未知の運用に上限付きを推していた．σ_{ref} と上限の組合せは評価していないので，本稿の推奨は結論のとおりとし，上限付きの規則は σ で登録した変種として報告する．以下の格子の値も σ のものである．

表 A·23 に，上限付きの規則を 4.3 節の格子の全条件で評価した FPR95 を示す（交差適合した σ，単体，3 回の平均）．

混入率が低い条件では Storey 型の閾値が τ に達せず，上限付きと上限なしの値は一致する．混入率 30%以上の 2 条件（SSB-hard 980 クラス ×20，50 枚）では上限付きの Storey 型は p^+ だけより 1.2–1.7 ポイント良く，980 クラス ×50 枚では種に混じる ID の割合が 0.255 から 0.066 に下がる．全 60 条件で上限付きの Storey 型が p^+ だけより 1 ポイント以上悪いのは 2 条件（NINCO c=10, 20 の r=10；上限なしも同じ値）で，そこでは種が数十枚しか選ばれず，その 79.1%が ID である（未知がごく少なく $\hat{\pi}_0$ が小さく出る条件；単純 BH 法は種を選ばない）．単純 BH 法は上限の有無に依らず全条件で p^+ だけより最大 0.2 ポイントしか悪くならない．登録時の仮説 H3（付録 A.17：混入率 30%以上で p^+ だけより 1 ポイント以上悪くならず，$r \geq 10$・混入率 30%未満で上限なしの利得を 1 ポイント以内に保つ）は，後者の 28 条件での差が最大 0.3 ポイントであり，成り立つ．

表 A·23 種の上限 τ=0.05 の規則の格子（FPR95[%]，交差適合した σ，単体，3 回の平均）．Storey 型・単純 BH 法はそれぞれ上限なし／あり．種は DINOv3 L/16 のビューで上限付き Storey 型に選ばれた枚数（2 つの折の合計）とそのうち ID の割合（%）．

			Storey 型		単純 BH 法				種（上限付き Storey 型）	
c	r	混入率	上限なし	τ=0.05	上限なし	τ=0.05	p^+ のみ	静的 p	枚数	ID
NINCO										
5	1	0.0	73.3	73.3	73.3	73.3	73.3	33.3	0	–
5	2	0.0	76.7	76.7	76.7	76.7	76.7	63.3	0	–
5	5	0.1	76.0	76.0	76.0	76.0	76.0	46.7	0	–
5	10	0.1	40.7	40.7	40.7	40.7	40.7	69.3	35	81.9
5	20	0.2	11.7	11.7	9.7	9.7	10.7	43.3	91	71.2
5	30	0.3	10.9	10.9	12.0	12.0	14.4	34.2	189	58.8
10	1	0.0	73.3	73.3	73.3	73.3	73.3	33.3	0	–
10	2	0.0	78.3	78.3	78.3	78.3	78.3	55.0	0	–
10	5	0.1	70.7	70.7	70.7	70.7	70.7	52.7	0	–
10	10	0.2	28.7	28.7	26.7	26.7	26.7	45.7	70	79.1
10	20	0.4	8.8	8.8	10.0	10.0	10.7	39.2	232	53.8
10	30	0.7	1.4	1.4	2.0	2.0	4.9	35.1	436	50.3
20	1	0.0	60.0	60.0	60.0	60.0	60.0	35.0	0	–
20	2	0.1	77.5	77.5	77.5	77.5	77.5	40.0	0	–
20	5	0.2	68.0	68.0	68.0	68.0	68.0	45.7	0	–
20	10	0.4	36.2	36.2	34.7	34.7	34.7	44.5	35	71.7
20	20	0.9	9.0	9.0	8.5	8.5	11.8	52.5	415	46.1
20	30	1.3	3.9	3.9	4.3	4.3	6.9	45.6	955	48.8
40	1	0.1	75.8	75.8	75.8	75.8	75.8	47.5	0	–
40	2	0.2	70.8	70.8	70.8	70.8	70.8	46.2	0	–
40	5	0.4	67.8	67.8	67.8	67.8	67.8	46.5	0	–
40	10	0.9	35.2	35.2	34.5	34.5	34.5	48.9	175	58.5
40	20	1.7	9.8	9.8	10.2	10.2	12.9	49.8	1081	47.5
40	30	2.6	2.7	2.7	3.2	3.2	5.9	45.1	1766	41.5
64	1	0.1	75.0	75.0	75.0	75.0	75.0	44.3	0	–
64	2	0.3	72.4	72.4	72.4	72.4	72.4	46.1	0	–
64	5	0.7	60.9	60.9	61.6	61.6	61.6	46.2	33	74.5
64	10	1.4	30.2	30.2	30.5	30.5	33.7	46.9	296	46.2
64	20	2.8	7.9	7.9	7.7	7.7	11.7	45.5	1689	41.5
64	30	4.1	2.5	2.5	2.9	2.9	6.7	46.0	2664	36.6
SSB-hard										
10	1	0.0	90.0	90.0	90.0	90.0	90.0	66.7	0	–
10	2	0.0	86.7	86.7	86.7	86.7	86.7	73.3	0	–
10	5	0.1	82.0	82.0	82.0	82.0	82.0	53.3	0	–
10	10	0.2	60.0	60.0	60.0	60.0	60.0	63.3	0	–
10	20	0.4	45.8	45.8	47.0	47.0	46.8	69.8	122	64.8
10	50	1.1	11.5	11.5	11.1	11.1	18.1	65.7	535	48.5
30	1	0.1	71.1	71.1	71.1	71.1	71.1	55.6	0	–
30	2	0.1	82.8	82.8	82.8	82.8	82.8	65.0	0	–
30	5	0.3	79.1	79.1	79.1	79.1	79.1	65.1	0	–
30	10	0.7	60.7	60.7	60.3	60.3	60.3	58.9	72	77.0
30	20	1.3	43.3	43.3	43.5	43.5	46.4	71.0	344	51.4
30	50	3.2	16.5	16.5	16.3	16.3	25.1	67.3	1507	41.9
100	1	0.2	80.0	80.0	80.0	80.0	80.0	65.0	0	–
100	2	0.4	84.0	84.0	84.0	84.0	84.0	71.0	0	–
100	5	1.1	76.1	76.1	75.8	75.8	75.8	70.3	33	87.9
100	10	2.2	50.7	50.7	51.5	51.5	56.5	68.1	404	55.2
100	20	4.3	32.4	32.4	33.3	33.3	38.5	66.9	1597	44.2
100	50	10	18.5	18.5	18.7	18.7	24.2	67.2	5132	31.6
300	1	0.7	78.6	78.6	78.6	78.6	78.6	67.1	0	–
300	2	1.3	73.6	73.6	73.6	73.6	73.6	64.7	0	–
300	5	3.2	58.9	58.9	58.7	58.7	62.2	64.6	402	49.7
300	10	6.2	42.3	42.3	42.8	42.8	47.9	66.8	1751	38.0
300	20	12	29.7	29.7	29.9	29.9	34.2	65.7	5348	32.2
300	50	25	19.3	19.6	19.6	19.6	22.1	66.9	14736	19.1
980	1	2.1	73.1	73.1	72.9	72.9	72.9	65.9	33	84.7
980	2	4.2	56.8	56.8	56.5	56.5	62.4	66.1	522	47.5
980	5	9.8	43.1	43.1	42.7	42.7	46.7	66.6	3381	36.1
980	10	18	32.8	32.8	32.6	32.6	35.5	66.7	9372	31.0
980	20	30	26.2	26.1	26.1	26.1	27.8	66.8	17485	16.7
980	50	52	22.6	22.2	21.5	22.2	23.4	66.6	40958	6.6

A.17 追加実験の事前登録と仮説の判定

付録 A.16 の上限付きの種，4.6 節の全学習画像・ゼロショットの基線，付録 A.15 の k_g の格子，付録 A.10 の中心化は，1 つの登録文書（公開リポジトリの `experiments/phase15/prereg_p15.json`，SHA-256 `83ea4061`$\cdots$）に計算の内容・報告の形・6 つの仮説を記してから実行した．登録文書は評価の実行前に公開リポジトリのブランチ `phase12-15-registrations`（コミット `8ef9c8d`）に置いた（学習画像の特徴抽出だけはその前に始めた）．構成の選択は行わず（τ と q は固定，主構成

は変えない），登録からの逸脱はない．系 1 の実測（付録 A.15）は査読後に加えた登録外の記述的な計算で，選択を含まない．判定は次のとおりである（いずれも交差適合した σ についての仮説）．

- **H1**（上限は害を消す：CIFAR-100 far-OOD と ImageNet-200 near-OOD で上限付きの規則は p^+ だけの+0.5 ポイント以内）：成立（+0.24，-0.53 ポイント）．
- **H2**（上限は ImageNet-1K near-OOD で上限なしの 0.5 ポイント以内）：成立（単体-0.18，×TINS +0.19 ポイント）．
- **H3**（格子：混入率 30%以上で p^+ だけより 1 ポイント以上悪くならず，$r \geq 10$・混入率 30%未満で上限なしの利得を 1 ポイント以内に保つ）：成立（付録 A.16）．
- **H4**（全学習画像の kNN（k=50）は両ベンチマークで 16 枚の静的 p より良く，ImageNet-200 の near-OOD では σ が kNN より低い FPR95 を保つ）：前半は否定（ImageNet-200 で kNN 28.04%／ 4.40%対静的 p 26.72%／ 3.71%，CIFAR-100 の far-OOD で 32.15%対 29.19%；CIFAR-100 の near-OOD だけ 16.35%対 16.49%），後半は成立（9.07%対 28.04%）．
- **H5**（σ が静的 p を下回る r は k_g が小さいほど小さく，大きい r での利得は $k_g \in \{10, 20\}$ で最大）：前半は否定，後半は $\{5, 10\}$ として部分的に成立（付録 A.15）．
- **H6**（中心化で CLIP の静的 p は DINO 系の範囲（near 70%未満，far 40%未満）に入り，DINO 系の変化は 10 ポイント以内）：前半は否定（near 91.41%，far 78.46%），後半は静的 p で成立（最大 8.97 ポイント），kNN では DINO (v1) の far-OOD で 10.92 ポイント動く．

一つの量の変種（付録 A.18）． 開発用分割 dev1 だけで 95 通りの構成を探索した後，構成，ベース検出器との積の形を選ぶ規則，dev2 での 3 つの仮説，採否の規則を登録文書（`experiments/phase16/prereg_p16.json`，SHA-256 `2e16ae0c`$\cdots$）に記し，公開リポジトリのブランチ `phase12-15-registrations`（コミット `6bbae3d`）で公開されたことを確かめてから実行した（2026 年 10 月 11 日 12:56 UTC）．H1–H3 は dev2 ですべて成立し，登録した規則では h が主構成になる．しかしテスト集合では σ に劣ったため（**表 A·24**），σ を主構成のまま h を変種として報告した（v19–v21）．これは登録からの逸脱であり，判断はテスト集合の値を見た後に行った（「結果が良ければ本文，悪ければ付録」とすることは実行前に決めていたが，登録文書には書いていない）．採否の規則は点推定（dev2 の差が+0.5 以下）で定めていた．dev2 の差の区間の上端は+0.89，+1.54 で，上端で判定していれば h は採用されず，この逸脱は生じなかった．修正記録は `experiments/phase16/prereg_p16_amendments.json` にある．

参照画像による読み出し（付録 A.2）． σ_{ref}，その採否の規則（区間の上端による），記述的な解析を登録文書（`experiments/phase17/prereg_p17.json`）に記し，公開を確かめてから実行した．規則は dev2 で成り立ち，σ_{ref} を主構成にした．登録からの逸脱はない．

A.18 一つの量としての読み出し（登録した変種）

v18–v21 の読み出し σ（付録 A.2）は，支持画像と種からの 2 本の伝播の較正順位を掛け，2 つの折で交差適合したものである．これを一つの量「画像から出たランダムウォークは支持画像と種のどちらに先に着くか」に置き換える読み出し h を，開発用分割 dev1 での探索の後に登録し，dev2 で確認し，テスト集合で構成を凍結したまま評価した（付録 A.17）．dev2 では登録した仮説がすべて成立したが，ベンチマークでは σ に及ばなかった（**表 A·24**）．参照画像で種を選び折を使わない仕組みは h から取り出して σ_{ref} に使った（2.5 節）．

A.18.1 定義

支持画像 $\mathcal{S}$，参照画像 $\mathcal{R}$，較正画像 $\mathcal{C}$，テスト画像 $\mathcal{T}$ のすべてを節点とする．ビュー v ごとに，各節点からコサイン類似度の上位 k_g=10 の節点へ重み

$$a_{ij}^{v} = \max\left(f_v(x_i)^{\top} f_v(x_j),\, 0\right)$$

の辺を張って $W_v = \max(A_v, A_v^{\top})$ とし，それぞれの次数の中央値で割って足した

$$W = \sum_{v} \frac{W_v}{\mathrm{med}_i\, \delta_i^{v}}$$

を 1 つのグラフとする（δ_i^{v} は W_v での節点 i の次数）．次数を $\delta_i = \sum_j W_{ij}$，$D = \mathrm{diag}(\delta_i)$，遷移確率を $P = D^{-1}W$ と書く．$\mathcal{R}$，$\mathcal{C}$，$\mathcal{T}$ はすべてラベルのない節点として同じ扱いを受け，グラフは節点の名札に依らない．

このグラフの上で，節点 i に平均 $1/\delta_i$ の指数時間とどまり，確率 P_{ij} で j へ跳ぶ連続時間のランダムウォーク X_t を考える．ランダムウォークはジャンプのたびに確率 $1-\lambda$ で，また単位時間あたり率 γ で消える．支持画像と種 $\hat{Q}$（A.18.2 節）

を吸収壁とし，

$$\begin{aligned} h(x) &= \Pr_x\big(\text{消える前に},\hat{Q}\text{より先に}\,\mathcal{S}\,\text{に着く}\big) \\ &= \mathbb{E}_x\big[\lambda^N e^{-\gamma T};\, \tau_{\mathcal{S}} < \tau_{\hat{Q}}\big] \end{aligned} \tag{A.1}$$

を画像 x の ID らしさとする（τ_A は集合 A に初めて着く時刻，N と T はそこまでのジャンプの回数と時間）．h は「支持画像に着く」「種に着く」「消える」という排反な 3 つの行き先のうち，支持画像が最初になる確率であり，3 つの確率の和は 1 である（付録 A.19）．λ=1, γ=0 では調和関数 [A6] やランダムウォーカーによる領域分割 [A7] の到達確率，一般には部分吸収ランダムウォーク [A8] の一つの形である．

命題 A1（三つの表示）．自由な節点を $F = V \setminus (\mathcal{S} \cup \hat{Q})$ とすると，次の 3 つは同じ h を与える．

(i) 確率式 (A.1).

(ii) 連立一次方程式（係数行列は対称正定値）

$$(D + \gamma I - \lambda W)_{FF}\, h_F = \lambda W_{F\mathcal{S}} \mathbf{1}.$$

(iii) $f|_{\mathcal{S}} = 1$，$f|_{\hat{Q}} = 0$ のもとで

$$\mathcal{E}(f) = \lambda \sum_{i<j} W_{ij}(f_i - f_j)^2 + \sum_i \big((1-\lambda)\delta_i + \gamma\big) f_i^2 \tag{A.2}$$

を最小にする f.

この f は，辺に伝導度 λW_{ij}，各節点と接地の間に伝導度 $(1-\lambda)\delta_i + \gamma$ の漏れを置いた抵抗回路で，支持画像を電位 1，種を接地したときの電位である [A9]（証明は付録 A.19）．

二つの代価．式 (A.2) の漏れ $(1-\lambda)\delta_i$ は次数に比例するので，これだけなら W を定数倍しても h は変わらず，h はグラフの形（P）だけで決まる．漏れ γ は絶対的で，次数の小さい疎な節点ほど流れの多くを失う．1 回の訪問で消えずに次へ跳ぶ確率

$$\rho_x = \frac{\lambda\,\delta_x}{\delta_x + \gamma}$$

は疎な節点で小さい．重みの尺度については

$$h(cW; \lambda, c\gamma) = h(W; \lambda, \gamma) \qquad (c > 0)$$

なので，γ は次数の中央値に対する比 g で置き，h を重みの全体の尺度に依らない量にする．

定理 A1（二つの代価の極限）．

(i) 種がなく，$\lambda = 1 - \mu\varepsilon$，$\gamma = \nu\varepsilon$（$\mu, \nu \geq 0$）とすると，$\varepsilon \to 0$ で

$$\frac{1 - h(x)}{\varepsilon} \;\longrightarrow\; \mu\,\mathbb{E}_x[N_{\mathcal{S}}] + \nu\,\mathbb{E}_x[T_{\mathcal{S}}]$$

である（$N_{\mathcal{S}}$，$T_{\mathcal{S}}$ は支持画像に着くまでの歩数と時間）．

(ii) 支持画像に置いた質量を伝播させる局所・大域一貫性 [15] の解

$$u = (1-\lambda)\big(I - \lambda D^{-1/2} W D^{-1/2}\big)^{-1} \mathbf{1}_{\mathcal{S}}$$

は，連結なグラフで $\lambda \to 1$ のとき $\sqrt{\boldsymbol{\delta}}$ に比例する量に収束する．

形と密度．(i) から，代価の小さい極限で種のない h の順位は，支持画像に着くまでの期待費用「1 歩あたり μ，時間あたり ν」で決まる．ランダムウォークは節点 i に平均 $1/\delta_i$ とどまるので，時間は経路の疎さを，歩数はたどる近傍の段数を測る．支持画像と疎にしかつながらない未知の塊（near-OOD）は形の現象，ID から離れた疎な領域（far-OOD）は密度の現象であり，二つの代価が一本のランダムウォークの上でそれぞれを測る（**図 A·4**）．支持画像を吸収壁にしない伝播 (ii) は，ランダムウォークが支持画像を通り抜けて定常分布に近づくため次数だけの量に退化するが，h は支持画像に着いた時点で止まる．

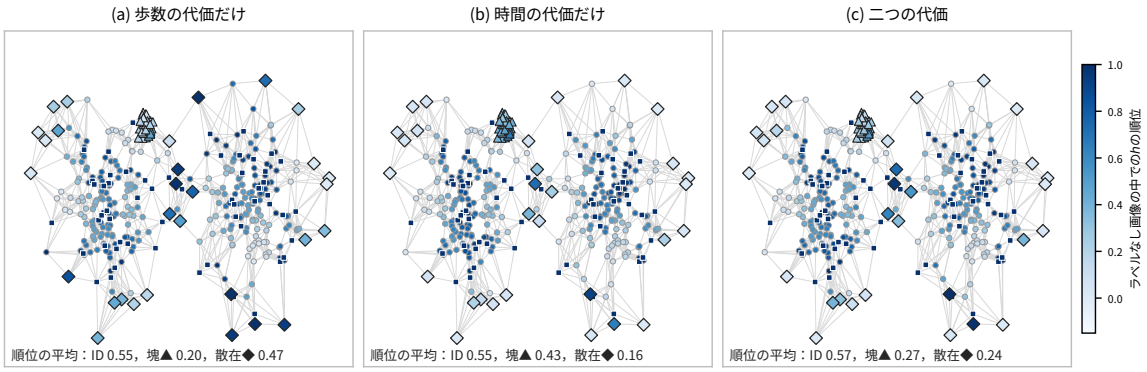


図 A·4　同じ量 h と二つの代価（2 次元の模式例；ガウス重みの対称な k 近傍グラフ，k=8）．■は支持画像，○は ID のラベルなし画像，▲は密な未知の塊，◆は疎に散らばった未知で，色はラベルなし画像の中での h の順位（薄いほど OOD らしい）．(a) 歩数の代価だけ（λ=0.8，γ=0）は塊を捉えるが散らばった未知を逃し，(b) 時間の代価だけ（λ=1，γ は次数の中央値の 0.3 倍）はその逆になり，(c) 二つの代価（λ=0.8，γ は 0.03 倍）は両方を ID より下に置く．種は使っていない．

A.18.2　種と較正順位

ラベル付き画像をクラスごとに支持画像 12 枚，参照画像 2 枚，較正画像 2 枚に，画像に依らない位置で分ける．読み出しは次の 4 段からなる．

(1) 種のない h を $h^{(0)}$ とし，プール $\mathcal{U} = \mathcal{C} \cup \mathcal{T}$ の各画像を参照画像の中での順位

$$p_{\mathcal{R}}(u) = \frac{1 + |\{r \in \mathcal{R} : h^{(0)}(r) \le h^{(0)}(u)\}|}{|\mathcal{R}| + 1}$$

で読む．

(2) $p_{\mathcal{R}}$ に Storey 型の BH 法 [16], [17]（水準 q=0.2）をかけ，棄却された画像を種 $\hat{Q} \subset \mathcal{U}$ とする（較正画像も候補に入る）．

(3) 種を吸収壁にした h を解き，すべてのラベルなし画像を一歩先読みの値

$$s(x) = \rho_x\,(Ph)(x) = \frac{\lambda (Wh)(x)}{\delta_x + \gamma} \tag{A.3}$$

で採点する．種でない画像では $s = h$，種では「一歩跳んだ後に種より先に支持画像に着く確率」（自分に戻れば種に着いたとみなす）である．

(4) s の較正画像の中での順位

$$p(x) = \frac{1 + |\{x' \in \mathcal{C} : s(x') \le s(x)\}|}{|\mathcal{C}| + 1} \tag{A.4}$$

を判定に，s を順位付けに使う．

較正画像の集合は 1 つなので p は s の単調関数であり，二つは同点を除いて同じ順序を与える．計算は疎な正定値系 2 本を共役勾配法で解くだけである．

定理 A2（有効性）．較正画像と ID のテスト画像が，他のすべての画像を所与として交換可能なら，次が成り立つ．

(i) ID のテスト画像 x について

$$\Pr\big(p(x) \le \alpha\big) \le \alpha.$$

(ii) $\{p(x)\}_{x \in \mathcal{T}}$ は ID の画像の上で PRDS であり，水準 q の BH 法で選んだ集合の偽発見率は $q\,m_0/m$ 以下，Storey 型では q 以下である（m_0 は ID のテスト画像の数）．

(iii) さらに参照画像とプールの ID の画像が交換可能なら，種の偽発見率も q 以下である．

s は $\mathcal{S}$，$\mathcal{R}$ と $\mathcal{U}$ の画像の特徴の集まり（順序なし）だけの関数で，$\mathcal{U}$ の中でどの画像を較正画像と呼ぶかに依らない．これは AdaDetect [12] の条件であり，p は同論文の経験 p 値である（付録 A.19）．種を $\mathcal{T}$ だけから $\mathcal{C}$ に対する順位で選ぶと s が較正画像の名札に依存して条件が崩れる．参照画像を分けて較正画像も種の候補にすることで，較正画像とテスト画像を折に分けずに保証が得られる．

A.18.3　逃げる確率と捕まる確率

両側の評価は一つの関数

$$\varphi(\rho, a, b) = \frac{\rho\, a}{1 - \rho\,(1 - a - b)} \qquad (a = 0 \text{ では} \varphi = 0) \tag{A.5}$$

で書ける．φ は ρ と a について増加，b について減少し，漏れがなければ

$$\varphi(1, a, b) = \frac{a}{a+b}$$

である．出口 a と出口 b の競争に，訪問ごとの生存率 ρ が掛かる量と読める．

定理 A3（逃げる確率：未知の側）．支持画像も種も含まない節点の集合 Q について，Q を初めて出る先が z である割引確率を $H_Q(y,z)$ とすると，

$$h(y) = \sum_{z \in \partial Q} H_Q(y,z)\, h(z) \qquad \text{（等式）}$$

であり，種でない外へ逃げる確率

$$\pi_Q(y) = \sum_{z \in \partial Q \setminus \hat{Q}} H_Q(y,z)$$

について $h(y) \le \pi_Q(y)$ である．$y \in Q$ の重みのうち種でない外へ向かう割合を e_y，種へ向かう割合を ζ_y とすると，

$$\pi_Q \le \varphi\big(\max_Q \rho,\ \max_Q e,\ \min_Q \zeta\big).$$

定理 A4（捕まる確率：ID の側）．支持画像も種も含まない節点の集合 B について，$y \in B$ の重みのうち支持画像へ向かう割合を ω_y，B にも支持画像にも属さない節点へ向かう割合を η_y とすると，B を出ずに支持画像に着く確率 κ_B について

$$h \ge \kappa_B \ge \varphi\big(\min_B \rho,\ \min_B \omega,\ \max_B \eta\big)$$

である．また，すべてのラベルなし画像で

$$s(x) \ge \rho_x\, \omega_x$$

である．

系 A1（分離）．種でないテスト画像 y が定理 A3 の Q に属し，各較正画像 x' について $\ell(x') \le s(x')$（例えば $\ell(x') = \rho_{x'}\omega_{x'}$）なら，

$$p(y) \le \frac{1 + |\{x' \in \mathcal{C} : \ell(x') \le \pi_Q(y)\}|}{|\mathcal{C}| + 1}. \tag{A.6}$$

特に $\pi_Q(y) < \min_{x' \in \mathcal{C}} \ell(x')$ なら $p(y)$ は床 $1/(|\mathcal{C}|+1)$ に落ち，y は $\alpha \ge 1/(|\mathcal{C}|+1)$ のすべての水準で OOD と判定される（証明は付録 A.19）．

読み方．未知の塊では「種でない外への辺」と「種への辺」が競い，ID の近傍では「支持画像への辺」と「漏れる辺」が競う．同じ φ が両側を抑え，その大小が較正順位の分離式 (A.6) を決める．有効性（定理 A2）と検知力（定理 A3–系 A1）は同じ量 s についての主張である．種を増やすと h は単調に減り，塊のどの節点でも重みの割合 ζ 以上が種へ向かえば，漏れがなくても逃げる確率は

$$\pi_Q \le \frac{\max_Q e}{\max_Q e + \zeta}$$

を満たす．同じ未知クラスの画像が複数枚あるとき，種になった画像は残りの画像の重みの一部を占め，その逃げる確率を下げる．これが自己ラベル付けの効く理由である．

A.18.4 結果

登録と判定．開発用分割 dev1 で 95 通りの構成を探索した後，構成を 1 つに固定し（λ=0.95，g=1/16，ビューの重みを次数の中央値で割った和のグラフ，クラスあたり支持 12・参照 2・較正 2，q=0.2，折なし），ベース検出器との積の形を選ぶ dev1 の規則，dev2 での 3 つの仮説，採否の規則を登録してから実行した（付録 A.17）．dev1 の規則は積を $s_0 \cdot p$ に決めた（$s_0 \cdot s$ は ×TINS の far-OOD が 24.00%で σ の 15.86%+0.5 を超える）．dev2 では H1（near-OOD の FPR95 の差が+0.5 以下）が-0.06，H2（far-OOD）が+0.25，H3（p の誤警報率が α=0.05 で 0.06 以下，0.2 で 0.21 以下）が 0.053 ／ 0.204 とすべて成立し，登録した規則では h を主構成にすることになった．ただし AUROC は σ より低く（-0.27 [-0.43, -0.11]，-0.38 [-0.48, -0.27] ポイント），FPR95 の差の区間の上端は near +0.89，far +1.54 と+0.5 を超えていた．規則は点推定で判定したので h が採用されたが，区間の上端で判定していれば採用されなかった．

表 A·24 一つの量 h（登録した構成）と交差適合した σ（単体，ベンチマークは 6 通りの抽出の平均，dev2 は 5 通り；差は $h-\sigma$，抽出を単位とする対応のある 95% t 区間）．×TINS の h は dev1 の規則で選んだ $s_0 \cdot p$.

	σ（交差適合）		一つの量 h		
設定	AUROC	FPR95	AUROC	FPR95	FPR95 の差 [95%区間]
dev2 near（登録した確認）	97.16	12.92	96.89	12.87	-0.06 [-1.00, +0.89]
dev2 far（登録した確認）	96.56	16.73	96.18	16.98	+0.25 [-1.04, +1.54]
ImageNet-1K near-OOD	97.94	11.50	97.18	13.65	+2.14 [+1.70, +2.58]
ImageNet-1K far-OOD	98.79	5.17	98.20	7.32	+2.15 [+1.87, +2.42]
Four-OOD	98.80	4.56	98.04	7.00	+2.44 [+2.06, +2.81]
ImageNet-200 near-OOD	98.17	9.07	96.57	8.10	-0.97 [-1.38, -0.56]
ImageNet-200 far-OOD	99.35	2.15	98.59	4.15	+2.00 [+1.77, +2.23]
CIFAR-100 near-OOD	99.18	2.90	98.44	6.42	+3.52 [+3.17, +3.87]
CIFAR-100 far-OOD	99.37	2.34	97.56	3.31	+0.97 [+0.50, +1.44]
ImageNet-1K near-OOD ×TINS	98.09	10.50	96.75	18.58	+8.09 [+7.54, +8.64]
ImageNet-1K far-OOD ×TINS	99.05	4.16	98.88	4.92	+0.77 [+0.60, +0.93]
Four-OOD ×TINS	99.09	3.39	98.97	3.56	+0.18 [+0.07, +0.28]

ベンチマーク．テスト集合では h は σ に及ばない（**表 A·24**）．ImageNet-1K の FPR95 は near-OOD で 11.50%から 13.65%（差+2.14 [+1.70, +2.58]），far-OOD で 5.17%から 7.32%，Four-OOD で 4.56%から 7.00%になり，AUROC はそれぞれ 0.76，0.59，0.76 ポイント下がる．ImageNet-200 の near-OOD だけは FPR95 が 0.97 ポイント良いが AUROC は 1.60 ポイント低く，far-OOD と CIFAR-100 では悪い．×TINS（$s_0 \cdot p$）の near-OOD は 10.50%から 18.58%へ大きく悪化する．p の床の上ではベース検出器が未知の順序を決めるためで，本文がベース検出器を $\exp \sigma_{\mathrm{ref}}$ と掛ける理由（2.6 節）と同じである．学習画像で較正した p の α=0.05 での誤警報率は ImageNet-1K で 0.067 ／ 0.071 ／ 0.071 であり，同じ較正の p^{fin}（0.058 ／ 0.064 ／ 0.062）より高い（較正画像とテスト画像は交換可能でない；4.4 節）．再出現の格子では 60 条件のうち 10 条件で σ より良いが，同じ未知クラスが 1–2 枚の 20 条件では平均+14.1 ポイント悪い（NINCO の c=64，r=1 で 92.2%，σ は 75.0%）．

開発用分割から移らなかったこと．dev2 は dev1 と同じ作り方で，far-OOD の画像集合（OpenImage-O）も共通であり，dev2 での非劣性はベンチマークに移らなかった．dev1 の探索（探索時のコードの値；σ の折の割り当ては登録した実行と異なる，付録 A.2）では，支持画像と種を吸収壁にして 1 歩ごとの代価だけを持たせた量は near-OOD で σ に並ぶが far-OOD で大きく劣り（FPR95 13.43%／ 28.27%，σ は 13.69%／ 16.74%；登録した実行の σ は 13.75%／ 16.51%），その原因は局所・大域一貫性の質量の次数成分にあった．次数だけをスコアにしても AUROC は far-OOD で 86.7%（DINOv2），82.2%（DINOv3）に達し，near-OOD では 49.1%，48.6%にとどまった（テスト集合では次数だけの AUROC は far-OOD でも 50.40%で，この手がかりは移らなかった；**表 3**）．時間の代価 γ はこの密度の手がかりを確率の中に戻すために入れたもので，dev1 では σ に並んだ（13.74%／ 16.77%）．ベンチマークでは再出現のない未知と far-OOD で劣ることから，γ による密度の取り込みは本文の伝播の次数成分の代わりとして十分でないと考えられる．

系 A1 の実測．再出現の格子で，$h \le \pi_Q$（定理 A3）と $\pi_Q \le \bar{\phi}$ はすべての未知画像で成り立つ（付録 A.5 の**表 A·4**）．h/π_Q の中央値は 0.52–0.69 で定理 A3 は緩くないが，系 A1 を較正画像側の下界 $\ell = \rho\omega$ で読むと，ℓ が実際のスコア s の 0.31–0.42 倍しかないため保証される未知は全条件で 0 である．実際のスコアで読めば最大 45%を保証する．下界側の弱さが，系 A1 が実際の検知を説明できない主な理由である．

位置づけ．以上から，σ を主構成のまま h を登録した変種として報告した（v19–v21）．これは登録からの逸脱であり，その判断はテスト集合の値を見た後に行った．ただし「結果が良ければ本文，悪ければ付録に置く」ことは実行の前に決めていた（登録文書には書いていない；付録 A.17）．区間の上端で判定する規則なら h は採用されず，逸脱は生じなかった．h は誤警報率の保証（定理 A2）と検知力（定理 A3–系 A1）を同じ量について述べられるが，ベンチマークでの性能は σ にも σ_{ref} にも及ばない．

A.19 一つの量 h の証明と性質

記号は A.18.1 節のとおりで，

$$M = (D + \gamma I - \lambda W)_{FF}, \qquad \rho_x = \frac{\lambda\, \delta_x}{\delta_x + \gamma}$$

とする．

命題 A1 の証明．

(i) **から** *(ii)***．** $x \in F$ で最初の滞在時間 $T_1 \sim \mathrm{Exp}(\delta_x)$ を生き延びる確率は

$$\mathbb{E}\, e^{-\gamma T_1} = \int_0^\infty \delta_x e^{-\delta_x t}\, e^{-\gamma t}\, dt = \frac{\delta_x}{\delta_x + \gamma}$$

であり，続くジャンプを生き延びて j へ移る確率は λP_{xj} である．よって

$$h(x)=\frac{\delta_x}{\delta_x+\gamma}\sum_j \lambda P_{xj}\,h(j)=\rho_x\,(Ph)(x)=\frac{\lambda\,(Wh)(x)}{\delta_x+\gamma}\qquad (x\in F)$$

であり，境界の値（$\mathcal{S}$ で 1，$\hat{Q}$ で 0）を代入すれば

$$(\delta_x+\gamma)\,h(x)-\lambda\sum_{j\in F}W_{xj}\,h(j)=\lambda\sum_{j\in\mathcal{S}}W_{xj}\qquad (x\in F),$$

すなわち (ii) の $Mh_F=\lambda W_{F\mathcal{S}}\mathbf{1}$ になる．

一意性． M の非対角成分の行和は

$$\lambda\sum_{j\in F}W_{xj}\le\lambda\,\delta_x$$

なので，$\gamma>0$，または $\lambda<1$ かつ $\delta_x>0$ なら M は狭義対角優位であり，対称なので正定値である（λ=1, γ=0 では，F と交わる各連結成分が境界を含めば既約対角優位）．よって解は一意で，確率式 (A.1)（方程式の最小の非負解）と一致する．

(iii)．$\mathcal{E}$ を f_x（$x\in F$）で微分すると

$$\frac{\partial\mathcal{E}}{\partial f_x}=2\Big[(\delta_x+\gamma)f_x-\lambda\sum_j W_{xj}f_j\Big]$$

で，停留条件は (ii) と同じ式であり，ヘッセ行列 $2M$ は正定値なのでその解が最小点である．回路ではこれが自由な節点でのキルヒホッフの電流則

$$\sum_j\lambda W_{xj}\,(f_x-f_j)+\big((1-\lambda)\delta_x+\gamma\big)f_x=0$$

にあたる．□

三つの行き先． $\mathcal{S}$ と $\hat{Q}$ の役割を入れ替えた量を $\check{h}$，どちらにも着く前に消える確率を d とすると，M が正則なとき

$$h+\check{h}+d=1$$

である（λ=1, γ=0 では $\check{h}=1-h$）．

証明． 最初の滞在と最初のジャンプで場合を分けると

$$d(x)=\frac{\gamma}{\delta_x+\gamma}+\frac{\delta_x}{\delta_x+\gamma}\Big[(1-\lambda)+\lambda\sum_{j\in F}P_{xj}\,d(j)\Big]\qquad (x\in F),$$

すなわち $Md_F=\gamma\mathbf{1}+(1-\lambda)\boldsymbol{\delta}_F$ である．一方

$$M\mathbf{1}_F=(1-\lambda)\boldsymbol{\delta}_F+\gamma\mathbf{1}+\lambda W_{F\mathcal{S}}\mathbf{1}+\lambda W_{F\hat{Q}}\mathbf{1},$$
$$Mh_F=\lambda W_{F\mathcal{S}}\mathbf{1},\qquad M\check{h}_F=\lambda W_{F\hat{Q}}\mathbf{1}$$

だから

$$M\big(h+\check{h}+d\big)_F=M\mathbf{1}_F$$

であり，M が正則なので $h+\check{h}+d=1$ である．□

定理 A1 の証明．

(i)．種がないので $h(x)=\mathbb{E}_x[\lambda^N e^{-\gamma T}]$（$N=N_{\mathcal{S}}$，$T=T_{\mathcal{S}}$）であり，

$$\lambda^N e^{-\gamma T}=\exp\big(N\log(1-\mu\varepsilon)-\nu\varepsilon T\big)$$

である．$1-e^{-u}\le u$ と $-\log(1-v)\le 2v$（$0\le v\le 1/2$）から，$\mu\varepsilon\le 1/2$ のとき

$$0\le\frac{1-\lambda^N e^{-\gamma T}}{\varepsilon}\le 2\mu N+\nu T$$

である．有限のグラフで各連結成分が支持画像を含めば N と T は指数的な裾を持ち可積分なので，各点収束

$$\frac{1-\lambda^N e^{-\gamma T}}{\varepsilon}\ \longrightarrow\ \mu N+\nu T\qquad(\varepsilon\to 0)$$

に優収束定理を使えば

$$\frac{1-h(x)}{\varepsilon} \;\longrightarrow\; \mu\,\mathbb{E}_x[N_{\mathcal{S}}] + \nu\,\mathbb{E}_x[T_{\mathcal{S}}]$$

を得る．期待値 $n = \mathbb{E}[N_{\mathcal{S}}]$ と $t = \mathbb{E}[T_{\mathcal{S}}]$ は，最初の 1 歩で分けた方程式

$$(D-W)_{FF}\,n = \boldsymbol{\delta}_F, \qquad (D-W)_{FF}\,t = \mathbf{1}$$

の解である．

(ii)．$\hat{W} = D^{-1/2} W D^{-1/2}$ を固有分解して

$$\hat{W} = \sum_{k} \theta_k\, \phi_k \phi_k^{\top}, \qquad \theta_1 = 1, \qquad \phi_1 = \frac{D^{1/2}\mathbf{1}}{\|D^{1/2}\mathbf{1}\|}$$

とする（連結なら θ_1 は単純）．

$$(1-\lambda)(I-\lambda\hat{W})^{-1} = \sum_{k} \frac{1-\lambda}{1-\lambda\theta_k}\,\phi_k\phi_k^{\top}$$

の係数は，$\lambda \to 1$ で $k \geq 2$ では 0 に（$\theta_k = -1$ でも $(1-\lambda)/(1+\lambda) \to 0$），$k = 1$ では 1 に収束する．よって

$$u \;\longrightarrow\; \phi_1\phi_1^{\top}\mathbf{1}_{\mathcal{S}} = \sqrt{\boldsymbol{\delta}}\,\frac{\sum_{j\in\mathcal{S}}\sqrt{\delta_j}}{\sum_i \delta_i}$$

である．大きなランダム近傍グラフでは 1 点への到達時間が次数で決まる量に退化することが知られ [A10]，λ=1, γ=0 の調和関数もラベルなしの点が非常に多い極限で平坦になり得る [A11]．本稿が極限ではなく有限の代価を使うのはこのためで，(i) は極限での読み方である．□

定理 A2 の証明．

(a) **置換不変性．**s は，ラベル付きの $\mathcal{S}$，$\mathcal{R}$ と，$\mathcal{U}$ の画像の特徴の集まり（順序なし）だけの関数で，$\mathcal{U}$ の中でどの画像を較正画像と呼ぶかを入れ替えても各画像の値は変わらない．グラフは節点の名札に依らず，$h^{(0)}$ は $\mathcal{S}$ を吸収壁とする同じ方程式の解，$p_{\mathcal{R}}$ は固定した $\mathcal{R}$ との比較，BH 法はプールの $p_{\mathcal{R}}$ の多重集合から閾値を決めるので種の選び方は $\mathcal{U}$ の画像を対称に扱い，第 2 段の h と s も同様だからである．

(b) *(i)* **と** *(ii)*．(a) は AdaDetect [12] の条件 (8) であり，p は同論文の経験 p 値 (10) で，同点を独立な一様乱数で崩せば同点なしの仮定も満たす（崩さずに $\leq$ で数えると (i) は保守的になる）．よって同論文の定理 3.3 が (i) と PRDS を，系 3.5 と 3.7 が (ii) を与える．系 3.7 を当てはめる Storey 型の $\hat{\pi}_0$ は上限を付けない推定量で，その閾値は

$$\lambda_{\mathrm{S}} = \frac{\lfloor |\mathcal{C}|/2 \rfloor}{|\mathcal{C}|+1}$$

である．

(c) *(iii)*．$h^{(0)}$ は $\mathcal{R}\cup\mathcal{U}$ の中の置換に不変なので，$\mathcal{R}$ を較正標本として同じ定理による．

クラスごとに位置で固定した分割は $\mathcal{C}$ と $\mathcal{R}$ を層化するので，交換可能性は厳密には仮定である．□

定理 A3 の証明．

出口の分解．Q を初めて出る時刻を τ とする．Q は支持画像も種も含まないので $\tau \leq \tau_{\mathcal{S}}$ かつ $\tau \leq \tau_{\hat{Q}}$ であり，割引 $\lambda^N e^{-\gamma T}$ は τ の前後の積に分かれる．強マルコフ性から

$$h(y) = \mathbb{E}_y\big[\lambda^{N_\tau} e^{-\gamma\tau}\, h(X_\tau)\big] = \sum_{z\in\partial Q} H_Q(y,z)\, h(z)$$

で，種の上で $h = 0$，それ以外で $h \leq 1$ だから

$$h(y) \leq \sum_{z\in\partial Q\setminus\hat{Q}} H_Q(y,z) = \pi_Q(y)$$

である．

逃げる確率の上界．最初の滞在と最初のジャンプで分けると，$\pi = \pi_Q$ は写像

$$\mathcal{K}(f)(y) = \rho_y\Big(e_y + \sum_{j\in Q} P_{yj}\, f(j)\Big) \qquad (y \in Q)$$

の最小の非負の不動点で，0 から反復して得られる（$\pi = \lim_{k\to\infty} \mathcal{K}^k(0)$）．$\sum_{j\in Q} P_{yj} = 1 - e_y - \zeta_y$ だから，定数 $c \in [0,1]$ に対し

$$\mathcal{K}(c\mathbf{1})(y) = \rho_y\big(e_y + (1 - e_y - \zeta_y)\, c\big) = \rho_y\big(c + (1-c)\, e_y - c\,\zeta_y\big)$$

で，これは ρ_y と e_y について増加，ζ_y について減少する．$\bar{\varphi} = \varphi(\max_Q \rho, \max_Q e, \min_Q \zeta)$ は

$$\bar{\varphi} = \max_Q \rho \Big(\max_Q e + \big(1 - \max_Q e - \min_Q \zeta\big)\, \bar{\varphi} \Big)$$

を満たすので $\mathcal{K}(\bar{\varphi}\mathbf{1}) \le \bar{\varphi}\mathbf{1}$（優解）である．$\mathcal{K}$ は単調（$f \le g$ なら $\mathcal{K}(f) \le \mathcal{K}(g)$）なので，反復の各段で

$$\mathcal{K}^k(0) \le \mathcal{K}^k(\bar{\varphi}\mathbf{1}) \le \bar{\varphi}\mathbf{1}$$

が保たれ，$\pi_Q \le \bar{\varphi}$ である．□

定理 A4 の証明． B の中だけを通って支持画像に着く経路は種を通らないので $\kappa_B \le h$ である．κ_B は

$$\mathcal{K}_B(f)(y) = \rho_y\Big(\omega_y + \sum_{j\in B} P_{yj}\, f(j)\Big) \qquad (y \in B)$$

の不動点で，$\sum_{j\in B} P_{yj} = 1 - \omega_y - \eta_y$ である．定理 A3 と逆向きに，$\underline{\varphi} = \varphi(\min_B \rho, \min_B \omega, \max_B \eta)$ は

$$\begin{aligned}\mathcal{K}_B(\underline{\varphi}\mathbf{1})(y) &= \rho_y\big(\underline{\varphi} + (1 - \underline{\varphi})\,\omega_y - \underline{\varphi}\,\eta_y\big) \\ &\ge \min_B \rho \Big(\min_B \omega + \big(1 - \min_B \omega - \max_B \eta\big)\, \underline{\varphi} \Big) = \underline{\varphi}\end{aligned}$$

を満たす（劣解）．よって $\mathcal{K}_B^k(\underline{\varphi}\mathbf{1})$ は k について増加して不動点に収束する．$\max_B \rho < 1$ なら $\mathcal{K}_B$ は縮小写像で不動点は κ_B ただ一つであり，λ=1, γ=0 でも B の各成分が出口を持てば一意で，出口のない成分があれば $\min_B \omega = 0$ で主張は自明である．最後の主張は，$\mathcal{S}$ で $h = 1$，他で $h \ge 0$ なので

$$s(x) = \rho_x \sum_j P_{xj}\, h(j) \ge \rho_x \sum_{j\in\mathcal{S}} P_{xj} = \rho_x\, \omega_x$$

による．□

系 A1 の証明． y は種でないので $s(y) = h(y) \le \pi_Q(y)$ である．$s(x') \le s(y)$ なら $\ell(x') \le s(x') \le s(y) \le \pi_Q(y)$ なので

$$\{x' \in \mathcal{C} : s(x') \le s(y)\} \subseteq \{x' \in \mathcal{C} : \ell(x') \le \pi_Q(y)\}$$

であり，これを式 (A.4) に代入すれば式 (A.6) を得る．□

クラスに依らない． ID のクラスごとの支持画像 $\mathcal{S}_c$ について，最初に着く支持画像が $\mathcal{S}_c$ に属する確率を h_c とすると

$$h = \sum_c h_c$$

である（事象 $\{\tau_{\mathcal{S}} < \tau_{\hat{Q}}\}$ は最初に着く支持画像のクラスで排反に分かれ，割引は共通）．h はクラスの分け方に依らない．同じグラフでクラスラベルを伝播させて最大値で読む LGC-max では，近い ID クラスが複数ある画像の到達確率がそれらに割れて最大値が薄まるが，h はその総和で割れても変わらない．

粒度の床． $p \ge 1/(|\mathcal{C}|+1)$ で，p は $1/(|\mathcal{C}|+1)$ 刻みの値を取る．種が選ばれるなら，その数は少なくとも $\hat{\pi}_0 m/(q(|\mathcal{R}|+1))$（プール $\mathcal{U}$ の大きさ m の割合 $\hat{\pi}_0/(q(|\mathcal{R}|+1))$）である．BH 法の棄却数 $\hat{k}$ は $p_{(\hat{k})} \le q\hat{k}/(\hat{\pi}_0 m)$ を満たし，$p_{\mathcal{R}}$ はつねに $1/(|\mathcal{R}|+1)$ 以上なので

$$\frac{1}{|\mathcal{R}|+1} \le p_{(\hat{k})} \le \frac{q\,\hat{k}}{\hat{\pi}_0\, m}, \qquad \text{すなわち} \qquad \hat{k} \ge \frac{\hat{\pi}_0\, m}{q\,(|\mathcal{R}|+1)}$$

である．ImageNet-1K（$|\mathcal{R}|$=2,000，q=0.2）ではプールの約 0.25%であり，共形 p 値の分解能から来る構造である．

付録の参考文献

[A1] V. Chernozhukov et al.: Double/debiased machine learning for treatment and structural parameters. *Econom. J.*, 21(1):C1–C68, 2018.
[A2] Y. Song, N. Sebe, and W. Wang: RankFeat: Rank-1 feature removal for out-of-distribution detection. *NeurIPS*, 2022.
[A3] M. Chen, J. Gao, and C. Xu: Conjugated semantic pool improves OOD detection with pre-trained vision-language models. *NeurIPS*, 2024.
[A4] M. Caron et al.: Emerging properties in self-supervised vision transformers. *ICCV*, 2021.
[A5] G. Blanchard and E. Roquain: Two simple sufficient conditions for FDR control. *Electron. J. Stat.*, 2:963–992, 2008.
[A6] X. Zhu, Z. Ghahramani, and J. Lafferty: Semi-supervised learning using Gaussian fields and harmonic functions. *ICML*, 2003.
[A7] L. Grady: Random walks for image segmentation. *IEEE TPAMI*, 2006.
[A8] X.-M. Wu et al.: Learning with partially absorbing random walks. *NeurIPS*, 2012.
[A9] P. G. Doyle and J. L. Snell: *Random Walks and Electric Networks*. Mathematical Association of America, 1984.
[A10] U. von Luxburg, A. Radl, and M. Hein: Hitting and commute times in large random neighborhood graphs. *JMLR*, 2014.
[A11] B. Nadler, N. Srebro, and X. Zhou: Statistical analysis of semi-supervised learning: The limit of infinite unlabelled data. *NeurIPS*, 2009.