



Salmon Ladder: Catching Recurring Unknowns

慶應義塾大学 総合政策学部 3 年 中澤・大越研究室 d-hacks 72402035 表 紘太郎

概要

視覚言語モデル (VLM) による分布外 (OOD) 検知は, ID クラスに意味的に近い near-OOD で弱い. 本研究は, テスト時のストリームで同じ未知クラスが繰り返し現れること (再来) を, 学習なしで利用する Salmon Ladder を提案する. 自己教師あり特徴とクラスあたり 16 枚のラベル付き画像を用い, プロトタイプとの距離を較正画像に対する順位 (較正順位) に変換して, OOD らしい画像を入口付きの視覚メモリに蓄える. ラベル伝播では, 伝わる質量が保存されるためグラフの成長とともに値が縮むことを示し, 現在のグラフ上の較正順位で補正する. 同じ調整予算で選んだ伝播のみの最良の構成と比べ, 設計に用いていない評価で FPR95↓ を 3.16 [2.16, 4.15] ポイント (ImageNet-1K の新しい 5 分割), 5.96 [5.16, 6.75] ポイント (ImageNet-O) 下げた. OpenOOD v1.5 では TINS との積が near-OOD で AUROC↑ 96.30%, FPR95↓ 16.76% となり, 同じ特徴による比較手法を上回った. 改善は同じクラスの再来とともに増え, 初出の画像では生じない.




図 1: Salmon Ladder の概要. メモリによる p_M と伝播による p_{LP} を較正画像に対する順位として求め, s_0 に掛ける.

1 Introduction

OOD 検知は, ID 以外の入力を見分ける問題である. CLIP [1] などの VLM は学習なしに OOD を検知でき [2], 負例ラベル [3] やテスト時の適応 [4, 5, 6] によって, ID から遠い far-OOD の AUROC↑ は 96–97% に達した. しかし ID に近い near-OOD では, OpenOOD v1.5 [7] での報告値の最良でも 84.53% であり [5], ID の兄弟クラス (WordNet で親が同じクラス) を未知とすると 65–70% にとどまる (表 1). 本研究は「Salmon Ladder」を提案する (図 1).

2 提案手法

設定と静的な較正順位. ID の各クラス c に 16 枚のラベル付き画像が与えられ, 12 枚を支持画像 S_c , 4 枚を較正画像とする (全体を $\mathcal{S}$, $\mathcal{C}$ とし, $n = |\mathcal{C}|$). テスト画像は ID と OOD が混ざったストリームとして届く. t 番目のバッチ B_t が届いた時点で, その各画像 x にスコア $s(x)$ (大きいほど ID らしい) を返す. モデルは更新しない.

正規化した特徴を $f(x)$, クラス c の支持画像の特徴の和を正規化したプロトタイプを μ_c , コサイン距離を dist とする. 支持画像の一つあたりの距離の中央値 $\tilde{\eta}_c$ と中央値絶対偏差による尺度 $\tilde{\sigma}_c$ (全クラスの値に向けて縮小) で標準化した $z_c(x) = (\text{dist}(f(x), \mu_c) - \tilde{\eta}_c) / \tilde{\sigma}_c$ から, $d(x) = \min_{c \in K(x)} z_c(x)$ を求める. $K(x)$ は CLIP のゼロショット分類の上位 20 クラスで, 全クラスで最小をとったものを d_{all} と書く. これを較正画像の中での順位

$$p(x) = \frac{1 + |\{x' \in \mathcal{C} : d(x') \geq d(x)\}|}{n + 1} \quad (1)$$

に変換する (d_{all} からは p_{all}). 較正画像と ID のテスト画像のスコアが交換可能なら, これは共形 p 値 [8] であり, $\Pr(p \leq \alpha) \leq \alpha$ を満たす. 以下, この形の量を較正順位と呼ぶ. p はストリームに依存しないので静的 p と呼ぶ.

入口付き視覚メモリ. 過去の画像の集合 $\mathcal{A}$ に対し, x から $\mathcal{A}$ の最近傍までのコサイン距離 $\rho_{\mathcal{A}}(x)$ を, 同じクラスの支持画像どうしの最近傍距離の中央値 η_M と尺度 σ_M で標準化して, $g_{\mathcal{A}}(x) = d(x) - (\rho_{\mathcal{A}}(x) - \eta_M) / \sigma_M$ とする. $g_{\mathcal{A}}$ は ID から遠く $\mathcal{A}$ に近いほど大きい. 式 (1) の d を $g_{\mathcal{A}}$ に替えた較正順位を $p_{\mathcal{A}}$ と書く. 較正画像も同じ $\mathcal{A}$ に対して採点するので, $\mathcal{A}$ に

ID が混ざっても順位は崩れにくい. 蓄える画像は 3 段で選ぶ.

$$\begin{aligned} \mathcal{A}_{1,t+1} &= \mathcal{A}_{1,t} \cup \{x \in B_t : p_{\text{all}}(x) \leq \varepsilon_1\}, \\ \mathcal{A}_{2,t+1} &= \mathcal{A}_{2,t} \cup \{x \in B_t : p_{\mathcal{A}_{1,t}}(x) \leq \varepsilon_2\}, \\ \mathcal{M}_{t+1} &= \mathcal{M}_t \cup \{x \in B_t : p_{\mathcal{A}_{2,t}}(x) \leq \varepsilon_3\} \end{aligned} \quad (2)$$

同じ未知クラスの画像は $\mathcal{A}_{1,t}$ の中で互いに近いので, 段を重ねるほど OOD に絞られる. 最終段 $\mathcal{M}_t$ をメモリと呼び, $p_M(x) = p_{\mathcal{M}_t}(x)$ とする. 採点には過去のバッチで加えた画像だけを使う. 閾値 $(\varepsilon_1, \varepsilon_2, \varepsilon_3) = (0.30, 0.20, 0.1019)$ は, ID が最終段に採用される割合が 10% になるように開発用分割で決めた.

較正順位によるラベル伝播. メモリは閾値に依存する. 相補的な証拠として, 支持画像のラベルをグラフ上で伝播させる [9]. 節点は支持画像, 較正画像, 届いたすべてのテスト画像 (N_t 個) であり, 各節点をコサイン類似度の上位 k_g 個と結び (一方の上位に入れば結ぶ), 類似度の γ 乗を重みとする対称な行列 $W = (w_{ij})$ を作る. 次数を $\delta_i = \sum_j w_{ij}$, $D = \text{diag}(\delta_i)$, $S = D^{-1/2} W D^{-1/2}$ とし, 支持画像で 1, それ以外で 0 のベクトル $\mathbf{y}$ と $\lambda \in (0, 1)$ を用いて

$$\mathbf{u}^{(\ell+1)} = \lambda S \mathbf{u}^{(\ell)} + (1 - \lambda) \mathbf{y} \quad (3)$$

を L 回反復する (前のバッチの値から始める). 画像 x の節点の値 $u(x)$ は, x に伝わった ID ラベルの量を表す.

命題 1 (質量の保存). $\omega = D^{1/2} \mathbf{1}$ ($\mathbf{1}$ は全成分が 1 のベクトル) とすると, 式 (3) の収束解 $\mathbf{u}^*$ は $\omega^\top \mathbf{u}^* = \omega^\top \mathbf{y} = \sum_{j \in \mathcal{S}} \sqrt{\delta_j}$ を満たす.

証明. 省略.

支持画像の数を N_s とすると, 命題 1 から, $\mathbf{u}^*$ の $(\sqrt{\delta_i}$ を重みとする) 平均は, 次数が同程度なら N_s/N_t にほぼ等しい. N_s は一定なので, 画像が届くほど一節点あたりの値は縮む. 開発用分割では, N_s/N_t が 0.74 から 0.29 に下がる間, $\mathbf{u}^*$ の平均はその 0.96–0.98 倍で推移した. 異なるバッチの $\mathbf{u}$ は一つの閾値で比べられないので, 同じグラフ上の較正画像の中での順位

$$p_{LP}(x) = \frac{1 + |\{x' \in \mathcal{C} : u(x') \leq u(x)\}|}{n + 1} \quad (4)$$

に変換する. 較正画像もラベルのない節点なので同じように縮み, 縮小が共通の狭義単調変換なら p_{LP} は変わらない.

再来が伝播に効く理由は次の上界で説明できる. 支持画像を含まない節点の集合 Q について, Q から外へ出る辺の重みの和を $w(Q, \bar{Q})$ とすると,

$$\sum_{i \in Q} \sqrt{\delta_i} u_i^* \leq \frac{\lambda}{1 - \lambda} \cdot \frac{w(Q, \bar{Q})}{\min_{j \in \mathcal{S}} \sqrt{\delta_j}} \quad (5)$$

が成り立つ (確率 $1 - \lambda$ で止まる酔歩による表現から従う [10]). 同じ未知クラスの画像が互いの近傍を占め, 外への辺が減るほど, その $\mathbf{u}^*$ の上界は小さくなる.

スコア. VLM による検出器のスコア s_0 との積

$$s(x) = s_0(x) \prod_v p_M^{(v)}(x) p_{LP}^{(v)}(x) \quad (6)$$

を返す (v は特徴の種類. $s_0 = 1$ の場合を単体と呼ぶ). 積は p 値ではないので, 順位付けのスコアとしてのみ用いる.

3 実験

設定. 特徴は DINOv2 [11] の ViT-B/14 と ViT-L/14 である. 設定 ($k_g=10$, $\gamma=1$, $\lambda=0.9$, $L=15$) は ImageNet-1K

表 1: 設計に用いていない評価 (AUROC↑/FPR95↓ [%]). × はスコアの積, ζ は同じ調整予算で選んだ伝播のみの最良の構成. (Ours) の色と太字は ×ζ からの改善を表す (すべて対応のある 95% 区間が 0 を含まない).

	U1: ImageNet-1K の新しい 5 分割 (兄弟クラスが未知)				U2: ImageNet-O			
ベース検出器 s_0	s_0 のみ	×ζ	×Salmon Ladder (Ours)		s_0 のみ	×ζ	×Salmon Ladder (Ours)	
なし (単体)	—	92.40 / 29.43	93.86 / 26.27		—	89.93 / 44.15	91.81 / 38.20	
MCM [2]	69.83 / 83.28	92.44 / 29.40	93.87 / 26.25		80.78 / 75.19	90.02 / 44.02	91.83 / 38.15	
NegLabel [3]	68.68 / 83.16	92.35 / 30.52	93.74 / 26.66		83.43 / 58.68	91.51 / 39.21	92.47 / 36.01	
AdaNeg [4]	68.40 / 83.62	92.32 / 30.34	93.80 / 26.39		83.04 / 66.43	90.69 / 41.67	92.12 / 36.82	
TANL [5]	69.82 / 74.88	92.55 / 29.73	93.88 / 26.02		88.11 / 50.88	92.23 / 35.19	92.90 / 33.90	
TINS [6]	64.95 / 85.67	92.27 / 30.17	93.79 / 26.48		78.62 / 68.46	90.48 / 42.32	92.07 / 37.26	

表 2: OpenOOD v1.5 ImageNet-1K ([%, 5 順序の平均]). 中 segment は同じ特徴による比較手法と TINS の積 (Maha.++ は Mahalanobis++). 色と太字は (Ours) 以外のすべての行を上回る値.

手法	near-OOD		far-OOD	
	AUROC↑	FPR95↓	AUROC↑	FPR95↓
TINS [6]	81.48	56.37	97.04	12.23
kNN [13] (16 枚)	84.56	52.39	98.25	8.57
Maha.++ [14] (16 枚)	86.37	44.57	98.52	7.51
Maha.++ (全学習画像)	87.83	41.35	98.69	6.85
AdaNeg 型メモリ	90.78	29.16	98.10	8.99
OOD 型メモリ	90.13	33.36	98.53	7.16
Salmon Ladder (Ours), 単体	96.12	17.81	98.36	7.41
Salmon Ladder (Ours) × TINS	96.30	16.76	98.85	5.55




図 2: 再来の介入実験 (U1 の 250 組, 単体). 固定した履歴の OOD のうち r 枚を入れ替えた. 帯と横線はブートストラップによる 95% 区間.

の学習画像から作った開発用分割だけで決め, 凍結した. 入口とメモリの寄与を測るため, 同じグラフ上で伝播だけから作れる検出器 (u そのもの, 質量の補正 uN_t/N_s , 較正順位, 頑健な標準化など) に同じ 27 通りのグラフ設定を与えて開発用分割で選び, 最良のものを固定した. これは, 較正画像の u の中央値と中央値絶対偏差で u を標準化し, 標準正規分布の分布関数に通した値であり, 以下 ζ と書く.

評価には, 本研究のどの段階でも用いていない画像から作った U1 (ImageNet-1K の新しい 5 分割. ID に兄弟クラスを持つ 100 クラスを未知とする 23,000 枚のストリーム) と U2 (ImageNet-O [12]) を用いる. 主要評価項目 (U1 の FPR95↓ の差. 単体と TINS との積) と判定の規則は, 評価の前に登録した. OpenOOD v1.5 の ImageNet-1K も用いる (テスト分割の使用は通算 5 回目). バッチは 256 枚で, 差の区間は, 分割 (U1), 16 枚の選び方 (U2), 順序 (OpenOOD) を単位とする対応のある 95% t 区間である.

設計に用いていない評価 (表 1). Salmon Ladder は ζ より FPR95↓ を, U1 の単体で 3.16 [2.16, 4.15] ポイント, TINS との積で 3.22 [2.24, 4.21] ポイント (ζ との積の重みは開発用分割で選んだ 1.5), U2 で 5.96 [5.16, 6.75] ポイント下げた. 差は 5 つのベース検出器のどれに掛けても残る. U1 ではどの検出器を掛けても値がほとんど変わらず, 兄弟クラスの区別はほぼ画像側の証拠による. 伝播のみの構成の中では, u をそのまま使うと FPR95↓ が 38.09% であるのに対し, 尺度を補正した変種は 29.43–30.95% であり, 命題 1 と整合する.

OpenOOD v1.5 (表 2). TINS との積は near-OOD で AUROC↑ 96.30%, FPR95↓ 16.76% となった. TINS との差には DINOv2 特徴と 16 枚のラベルの効果が含まれるが, 同じ特徴による kNN [13], Mahalanobis++ [14], 入口のないメモリも上回る. その中で最も強い AdaNeg 型メモリより FPR95↓ が 12.40 [12.10, 12.69] ポイント低い.

再来の介入実験. 履歴 (ID 768 枚と OOD 256 枚) を固定し, その OOD のうち r 枚だけを評価するクラスの画像に入れ

替えて, AUROC↑ の変化を測った (図 2). 同じクラスの画像を 20 枚入れると, Salmon Ladder は 82.88% から 97.16% に上がる. メモリを使わない構成 (静的 $p \times p_{LP}$) の上昇を引いた値は +5.50 [+4.82, +6.28] ポイントである (区間は 250 組のブートストラップ). メモリ p_M は 1 枚目から上がり ($r=1$ で +3.98), 伝播 p_{LP} は近傍の数 $k_g=10$ に近づいてから上がる ($r=10$ で +7.93). これは式 (5) から予想されるとおりである. 1 枚の画像の弱い変形だけを入れた場合の上昇 (+10.54) は, 同じクラスの別の画像 (+14.28) より小さい. 最も遠い別の未知クラスを入れても変わらない (-0.05 [$-0.11, 0.00$]).

限界. 初出の画像 ($r=0$) では静的 p を下回り (82.88% と 84.20%), OOD が 1% のストリームではメモリの積み上げがない. ID が同じクラスごとに続けて届き, かつ OOD が 5% と少ないと, FPR95↓ は 47.07% に悪化する (ζ は 76.30%). 較正画像を入口の各段で使い回すので, 実装全体に共形の保証はない. ただしランダムな順のストリームでは, 名目 1% に固定した閾値での ID の誤警報率は 0.97% であった. 全節点を 0 から反復する伝播は, 較正画像とテスト画像の入れ替えに対する同変性を満たし, U1 の FPR95↓ をさらに 1.02 [0.83, 1.21] ポイント下げる. Salmon Ladder に固有の処理は画像あたり 0.21 ミリ秒である.

4 結論

未知クラスの再来を学習なしで利用する Salmon Ladder を提案した. 視覚メモリへの採用とラベル伝播をどちらも較正順位で扱い, 伝播の質量保存から, 成長するグラフでは順位による補正が必要であることを示した. 伝播のみの構成に対する改善は, 設計に用いていない 2 つの評価と 5 つのベース検出器で一貫し, 介入実験で再来に由来することを確かめた.

参考文献

- [1] A. Radford et al.: Learning transferable visual models from natural language supervision. *ICML*, 2021.
- [2] Y. Ming et al.: Delving into out-of-distribution detection with vision-language representations. *NeurIPS*, 2022.
- [3] X. Jiang et al.: Negative label guided OOD detection with pre-trained vision-language models. *ICLR*, 2024.
- [4] Y. Zhang and L. Zhang: AdaNeg: Adaptive negative proxy guided OOD detection with vision-language models. *NeurIPS*, 2024.
- [5] Y. Zhang et al.: Activation matters: Test-time activated negative labels for OOD detection with vision-language models. *CVPR*, 2026.
- [6] Y. Yang et al.: TINS: Test-time ID-prototype-separated negative semantics learning for OOD detection. arXiv:2605.10756, 2026.
- [7] J. Zhang et al.: OpenOOD v1.5: Enhanced benchmark for out-of-distribution detection. *J. Data-centric Mach. Learn. Res.*, 2024.
- [8] S. Bates et al.: Testing for outliers with conformal p-values. *Ann. Stat.*, 51(1):149–178, 2023.
- [9] D. Zhou et al.: Learning with local and global consistency. *NeurIPS*, 2004.
- [10] R. Andersen, F. Chung, and K. Lang: Local graph partitioning using PageRank vectors. *FOCS*, 2006.
- [11] M. Oquab et al.: DINOv2: Learning robust visual features without supervision. *Trans. Mach. Learn. Res.*, 2024.
- [12] D. Hendrycks et al.: Natural adversarial examples. *CVPR*, 2021.
- [13] Y. Sun et al.: Out-of-distribution detection with deep nearest neighbors. *ICML*, 2022.
- [14] M. Müller and M. Hein: Mahalanobis++: Improving OOD detection via feature normalization. *ICML*, 2025.

付録：追加実験の結果

設定は本文の凍結のまま (OpenOOD のテスト分割は不使用) . 値は単体の AUROC $\uparrow$ / FPR95 $\downarrow$ [%], 区間是对应のある 95% t 区間. 拡張は, Salmon Ladder の評価の後に開発用分割で選んで固定した読み出して, 同じバッチの採用画像も参照し, g_A の第 2 項を $\max\{0, 2 - (\rho_A(x) - \eta_M) / \sigma_M\}$ に替え, 伝播を 0 から反復する. 色と太字は改善を表す (Salmon Ladder は ζ から, 拡張は Salmon Ladder から. 区間が 0 を含まない). $\dagger$ は結果を見た後に追加.




図 3: 未知クラスの中での到着順ごとの見逃し率 (U1 の 45 本). 白抜きは, 出力したスコアを変えずに後のバッチのメモリとグラフで採点し直した値で, 全体の FPR95 は 26.27% から, 5 バッチ後に 24.59%, 終了時に 21.34% になる.

表 3: 到着時の証拠で分けた OOD (U1, [%]). R: 過去のバッチの同じクラスの画像がメモリにある, C: 同じバッチに同じクラスの採用画像がある, N1: 単独の初出, N+: 先に届いたが未採用. R 以外が R 並みでも全体の AUROC の上昇は +0.80.

		AUROC↑			見逃し率 ↓	
場合	割合	静的 p	ζ	Salmon Ladder	Salmon Ladder	拡張
R	94.66	85.70	92.94	94.66	23.93	23.34
C	1.10	84.14	86.45	85.85	53.75	38.76
N1	1.71	83.46	83.39	83.77	54.88	54.59
N+	2.54	61.43	80.07	74.32	82.89	81.11
全体	100	84.98	92.40	93.86	26.27	25.50

表 5: 特徴抽出器を替えたときの結果 (CLIP RN50 以外は ViT). パラメータ数 [百万] と 1 枚あたりの符号化時間 [ms] (RTX 2080 Ti, 単精度. CLIP の RN50 と B/16 は半精度) は画像側のエンコーダの値, NCM は支持画像 12 枚の平均による最近傍クラス平均の正解率 [%]. 下段は 2 つの特徴の積で, 1 行目が本文の構成. ViT-B/14 を DINOv3 ViT-L/16 に替えたときの FPR95 の差は, U1 で -5.44 [$-6.67, -4.20$], U2 で -5.75 [$-6.61, -4.90$] である (評価の前に登録した仮説).

特徴	パラメータ	時間	NCM	静的 p	U1 (AUROC $\uparrow$ / FPR95 $\downarrow$)			U2 (FPR95 $\downarrow$)		
					ζ	Salmon Ladder	拡張	ζ	Salmon Ladder	拡張
DINOv2 S/14	22	1.4	70.6	75.27 / 79.45	84.12 / 52.08	87.55 / 46.42	88.35 / 43.87	63.65	54.53	53.53
DINOv2 B/14	87	4.5	77.4	82.50 / 65.44	90.35 / 36.08	92.43 / 31.37	92.74 / 29.99	52.77	44.94	44.70
DINOv2 L/14	304	15.1	80.0	85.69 / 53.91	92.39 / 29.10	93.86 / 26.40	93.85 / 26.08	43.73	38.68	39.12
DINOv2 g/14	1136	55.9	79.0	85.06 / 52.87	91.82 / 29.83	93.45 / 27.84	93.07 / 28.94	46.37	43.58	42.62
DINOv3 S/16 $\dagger$	22	1.7	67.0	73.22 / 82.65	79.24 / 62.10	84.19 / 54.35	85.19 / 51.52	74.28	63.31	61.74
DINOv3 S+/16 $\dagger$	29	2.1	70.9	75.82 / 80.12	83.05 / 55.07	87.16 / 47.34	88.03 / 44.57	71.43	60.37	58.80
DINOv3 B/16	86	5.2	77.3	79.97 / 73.64	87.90 / 43.43	90.76 / 36.80	91.40 / 34.43	60.88	50.44	49.22
DINOv3 L/16	303	17.0	83.4	87.56 / 54.74	93.16 / 27.12	94.78 / 22.66	95.02 / 21.49	43.44	34.76	34.85
DINO B/16	86	3.5	68.2	73.19 / 79.41	82.46 / 51.19	86.02 / 47.92	86.71 / 46.20	64.73	57.62	57.01
MAE B/16	86	3.5	4.4	49.81 / 95.17	51.04 / 93.58	50.49 / 94.14	50.66 / 94.12	87.67	87.80	87.53
CLIP RN50 $\dagger$	38	0.7	51.0	59.49 / 91.22	65.50 / 78.41	71.09 / 77.31	71.91 / 76.02	76.13	69.52	69.13
CLIP B/16	86	1.3	63.1	63.09 / 90.75	72.41 / 67.91	78.91 / 64.92	79.32 / 64.52	72.37	63.53	65.35
CLIP L/14	304	16.2	73.0	66.99 / 90.34	77.45 / 59.18	84.24 / 54.06	84.31 / 54.93	69.18	57.50	61.42
SigLIP 2 L/16	316	15.8	81.3	71.09 / 88.25	82.52 / 48.96	89.45 / 40.70	89.40 / 41.44	61.06	45.63	49.68
DINOv2 B/14 $\times$ L/14	391	19.6	-	84.98 / 56.89	92.40 / 29.43	93.86 / 26.27	93.98 / 25.50	44.15	38.20	38.25
DINOv2 S/14 $\times$ B/14	109	6.0	-	80.39 / 70.55	89.44 / 38.68	91.57 / 34.17	92.04 / 32.24	53.65	45.76	45.18
DINOv2 S/14 $\times$ DINOv3 S/16 $\dagger$	44	3.1	-	75.12 / 80.09	83.92 / 53.03	87.39 / 46.50	88.27 / 43.75	66.09	54.96	53.85
DINOv2 S/14 $\times$ CLIP RN50 $\dagger$	60	2.1	-	70.83 / 83.99	82.27 / 55.15	85.88 / 51.28	86.74 / 48.80	63.15	52.98	52.20
DINOv2 S/14 $\times$ CLIP B/16	108	2.7	-	72.23 / 83.16	83.91 / 51.63	87.59 / 46.45	88.23 / 44.70	61.30	50.17	50.51
DINOv2 B/14 $\times$ CLIP B/16	173	5.8	-	78.22 / 74.11	89.26 / 38.36	91.49 / 34.51	91.81 / 33.21	52.25	43.17	43.85
DINOv2 L/14 $\times$ CLIP B/16	391	16.4	-	81.52 / 65.19	91.54 / 30.91	92.92 / 29.31	93.00 / 28.69	44.07	37.61	38.83
DINOv2 L/14 $\times$ g/14	1441	71.0	-	85.64 / 52.37	92.55 / 28.28	94.04 / 25.88	93.81 / 26.48	42.89	38.77	38.57
DINOv3 S/16 $\times$ S+/16 $\dagger$	50	3.8	-	74.96 / 80.98	82.49 / 56.14	86.65 / 48.59	87.57 / 45.65	71.33	59.78	58.10
DINOv3 B/16 $\times$ L/16	389	22.2	-	85.22 / 61.67	92.30 / 30.13	93.96 / 25.48	94.32 / 23.91	47.21	38.29	37.63
DINOv2 L/14 $\times$ DINOv3 L/16	608	32.1	-	87.77 / 51.09	94.01 / 24.38	95.23 / 20.83	95.34 / 20.24	38.16	32.44	32.49
CLIP B/16 $\times$ L/14	390	17.5	-	65.46 / 90.31	77.13 / 61.09	83.63 / 55.81	83.77 / 56.26	68.74	56.42	60.31

表 6: データセットを替えたときの結果. C は ID のクラス数, U は未知クラスの数, m は未知クラスあたりの枚数の中央値. 上段は各データの評価画像をすべて流した自然なストリーム, 下段は構成をそろえたストリーム (未知 40 クラス $\times$ 25 枚と ID 4,000 枚). k NN と Maha.++ は同じ特徴と同じ 16 枚による静的な検出器. 区間の単位は分割 (5 つ) で, SSB の CUB だけは順序 (3 つ) である.

データ	C	U	m	OOD [%]	kNN	Maha.++	静的 p	ζ	Salmon Ladder	拡張
ImageNet-Sketch	900	100	50	21.7	75.00 / 76.18	78.87 / 70.31	77.03 / 78.06	86.90 / 41.95	88.27 / 42.82	88.86 / 41.07
ImageNet-R	160	40	100	21.1	80.62 / 67.72	85.57 / 60.31	84.65 / 67.95	88.95 / 33.91	92.32 / 32.71	92.60 / 31.56
Places365	292	73	100	22.9	62.27 / 91.69	65.24 / 88.88	65.73 / 88.62	70.04 / 76.64	72.31 / 75.07	72.83 / 74.11
CUB-200	150	50	30	25.1	78.78 / 67.80	81.89 / 61.69	81.72 / 63.84	91.34 / 31.35	92.59 / 29.86	92.35 / 30.77
CIFAR-100	50	50	100	50.0	90.33 / 43.26	92.89 / 32.60	92.41 / 36.02	96.95 / 13.64	97.20 / 13.11	97.35 / 12.44
CUB (SSB, Easy)	100	32	30	24.1	91.56 / 31.58	93.99 / 27.43	93.39 / 28.42	98.28 / 6.99	98.57 / 6.05	98.61 / 6.08
CUB (SSB, Medium)	100	34	30	25.8	76.85 / 72.71	80.35 / 69.32	81.04 / 70.22	94.88 / 23.94	94.62 / 22.81	94.78 / 23.54
CUB (SSB, Hard)	100	34	30	25.6	68.54 / 83.55	71.75 / 81.94	71.87 / 81.13	89.78 / 46.59	90.52 / 45.98	89.56 / 52.51
ImageNet-1K (U1)	900	40	25	20.0	82.15 / 63.68	85.33 / 52.44	85.17 / 54.76	91.02 / 33.13	93.67 / 25.62	93.81 / 24.50
ImageNet-Sketch	900	40	25	20.0	75.25 / 75.37	79.24 / 69.42	77.43 / 77.51	84.02 / 47.26	86.79 / 45.35	87.58 / 42.82
ImageNet-R	160	40	25	20.0	80.56 / 68.11	85.41 / 60.49	84.45 / 68.17	85.70 / 44.69	89.79 / 42.63	90.44 / 39.99
Places365	292	40	25	20.0	61.78 / 92.16	65.12 / 89.38	65.62 / 89.14	67.55 / 81.71	70.40 / 78.11	71.32 / 75.93
CUB-200	150	40	25	20.0	78.77 / 66.97	81.69 / 60.79	81.56 / 63.13	90.66 / 33.33	91.81 / 31.31	91.59 / 32.19
CIFAR-100	50	40	25	20.0	90.18 / 43.89	92.78 / 33.31	92.29 / 36.91	93.18 / 27.81	94.79 / 22.94	94.93 / 22.29




図 5: ストリーム条件を変えたときの FPR95 (U1 の画像で構成, 5 分割の平均). (a) 未知 100 クラスが m 枚ずつと ID 18,000 枚がランダムに順に届く (帯は 95% 区間). $m=1$ では Salmon Ladder が静的 p より +4.70 [+0.34, +9.06] ポイント高い. (b) Salmon Ladder と静的 p の差 [ポイント]. (c) 未知 100 クラス $\times$ 50 枚と ID 18,000 枚で, 到着の順序だけを変えた (横線は 95% 区間. 静的 p は 56.39%). (d) OOD が同じクラスで続けて届くととき, バッチの大きさとの関係.