Salmon Ladder: Conformal Label Propagation for Transductive OOD Detection with Self-Labelled Seeds

表 紘太朗[1]　尾崎 慶次郎[2]

概要

OpenOOD v1.5 の near-OOD では，VLM の最良の報告値でも AUROC は 82.65%にとどまる．凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで，支持画像からの質量を 1 つのグラフで伝播させ，較正画像の中での順位（共形 p 値）で読む転導的な検知器 Salmon Ladder を提案する．学習なしの単体で near-OOD AUROC 97.94%・FPR95 11.50%，far-OOD 98.79%・5.17%，Four-OOD 98.80%・4.56%に達し，ImageNet-200 と CIFAR-100 でも最良値を更新した．再出現する未知は，偽発見率を制御する検定で自己ラベル付けした種から引き上げ，2 つの折の交差適合で読み出しも共形 p 値になる．種は再出現が多く混入率が中程度のときに効き，閾値の上限で害を抑える．コード：omotes24/SalmonLadder

1. はじめに

OOD 検知は, 学習時のクラス（ID）以外の入力を見分ける問題である．CLIP [1] などの VLM は学習なしに OOD を検知でき [2]，負例ラベル [3] やテスト時の適応 [4], [5], [6], [7] で far-OOD の AUROC は 97%に達したが, ID に近い near-OOD は難しい．OpenOOD v1.5 [8] の ImageNet-1K では，VLM による最良の報告値でも near-OOD の AUROC は 82.65%，FPR95 は 57.88%にとどまり [7]，ImageNet-1K のラベルで学習した検出器 [9], [10] や教師なし生成モデルの DisCoPatch [11] でも FPR95 は 29–48%残る（**表 1**）．

本研究は，凍結した特徴抽出器と ID クラスあたり 16 枚のラベル付き画像だけで，この残りを学習なしで減らす転導的な枠組み **Salmon Ladder** を提案する．支持画像・較正画像・テスト画像を節点とする 1 つのグラフの上で，支持画像に置いた質量を伝播させ，届いた質量を固定した較正画像の中での順位（**較正順位**）で読む．支持画像から遠く互いに近い未知の塊には質量が届かず，較正順位は AdaDetect [12] の意味での共形 p 値になる．この伝播だけで見出しの数字の大半が得られる（**表 2**）．その上で，テスト集合に同じ未知クラスの画像が複数枚含まれる（**再出現**）ときの拡張として，偽発見率を制御する多重検定で未知の側に偏った画像を自己ラベル付けして**種**にし，種に置いた質量を同じグラフで伝播させて同じクラスの残りの未知を引き上げる[*1]．較正画像とテスト画像を 2 つの折に分け，一方の折の種で他方の折を採点する**交差適合**により，種を含む読み出しの較正順位そのものが共形 p 値になる．

主たる設定はテスト集合が揃ってから全体を見て採点する**事後採点**（transductive）で，画像が順に届く**到着時採点**も示す（付録 A.6）．貢献は 4 点である．(1) **共形ラベル伝播**：グラフ上のラベル伝播を共形 p 値として読む検知器（命題 1–3）．学習なし・16 枚のラベルだけで，OpenOOD v1.5 ImageNet-1K の near-OOD で AUROC 97.94%，FPR95 11.50%（6 通りの抽出の平均，単体）を達成し，公開の最良値を AUROC で 2.89 ポイント，FPR95 で 17.90 ポイント更新した（**表 1**，付録 A.3 の**図 A·1**）．far-OOD と Four-OOD [13] でも最良で，ベース検出器との積（10.50%）や構成を固定したまま評価した ImageNet-200 と CIFAR-100 でも報告値の最良を上回る（4.6 節）．(2) **種と交差適合**：種は再出現（クラスあたり 10 枚以上）と混入率が中程度のときの拡張であり，ImageNet-1K の near-OOD で FPR95 を 0.86（単体）／1.65（×TINS）ポイント下げるが，ImageNet-200 と CIFAR-100 では効かない．効く範囲を再出現の枚数と混入率の格子で実測し（4.3 節），種の閾値に上限 τ を付けた規則（実行前に登録）は混入率が高いときの害をほぼ消し，ImageNet-200 の near-OOD で FPR95 を 9.07%から 6.91%にして p^+ だけ（7.45%）を下回る（4.4 節）．交差適合により読み出しが共形 p 値になり（命題 4），利用者は閾値を「ID の誤警報率 α」として直接指定できる．交換可能な設定での実測の誤警報率と偽発見割合は水準どおりである（4.5 節）．(3) **比較**：同じ特徴の静的な検出器，同じグラフ上のクラスラベル伝播（LGC-max），全

[1] 慶應義塾大学　総合政策学部 3 年
中澤・大越研究室 d-hacks　72402035
[2] 慶應義塾大学院　政策・メディア研究科

[*1] コード：`https://github.com/omotes24/SalmonLadder`

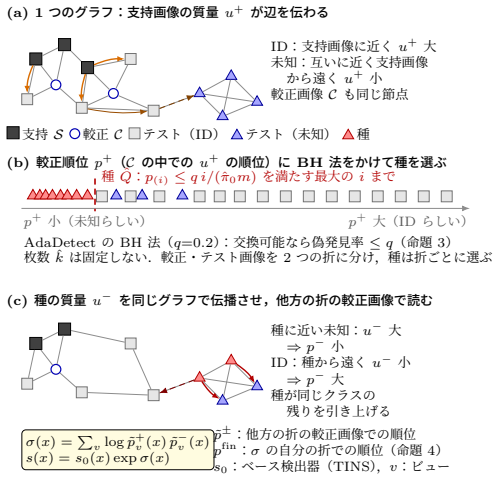


図 1 Salmon Ladder の概要．(a) 支持画像 $\mathcal{S}$・較正画像 $\mathcal{C}$・テスト画像 $\mathcal{T}$ を節点とする 1 つの k_g 近傍グラフで，支持画像に置いた質量 u^+ を伝播させる．(b) テスト画像の u^+ を $\mathcal{C}$ の中での順位 p^+（共形 p 値）に変え，偽発見率を制御する BH 法で棄却された画像を種 $\hat{Q}$ とする（折ごと）．(c) 種に置いた質量 u^- を同じグラフで伝播させ，他方の折の較正画像の中での順位に変えて足した統計量 σ を，自分の折の較正画像の中での順位 p^{fin} で読む．スコアは $s_0 \exp\sigma$（s_0 はベース検出器）．

学習画像を使う kNN とクラス平均，ゼロショットの MCM と NegLabel との比較で利得の出どころを切り分け（**表 2**，4.6 節），4 つのベース検出器と 6 つの特徴抽出器で確かめる（付録 A.5）．(4) **事前登録**：構成は開発用分割の事前登録した規則で選んでテスト集合では変えず（3 節），登録からの 1 つの逸脱（ベース検出器との積の形）と探索の履歴を開示する．

2. 提案手法

2.1 問題設定と全体像

ID の各クラス c に 16 枚のラベル付き画像が与えられ，12 枚を支持画像 $\mathcal{S}_c$，4 枚を較正画像とする（全体を $\mathcal{S}$，$\mathcal{C}$，$n = |\mathcal{C}| = 4{,}000$）．テスト集合 $\mathcal{T}$ は ID と OOD が混ざったラベルなしの画像の集合で，各画像 $x \in \mathcal{T}$ にスコア $s(x)$（大きいほど ID らしい）を返す．主たる設定は $\mathcal{T}$ の全画像が揃ってから採点する**事後採点**（transductive）で，画像が届くたびに採点する**到着時採点**は付録 A.6 で扱う．特徴抽出器 f は凍結し，モデルは更新しない．Salmon Ladder は次の 4 つの部品からなる（**図 1**）．

(1) **較正順位**：ID らしさの値を，固定した較正画像の中での順位に変えて読む（2.2 節）．すべての部品の共通の物差しで，共形 p 値である．

(2) **支持画像からの質量** u^+：支持画像・較正画像・テスト画像を節点とする 1 つのグラフ上で支持画像に置いた質量を伝播させ，較正順位 p^+ で読む（2.3 節）．

(3) **未知からの質量** u^-：p^+ に偽発見率を制御する多重検定（AdaDetect [12] の意味での BH 法）をかけて未知の側に偏った画像の集合 $\hat{Q}$（種）を自己ラベル付けし，種の質量を同じグラフで伝播させて較正順位 p^- で読む（2.4 節）．

(4) **交差適合**：較正画像とテスト画像を 2 つの折に分け，一方の折の種で他方の折を採点した統計量 σ を作る（2.5 節）．σ の自分の折での較正順位 p^{fin} は共形 p 値で，ID の誤警報率と BH 法の偽発見率が保証される（命題 4）．

スコアは $s(x) = s_0(x)\exp\sigma(x)$ で，s_0 は任意のベース検出器である（2.6 節）．判定には p^{fin} を使う．

2.2 較正順位：固定した較正画像の中での順位

ID らしさを表す値 $a(x)$（小さいほど OOD らしい）を，較正画像の集合 $\mathcal{C}'$（$n' = |\mathcal{C}'|$）を同じ方法で採点した値の中での順位

$$p(x) = \frac{1 + |\{x' \in \mathcal{C}' : a(x') \le a(x)\}|}{n' + 1} \in \left[\frac{1}{n'+1}, 1\right] \tag{1}$$

で読む（**較正順位**）．較正画像と ID のテスト画像が交換可能で，a が両者を対称に扱うなら，これは $\Pr(p(x) \le \alpha) \le \alpha$ を満たす共形 p 値 [12], [14] であり，閾値 α で OOD と判定したときの ID の誤警報率は α 以下になる．大きいほど OOD らしい値は不等号を逆にして読む（式 (8)）．順位は $[0,1]$ の値なので尺度の違うビューどうしの積が取れる（$1/(n'+1)$ 刻みの粒度は 2.4 節）．

2.3 支持画像からの質量：ラベル伝播のグラフ

2.3.1 グラフの構成

支持画像 $\mathcal{S}$，較正画像 $\mathcal{C}$，テスト画像 $\mathcal{T}$ のすべてを節点とする（節点数 $N = |\mathcal{S}| + |\mathcal{C}| + |\mathcal{T}|$）．各節点 i から，コサイン類似度 $f(x_i)^\top f(x_j)$ が上位 k_g=10 の節点 j へ向かう辺を張り，重みを $a_{ij} = \max(f(x_i)^\top f(x_j), 0)$ とする（行列 A）．向きのない辺にするために $W = \max(A, A^\top)$（成分ごとの最大）とし，次数 $\delta_i = \sum_j W_{ij}$，$D = \mathrm{diag}(\delta_i)$，正規化した行列

$$S = D^{-1/2} W D^{-1/2} \tag{2}$$

を作る [15]．S は対称で固有値は $[-1, 1]$ にあり，非零成分は $O(Nk_g)$ の疎行列である．較正画像とテスト画像はどちらもラベルを持たない節点として全く同じ扱いを受け，グラフは節点の順序や名札に依らない（**図 2**a）．グラフはビューごとに 1 つ作り，2 つの質量を同じグラフで伝播させる．

2.3.2 伝播の反復とランダムウォークとしての意味

支持画像の節点で 1，他で 0 のベクトル $\mathbf{y}^+ \in \{0,1\}^N$ と λ=0.9 で

$$\mathbf{u}^{(\ell+1)} = \lambda S \mathbf{u}^{(\ell)} + (1-\lambda)\mathbf{y}^+ \tag{3}$$

を収束するまで反復する（$\mathbf{u}^{(0)} = \mathbf{0}$；局所・大域一貫性 [15] の反復）．$\lambda < 1$ かつ $\|S\|_2 \le 1$ なので縮小写像であり，収束解 $\mathbf{u}^+ = (1-\lambda)\sum_{\ell \ge 0} \lambda^\ell S^\ell \mathbf{y}^+$ を持つ．$(S^\ell \mathbf{y}^+)_i$ は節点

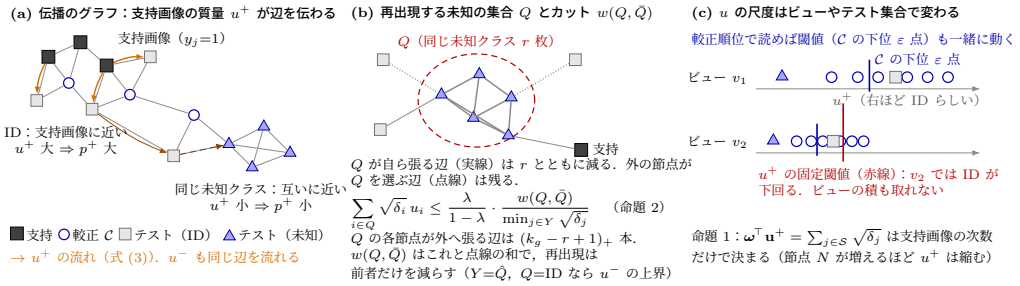


図 2 ラベル伝播のグラフ．(a) 節点は支持画像・較正画像・テスト画像で，各節点をコサイン類似度の上位 k_g 個と結ぶ．支持画像に置いた質量 $\mathbf{y}^+$ が辺を伝わり（式 (3)），支持画像に近い ID 画像には多く，互いに近い同じ未知クラスの画像には少ししか届かない．種に置いた質量 $\mathbf{y}^-$ も同じ辺を伝わる．(b) 初期質量を置いた節点を含まない集合 Q に届く質量は，Q と外とを結ぶ辺の重みの和 $w(Q,\bar{Q})$ で上から抑えられる（命題 2）．これには Q の節点が自ら張る辺（実線）と外の節点が Q へ張る辺（点線）が入り，同じ未知クラスが r 枚そろうと前者は減るが後者は残り得る．(c) 質量の総和は支持画像の次数だけで決まるので（命題 1）u の尺度はビューやテスト集合ごとに違うが，較正画像の u も同じ尺度で動くので，較正順位で読めば閾値もビューの積も同じ物差しに乗る．

i と支持画像を結ぶ長さ ℓ の歩道の重みの和なので，u_i^+ は「短い歩道で支持画像とつながる節点ほど大きい」量である．ランダムウォークで言えば，$P=D^{-1}W$ を遷移確率とし，各ステップで確率 $1-\lambda$ で止まるランダムウォークを節点 i から始めたとき，

$$\frac{u_i^+}{\sqrt{\delta_i}}=\mathbb{E}_i\Big[\frac{\mathbf{1}[X_T\in\mathcal{S}]}{\sqrt{\delta_{X_T}}}\Big] \tag{4}$$

である（X_T は止まった節点．$S^\ell=D^{1/2}P^\ell D^{-1/2}$ から従う）．支持画像に近い ID 画像からは数歩で支持画像に着くので u^+ は大きく，互いに近い未知の塊からは支持画像へ出る辺が少ないので u^+ は小さい（**図 2**a）．

2.3.3 較正順位による読み出し

較正画像はグラフの節点であり（$y^+=0$），同じ反復で u^+ を受け取るので，$\mathcal{C}'$ を参照する較正画像の集合として

$$p^+(x)=\frac{1+|\{x'\in\mathcal{C}':u^+(x')\le u^+(x)\}|}{|\mathcal{C}'|+1} \tag{5}$$

とする．u^+ は支持画像の特徴と「較正画像とテスト画像を合わせた集合」だけで決まり，その集合の中の節点を入れ替えても各画像の値は変わらない（置換不変性）．したがって較正画像と ID のテスト画像が交換可能なら，p^+ は AdaDetect [12] の経験 p 値で，ID のテスト画像について超一様である．p^+ だけでも検知器として完結し（**表 2** の「p^+ のみ」），以下の種は再出現する未知のための拡張である．

2.3.4 質量の保存とカットの上界

命題 1（質量の保存）． $\boldsymbol{\omega}=D^{1/2}\mathbf{1}$ とすると，式 (3) を $\mathbf{u}^{(0)}=\mathbf{0}$ から L 回反復した値は $\boldsymbol{\omega}^\top\mathbf{u}^{(L)}=(1-\lambda^L)\sum_{j\in\mathcal{S}}\sqrt{\delta_j}$ を満たし，収束解では $\boldsymbol{\omega}^\top\mathbf{u}^+=\sum_{j\in\mathcal{S}}\sqrt{\delta_j}$ である（証明は付録 A.1）．右辺は支持画像の次数だけで決まる．重みづけた質量の総和がテスト画像の枚数に依らず一定なので，1 節点あたりの u^+ の尺度はテスト集合やビューごとに変わり（**図 2**c），値をそのまま閾値にかけたりビューどうしで掛けたりはできない．較正順位式 (5) がこの尺度を取り除く．**命題 2（カットの上界）．** 初期質量を置いた節点の集合 Y を含まない節点の集合 Q について，Q と外とを結ぶ辺の重みの和を $w(Q,\bar{Q})=\sum_{i\in Q,\,j\notin Q}W_{ij}$ とすると，収束解 $\mathbf{u}$ は

$$\sum_{i\in Q}\sqrt{\delta_i}\,u_i\le\frac{\lambda}{1-\lambda}\cdot\frac{w(Q,\bar{Q})}{\min_{j\in Y}\sqrt{\delta_j}} \tag{6}$$

を満たす（証明は付録 A.1）．$W=\max(A,A^\top)$ なので，$w(Q,\bar{Q})$ には Q **の節点が自ら張る辺**と**外の節点が** Q **へ張る辺**の両方が入る（**図 2**b）．$Y=\mathcal{S}$，Q を同じ未知クラスの r 枚とし，それらが互いの近傍の上位を占めるなら，前者は節点あたり $(k_g-r+1)_+$ 本に減り，$r\ge k_g$ で尽きる．後者は外の節点が Q の画像を近傍に選ぶかどうかで決まる．命題 2 が言うのは「再出現が自ら張る辺を減らす分だけ上界が下がる」ことで，残りは外から入る辺の分である（r と k_g を変えた実測は 4.3 節と付録 A.10）．

2.4 未知からの質量：自己ラベル付けと負の伝播

2.4.1 種の選択：AdaDetect の意味での BH 法

p^+ は，ID のテスト画像について超一様な p 値である．そこで「x は ID である」を帰無仮説とする m' 個の検定（m' は対象のテスト画像の数）とみなし，偽発見率（FDR：選んだ集合に混じる ID の割合の期待値）を水準 q に抑える選び方で未知の集合 $\hat{Q}$ を選ぶ．Benjamini–Hochberg（BH）法 [16] は，$p_{(1)}\le\cdots\le p_{(m')}$ を p^+ の昇順として $p_{(i)}\le q\,i/m'$ を満たす最大の i まで棄却する．本稿は ID の割合 π_0 を推定して水準を $q/\hat{\pi}_0$ に上げる Storey 型 [17] を用い，$\lambda_{\mathrm{S}}=K/(n'+1)$（$K=\lfloor n'/2\rfloor$）として

$$\hat{\pi}_0=\frac{1+|\{x:p^+(x)\ge\lambda_{\mathrm{S}}\}|}{m'\,(1-\lambda_{\mathrm{S}})},\quad \hat{k}=\max\{i:p_{(i)}\le\tfrac{q\,i}{\hat{\pi}_0 m'}\} \tag{7}$$

とし，p^+ が小さい方から $\hat{k}$ 枚の画像の集合 $\hat{Q}$ を**種**と呼ぶ．

本稿の構成は q=0.2 で，単純な BH 法（$\hat{\pi}_0$=1）も候補にして開発用分割で比べた（3 節）．枚数 $\hat{k}$ は未知の量と p^+ の分布から決まる．

命題 3（偽発見率，AdaDetect [12]）．較正画像 $\mathcal{C}'$ と ID のテスト画像が交換可能なら，(i) 水準 q の BH 法（$\hat{\pi}_0 = 1$）で選んだ $\hat{Q}$ の FDR は $q\,m'_0/m' \le q$ 以下，(ii) 式 (7) の Storey 型で選んだ $\hat{Q}$ の FDR は q 以下である（m'_0 は ID のテスト画像の数）．**証明．**AdaDetect の枠組みでは，スコア関数が「帰無の学習標本」（本稿の支持画像）と「較正標本とテスト標本を合わせた集合」から作られ，後者の中での置換に対して不変であることだけを要求する（同論文の条件 (8)）．u^+ は 2.3 節で述べたとおりこの不変性を満たし，式 (5) は同論文の経験 p 値 (10) である．よって同論文の定理 3.3 により p^+ は帰無仮説のもとで PRDS（正の回帰従属性）かつ超一様であり，系 3.5 が (i) を，$\lambda_{\mathrm{S}} = K/(n'+1)$，$K \in \{2,\dots,n'\}$ に対する系 3.7 が (ii) を与える．□

較正画像（学習画像）と ID のテスト画像（検証画像）は厳密には交換可能ではなく，実際に混じる ID の割合は 4.5 節で報告する．**順位の粒度．**p^+ の最小値は $1/(n'+1)$ なので，種が 1 枚でも選ばれるには最小値を取る画像が $\hat{\pi}_0 m'/(q(n'+1))$ 枚以上要る（2.5 節の折では n'=2,000，q=0.2 なら折のテスト画像の約 0.25%）．未知がそれより少なければ種は選ばれず，$p^- \equiv 1$ として p^+ だけの読み出しに戻る（4.3 節）．**種の数の上限．**命題 3 が抑えるのは種に混じる ID の**割合**であり，未知が大半を占めるテスト集合では割合 q の種が ID のほぼ全数になる（4.6 節）．そこで，step-up の臨界値を $c_i = \min(q\,i/m', \tau)$（Storey 型では $q/\hat{\pi}_0$）に置き換えた規則も用意する（4.4 節）．棄却された p はすべて τ 以下なので種に混じる ID の**数**の期待値は $\tau m'_0$ 以下であり，単純 BH 法では $p \le q\,i^*/m'$（i^* は棄却数）も満たすので，PRDS のもとで自己整合な手続きとして FDR$\le q\,m'_0/m'$ が保たれる [18]．τ=0.05 は選ばずに固定した．

2.4.2　負の質量とその読み出し

種で 1，他で 0 のベクトル $\mathbf{y}^- = \mathbf{1}_{\hat{Q}}$ を初期質量とし，同じグラフ・同じ λ で式 (3) を収束まで反復した値を $\mathbf{u}^-$ とする．式 (4) と同様に，$u_i^-/\sqrt{\delta_i}$ は節点 i から出たランダムウォークが種で止まる確率である．種は未知なので，u^- は**大きいほど未知らしい**．較正画像も同じ反復で u^- を受け取るので，不等号を逆にした較正順位

$$p^-(x) = \frac{1 + |\{x' \in \mathcal{C}' : u^-(x') \ge u^-(x)\}|}{|\mathcal{C}'| + 1} \qquad (8)$$

で読む．命題 2 を $Y = \hat{Q}$，Q を種を含まない ID の画像の集合として適用すると，ID に届く負の質量の総和は ID と種を隔てるカットで上から抑えられる．ID の画像どうしは支持画像を介して密につながり種とは疎にしかつながらないので，u^- は ID には小さく，種のまわりの同じ未知クラスの画像には大きい（**図 2**a）．種が選ばれなかったときは $p^- \equiv 1$ とする．p^+ だけでは支持画像に比較的近い未知（ID の兄弟クラスなど）が取り逃されるが，そのクラスのうち支持画像から遠い画像は命題 3 の意味で誤りを抑えながら種として選ばれ，種の質量がクラス内の密な辺を通って残りへ流れる．

2.5　交差適合：最終スコアを共形 p 値にする

種 $\hat{Q}$ は p^+ から選んだので p^- は p^+ と同じテスト画像に依存し，両者の積に命題 3 の形の保証は直接には出ない．そこで，較正画像とテスト画像を，画像とは独立に等確率で 2 つの**折** $b \in \{1,2\}$ に分ける（$\mathcal{C} = \mathcal{C}_1 \sqcup \mathcal{C}_2$，$\mathcal{T} = \mathcal{T}_1 \sqcup \mathcal{T}_2$，$n_b = |\mathcal{C}_b| = 2{,}000$）．グラフと u^+ は全画像で 1 つのままである．折 b の種 $\hat{Q}_b$ は，$\mathcal{T}_b$ の画像の p^+ を $\mathcal{C}' = \mathcal{C}_b$ で読んだ値に式 (7) をかけて選び（命題 3 が折ごとに成り立つ），その質量 $\mathbf{u}_b^-$ を伝播させる．折 b の節点 $x \in \mathcal{C}_b \cup \mathcal{T}_b$ は，**他方の折** $\bar{b}$ の較正画像と種で採点する：$\tilde{p}_v^+(x)$ を $u_v^+(x)$ の $\mathcal{C}_{\bar{b}}$ の中での順位式 (5)，$\tilde{p}_v^-(x)$ を $u_{\bar{b},v}^-(x)$ の $\mathcal{C}_{\bar{b}}$ の中での逆順位式 (8) として

$$\sigma(x) = \textstyle\sum_v \big[\log \tilde{p}_v^+(x) + \log \tilde{p}_v^-(x)\big], \qquad p^{\mathrm{fin}}(x) = \frac{1 + |\{x' \in \mathcal{C}_b : \sigma(x') \le \sigma(x)\}|}{n_b + 1} \qquad (9)$$

とする．σ は折 b の較正画像とテスト画像を全く同じ手続きで採点し，p^{fin} はその値を**自分の折**の較正画像の中での順位で読む．

命題 4（最終読み出しの保証）．折 b の較正画像 $\mathcal{C}_b$ と $\mathcal{T}_b$ の ID の画像が，他のすべての画像を所与として交換可能なら，(i) $\mathcal{T}_b$ の各 ID 画像 x について $\Pr(p^{\mathrm{fin}}(x) \le \alpha) \le \alpha$，すなわち閾値 α で OOD と判定したときの ID の誤警報率は α 以下である．(ii) $\{p^{\mathrm{fin}}(x) : x \in \mathcal{T}_b\}$ は ID の画像の上で PRDS であり，これに水準 q の BH 法をかけて選んだ集合の FDR は $q\,m_{0,b}/m_b \le q$ 以下，Storey 型（$\lambda_{\mathrm{S}} = K/(n_b+1)$）では q 以下である．**証明の要点．**σ は，$\mathcal{C}_b \cup \mathcal{T}_b$ の中でどの節点を較正画像と呼ぶかを入れ替えても変わらない（グラフと $\mathbf{u}^+$ は節点の名札に依らず，$\hat{Q}_{\bar{b}}$ と $\mathbf{u}_{\bar{b}}^-$ は折 $\bar{b}$ の画像から決まる）．これは AdaDetect の条件 (8) であり，p^{fin} は同論文の経験 p 値 (10) なので，定理 3.3 と系 3.5・3.7 が従う（付録 A.1）．

命題 3 との違いは，保証の対象が種ではなく**返す読み出しそのもの**であることにある．p^{fin} は折ごとに有効な共形 p 値なので，利用者は「ID の誤警報率 α」という閾値を調整なしに直接指定できる．順位付け（AUROC，FPR95）には σ を使い，p^{fin} はその単調変換なので折の中では同じ順序を与える．p^{fin} は $1/(n_b+1)$ 刻みで，σ が較正画像の最小値を下回る画像（未知の大半）はすべて同じ最小値になる（床）．この床のために，ベース検出器との積は p^{fin} ではなく σ で取る（2.6 節）．代価は参照する較正画像が

n_b=2,000 枚に半減することと，種が各折のテスト画像だけから選ばれることで，影響は 4.2 節と 4.3 節で実測する．他方の折の種で採点する手続きは，局外関数を一方の標本で推定し他方で評価する**交差適合**（cross-fitting） [19] と同じ構造である．

2.6 スコアと枠組み

$s(x) = s_0(x)\exp\sigma(x)$ を返す．特徴抽出器ごとの値を**ビュー** v と呼び，ビューごとにグラフと種を持ち，式 (9) の和で合わせる．s_0 はベース検出器で，s_0=1 を**単体**と呼ぶ．ベース検出器は較正画像のスコアを持たない（テスト画像にしか付かない）ので較正順位に変えられず，σ との積で合わせる．事前登録では p^{fin} との積を予定していたが，p^{fin} の床の上ではベース検出器の対数スコアが順序を決めてしまうため σ に替えた（4.2 節；登録文書の修正記録に開示）．本稿の構成は，DINOv2 [20] ViT-L/14 と DINOv3 [21] ViT-L/16 の 2 ビュー，Storey 型の種，q=0.2 で，3 節の規則で開発用分割から選んだ．ベース検出器には TINS [7]（CLIP ViT-B/16）を用い，NegLabel，AdaNeg，TANL に差し替えた値も示す．グラフも種も VLM には依らない．計算は，ビューごとに厳密な k_g 近傍探索と疎行列と密ベクトルの積 $O(Nk_g)$ の反復 3 回で，OpenOOD の 1 つのテスト集合（$N \approx$ 6–11 万）に 1 枚の GPU で 1 分以内である．

2.7 関連する枠組みとの関係

半教師あり新奇性検知．ラベル付きの ID 標本と未知が混じったラベルなし標本から未知を見分ける設定は Scott と Blanchard [22], [23] が定式化した．本稿は同じ設定を凍結特徴の上のグラフとラベル伝播で解く．**共形 p 値による OOD 検知．**Bates ら [14] は固定したスコアの較正順位が共形 p 値になることと BH 法での FDR 制御を示し，Haroush ら [24]，Liang ら [25] もスコアはテスト集合に依らない．AdaDetect [12] は帰無の学習標本と混合標本から学んだ置換不変なスコアに交換可能性だけで FDR 制御を与える枠組みで，本稿の p^+ と p^{fin} はその特別な場合である．違いは，スコアが 16 枚のラベルで動くグラフ上のラベル伝播であること，棄却集合（種）から第 2 段の伝播 p^- を起こすこと，交差適合で第 2 段を含む読み出しを再び共形 p 値にすることである．**ラベル伝播と転導的推論．**局所・大域一貫性 [15] や TPN [26] はクラスラベルを伝播させ，閉集合を仮定してクラスへ割り当てる．本稿はクラスを割り当てず，「ID である」質量と「未知である」質量の 2 本だけを伝播させる．クラスラベル伝播の最大質量を較正順位で読む LGC-max を同じグラフで実測して比べる（4.2 節）．**テスト時適応の OOD 検知．**AdaNeg [4]，OODD [27]，TANL [5]，TINS [7] はテスト画像の特徴や負例を蓄えて到着順に適応し，RTL [28] はテストバッチ上の回帰で既存スコアを補正し，AUTO [29] は選んだテスト画像でモデルを更新する．いずれも誤警報率や FDR の保証を持たない．本稿は何も更新せず，テスト集合の情報をグラフの辺と種としてだけ使い，クラスの擬似ラベルは付けず（種は「ID でない」という 1 ビット），未知クラスの数も形も仮定しない．テスト集合全体を見られる分の有利は，同条件の静的検出器と LGC-max，全学習画像を使う基線，到着時採点モードで埋める．

3. 実験設定

ベンチマーク．評価は OpenOOD v1.5 [8] の ImageNet-1K ベンチマークに従う．ID は ImageNet-1K の検証画像 45,000 枚，near-OOD は SSB-hard と NINCO，far-OOD は iNaturalist，Textures，OpenImage-O である．Four-OOD [13] は検証画像 50,000 枚に対する iNaturalist, SUN, Places，Textures である．OOD データセットごとに ID と混ぜた集合を 1 つのテスト集合とし，指標は AUROC と，ID の 95%を受け入れる閾値での OOD の誤受理率 FPR95 である．ImageNet-200（ID は 200 クラスの検証画像 9,000 枚；OOD は同じ 5 データセット）と CIFAR-100（near-OOD は CIFAR-10 と Tiny ImageNet, far-OOD は MNIST, SVHN, Textures，Places365）の OpenOOD v1.5 ベンチマークでも，構成を固定したまま単体で評価する（4.6 節）．

ラベル付き画像とその抽出．クラスあたり 16 枚（支持 12 枚，較正 4 枚）を ID の学習画像から取る．抽出は 6 通り（ベース検出器の 16 枚と同じ 1 通りと，重ならない 5 通り）で，表の値はその平均，本文の区間は抽出を単位とする対応のある 95% t 区間である．事後採点のスコアは画像の順序に依らない．ベース検出器は到着順に依存するので，× ベース検出器の値はさらに OpenOOD で 5 通り，Four-OOD で 3 通りの順序の平均である．

構成の選び方（事前登録）．k_g=10, λ=0.9 は，ImageNet-1K の学習画像だけから作った開発用分割（900 クラスを ID，残りを未知とする 2 つの分割 dev1，dev2）で以前に決めた値を凍結して用いる．構成の選択は 2 段階とも開発用分割で行い，規則「dev1 の near-OOD の FPR95 を最小にする．ただし dev1 の far-OOD の FPR95 が参照構成より 0.5 ポイント以上悪化しない」をテスト集合の計算前に登録した（dev2 は確認用）．第 1 段はビューの組（8 通り）$\times q \in \{0.05, 0.1, 0.2\}$ の 24 候補から DINOv2 L/14 + DINOv3 L/16，q=0.2 を，第 2 段は種の規則 {Storey 型，単純 BH} $\times q\times$ 統計量 $\{p^+p^-,\ p^+p^-\times$ 静的 $p,\ \min(\cdot)\}$ の 18 候補から Storey 型・q=0.2・p^+p^- を選んだ（dev1 near FPR95 13.55%，参照 14.10%；付録 A.7）．登録文書は SHA-256 とともに計算サーバに実行前に置き（ファイル時刻と実行ログ），公開リポジトリには本稿の執筆時にコミットした．追加実験（4.4 節，4.6 節の全学習画像の基線，付録 A.10 の k_g の格子）の登録文書は評価の実行前に

公開リポジトリにコミットし，そのコミット時刻が第三者の確認できる時刻である（付録 A.12）．ベース検出器は報告値が最良の VLM 手法 TINS [7]（CLIP ViT-B/16）で，本稿の実験では選んでいない．登録は p^{fin} とベース検出器の積を予定していたが，テスト集合の値を見て σ との積に替えた（2.6 節，4.2 節）．これは登録からの逸脱であり，単体の値は登録どおりである．v16 までの版で候補の集合を決めるまでにテスト集合上の探索を行ったことも開示し，その表を付録 A.8 に示す．

比較手法．公開されている値は報告値（†）を用い，公式実装のある NegLabel，AdaNeg，TANL，TINS は同じテスト集合で実測した．これらは到着順に採点するテスト時適応の手法なので，(i) 同じ特徴と同じ 16 枚で動く静的な検出器（静的 p：支持画像 12 枚の平均を原型とし，最も近い原型への余弦類似度の較正順位；kNN [30]：支持画像への k 近傍（k=10）の類似度の較正順位），(ii) 同じグラフ上で支持画像のクラスラベルを伝播させ最大のクラス質量を較正順位で読む LGC-max [15], [26]，(iii) 伝播だけの読み出しを同じテスト集合・同じ 6 通りの抽出で実測し（**表 2**），(iv) 到着時採点モードも示す（付録 A.6）．ImageNet-200 と CIFAR-100 では，同じ 2 つの特徴で全学習画像を使う kNN（k=50）とクラス平均，CLIP ViT-B/16 のゼロショットの MCM [2] と NegLabel（公式実装）も実測する（4.6 節）．6 つの単一ビュー（CLIP ViT-B/16 と DINO (v1) [31] を含む）の値は付録 A.5 に示す．

4. 結果

4.1 OpenOOD v1.5 ImageNet-1K（表 1）

単体（主結果）．ベース検出器を使わない Salmon Ladder は，**表 1** の 6 列すべてで報告値の最良を上回る．near-OOD では AUROC 97.94%，FPR95 11.50%（抽出を振った 95% 区間 [11.20, 11.81]）で，報告値の最良である DisCoPatch（95.05%，29.40%）を AUROC で 2.89 ポイント上回り，FPR95 を 17.90 ポイント（2.6 分の 1 に）下げた．far-OOD では AUROC 98.79%，FPR95 5.17%で，ラベルで学習した検出器の最良（NNGuide, 97.80%, 9.87%）を FPR95 で 4.70 ポイント下回り，Four-OOD では AUROC 98.80%，FPR95 4.56%で，報告値の最良である TINS（98.51%，6.72%）を下回る．抽出による幅は FPR95 で 1 ポイント程度である．**データセット別**（付録 A.3）では，9 データセットの 18 列のうち 17 列で本手法が報告値の最良を上回る．残る 1 列は SSB-hard（ID の兄弟クラス）の FPR95 で，×TINS の 19.96%は DisCoPatch（95.8%／19.8%）より 0.16 ポイント高いが，抽出による 95%区間 [19.53, 20.40] は 19.8%を含み，AUROC（96.51%）は 0.71 ポイント上回る．NINCO（64 クラス）では FPR95 1.03%で，DisCoPatch（39.0%）を 37.97 ポイント下回る．

ベース検出器との積（登録外の形）．ベース検出器 s_0 は $s_0 \exp \sigma$ の形で掛ける．事前登録では $p^{\mathrm{fin}} \times s_0$ を予定していたが，テスト集合で near-OOD の FPR95 が 13.25%と単体より悪化したのを見て σ に替えた（原因は p^{fin} の床，2.6 節；両方を**表 2** に示す）．TINS との積は near-OOD AUROC 98.09%，FPR95 10.50%，far-OOD 99.05%，4.16%，Four-OOD 99.09%，3.39%で，報告値の最良を near-OOD の FPR95 で 18.90 ポイント，Four-OOD の TINS の FPR95 をほぼ半分に下げる．NegLabel，AdaNeg，TANL との積もすべての列で報告値を上回り，同じテスト集合で実測した各ベース検出器の near-OOD の FPR95（56.37–75.90%）を 45.56–64.97 ポイント下げる．

4.2 利得の出どころ：同じ特徴での比較（表 2）

特徴とラベルの分．同じ 2 つの特徴抽出器と同じ 16 枚で動く静的な検出器は，near-OOD の FPR95 が ×TINS で静的 p 47.27%，kNN 51.34%，単体で 54.36%，59.51%であり，報告値の最良（29.40%）に及ばない．**伝播の分．**p^+ だけで FPR95 は 12.36%（単体），12.14%（×TINS）になり，見出しの数字の大半はこの共形ラベル伝播による．**転導的なクラスラベル伝播．**同じグラフでクラスラベルを伝播させる LGC-max は 19.52%（単体），18.04%（×TINS）で，静的な検出器よりは良いが p^+ に遠く及ばない．閉集合を仮定する伝播は未知を近い ID クラスへ引き寄せる．**種の分．**種からの質量 p^- を加えた σ は 11.50%（単体），10.50%（×TINS）で，p^+ だけとの差は単体で-0.86 [-1.05, -0.67]，×TINS で-1.65 [-1.77, -1.52] ポイント（抽出を単位とする対応のある 95% t 区間）．far-OOD と Four-OOD でも種は FPR95 を下げる．**交差適合の代価．**交差適合なしの p^+p^-（v16 までの読み出し）に対する σ の差は，near-OOD で単体 0.12 [0.03, 0.20]，×TINS 0.24 [0.13, 0.35] ポイント，far-OOD で-0.05，Four-OOD で-0.12 ポイントと改善する．**p^{fin} をそのままスコアにした場合．**単体では 11.52%と σ と同じだが，TINS との積は 13.25%（σ より 1.73 ポイント悪化），Four-OOD では逆に 2.95%と良い．p^{fin} の床（2.5 節）の上ではベース検出器が順序を決めるので，TINS が弱い near-OOD で悪化し，強い Four-OOD で改善する．**種の規則と統計量．**種を単純な BH 法で選ぶと 11.00%（単体），10.29%（×TINS）で，テスト集合では Storey 型よりわずかに良い（開発用分割では逆，付録 A.7）．σ に静的 p を加えると，near-OOD は 12.16%（×TINS）と悪化し，far-OOD では 3.69%と改善する（**表 A·11**）．

4.3 再出現と混入率（図 3）

同じクラスが何枚あり，どの混入率から効くのかを，OpenOOD の ID の検証画像 45,000 枚に，NINCO（64 クラス）または SSB-hard（980 クラス，各 50 枚）から c 個の未知クラスを r 枚ずつ加えたテスト集合で実測した（**図 3**，

表 1　OpenOOD v1.5 ImageNet-1K と Four-OOD（[%]）．† は原論文の報告値（近／遠の平均は本稿で計算）．実測値は同じテスト集合での値（到着順は OpenOOD で 5 通り，Four-OOD で 3 通りの平均）．本手法は抽出 6 通りの平均（× ベース検出器の行は順序の平均も取る）．★ は列の最良値，青 は比較手法のすべてを上回る値，括弧の行は最良の比較手法との差（正は本手法が良い）．

手法	OpenOOD near-OOD AUROC↑	FPR95↓	OpenOOD far-OOD AUROC↑	FPR95↓	Four-OOD AUROC↑	FPR95↓
ImageNet-1K のラベルで学習した検出器（報告値 †，近／遠の平均は本稿で計算）						
MOODv2 [10]（BEiTv2）	88.85	48.15	97.10	13.37	–	–
NNGuide [9]（RegNet）	89.20	41.80	97.80	9.87	–	–
SCALE [32]（ResNet-50）	81.40	59.75	96.53	16.53	–	–
教師なし（報告値 †）						
DisCoPatch [11]（教師なし生成）	95.05	29.40	96.63	17.40	–	–
VLM，到着時採点（*CLIP ViT-B/16*，報告値 †）						
NegLabel [3]（CLIP B/16，ゼロショット）	75.18	69.45	94.85	23.73	94.21	25.40
AdaNeg [4]（CLIP B/16，テスト時適応）	76.70	67.51	96.43	17.31	96.66	18.92
InterNeg [6]（CLIP B/16，テスト時適応）	82.20	65.43	96.71	16.96	97.43	14.04
TINS [7]（CLIP B/16，テスト時適応）	82.65	57.88	96.92	12.99	98.51	6.72
同じテスト集合での実測（公式実装，到着時採点，学習なし）						
NegLabel [3]	74.64	75.90	94.67	24.61	94.38	24.55
AdaNeg [4]	76.60	72.00	96.18	17.56	96.34	14.38
TANL [5]	82.85	56.80	96.19	15.91	97.55	8.91
TINS [7]	81.48	56.37	97.04	12.23	98.52	6.85
Salmon Ladder（*Ours*，学習なし，クラスあたり *16* 枚，事後採点；*6* 通りの抽出の平均）						
Salmon Ladder，単体	**97.94**	**11.50**	**98.79**	**5.17**	**98.80**	**4.56**
最良の比較手法との差	(+2.89)	(+17.90)	(+0.99)	(+4.70)	(+0.28)	(+2.16)
ベース検出器との積 $s_0 \exp \sigma$（登録時の形 $p^{\mathrm{fin}} \times s_0$ ではない；*2.6* 節）						
×NegLabel	**97.99**	**10.94**	**98.93**	**4.69**	**98.89**	**4.13**
×AdaNeg	**98.02**	**10.71**	**98.94**	**4.59**	**98.91**	**3.98**
×TANL	**97.98**	**11.24**	**98.89**	**4.84**	**98.94**	**3.96**
×TINS	**98.09**★	**10.50**★	**99.05**★	**4.16**★	**99.09**★	**3.39**★
最良の比較手法との差	(+3.04)	(+18.90)	(+1.25)	(+5.71)	(+0.57)	(+3.33)

表 2　同じ特徴での読み出しの比較（[%]，×TINS；単体は付録 A.8 の**表 A·11**）．静的 p と kNN はグラフを使わない検出器，LGC-max は同じグラフ上のクラスラベル伝播（いずれも較正順位で読む）．p^+ は支持画像からの伝播，p^- は種からの伝播，σ は交差適合した統計量，p^{fin} はその較正順位（2.5 節）．到着時採点は付録 A.6 のモード（抽出は 1 通り）．★ は列の最良値．

構成	OpenOOD near-OOD AUROC↑	FPR95↓	OpenOOD far-OOD AUROC↑	FPR95↓	Four-OOD AUROC↑	FPR95↓
同じ特徴（*DINOv2 L/14 + DINOv3 L/16*）での読み出し，×*TINS*（単体は付録 *A.8* の表 *A·11*）						
静的 p（原型への余弦の較正順位，グラフなし）	86.18	47.27	98.61	6.62	97.84	7.97
kNN [30]（支持画像への k=10 近傍の較正順位，グラフなし）	83.63	51.34	98.23	8.31	97.68	8.45
LGC-max（支持画像のクラスラベルを伝播，最大クラス質量の較正順位）	96.07	18.04	98.82	5.31	98.56	5.60
p^+ のみ（支持画像からの伝播，種なし，交差適合）	97.59	12.14	99.01	4.33	98.99	3.52
p^+p^-，交差適合なし（v16 までの読み出し；保証は種だけ）	98.12★	10.26★	99.05	4.21	99.07	3.50
σ：交差適合した p^+p^-（本稿）	98.09	10.50	99.05	4.16	99.09	3.39
σ，上限付きの種（Storey 型）（4.4 節）	97.88	10.69	99.07	4.05	99.09	3.38
σ，上限付きの種（単純 BH 法）（4.4 節）	97.89	10.66	99.08★	4.02★	99.10	3.32
p^{fin}：σ の較正順位をそのままスコアにしたもの（登録時の形）	97.46	13.25	99.02	4.43	99.17★	2.95★
p^+p^-，到着時採点，交差適合なし（付録 A.6）	97.41	13.39	98.89	5.13	98.96	4.10
σ，到着時採点（付録 A.6）	97.35	13.83	98.87	5.25	98.97	4.00

全条件は付録 A.9）．

再出現しない未知には静的な検出器より劣る． $r \le 5$ では，σ は同じ特徴の静的 p より FPR95 が高い（30 条件中 27 条件，差は最大 40.0 ポイント）．NINCO の 64 クラス ×1 枚では σ 75.0%，p^+ だけでも 75.0%に対し，静的 p は 44.3%である．1 枚だけの未知は k_g=10 本の辺をすべて外へ張るので，伝播はその画像を隣の ID に均す．$r \ge 10$ では逆転し（30 条件中 29 条件），NINCO の 64 クラス ×10 枚で 30.2%，30 枚で 2.5%（静的 p は 46.0%）まで下がる．SSB-hard（兄弟クラス）は遅く，980 クラス ×10 枚で 32.8%，50 枚で 22.6%である．

交差適合と静的 p． 交差適合なしの p^+p^- との FPR95 の差は 60 条件中 50 条件で 1 ポイント以内である（灰色の細線）．σ に静的 p を加えると，再出現しない未知での劣化は縮み（64 クラス ×1 枚で 53.6%），$r \ge 10$ では 30 条件中 23 条件で σ より悪い（付録 A.9）．命題 4 はどちらにも成り立つ．**近傍数 k_g．** 同じ格子で $k_g \in \{3, 5, 10, 20, 40\}$ を変えると（付録 A.10 の**図 A·2**），k_g が大きいほど再出現の少ない側で良く（NINCO 64 クラス ×1 枚：k_g=40 で 39.6%，k_g=10 で 75.0%），多い側で悪い（×30 枚：15.9%と 2.5%）．登録時の仮説「小さい k_g ほど小さい r で静的 p を下回る」は否定され（付録 A.12），k_g=10 は最大の r で NINCO の最良，SSB-hard で最良との差 0.3 ポイントである．**保証は条件に依らない．** p^{fin} の ID の誤警報率 $\Pr(p^{\mathrm{fin}} \le 0.05)$ は格子の全条件で 0.056–0.070 であり，未知の量や再出現の枚数に依らず一定である（学習画像の較正では 4.5 節のとおり 0.05 をやや超える）．

4.4　種の数の上限：混入率が高いときの害を抑える

混入率が高いと水準 q の種は ID のほぼ全数に達し，p^-

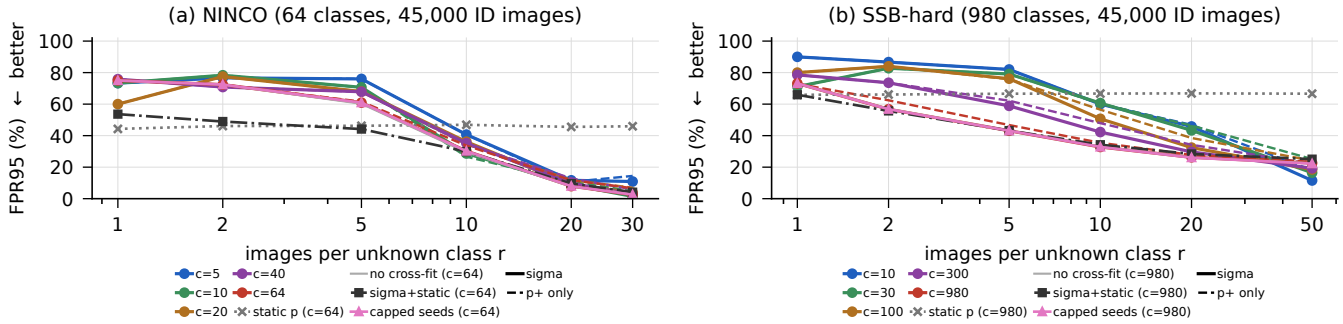


図 3 再出現と混入率（FPR95，単体，DINOv2 L/14 + DINOv3 L/16）．ID の検証画像 45,000 枚に，NINCO（a）または SSB-hard（b）から c 個の未知クラス $\times r$ 枚を加えたテスト集合（クラスと画像の選び方を変えた 3 回の平均）．実線は σ，破線は p^+ だけ，灰色の点線は静的 p，灰色の細い実線は交差適合なしの p^+p^-，黒の一点鎖線は静的 p を統計量に含めた σ，桃色は上限付きの種の σ（4.4 節；後四者は c が最大の条件）．

は情報を失う（4.6 節）．そこで，棄却の閾値に上限を付けた規則（2.4 節：$c_i = \min(q\,i/m', \tau)$，$\tau$=0.05，$q$=0.2）を実行前に登録し，上限なしの規則と同じ実行の中で評価した（付録 A.12）．

ImageNet-1K では変わらない．上限が効くのは Storey 型の閾値が τ を超える SSB-hard と OpenImage-O（iNaturalist ではわずか）で，SSB-hard では種が折の 66.02%から 42.88%に減り，種に混じる ID の割合は 0.230 から 0.060 に下がる．near-OOD の FPR95 は単体で 11.32%（上限なし 11.50%；対応のある差-0.18 [-0.41, +0.04]），×TINS で 10.69%（+0.19），far-OOD と Four-OOD の単体は 5.00%，4.54%で，いずれも上限なしと 0.25 ポイント以内である．

混入率が高いベンチマークでは害がほぼ消える．ImageNet-200 の near-OOD では FPR95 が 9.07%から 6.91%へ下がり（差-2.16 [-2.79, -1.53]），p^+ だけ（7.45%）より 0.53 ポイント低い（[-0.64, -0.43]）．far-OOD は 1.23%で p^+ だけ（1.25%）と並ぶ．CIFAR-100 では near-OOD が 2.90%から 2.55%（p^+ だけ 2.88%），far-OOD が 2.34%から 1.46%になり，p^+ だけ（1.22%）との差は+1.11 から+0.24 [0.14, 0.33] ポイントに縮む．4.3 節の格子の 60 条件でも，上限付きの規則が p^+ だけより 1 ポイント以上悪い条件は混入率 30%以上の 2 条件で 0，$r \geq 10$・混入率 30%未満の 28 条件では上限なしとの差が最大 0.3 ポイントと利得を保つ（付録 A.11）．

位置づけ．本稿の主構成は登録どおり上限なしの Storey 型であり（**表 1**），上限付きは登録済みの変種として報告する．上限付きの種は CIFAR-100 far-OOD の+0.24 ポイントを除いて p^+ だけと同等以上で，ImageNet-1K では上限なしと変わらないから，混入率が未知の運用には上限付きを推す．

4.5 最終スコアの保証の実測

命題 4 は折の較正画像と ID のテスト画像の交換可能性を仮定するが，ベンチマークでは前者が学習画像，後者が検証画像である．較正画像を ID の検証画像から取った交換可能な設定（3 通り，付録 A.2）では，ID の誤警報率 $\Pr(p^{\text{fin}} \leq \alpha)$ は α=0.05 で 0.049–0.054，0.2 で 0.197–0.203，BH 法（q=0.2）の偽発見割合は 0.091–0.191 と水準以下で，検知性能は変わらない（near-OOD の FPR95 は単体で 11.51%）．命題 4 の保証は実測でも成り立つ．学習画像の較正では $\Pr(p^{\text{fin}} \leq 0.05)$ が 0.052–0.067，偽発見割合が 0.101–0.239 と，ずれの分だけ水準を超える．

4.6 ImageNet-200 と CIFAR-100

ImageNet-200．構成を固定したまま単体で評価した（6 通りの抽出の平均，較正画像 n=800；付録 A.4 の**表 A·6**）．σ は near-OOD で AUROC 98.17%，FPR95 9.07%，far-OOD で 99.35%，2.15%であり，OpenOOD v1.5 [8] の報告値の最良（near 84.84%／52.30%，far 95.01%／21.22%；ImageNet-200 で学習した ResNet-18）を大きく上回る．ラベルの数を揃えない基線として，同じ 2 つの特徴で全学習画像 258,951 枚を使う kNN（k=50）とクラス平均，CLIP ViT-B/16 のゼロショットの MCM と NegLabel も測った．kNN は FPR95 28.04%／4.40%，クラス平均は 24.69%／3.20%で 16 枚の静的 p（26.72%／3.71%）と同程度にとどまり，MCM と NegLabel は 57.89%／14.92%，56.16%／10.21%である．ラベル付き画像を約 80 倍使っても伝播の分（p^+ だけで 7.45%／1.25%）は得られない．一方，上限なしの種は効かない．LGC-max は 7.99%／1.65%で，p^- を加えた本稿の構成はこれらより悪い．ID が 9,000 枚しかなく，SSB-hard では未知が全画像の 84.48%を占めて折の全画像が種になる（付録 A.4；単純 BH 法の種では 7.24%）．上限付きの種（4.4 節）では 6.91%／1.23%と p^+ だけと同等以上になる．

CIFAR-100．OpenOOD v1.5 の CIFAR-100 ベンチマーク（3 節）で，同じ凍結特徴と学習画像からの 16 枚（クラスあたり，重ならない 6 通りの抽出，較正画像 n=400），同じ構成で単体の値を測った（**表 A·5**）．σ は near-OOD

で AUROC 99.18%，FPR95 2.90%，far-OOD で 99.37%，2.34%で，報告値（CIFAR-100 で学習した ResNet-18）の最良である OE（near 88.30%／30.73%，外れ値データで学習）と RotPred（far 88.40%／34.50%）を AUROC で 10 ポイント以上上回る．全学習画像 50,000 枚の kNN（k=50, 16.35%／32.15%）とクラス平均（12.91%／28.05%）は 16 枚の静的 p（16.49%／29.19%）から数ポイント以内にとどまり，32×32 の画像ではゼロショットの MCM と NegLabel は弱い（94.06%／89.10%，76.98%／64.84%）．ここでも利得は p^+ の伝播にあり，種は効かない．p^+ だけで 2.88%／1.22%，σ との差は near-OOD で 0.02 [-0.25, +0.29]，far-OOD で+1.11 [+0.74, +1.49] ポイントで，far-OOD では p^- が害になる．未知が MNIST・SVHN・Places365 で全画像の 74–89%を占め，割合 q の種が ID のほぼ全数になって p^- は情報を失う（付録 A.4）．上限付きの種では近 2.55%，遠 1.46%になる（4.4 節）．

5. 結論

支持画像からの質量を 1 つのグラフで伝播させ較正画像の中での順位（共形 p 値）で読む共形ラベル伝播と，再出現する未知を自己ラベル付けした種から引き上げる負の伝播，交差適合で読み出し p^{fin} を共形 p 値にする枠組み Salmon Ladder を提案した．凍結した特徴抽出器とクラスあたり 16 枚のラベル付き画像だけで，OpenOOD v1.5 ImageNet-1K の near-OOD（単体で AUROC 97.94%，FPR95 11.50%），far-OOD，Four-OOD，ImageNet-200，CIFAR-100 のすべてで公開の最良値を更新し，near-OOD の FPR95 を 2.6 分の 1 にした．利得の大半はグラフ上の伝播にあり，同じグラフ上のクラスラベル伝播，静的な検出器，全学習画像を使う kNN では得られず，4 つのベース検出器と 6 つの特徴抽出器で再現する．種は ImageNet-1K の near-OOD で FPR95 をさらに 0.86 ポイント下げるが，効くのは再出現がクラスあたり 10 枚以上で混入率が中程度のときに限られ，種の閾値に上限 τ=0.05 を付けた規則が混入率の高いときの害をほぼ消す（ImageNet-200 near-OOD で 6.91%，p^+ だけは 7.45%）．限界は，1 枚しか現れない未知には静的な検出器より劣ること，ベース検出器との積には床のない σ が要ること（登録外の形），理論が扱うのは有効性であって検知力ではないことである．

参考文献

[1] A. Radford et al.: Learning transferable visual models from natural language supervision. *ICML*, 2021.
[2] Y. Ming et al.: Delving into out-of-distribution detection with vision-language representations. *NeurIPS*, 2022.
[3] X. Jiang et al.: Negative label guided OOD detection with pretrained vision-language models. *ICLR*, 2024.
[4] Y. Zhang and L. Zhang: AdaNeg: Adaptive negative proxy guided OOD detection with vision-language models. *NeurIPS*, 2024.
[5] Y. Zhang et al.: Activation matters: Test-time activated negative labels for OOD detection with vision-language models. *CVPR*, 2026.
[6] Z. Xu et al.: Mind the way you select negative texts: Pursuing the distance consistency in OOD detection with VLMs. *CVPR*, 2026.
[7] Y. Yang et al.: TINS: Test-time ID-prototype-separated negative semantics learning for OOD detection. arXiv:2605.10756, 2026.
[8] J. Zhang et al.: OpenOOD v1.5: Enhanced benchmark for out-of-distribution detection. *DMLR*, 2024.
[9] J. Park, Y. G. Jung, and A. B. J. Teoh: Nearest neighbor guidance for out-of-distribution detection. *ICCV*, 2023.
[10] J. Li et al.: MOODv2: Masked image modeling for out-of-distribution detection. *IEEE TPAMI*, 2024.
[11] F. Caetano et al.: DisCoPatch: Taming adversarially-driven batch statistics for improved out-of-distribution detection. *ICCV*, 2025.
[12] A. Marandon, L. Lei, D. Mary, and E. Roquain: Adaptive novelty detection with false discovery rate guarantee. *Ann. Stat.*, 52(1), 2024.
[13] R. Huang and Y. Li: MOS: Towards scaling out-of-distribution detection for large semantic space. *CVPR*, 2021.
[14] S. Bates, E. Candès, L. Lei, Y. Romano, and M. Sesia: Testing for outliers with conformal p-values. *Ann. Stat.*, 51(1):149–178, 2023.
[15] D. Zhou et al.: Learning with local and global consistency. *NIPS*, 2004.
[16] Y. Benjamini and Y. Hochberg: Controlling the false discovery rate: A practical and powerful approach to multiple testing. *J. R. Stat. Soc. B*, 1995.
[17] J. D. Storey: A direct approach to false discovery rates. *J. R. Stat. Soc. B*, 2002.
[18] G. Blanchard and E. Roquain: Two simple sufficient conditions for FDR control. *Electron. J. Stat.*, 2:963–992, 2008.
[19] V. Chernozhukov et al.: Double/debiased machine learning for treatment and structural parameters. *Econom. J.*, 21(1):C1–C68, 2018.
[20] M. Oquab et al.: DINOv2: Learning robust visual features without supervision. *TMLR*, 2024.
[21] O. Siméoni et al.: DINOv3. arXiv:2508.10104, 2025.
[22] C. Scott and G. Blanchard: Novelty detection: Unlabeled data definitely help. *AISTATS*, pp. 464–471, 2009.
[23] G. Blanchard, G. Lee, and C. Scott: Semi-supervised novelty detection. *J. Mach. Learn. Res.*, 11:2973–3009, 2010.
[24] M. Haroush, T. Frostig, R. Heller, and D. Soudry: A statistical framework for efficient out of distribution detection in deep neural networks. *ICLR*, 2022.
[25] Z. Liang, M. Sesia, and W. Sun: Integrative conformal p-values for out-of-distribution testing with labelled outliers. *J. R. Stat. Soc. B*, 86(3):671–693, 2024.
[26] Y. Liu et al.: Learning to propagate labels: Transductive propagation network for few-shot learning. *ICLR*, 2019.
[27] Y. Yang et al.: OODD: Test-time out-of-distribution detection with dynamic dictionary. *CVPR*, 2025.
[28] K. Fan et al.: Test-time linear out-of-distribution detection. *CVPR*, pp. 23752–23761, 2024.
[29] P. Yang, J. Liang, J. Cao, and R. He: AUTO: Adaptive outlier optimization for test-time OOD detection. arXiv:2303.12267, 2023.
[30] Y. Sun, Y. Ming, X. Zhu, and Y. Li: Out-of-distribution detection with deep nearest neighbors. *ICML*, 2022.
[31] M. Caron et al.: Emerging properties in self-supervised vision transformers. *ICCV*, 2021.
[32] K. Xu et al.: Scaling for training time and post-hoc out-of-distribution detection enhancement. *ICLR*, 2024.
[33] Y. Song, N. Sebe, and W. Wang: RankFeat: Rank-1 feature removal for out-of-distribution detection. *NeurIPS*, 2022.
[34] M. Chen, J. Gao, and C. Xu: Conjugated semantic pool improves OOD detection with pre-trained vision-language models. *NeurIPS*, 2024.

付　　録

A.1　命題 1 と命題 2 の証明

命題 1. $S\boldsymbol{\omega} = D^{-1/2}WD^{-1/2}D^{1/2}\mathbf{1} = D^{-1/2}W\mathbf{1} = \boldsymbol{\omega}$ であり，S は対称なので $\boldsymbol{\omega}^\top S = \boldsymbol{\omega}^\top$．よって $\boldsymbol{\omega}^\top\mathbf{u}^{(\ell+1)} = \lambda\boldsymbol{\omega}^\top\mathbf{u}^{(\ell)} + (1-\lambda)\boldsymbol{\omega}^\top\mathbf{y}^+$ となり，$\mathbf{u}^{(0)} = \mathbf{0}$ から解けば $\boldsymbol{\omega}^\top\mathbf{u}^{(L)} = (1-\lambda^L)\boldsymbol{\omega}^\top\mathbf{y}^+ = (1-\lambda^L)\sum_{j\in\mathcal{S}}\sqrt{\delta_j}$ を得る．□

命題 4. σ を折 b の節点の上の関数とみる．それを定めるのは，支持画像，折 $\bar{b}$ の節点とその較正・テストの区別，および「$\mathcal{C}_b \cup \mathcal{T}_b$ という節点の集合」だけである．グラフと $\mathbf{u}^+$ は節点の名札に依らず（2.3 節），$\hat{Q}_{\bar{b}}$ と $\mathbf{u}^-_{\bar{b}}$ は折 $\bar{b}$ の画像と $\mathbf{u}^+$ から決まり，参照する較正画像は $\mathcal{C}_{\bar{b}}$ である．したがって σ は，$\mathcal{C}_b \cup \mathcal{T}_b$ の中でどの節点を較正画像と呼ぶかを入れ替えても変わらない．これは AdaDetect の条件 (8)（学習標本を支持画像と折 $\bar{b}$ の全節点，帰無の較正標本を $\mathcal{C}_b$，テスト標本を $\mathcal{T}_b$ としたもの．同論文の証明は学習標本を所与とした置換の議論なので，その中身は問わない）であり，式 (9) の p^{fin} は同論文の経験 p 値 (10) である．よって定理 3.3 から (i) と (ii) の PRDS・超一様性が従い，系 3.5 と系 3.7 が FDR の上界を与える．□

命題 2. $i \in Q$ では $y_i = 0$ なので $u_i = \lambda\sum_j W_{ij}u_j/\sqrt{\delta_i\delta_j}$．両辺に $\sqrt{\delta_i}$ を掛けて Q で足すと，Q の内側の辺からの寄与は $\sum_{j\in Q}(u_j/\sqrt{\delta_j})\sum_{i\in Q}W_{ij} \le \sum_{j\in Q}\sqrt{\delta_j}u_j$ で抑えられ，外側の辺からの寄与は $w(Q,\bar{Q})\max_j u_j/\sqrt{\delta_j}$ で抑えられる．式 (4) と同じランダムウォークの表現より $u_j/\sqrt{\delta_j} \le 1/\min_{s\in Y}\sqrt{\delta_s}$ なので，移項して式 (6) を得る．□

A.2　最終読み出しの保証の実測と種に混じる ID の割合

4.5 節の 2 つの設定の詳細を示す．

交換可能な較正（検証画像）. 較正画像を ID の検証画像からクラスあたり 4 枚取り（残りの検証画像が ID のテスト集合），支持画像は学習画像のままにすると，較正画像と ID のテスト画像は交換可能になる．3 通りの抽出・9 データセットで，ID の誤警報率 $\Pr(p^{\text{fin}} \le \alpha)$ は α=0.01 で 0.009–0.011，0.05 で 0.049–0.054，0.1 で 0.097–0.103，0.2 で 0.197–0.203 とどの水準でも α のまわりに収まり，p^{fin} への BH 法（q=0.2）の偽発見割合は 0.091–0.191 で水準以下，その再現率（未知のうち棄却された割合）は 0.855–0.998 である．種に混じる ID の割合（折ごと，命題 3 の対象）も q=0.2 で 0.193–0.215（Storey 型）である．検知性能は学習画像の較正と変わらない（near-OOD の FPR95 は ×TINS で 10.60%，単体で 11.51%）．命題 4 の保証は実測でも成り立つ．

表 A·1　最終スコア p^{fin} の保証の実測（交換可能な較正：ID の検証画像からクラスあたり 4 枚を較正画像とし，3 通りの抽出の平均，単体）．ID の誤警報率は $p^{\text{fin}} \le \alpha$ と判定された ID のテスト画像の割合（命題 4(i)：$\le \alpha$），偽発見割合は BH 法（q=0.2）で棄却された画像のうち ID の割合（命題 4(ii)：期待値 ≤ 0.2），再現率は未知のうち棄却された割合．

	ID の誤警報率 $\Pr(p^{\text{fin}} \le \alpha)$				BH 法（q=0.2）	
データセット	α=0.01	0.05	0.1	0.2	偽発見割合	再現率
SSB-hard	0.009	0.051	0.099	0.201	0.091	0.901
NINCO	0.011	0.052	0.100	0.197	0.183	0.983
iNaturalist	0.009	0.049	0.099	0.198	0.158	0.998
Textures	0.011	0.054	0.103	0.202	0.191	0.928
OpenImage-O	0.009	0.051	0.103	0.199	0.147	0.901
iNat. (Four-OOD)	0.009	0.050	0.101	0.203	0.165	0.998
SUN	0.010	0.051	0.097	0.200	0.168	0.981
Places	0.009	0.050	0.099	0.198	0.165	0.855
Textures (Four-OOD)	0.011	0.051	0.102	0.203	0.191	0.915

表 A·2　学習画像の較正で選ばれた種（折あたり，6 通りの抽出の平均）．種は種の数，ID 率は種に混じっていた ID の割合（実測の偽発見割合，水準 q=0.2）．

	DINOv2 L/14				DINOv3 L/16			
	Storey 型		単純 BH		Storey 型		単純 BH	
データセット	種	ID 率	種	ID 率	種	ID 率	種	ID 率
SSB-hard	30,383	0.219	23,993	0.102	31,030	0.230	24,227	0.103
NINCO	3,784	0.254	3,597	0.219	3,993	0.281	3,685	0.226
iNaturalist	6,642	0.249	6,197	0.196	6,808	0.266	6,240	0.200
Textures	3,064	0.248	2,892	0.213	3,277	0.278	3,030	0.230
OpenImage-O	9,433	0.235	8,281	0.167	9,932	0.256	8,584	0.174
iNat. (Four-OOD)	6,653	0.250	6,235	0.201	6,895	0.276	6,326	0.211
SUN	6,414	0.249	5,911	0.192	6,668	0.266	6,075	0.199
Places	5,587	0.246	5,071	0.196	5,960	0.260	5,313	0.196
Textures (Four-OOD)	3,325	0.255	3,103	0.214	3,492	0.272	3,253	0.230

ベンチマークの較正（学習画像）. 同じ量を**表 1** の設定（6 通りの抽出）で測ると，$\Pr(p^{\text{fin}} \le 0.05)$ は 0.052–0.067，BH 法の偽発見割合は 0.101–0.239，種の ID の割合は 0.219–0.281（単純 BH 法では 0.102–0.230）であり，学習画像と検証画像のずれの分だけ水準を超える（**表 A·2**）．ベンチマークの値（**表 1**）はその定めどおり学習画像の較正で報告する．

表 A·1 に，交換可能な較正での p^{fin} の実測の誤警報率と BH 法の偽発見割合をデータセット別に示す．**表 A·2** に，**表 1** の設定（学習画像の較正，q=0.2，6 通りの抽出の平均）で折ごとに選ばれた種の数（2 つの折の平均）と，種に混じっていた ID の割合（実測の偽発見割合）を，Storey 型と単純 BH 法の両方について，データセット別・ビュー別に示す（4.5 節）．交換可能な較正での同じ量は 4.5 節の本文に範囲で示した．

A.3　データセット別の値と散布図

表 A·3 と**表 A·4** に**表 1** のデータセット別の値を示す（4.1 節）．**図 A·1** は**表 1** の全手法の AUROC と FPR95 の散布図である．

A.4　ImageNet-200 と CIFAR-100

表 A·6 と**表 A·5** に 4.6 節の ImageNet-200 と CIFAR-100 の値を示す．CIFAR-100 の ID の誤警報率 $\Pr(p^{\text{fin}} \le 0.05)$ は 0.055（near）／0.051（far），BH 法の偽発見割合は 0.105 ／ 0.057 である（学習画像の較正）．CIFAR-100 の 32×32

表 A·3　OpenOOD v1.5 ImageNet-1K のデータセット別の結果([%], AUROC↑／FPR95↓). 記法は**表 1** と同じ．TINS の報告値は原論文の表 8 のとおりで，iNaturalist と Textures は同論文の Four-OOD の表 1 と同じ値が報告されている（**表 A·4**）.

	near-OOD				far-OOD					
	SSB-hard		NINCO		iNaturalist		Textures		OpenImage-O	
手法	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MOODv2 [10]†	85.00	58.10	92.70	38.20	99.60	1.80	94.30	24.70	97.40	13.60
NNGuide [9]†	84.70	54.70	93.70	28.90	99.90	1.80	95.80	17.00	97.70	10.80
RankFeat [33]†	89.40	47.90	90.00	39.30	96.00	13.00	95.00	25.40	92.40	33.30
SCALE [32]†	77.40	67.70	85.40	51.80	98.00	9.50	97.60	11.90	94.00	28.20
DisCoPatch [11]†	95.80	19.80★	94.30	39.00	99.10	3.60	96.40	18.90	94.40	29.70
TINS [7]†	81.38	61.68	83.91	54.09	99.93	0.21	97.83	10.09	92.99	28.68
TINS [7]（実測）	82.22	56.65	80.74	56.09	99.93	0.17	98.11	8.31	93.09	28.20
Salmon Ladder，単体	**96.24**	21.72	**99.65**	**1.28**	99.93	**0.16**	**98.91**	**4.37**	97.55	10.98
Salmon Ladder ×TINS	**96.51**★	19.96	**99.68**★	**1.03**★	**99.96**★	**0.11**★	**99.31**★	**2.56**★	**97.87**★	**9.81**★
最良の比較手法との差	(+0.71)	(-0.16)	(+5.38)	(+27.87)	(+0.03)	(+0.06)	(+1.20)	(+5.75)	(+0.17)	(+0.99)

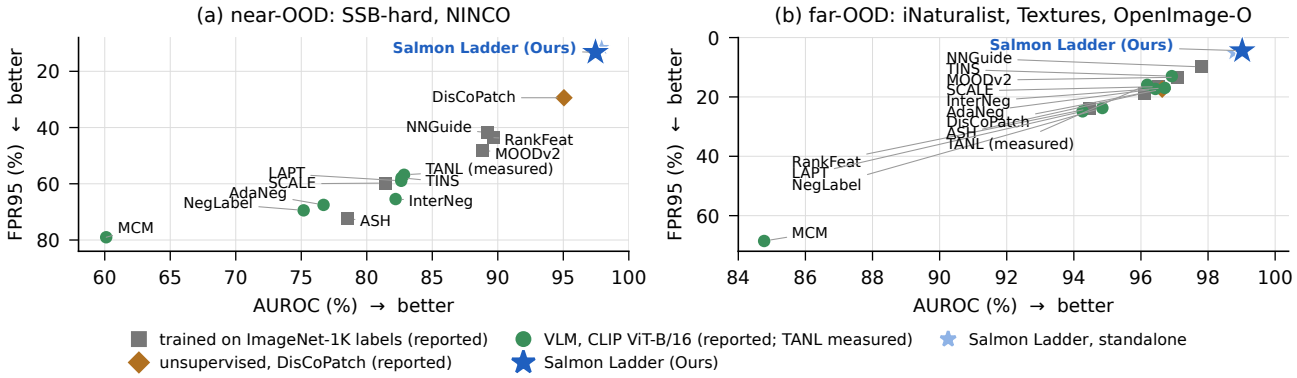


図 A·1　OpenOOD v1.5 ImageNet-1K での AUROC と FPR95 (**表 1** の全手法，右上ほど良い)．大きな星が本稿の構成（×TINS)，小さな星は単体．比較手法は報告値（TANL のみ実測)．

表 A·4　Four-OOD（ImageNet-1K に対する iNaturalist，SUN，Places，Textures，[%]）．比較手法はすべて CLIP ViT-B/16 による報告値 †（TINS は実測も併記）．記法は**表 1** と同じ.

	iNaturalist		SUN		Places		Textures		平均	
手法	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
MCM [2]†	94.59	32.20	92.25	38.80	90.31	46.20	86.12	58.50	90.82	43.93
NegLabel [3]†	99.49	1.91	95.49	20.53	91.64	35.59	90.22	43.56	94.21	25.40
CSP [34]†	99.60	1.54	96.66	13.66	92.90	29.32	93.86	25.52	95.76	17.51
OODD [27]†	99.79	0.85	97.17	12.94	92.51	30.68	94.51	30.67	96.00	18.79
AdaNeg [4]†	99.71	0.59	97.44	9.50	94.55	34.34	94.93	31.27	96.66	18.92
InterNeg [6]†	99.79	0.40	98.68	6.78	95.01	27.11	96.26	21.85	97.43	14.04
TINS [7]†	99.93	0.21	99.14	3.84	97.14	12.73	97.83	10.09	98.51	6.72
TINS [7]（実測）	99.93	0.22	99.12	4.35	97.12	12.98	97.94	9.83	98.52	6.85
Salmon Ladder，単体	99.92	**0.16**	**99.49**	**1.63**	97.05	**11.35**	**98.72**	**5.12**	**98.80**	**4.56**
Salmon Ladder ×TINS	**99.96**★	**0.11**★	**99.66**★	**0.97**★	**97.55**★	**9.26**★	**99.18**★	**3.20**★	**99.09**★	**3.39**★
最良の比較手法との差	(+0.03)	(+0.10)	(+0.52)	(+2.87)	(+0.41)	(+3.47)	(+1.24)	(+6.63)	(+0.57)	(+3.33)

の画像は他と同じ前処理で拡大して入力し，Textures は ImageNet-1K ベンチマークと同じ画像ファイルなので特徴を共有する．CIFAR-100 の種は，Storey 型 q=0.2 で CIFAR-10・Tiny ImageNet では折の 50–64%，MNIST・SVHN・Places365 では 91–100%，Textures では 47%を占め，種に混じる ID の割合は 0.114–0.190 である（DINOv3 L/16 のビュー，2 つの折・6 通りの抽出の平均)．単純 BH 法の種は折の 43–91%，ID の割合 0.022–0.123 である．種に混じる ID の割合は命題 3 どおり q 以下でも，割合 q の種が ID のほぼ全数になって p^- は情報を失う（Places365：σ 8.40%，p^+ だけ 3.99%，単純 BH 法の種で 5.64%，上限付きの種で 5.04%)．ImageNet-200 の SSB-hard では未知が全画像の 84.48%を占めて Storey 型の $\hat{\pi}_0$ が 0.15 になり，水準 $q/\hat{\pi}_0$ が 1 を超えて折の全画像が種になる（単純 BH 法の種は折の 84%，上限付きの種は 75%，ID の割合 0.012)．

A.5　特徴抽出器の族

表 A·7 に，ImageNet-1K のベンチマークで 6 つの特徴抽出器をそれぞれ単一のビューとして使った値を示す（抽出 1 通り)．DINOv2 B/14・L/14，DINOv3 B/16・L/16，DINO (v1) ViT-B/16，CLIP ViT-B/16 の 6 ビューのすべてで，σ は near-OOD の FPR95 が静的 p (6/6)，LGC-max (6/6)，p^+ だけ（6/6）より低く，交差適合なしの p^+p^- との差は-0.92–+0.19 ポイントである．たとえば CLIP ViT-B/16（ベース検出器と同じ重み）では静的 p 93.64%から σ 13.43%へ，DINO (v1) では 80.38%から 26.22%へ下が

表 A·5 OpenOOD v1.5 CIFAR-100（[%]，単体，6 通りの抽出の平均）．† は OpenOOD v1.5 [8] の報告値（AUROC は論文の表 2，FPR95 は同論文の脚注 6 が指す公開の表）．全学習画像の kNN・クラス平均は本稿と同じ 2 つの特徴（L2 正規化して連結），ゼロショットは CLIP ViT-B/16（4.6 節）．上限付きの種は τ=0.05（4.4 節）．★ は列の最良値，青 は本手法以外の全行（報告値，全学習画像・ゼロショットの基線，静的検出器，LGC-max）を上回る値．

	near-OOD		far-OOD	
手法	AUROC↑	FPR95↓	AUROC↑	FPR95↓
***CIFAR-100* で学習した *ResNet-18*（報告値 †）**				
MSP†	80.27	54.80	77.76	58.70
MLS†	81.05	55.47	79.67	56.73
RMDS†	80.15	55.46	82.92	52.81
VOS†	80.93	55.56	81.32	53.70
G-ODIN†	77.15	67.58	85.67	42.68
RotPred†	76.43	62.58	88.40	34.50
OE†（外れ値データで学習）	88.30	30.73	81.41	54.82
全学習画像（*50,000* 枚）またはゼロショット（本稿で実測）				
kNN，全学習画像（k=50）	97.09	16.35	94.94	32.15
クラス平均，全学習画像	97.61	12.91	95.38	28.05
MCM [2]，ゼロショット	70.30	94.06	74.59	89.10
NegLabel [3]，ゼロショット	72.98	76.98	80.25	64.84
凍結特徴，クラスあたり *16* 枚，学習なし，単体（*6* 通りの抽出の平均）				
静的 p（グラフなし）	96.94	16.49	94.88	29.19
kNN（グラフなし）	92.35	39.22	88.47	49.80
LGC-max	98.80	5.39	99.42	2.21
p^+ のみ	**99.11**	**2.88**	**99.57**	**1.22**
p^+p^-，交差適合なし	**99.25**	**2.83**	99.35	2.58
σ（本稿の構成）	**99.18**	**2.90**	99.37	2.34
σ に静的 p を加える	**99.34**★	**2.60**	**99.64**★	**1.00**★
σ，DINOv3 L/16 のみ	**98.95**	**3.77**	99.15	3.48
σ，上限付きの種（Storey 型）	**99.26**	**2.55**★	**99.59**	**1.46**
σ，上限付きの種（単純 BH 法）	**99.26**	**2.55**★	**99.59**	**1.46**

表 A·6 OpenOOD v1.5 ImageNet-200 ([%], 単体, 6 通りの抽出の平均)．† は OpenOOD v1.5 [8] の報告値（ImageNet-200 で学習した ResNet-18；リーダーボードと同論文の脚注 6 が指す公開の表）．全学習画像の kNN・クラス平均は本稿と同じ 2 つの特徴，ゼロショットは CLIP ViT-B/16（4.6 節）．上限付きの種は τ=0.05（4.4 節）．★ は列の最良値，青 は本手法以外の全行（報告値，全学習画像・ゼロショットの基線，静的検出器，LGC-max）を上回る値．

	near-OOD		far-OOD	
手法	AUROC↑	FPR95↓	AUROC↑	FPR95↓
***ImageNet-200* で学習した *ResNet-18*（報告値 †）**				
OE†（外れ値データで学習）	84.84	52.30	89.02	34.17
RegMixup + MSP†	84.13	53.78	90.81	33.88
TempScale†（事後手法の最良）	83.69	54.82	90.82	34.00
PixMix + ASH†	81.36	63.51	95.01	21.22
NPOS†	79.40	62.09	94.49	21.76
全学習画像（*258,951* 枚）またはゼロショット（本稿で実測）				
kNN，全学習画像（k=50）	92.09	28.04	98.56	4.40
クラス平均，全学習画像	92.88	24.69	98.96	3.20
MCM [2]，ゼロショット	84.53	57.89	96.85	14.92
NegLabel [3]，ゼロショット	86.82	56.16	97.90	10.21
凍結特徴，クラスあたり *16* 枚，学習なし，単体（*6* 通りの抽出の平均）				
静的 p（同じ特徴，グラフなし）	92.25	26.72	98.71	3.71
kNN（同じ特徴，グラフなし）	89.20	38.95	97.84	7.62
LGC-max（同じグラフ）	98.31	7.99	99.41	1.65
p^+ のみ（種なし）	**98.43**	**7.45**	99.39	**1.25**
p^+p^-，交差適合なし	98.11	9.26	99.37	2.45
σ（本稿の構成）	98.17	9.07	99.35	2.15
σ，単純 BH 法の種	**98.54**★	**7.24**	**99.45**	**1.51**
σ，上限付きの種（Storey 型）	**98.43**	**6.91**★	**99.49**★	**1.23**★
σ，上限付きの種（単純 BH 法）	**98.43**	**6.91**★	**99.49**★	**1.23**★

る．利得は自己教師あり学習の世代や VLM かどうかに依らず，特徴空間で ID が支持画像のまわりに集まり未知が互いに近いという性質だけに依る．**CLIP の静的 p について．** CLIP ViT-B/16 の静的 p と kNN は near 93.64%，far 95.38%とほとんど分離しない．特徴は TINS が使うのと同じ画像埋め込み（投影後，単位ノルム）であり取り違えではなく，同じ特徴でゼロショットの MCM は ImageNet-200 で動く（**表 A·6**）．CLIP の画像埋め込みは狭い錐に集まり（支持画像の平均のノルムは 0.71，DINO 系では 0.10–0.27），最も近い原型への余弦は ID で 0.847±0.068，Textures で 0.809±0.043 と平均は分かれるが，ID の下側の裾が Textures の全体を覆うので，ID の 95%を受け入れる閾値では Textures のほぼ全部が通る．登録時の仮説「支持画像の平均を引いてから余弦を取れば（中心化）DINO 系の範囲に入る」は否定された（付録 A.12）．中心化で静的 p は near 91.41%，far 78.46%，kNN は near 94.65%，far 88.81%になり，far は 16.96 ポイント改善するが near はほぼ変わらない（**表 A·7** の中心化の列；DINO 系の静的 p の変化は 8.97 ポイント以内）．中心化なしの同じ計算（交差適合なし）は表の静的 p と 0.43 ポイント以内で一致する．グラフは相対的な近傍だけを使うので，同じ特徴でも p^+ と σ はこの影響を受けない． CLIP ViT-B/16 はベース検出器 TINS が使う画像エンコーダと同じ重みで，DINO (v1) は ImageNet-1K の画像だけで自己教師あり学習した ViT-B/16 である．

A.6 到着時採点モード

画像がバッチ（256 枚）で順に届く設定では，届いた画像を節点に加えてグラフを厳密な k_g 近傍グラフに保ち，画像の折は到着番号の偶奇で決める（較正画像の折は最初に 1 回決める）．各バッチで，$\mathbf{u}^+$ と各折の $\mathbf{u}_b^-$ をその時点のグラフ上で式 (3) の不動点まで反復し（前のバッチの値を初期値にして反復を減らすが，不動点は初期値に依らない．相対残差 10^{-8} まで平均 117 回），種はその時点までに届いた各折の画像の p^+ に式 (7) をかけて毎バッチ選び直す．届いたバッチの画像は式 (9) のとおり採点し，p^{fin} はその時点の自分の折の較正画像の σ の中での順位で確定して後のバッチで見直さない．到着順がランダムなら，各時点で折 b の較正画像とそれまでに届いた折 b の ID 画像は交換可能なので，命題 4 は各時点の判定に当てはまる．事後採点との違いは，各画像が「それより後に届く画像」を使えないことだけである．

表 A·8 に到着時採点モードのデータセット別の値を示す（本稿の 2 ビュー，Storey 型 q=0.2，折は到着番号の偶奇；OpenOOD は 5 通り，Four-OOD は 3 通りの到着順の平均，抽出は 1 通り）．交差適合なしの到着時採点（v16 までの読み出し）も併記する．このモード（near-OOD の FPR95 は単体 14.80%，×TINS 13.83%）は後に届く画像を使えない分だけ劣るが，報告値の最良は上回る．到着時の p^{fin} の ID の誤警報率 $\Pr(p^{\text{fin}} \le 0.05)$ は近 0.061，遠 0.064，Four-OOD 0.064 である（学習画像の較正）．

表 A·7　6 つの特徴抽出器をそれぞれ単一のビューとした値（FPR95[%]，OpenOOD v1.5 ImageNet-1K，近= near-OOD，遠= far-OOD，抽出 1 通り）．

	静的 p		静的 p，中心化		kNN		kNN，中心化		LGC-max		p^+ のみ		p^+p^-（交差なし）		σ（本稿）		$\sigma\times$TINS	
ビュー	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠	近	遠
DINOv2 B/14（768 次元）	61.19	21.44	62.01	22.81	65.12	23.16	65.40	24.90	28.30	13.93	16.02	8.48	15.11	6.71	15.05	6.71	14.44	5.36
DINOv2 L/14（1024 次元）	55.43	20.22	55.94	21.66	59.37	25.81	59.47	27.57	24.56	13.71	14.62	8.77	14.18	7.83	14.18	7.61	13.42	5.33
DINOv3 B/16（768 次元）	76.08	25.38	76.78	28.34	82.67	34.96	83.12	38.70	29.17	13.72	17.65	7.63	14.48	5.67	14.44	5.60	13.88	4.97
DINOv3 L/16（1024 次元）	62.77	19.42	62.80	20.61	69.97	25.69	70.65	28.63	20.46	11.79	13.63	7.22	12.09	6.12	12.28	5.86	11.62	4.36
DINO（v1）ViT-B/16（768 次元）	80.38	40.72	83.33	49.60	86.11	52.80	88.76	63.71	46.45	19.86	30.08	10.20	27.14	8.56	26.22	8.26	24.42	7.01
CLIP ViT-B/16（画像埋め込み）（512 次元）	93.64	95.38	91.41	78.46	95.91	97.41	94.65	88.81	41.12	21.53	16.67	10.38	14.20	7.14	13.43	6.60	13.79	6.07

表 A·8　到着時採点モードのデータセット別の値（[%]，AUROC ／ FPR95）．

	SSB-hard		NINCO		iNat.		Textures		OImO		iNat.		SUN		Places		Textures	
$\sigma\times$TINS	95.71	23.44	98.98	4.22	99.95★	0.09★	99.10★	3.72★	97.56	11.94	99.95	0.12★	99.58★	1.38★	97.40★	10.04★	98.93★	4.44★
σ，単体	95.48	25.44	99.05	4.15	99.91	0.18	98.64	5.59	97.24	13.12	99.91	0.21	99.42	1.92	96.88	11.76	98.41	6.63
$p^+p^-\times$TINS，交差適合なし	95.79★	22.93★	99.04	3.85★	99.95	0.10	99.08	4.01	97.63★	11.26★	99.95★	0.13	99.57	1.52	97.38	10.14	98.92	4.60
p^+p^-，単体，交差適合なし	95.49	25.32	99.08★	3.87	99.92	0.20	98.61	6.13	97.30	12.61	99.91	0.22	99.41	2.27	96.85	12.27	98.39	7.07

A.7　開発用分割での構成の選択

表 A·9 に第 1 段（ビューと q，交差適合なしの p^+p^-），**表 A·10** に第 2 段（交差適合の種の規則・q・統計量）の，開発用分割 dev1（選択）と dev2（確認）での候補の値を示す（単体，5 通りの抽出の平均；各分割は near と far の 2 つの未知の集合を持つ）．第 2 段では，静的 p を統計量に含める候補は dev1 の far-OOD では最も良いが near-OOD で悪く（16.29%／11.33%），q=0.05 はどの組でも悪い．選ばれた Storey 型・q=0.2・p^+p^- は dev1 near で 13.55%（18 候補中 1 位），dev2 near で 13.01%であり，交差適合なしの参照（dev1 14.10%）より良い．LGC-max は dev1 near で 38.05%である．

A.8　テスト集合での感度と選択の履歴

表 A·11 に，**表 2** の読み出しの単体での値と，第 2 段の候補（種の規則，q，統計量）の一部のテスト集合での値を示す．テスト集合では単純 BH 法の種が Storey 型よりわずかに良く，q=0.1 が q=0.2 よりわずかに良いが，構成は開発用分割の規則で選んだものを変えない（3 節）．**表 A·12** に，交差適合なしの p^+p^- について，ビューの組と q とベース検出器のすべての組合せのテスト集合での値（6 通りの抽出の平均）を示す．v16 までの版では，グラフの近傍数，相互近傍グラフ，λ，種の 2 巡目，種への最近傍項，重み，DINOv3 の採用，静的 p との積をテスト集合上で探索し，その上で第 1 段の候補の集合を決めた．本稿の構成はこの表からは選んでおらず（3 節），交差適合に関わる第 2 段の候補と規則はテスト集合の計算前に登録した．探索の記録は `https://github.com/omotes24/SalmonLadder` に残している．

A.9　再出現と混入率の格子

4.3 節の格子の全条件を**表 A·13**（NINCO）と**表 A·14**（SSB-hard）に示す．交差適合なしの p^+p^- との FPR95 の差は 60 条件で-4.0–+2.2 ポイントの範囲にある．種は各折のテスト画像から選ばれるので 1 つの折に入る未知は半分になるが，他方の折の種が同じクラスの残りを引き上げる．σ に静的 p を加えると，$r \le 5$ で静的 p に劣る条件は 23 に減り差も最大 14.2 ポイントになるが，64 クラス ×30 枚では 2.5%から 4.1%へ悪化する．c は未知クラスの数，r は各クラスの枚数，混入率は未知の枚数をテスト集合の枚数で割った値．検出器の列は AUROC ／ FPR95（DINOv2 L/14 + DINOv3 L/16，ラベル付き画像は本稿の抽出 1 通り，クラスと画像の選び方を変えた 3 回の平均；学習画像の較正）．$\Pr(p^{\mathrm{fin}} \le 0.05)$ は本稿の構成の p^{fin} の ID の誤警報率．種は DINOv3 L/16 のビューで Storey 型 q=0.2 のときに選ばれた枚数（2 つの折の合計），ID はそのうち ID だった割合（%），再現は未知のうち種に選ばれた割合（%）．

A.10　近傍数 k_g を変えた格子

図 A·2 に，同じ格子の NINCO（c=64）と SSB-hard（c=980）で，グラフの近傍数を $k_g \in \{3, 5, 10, 20, 40\}$ と変えた値を示す（単体，本稿の抽出 1 通り，3 回の平均；1 つのテスト集合につき上位 40 個の近傍リストを 1 回作り，全 k_g を同じリストで評価）．k_g を変えても較正順位の仕組みは同じで，変わるのはグラフの密さだけである．NINCO（a）では，k_g=40 の σ は r=1 から静的 p を下回る（39.6% 対 44.3%）が r=30 でも 15.9%にとどまり，k_g=3 は r=1 で 91.1%と最も悪いが r=30 で 6.5%まで下がる．σ が静的 p を初めて下回る r は $k_g \in \{3, 5, 10, 20\}$ で 10，k_g=40 で 1 である．SSB-hard（b）では $k_g \ge 20$ は r=1 から，$k_g \le 10$ は r=2 から静的 p を下回り，r=50 では k_g=5（22.3%）と 10（22.6%）が最も良く，k_g=40 は 28.3%である．p^+ だけ（破線）も同じ順に並び，種の利得（実線と破線の差）は $r \ge 10$ で現れ，k_g=40 では小さい．密なグラフでは再出現する未知の塊の内側の辺の割合が下がり，塊が孤立しにくい（命題 2 のカット条件）と解釈できる．登録時の仮説 H5（付録 A.12）の前半（小さい k_g ほど小さい r で静的 p を下回る）は否定され，後半（大きい r での最良は $k_g \in \{10, 20\}$）は $\{5, 10\}$ として部分的に成り立つ．本稿の k_g=10 は登録どおり変えない．

A.11　種の上限 τ の格子

表 A·15 に，4.4 節の上限付きの規則を 4.3 節の格子の

表 A·9　第 1 段の候補（ビューと q；[%]，交差適合なしの $p^{+}p^{-}$，単体，5 通りの抽出の平均）．★ は列の最良値．

	dev1（選択）				dev2（確認）			
	near		far		near		far	
構成（$p^{+}p^{-}$，単体）	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
DINOv2 L/14，q=0.05	94.95	21.50	95.29	22.03	94.84	22.59	95.18	23.19
DINOv2 L/14，q=0.1	95.69	18.43	95.36	22.19	95.66	18.40	95.35	22.34
DINOv2 L/14，q=0.2	95.94	19.26	95.68	20.12	96.11	18.12	95.56	20.92
DINOv3 L/16，q=0.05	95.69	20.80	95.59	20.54	95.86	18.71	95.55	20.00
DINOv3 L/16，q=0.1	96.57	16.38	95.87	19.57	96.73	15.52	95.85	18.62
DINOv3 L/16，q=0.2	96.81	16.86	96.28	17.19	96.94	15.65	96.12	17.40
連結ビュー，q=0.05	96.03	17.23	95.96	19.49	95.95	17.82	95.92	19.75
連結ビュー，q=0.1	96.66	15.34	96.09	18.94	96.57	14.62	96.11	18.87
連結ビュー，q=0.2	96.79	15.86	96.45	16.91	96.86	14.48	96.37	17.47
DINOv2 L/14 + DINOv3 L/16，q=0.05	96.34	17.15	96.36	17.84	96.25	17.27	96.32	17.73
DINOv2 L/14 + DINOv3 L/16，q=0.1	96.89	14.59	96.40	18.05	96.91	14.35	96.39	17.60
DINOv2 L/14 + DINOv3 L/16，q=0.2（選択）	97.06	14.10★	96.71	16.43	97.16	13.58	96.57	16.93
連結ビュー + DINOv3 L/16，q=0.05	96.39	17.17	96.17	18.03	96.35	16.46	96.09	18.49
連結ビュー + DINOv3 L/16，q=0.1	96.96	14.44	96.30	17.96	96.98	13.91	96.30	17.42
連結ビュー + DINOv3 L/16，q=0.2	97.10★	14.37	96.68	16.39★	97.18★	13.53★	96.54	16.78
DINOv3 B/16 + L/16，q=0.05	94.73	24.54	95.62	20.93	94.94	22.85	95.58	20.15
DINOv3 B/16 + L/16，q=0.1	95.92	20.30	95.96	19.30	96.03	19.12	95.89	18.89
DINOv3 B/16 + L/16，q=0.2	96.33	19.13	96.37	17.95	96.41	18.50	96.19	17.47
DINOv2 B/14 + L/14，q=0.05	94.80	23.72	95.73	21.20	94.62	23.77	95.72	21.01
DINOv2 B/14 + L/14，q=0.1	95.73	19.74	95.85	20.61	95.59	19.34	95.73	20.75
DINOv2 B/14 + L/14，q=0.2	96.03	19.06	96.15	19.08	96.11	18.11	95.98	19.77
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.05	95.95	19.30	96.30	18.30	95.72	19.52	96.27	18.01
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.1	96.64	16.11	96.40	18.18	96.54	16.38	96.36	17.48
DINOv2 L/14 + DINOv3 B/16 + L/16，q=0.2	96.87	15.52	96.74★	16.51	96.89	15.50	96.59★	16.46★

表 A·10　第 2 段の候補（交差適合の種の規則・q・統計量；[%]，p^{fin}，単体，5 通りの抽出の平均）と参照．★ は列の最良値．

	dev1（選択）				dev2（確認）			
	near		far		near		far	
候補（p^{fin}，単体）	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95	AUROC	FPR95
Storey 型，q=0.2，$p^{+}p^{-}$（選択）	97.08	13.55	96.66	16.53	97.15	13.01★	96.54	16.97
Storey 型，q=0.2，$p^{+}p^{-}\times$ 静的 p	96.68	16.29	97.67★	11.33★	96.73	15.28	97.60★	11.50★
Storey 型，q=0.2，$\min(p^{+}p^{-}$，静的 $p)$	97.09	13.74	96.93	15.58	97.16	13.14	96.80	16.03
Storey 型，q=0.1，$p^{+}p^{-}$	96.84	14.59	96.48	17.39	96.84	14.39	96.36	17.69
Storey 型，q=0.1，$p^{+}p^{-}\times$ 静的 p	96.41	17.48	97.59	11.56	96.39	16.48	97.52	11.72
Storey 型，q=0.1，$\min(p^{+}p^{-}$，静的 $p)$	96.87	14.73	96.82	15.95	96.85	14.52	96.69	16.33
Storey 型，q=0.05，$p^{+}p^{-}$	96.23	17.74	96.40	17.47	96.08	18.16	96.38	17.36
Storey 型，q=0.05，$p^{+}p^{-}\times$ 静的 p	95.71	20.92	97.52	11.92	95.62	19.67	97.50	11.81
Storey 型，q=0.05，$\min(p^{+}p^{-}$，静的 $p)$	96.25	17.98	96.93	15.30	96.08	18.24	96.90	15.08
単純 BH，q=0.2，$p^{+}p^{-}$	97.03	13.77	96.64	16.65	97.07	13.37	96.52	16.99
単純 BH，q=0.2，$p^{+}p^{-}\times$ 静的 p	96.62	16.55	97.66	11.36	96.63	15.62	97.59	11.53
単純 BH，q=0.2，$\min(p^{+}p^{-}$，静的 $p)$	97.04	14.00	96.91	15.73	97.07	13.51	96.80	16.10
単純 BH，q=0.1，$p^{+}p^{-}$	96.72	15.19	96.45	17.52	96.65	15.30	96.35	17.72
単純 BH，q=0.1，$p^{+}p^{-}\times$ 静的 p	96.27	18.01	97.57	11.72	96.19	17.19	97.52	11.74
単純 BH，q=0.1，$\min(p^{+}p^{-}$，静的 $p)$	96.75	15.36	96.80	16.09	96.66	15.43	96.68	16.45
単純 BH，q=0.05，$p^{+}p^{-}$	95.89	19.70	96.43	17.13	95.72	19.95	96.40	17.28
単純 BH，q=0.05，$p^{+}p^{-}\times$ 静的 p	95.32	22.93	97.53	11.88	95.28	21.25	97.50	11.84
単純 BH，q=0.05，$\min(p^{+}p^{-}$，静的 $p)$	95.90	19.97	97.00	14.77	95.72	19.97	96.94	14.90
参照：$p^{+}p^{-}$，交差適合なし（Storey 型，q=0.2）	97.06	14.10	96.71	16.43	97.16	13.58	96.57	16.93
p^{+} のみ	95.65	18.81	96.50	16.46	95.99	17.40	96.44	17.14
静的 p	84.84	58.45	97.12	13.30	85.36	57.77	97.19	13.16
kNN	80.13	68.20	96.00	19.05	79.42	66.82	95.95	19.08
LGC-max	91.80	38.05	94.04	29.53	93.24	32.97	94.32	28.38
選択した構成の σ（順位付けの統計量）	97.10★	13.54★	96.67	16.60	97.17★	13.09	96.54	17.00
選択した構成の σ×TINS	97.09	13.80	96.85	15.94	97.12	13.44	96.71	16.44
選択した構成の p^{fin}×TINS	96.82	14.99	96.73	16.71	96.74	15.07	96.52	17.87

全条件で評価した FPR95 を示す（単体，3 回の平均）．混入率が低い条件では Storey 型の閾値が τ に達せず，上限付きと上限なしの値は一致する．混入率 30%以上の 2 条件（SSB-hard 980 クラス ×20，50 枚）では上限付きの Storey 型は p^{+} だけより 1.2–1.7 ポイント良く，980 クラス ×50 枚では種に混じる ID の割合が 0.255 から 0.066 に下がる．全 60 条件で上限付きの Storey 型が p^{+} だけより 1 ポイント以上悪いのは 2 条件（NINCO c=10, 20 の r=10；上限なしも同じ値）で，そこでは種が数十枚しか選ばれず，その 79.1%が ID である（未知がごく少なく $\hat{\pi}_0$ が小さく出る条件；単純 BH 法は種を選ばない）．単純 BH 法は上限の有無に依らず全条件で p^{+} だけより最大 0.2 ポイントしか悪くならない．登録時の仮説 H3（付録 A.12：混入率 30%以上で p^{+} だけより 1 ポイント以上悪くならず，$r \geq 10$・混入率 30%未満で上限なしの利得を 1 ポイント以内に保つ）は，後者の 28 条件での差が最大 0.3 ポイントであり，成り立つ．

A.12　追加実験の事前登録と仮説の判定

4.4 節の上限付きの種，4.6 節の全学習画像・ゼロショットの基線，付録 A.10 の k_g の格子，付録 A.5 の中心化は，1 つの登録文書（公開リポジトリの `experiments/phase15/prereg_p15.json`，SHA-256 `83ea4061`…）に計算の内容・報告の形・6 つの仮説を記してから実行した．登録文書は評価の実行前に公開リポジトリのブランチ `phase12-15-registrations`（コミッ

表 A·11　同じ特徴での読み出しの比較（単体）と第 2 段の他の候補の値（[%]，6 通りの抽出の平均）．記法は**表 2** と同じ．

構成	OpenOOD near-OOD AUROC↑	OpenOOD near-OOD FPR95↓	OpenOOD far-OOD AUROC↑	OpenOOD far-OOD FPR95↓	Four-OOD AUROC↑	Four-OOD FPR95↓
同じ特徴での読み出し，単体						
静的 p	82.30	54.36	96.48	15.92	93.77	24.85
kNN [30]	78.75	59.51	95.52	19.27	92.71	28.55
LGC-max	95.69	19.52	97.70	10.13	96.98	11.38
p^+ のみ	97.53	12.36	98.45	6.04	98.26	5.75
p^+p^-，交差適合なし	97.96	11.39	98.80	5.21	98.79	4.69
σ：交差適合した p^+p^-	97.94	11.50	98.79	5.17	98.80	4.56
σ，上限付きの種（Storey 型）	97.78	11.32	98.83	5.00	98.80	4.54
σ，上限付きの種（単純 BH 法）	97.79	11.29	98.84	4.94	98.83	4.43
p^{fin}：σ の較正順位をそのままスコアにしたもの	97.93	11.52	98.77	5.15	98.78	4.55
σ，種を単純 BH 法で選択	97.93	11.00	98.84	4.96	98.83	4.43
σ に静的 p を加える	97.64	12.57	98.98	4.48	98.71	4.81
$\min(\sigma, \text{log 静的 } p)$	97.92	11.49	98.83	5.17	98.79	4.52
単純 BH 法の種，静的 p を加える	97.56	12.31	99.01	4.39	98.73	4.75
σ，q=0.1	97.95	11.01	98.88	4.78	98.88	4.19
σ，q=0.05	97.78	11.32	98.89	4.74	98.89	3.94
単純 BH 法の種，q=0.1	97.75	11.40	98.89	4.70	98.88	4.07
p^+p^-，交差適合なし，q=0.1	97.97	10.87	98.88	4.84	98.88	4.23
p^+p^-，交差適合なし，q=0.05	97.79	11.28	98.90	4.71	98.89	3.96
p^+p^-，到着時採点，交差適合なし	97.28	14.60	98.61	6.31	98.64	5.46
σ，到着時採点	97.26	14.80	98.60	6.29	98.65	5.13
第 2 段の他の候補，×*TINS*						
σ（本稿：Storey 型，q=0.2）	98.09★	10.50	99.05	4.16	99.09	3.39
σ，上限付きの種（Storey 型）	97.88	10.69	99.07	4.05	99.09	3.38
σ，上限付きの種（単純 BH 法）	97.89	10.66	99.08	4.02	99.10	3.32
σ，種を単純 BH 法で選択	98.03	10.29	99.07	4.03	99.10	3.32
σ に静的 p を加える（4.3 節）	97.72	12.16	99.19	3.69	99.00	3.75
$\min(\sigma, \text{log 静的 } p)$	98.06	10.54	99.08	4.14	99.09	3.36
単純 BH 法の種，静的 p を加える	97.63	11.94	99.20★	3.64★	99.01	3.72
σ，q=0.1	98.06	10.26	99.09	3.96	99.12★	3.20
σ，q=0.05	97.87	10.74	99.08	4.03	99.11	3.07★
単純 BH 法の種，q=0.1	97.84	10.82	99.10	3.95	99.12	3.15
p^+p^-，交差適合なし，q=0.1	98.08	10.08★	99.09	4.00	99.11	3.25
p^+p^-，交差適合なし，q=0.05	97.88	10.64	99.09	4.00	99.11	3.09

表 A·12　テスト集合での感度（[%]，交差適合なしの p^+p^-，6 通りの抽出の平均）．★ は列の最良値．

構成（交差適合なしの p^+p^-）	OpenOOD near-OOD AUROC↑	OpenOOD near-OOD FPR95↓	OpenOOD far-OOD AUROC↑	OpenOOD far-OOD FPR95↓	Four-OOD AUROC↑	Four-OOD FPR95↓
DINOv2 L/14，q=0.05，単体	97.36	13.01	98.54	6.04	98.53	5.28
DINOv2 L/14，q=0.05，×TINS	97.43	12.40	98.93	4.80	99.04	3.43
DINOv2 L/14，q=0.1，単体	97.54	12.81	98.50	6.43	98.50	5.74
DINOv2 L/14，q=0.1，×TINS	97.64	11.98	98.94	4.78	99.04	3.64
DINOv2 L/14，q=0.2，単体	97.47	13.69	98.38	7.02	98.37	6.52
DINOv2 L/14，q=0.2，×TINS	97.64	12.55	98.89	4.98	99.00	3.94
DINOv3 L/16，q=0.05，単体	97.72	11.69	98.79	4.91	98.83	4.04
DINOv3 L/16，q=0.05，×TINS	97.72	11.31	99.05	4.11	99.15	2.90★
DINOv3 L/16，q=0.1，単体	97.91	11.06	98.79	5.17	98.83	4.33
DINOv3 L/16，q=0.1，×TINS	97.93	10.56	99.07	4.02	99.17★	3.00
DINOv3 L/16，q=0.2，単体	97.91	11.62	98.71	5.55	98.75	4.88
DINOv3 L/16，q=0.2，×TINS	97.97	10.81	99.04	4.18	99.14	3.19
連結ビュー，q=0.05，単体	97.75	11.34	98.78	4.88	98.76	4.36
連結ビュー，q=0.05，×TINS	97.76	11.06	99.05	4.10	99.12	3.07
連結ビュー，q=0.1，単体	97.90	11.08	98.75	5.27	98.74	4.71
連結ビュー，q=0.1，×TINS	97.93	10.59	99.06	4.08	99.12	3.21
連結ビュー，q=0.2，単体	97.83	11.90	98.65	5.74	98.64	5.39
連結ビュー，q=0.2，×TINS	97.93	11.10	99.02	4.29	99.09	3.46
DINOv2 L/14 + DINOv3 L/16，q=0.05，単体	97.79	11.28	98.90	4.71	98.89	3.96
DINOv2 L/14 + DINOv3 L/16，q=0.05，×TINS	97.88	10.64	99.09	4.00	99.11	3.09
DINOv2 L/14 + DINOv3 L/16，q=0.1，単体	97.97	10.87	98.88	4.84	98.88	4.23
DINOv2 L/14 + DINOv3 L/16，q=0.1，×TINS	98.08	10.08	99.09★	4.00	99.11	3.25
DINOv2 L/14 + DINOv3 L/16，q=0.2，単体	97.96	11.39	98.80	5.21	98.79	4.69
DINOv2 L/14 + DINOv3 L/16，q=0.2，×TINS	98.12	10.26	99.05	4.21	99.07	3.50
連結ビュー + DINOv3 L/16，q=0.05，単体	97.84	11.15	98.88	4.61	98.88	3.93
連結ビュー + DINOv3 L/16，q=0.05，×TINS	97.93	10.45	99.08	3.91★	99.10	3.06
連結ビュー + DINOv3 L/16，q=0.1，単体	98.00	10.65	98.87	4.83	98.87	4.22
連結ビュー + DINOv3 L/16，q=0.1，×TINS	98.12	9.87★	99.08	4.02	99.11	3.23
連結ビュー + DINOv3 L/16，q=0.2，単体	97.97	11.24	98.78	5.18	98.78	4.71
連結ビュー + DINOv3 L/16，q=0.2，×TINS	98.14★	10.10	99.03	4.23	99.07	3.57

ト `8ef9c8d`）にコミットし，その時刻が第三者の確認できる時刻である（学習画像の特徴抽出だけはコミット前に始めた）．構成の選択は行わず（τ と q は固定，本稿の主構成は変えない），登録からの逸脱はない．判定は次のとおりである．**H1**（上限は害を消す：CIFAR-100 far-OOD と ImageNet-200 near-OOD で上限付きの規則は p^+ だけの+0.5 ポイント以内）：成立（+0.24, -0.53 ポイント）．**H2**（上限は ImageNet-1K near-OOD で上限なしの 0.5 ポイント以内）：成立（単体-0.18，×TINS +0.19 ポイント）．**H3**（格子：混入率 30%以上で p^+ だけより 1 ポイント以上悪くならず，$r \geq 10$・混入率 30%未満で上限なしの利得を 1 ポイント以内に保つ）：成立（付録 A.11）．**H4**（全学習画

表 A·13　再出現と混入率の格子：NINCO（[%]）.

c	r	未知	混入率	静的 p	p^+	p^+p^-（交差なし）	σ（本稿）	σ+静的 p	$\sigma\times$TINS	$\Pr(p^{\text{fin}}\leq 0.05)$	種	ID	再現
5	1	5	0.01	94.2 ／ 33.3	76.6 ／ 73.3	76.7 ／ 73.3	76.6 ／ 73.3	90.0 ／ 40.0	83.7 ／ 46.7	0.065	0	–	0
5	2	10	0.02	83.8 ／ 63.3	78.4 ／ 76.7	78.4 ／ 76.7	78.4 ／ 76.7	83.2 ／ 63.3	81.6 ／ 53.3	0.066	0	–	0
5	5	25	0.06	85.9 ／ 46.7	83.7 ／ 76.0	83.7 ／ 74.7	83.7 ／ 76.0	87.5 ／ 53.3	86.5 ／ 62.7	0.066	0	–	0
5	10	50	0.11	81.4 ／ 69.3	89.6 ／ 40.7	89.4 ／ 41.3	89.5 ／ 40.7	89.2 ／ 44.7	91.4 ／ 40.0	0.066	35	82	13
5	20	100	0.22	89.3 ／ 43.3	97.8 ／ 10.7	98.1 ／ 11.0	97.8 ／ 11.7	96.7 ／ 20.3	97.7 ／ 12.0	0.067	91	71	26
5	30	150	0.33	94.8 ／ 34.2	96.7 ／ 14.4	98.0 ／ 10.4	97.7 ／ 10.9	99.0 ／ 5.6	98.9 ／ 6.7	0.065	189	59	52
10	1	10	0.02	90.5 ／ 33.3	83.4 ／ 73.3	83.4 ／ 73.3	83.4 ／ 73.3	89.8 ／ 43.3	84.9 ／ 60.0	0.066	0	–	0
10	2	20	0.04	84.4 ／ 55.0	80.4 ／ 78.3	80.5 ／ 78.3	80.4 ／ 78.3	86.1 ／ 58.3	84.4 ／ 51.7	0.066	0	–	0
10	5	50	0.11	83.7 ／ 52.7	81.3 ／ 70.7	81.2 ／ 70.7	81.3 ／ 70.7	87.1 ／ 58.0	85.7 ／ 54.7	0.066	0	–	0
10	10	100	0.22	89.4 ／ 45.7	94.4 ／ 26.7	94.2 ／ 27.0	93.8 ／ 28.7	95.0 ／ 25.3	94.5 ／ 29.3	0.066	70	79	15
10	20	200	0.44	92.6 ／ 39.2	97.1 ／ 10.7	98.4 ／ 7.7	98.2 ／ 8.8	98.1 ／ 10.7	98.5 ／ 8.0	0.066	232	54	54
10	30	300	0.66	91.4 ／ 35.1	98.9 ／ 4.9	99.6 ／ 1.0	99.5 ／ 1.4	99.2 ／ 4.0	99.5 ／ 1.8	0.064	436	50	72
20	1	20	0.04	91.4 ／ 35.0	86.5 ／ 60.0	86.5 ／ 60.0	86.5 ／ 60.0	92.6 ／ 41.7	92.1 ／ 43.3	0.067	0	–	0
20	2	40	0.09	90.9 ／ 40.0	81.3 ／ 77.5	81.3 ／ 78.3	81.3 ／ 77.5	90.3 ／ 54.2	86.4 ／ 56.7	0.066	0	–	0
20	5	100	0.22	89.5 ／ 45.7	86.4 ／ 68.0	86.4 ／ 67.3	86.4 ／ 68.0	90.8 ／ 46.0	89.0 ／ 50.0	0.066	0	–	0
20	10	200	0.44	89.0 ／ 44.5	91.8 ／ 34.7	91.5 ／ 35.7	91.6 ／ 36.2	92.4 ／ 34.5	92.7 ／ 31.2	0.067	35	72	5
20	20	400	0.88	87.6 ／ 52.5	97.4 ／ 11.8	98.2 ／ 8.2	98.1 ／ 9.0	97.7 ／ 13.1	98.4 ／ 8.6	0.067	415	46	56
20	30	600	1.32	88.3 ／ 45.6	98.5 ／ 6.9	99.3 ／ 3.4	99.2 ／ 3.9	99.1 ／ 5.1	99.4 ／ 2.3	0.065	955	49	82
40	1	40	0.09	86.8 ／ 47.5	79.6 ／ 75.8	79.6 ／ 75.8	79.6 ／ 75.8	87.0 ／ 53.3	84.4 ／ 55.8	0.067	0	–	0
40	2	80	0.18	88.8 ／ 46.2	84.0 ／ 70.8	84.0 ／ 70.4	84.0 ／ 70.8	89.3 ／ 49.6	86.7 ／ 53.3	0.067	0	–	0
40	5	200	0.44	87.9 ／ 46.5	84.7 ／ 67.8	84.7 ／ 68.0	84.7 ／ 67.8	89.4 ／ 47.2	88.0 ／ 49.0	0.067	0	–	0
40	10	400	0.88	86.9 ／ 48.9	92.9 ／ 34.5	93.6 ／ 34.4	92.9 ／ 35.2	92.9 ／ 32.1	93.4 ／ 32.5	0.066	175	58	18
40	20	800	1.75	87.6 ／ 49.8	96.9 ／ 12.9	98.4 ／ 7.8	98.1 ／ 9.8	97.8 ／ 12.3	98.2 ／ 9.4	0.064	1,081	48	71
40	30	1,200	2.60	88.6 ／ 45.1	98.6 ／ 5.9	99.3 ／ 2.7	99.3 ／ 2.7	99.3 ／ 3.4	99.5 ／ 1.7	0.069	1,766	42	86
64	1	64	0.14	88.0 ／ 44.3	81.6 ／ 75.0	81.6 ／ 75.0	81.6 ／ 75.0	88.2 ／ 53.6	85.4 ／ 57.8	0.067	0	–	0
64	2	128	0.28	87.8 ／ 46.1	82.1 ／ 72.4	82.1 ／ 72.4	82.1 ／ 72.4	88.4 ／ 49.0	85.8 ／ 54.4	0.067	0	–	0
64	5	320	0.71	88.3 ／ 46.2	85.7 ／ 61.6	87.0 ／ 60.2	85.4 ／ 60.9	90.0 ／ 44.2	88.2 ／ 47.4	0.068	33	74	3
64	10	640	1.40	88.1 ／ 46.9	93.2 ／ 33.7	94.5 ／ 29.5	94.5 ／ 30.2	94.2 ／ 29.9	94.8 ／ 27.3	0.064	296	46	25
64	20	1,280	2.77	88.1 ／ 45.5	97.3 ／ 11.7	98.5 ／ 7.7	98.5 ／ 7.9	98.3 ／ 9.6	98.6 ／ 6.5	0.067	1,689	41	77
64	30	1,920	4.09	88.2 ／ 46.0	98.4 ／ 6.7	99.2 ／ 3.1	99.3 ／ 2.5	99.2 ／ 4.1	99.3 ／ 2.2	0.070	2,664	37	88

表 A·14　再出現と混入率の格子：SSB-hard（[%]）.

c	r	未知	混入率	静的 p	p^+	p^+p^-（交差なし）	σ（本稿）	σ+静的 p	$\sigma\times$TINS	$\Pr(p^{\text{fin}}\leq 0.05)$	種	ID	再現
10	1	10	0.02	76.4 ／ 66.7	60.9 ／ 90.0	61.0 ／ 90.0	60.9 ／ 90.0	71.3 ／ 70.0	78.8 ／ 60.0	0.066	0	–	0
10	2	20	0.04	76.9 ／ 73.3	66.1 ／ 86.7	66.1 ／ 86.7	66.1 ／ 86.7	73.6 ／ 80.0	78.0 ／ 66.7	0.065	0	–	0
10	5	50	0.11	83.3 ／ 53.3	73.9 ／ 82.0	73.8 ／ 82.0	73.9 ／ 82.0	81.8 ／ 56.0	86.2 ／ 53.3	0.066	0	–	0
10	10	100	0.22	75.6 ／ 63.3	76.6 ／ 60.0	78.9 ／ 64.0	76.6 ／ 60.0	78.8 ／ 58.3	85.2 ／ 46.7	0.066	0	–	0
10	20	200	0.44	74.5 ／ 69.8	83.0 ／ 46.8	85.3 ／ 44.7	84.9 ／ 45.8	83.1 ／ 50.8	87.6 ／ 39.3	0.065	122	65	22
10	50	500	1.10	73.9 ／ 65.7	94.4 ／ 18.1	98.2 ／ 9.3	97.7 ／ 11.5	96.0 ／ 17.9	98.2 ／ 9.7	0.064	535	49	55
30	1	30	0.07	80.6 ／ 55.6	73.6 ／ 71.1	73.6 ／ 71.1	73.6 ／ 71.1	79.4 ／ 53.3	82.0 ／ 50.0	0.066	0	–	0
30	2	60	0.13	79.3 ／ 65.0	70.1 ／ 82.8	70.1 ／ 82.8	70.1 ／ 82.8	77.1 ／ 65.6	79.8 ／ 63.3	0.066	0	–	0
30	5	150	0.33	75.8 ／ 65.1	68.5 ／ 79.1	68.5 ／ 79.1	68.5 ／ 79.1	74.2 ／ 68.9	77.6 ／ 67.3	0.066	0	–	0
30	10	300	0.66	79.8 ／ 58.9	80.3 ／ 60.3	81.1 ／ 59.9	80.1 ／ 60.7	82.4 ／ 54.1	85.2 ／ 48.6	0.067	72	77	6
30	20	600	1.32	74.9 ／ 71.0	83.8 ／ 46.4	87.9 ／ 42.1	86.0 ／ 43.3	85.1 ／ 48.2	88.4 ／ 38.0	0.065	344	51	28
30	50	1,500	3.23	71.3 ／ 67.3	92.3 ／ 25.1	96.1 ／ 15.6	96.0 ／ 16.5	95.3 ／ 21.6	96.7 ／ 13.8	0.068	1,507	42	58
100	1	100	0.22	75.2 ／ 65.0	68.9 ／ 80.0	68.9 ／ 79.7	68.9 ／ 80.0	74.2 ／ 68.0	80.5 ／ 62.3	0.066	0	–	0
100	2	200	0.44	72.5 ／ 71.0	66.7 ／ 84.0	66.6 ／ 83.8	66.7 ／ 84.0	71.6 ／ 74.2	77.2 ／ 66.7	0.066	0	–	0
100	5	500	1.10	74.8 ／ 70.3	72.9 ／ 75.8	72.9 ／ 76.3	72.6 ／ 76.1	75.8 ／ 69.9	80.3 ／ 60.1	0.066	33	88	1
100	10	1,000	2.17	75.4 ／ 68.1	80.2 ／ 56.5	84.7 ／ 51.3	84.3 ／ 50.7	84.7 ／ 54.1	88.0 ／ 42.9	0.066	404	55	18
100	20	2,000	4.26	74.5 ／ 66.9	87.8 ／ 38.5	91.5 ／ 32.4	91.3 ／ 32.4	90.2 ／ 35.8	92.5 ／ 28.7	0.065	1,597	44	45
100	50	5,000	10.00	75.9 ／ 67.2	93.6 ／ 24.2	96.2 ／ 19.6	96.2 ／ 18.5	95.3 ／ 22.9	96.6 ／ 17.2	0.063	5,132	32	70
300	1	300	0.66	74.9 ／ 67.1	68.9 ／ 78.6	68.8 ／ 78.4	68.9 ／ 78.6	73.8 ／ 68.9	78.0 ／ 62.1	0.066	0	–	0
300	2	600	1.32	75.4 ／ 64.7	71.7 ／ 73.6	71.7 ／ 73.7	71.7 ／ 73.6	75.8 ／ 66.2	80.6 ／ 58.0	0.067	0	–	0
300	5	1,500	3.23	77.1 ／ 64.6	78.2 ／ 62.2	81.7 ／ 57.9	80.9 ／ 58.9	82.3 ／ 56.5	85.4 ／ 48.3	0.067	402	50	13
300	10	3,000	6.25	76.0 ／ 66.8	84.5 ／ 47.9	88.2 ／ 42.3	88.0 ／ 42.3	87.6 ／ 44.4	89.7 ／ 37.1	0.065	1,751	38	36
300	20	6,000	11.76	76.3 ／ 65.7	90.4 ／ 34.2	93.4 ／ 30.3	93.4 ／ 29.7	92.2 ／ 32.0	94.0 ／ 27.3	0.065	5,348	32	60
300	50	15,000	25.00	75.4 ／ 66.9	94.9 ／ 22.1	96.4 ／ 19.4	96.5 ／ 19.3	95.7 ／ 23.2	96.7 ／ 18.2	0.061	18,001	28	86
980	1	980	2.13	75.7 ／ 65.9	73.4 ／ 72.9	73.4 ／ 73.0	73.3 ／ 73.1	76.7 ／ 66.0	81.0 ／ 58.2	0.065	33	85	1
980	2	1,960	4.17	75.4 ／ 66.1	78.2 ／ 62.4	81.6 ／ 57.0	81.5 ／ 56.8	82.3 ／ 55.7	85.3 ／ 47.6	0.064	522	47	14
980	5	4,900	9.82	75.6 ／ 66.6	85.3 ／ 46.7	89.0 ／ 43.2	89.0 ／ 43.1	88.3 ／ 43.2	90.2 ／ 38.0	0.067	3,381	36	44
980	10	9,800	17.88	75.5 ／ 66.7	90.0 ／ 35.5	92.5 ／ 33.1	92.5 ／ 32.8	91.5 ／ 34.2	93.1 ／ 29.7	0.065	9,400	31	66
980	20	19,600	30.34	75.4 ／ 66.8	93.4 ／ 27.8	94.8 ／ 26.1	94.8 ／ 26.2	93.9 ／ 28.4	95.1 ／ 24.3	0.064	22,780	27	85
980	50	49,000	52.13	75.4 ／ 66.6	95.6 ／ 23.4	96.1 ／ 22.5	96.1 ／ 22.6	95.5 ／ 25.1	96.4 ／ 20.8	0.056	64,430	25	98

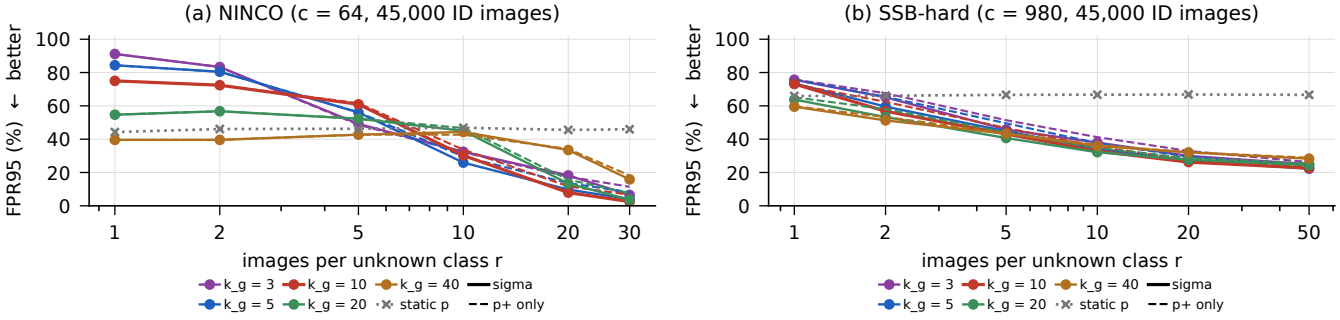


図 A·2　近傍数 k_g を変えた再出現の格子（FPR95，単体，DINOv2 L/14 + DINOv3 L/16）．
実線は σ，破線は p^+ だけ，灰色の点線は静的 p（k_g に依らない）．

像の kNN（k=50）は両ベンチマークで 16 枚の静的 p より良く，ImageNet-200 の near-OOD では σ が kNN より低い FPR95 を保つ）：前半は否定（ImageNet-200 で kNN 28.04%／ 4.40%対静的 p 26.72%／ 3.71%，CIFAR-100 の far-OOD で 32.15%対 29.19%；CIFAR-100 の near-OOD だけ 16.35%対 16.49%），後半は成立（9.07%対 28.04%）．**H5**（σ が静的 p を下回る r は k_g が小さいほど小さく，大きい r での利得は $k_g \in \{10, 20\}$ で最大）：前半は否定，後

表 A·15 種の上限 τ=0.05 の規則の格子（FPR95[%]，単体，3 回の平均）．Storey 型・単純 BH 法はそれぞれ上限なし／あり．種は DINOv3 L/16 のビューで上限付き Storey 型に選ばれた枚数（2 つの折の合計）とそのうち ID の割合（%）．

			Storey 型		単純 BH 法				種（上限付き Storey 型）	
c	r	混入率	上限なし	τ=0.05	上限なし	τ=0.05	p^+ のみ	静的 p	枚数	ID
NINCO										
5	1	0.0	73.3	73.3	73.3	73.3	73.3	33.3	0	–
5	2	0.0	76.7	76.7	76.7	76.7	76.7	63.3	0	–
5	5	0.1	76.0	76.0	76.0	76.0	76.0	46.7	0	–
5	10	0.1	40.7	40.7	40.7	40.7	40.7	69.3	35	81.9
5	20	0.2	11.7	11.7	9.7	9.7	10.7	43.3	91	71.2
5	30	0.3	10.9	10.9	12.0	12.0	14.4	34.2	189	58.8
10	1	0.0	73.3	73.3	73.3	73.3	73.3	33.3	0	–
10	2	0.0	78.3	78.3	78.3	78.3	78.3	55.0	0	–
10	5	0.1	70.7	70.7	70.7	70.7	70.7	52.7	0	–
10	10	0.2	28.7	28.7	26.7	26.7	26.7	45.7	70	79.1
10	20	0.4	8.8	8.8	10.0	10.0	10.7	39.2	232	53.8
10	30	0.7	1.4	1.4	2.0	2.0	4.9	35.1	436	50.3
20	1	0.0	60.0	60.0	60.0	60.0	60.0	35.0	0	–
20	2	0.1	77.5	77.5	77.5	77.5	77.5	40.0	0	–
20	5	0.2	68.0	68.0	68.0	68.0	68.0	45.7	0	–
20	10	0.4	36.2	36.2	34.7	34.7	34.7	44.5	35	71.7
20	20	0.9	9.0	9.0	8.5	8.5	11.8	52.5	415	46.1
20	30	1.3	3.9	3.9	4.3	4.3	6.9	45.6	955	48.8
40	1	0.1	75.8	75.8	75.8	75.8	75.8	47.5	0	–
40	2	0.2	70.8	70.8	70.8	70.8	70.8	46.2	0	–
40	5	0.4	67.8	67.8	67.8	67.8	67.8	46.5	0	–
40	10	0.9	35.2	35.2	34.5	34.5	34.5	48.9	175	58.5
40	20	1.7	9.8	9.8	10.2	10.2	12.9	49.8	1081	47.5
40	30	2.6	2.7	2.7	3.2	3.2	5.9	45.1	1766	41.5
64	1	0.1	75.0	75.0	75.0	75.0	75.0	44.3	0	–
64	2	0.3	72.4	72.4	72.4	72.4	72.4	46.1	0	–
64	5	0.7	60.9	60.9	61.6	61.6	61.6	46.2	33	74.5
64	10	1.4	30.2	30.2	30.5	30.5	33.7	46.9	296	46.2
64	20	2.8	7.9	7.9	7.7	7.7	11.7	45.5	1689	41.5
64	30	4.1	2.5	2.5	2.9	2.9	6.7	46.0	2664	36.6
SSB-hard										
10	1	0.0	90.0	90.0	90.0	90.0	90.0	66.7	0	–
10	2	0.0	86.7	86.7	86.7	86.7	86.7	73.3	0	–
10	5	0.1	82.0	82.0	82.0	82.0	82.0	53.3	0	–
10	10	0.2	60.0	60.0	60.0	60.0	60.0	63.3	0	–
10	20	0.4	45.8	45.8	47.0	47.0	46.8	69.8	122	64.8
10	50	1.1	11.5	11.5	11.1	11.1	18.1	65.7	535	48.5
30	1	0.1	71.1	71.1	71.1	71.1	71.1	55.6	0	–
30	2	0.1	82.8	82.8	82.8	82.8	82.8	65.0	0	–
30	5	0.3	79.1	79.1	79.1	79.1	79.1	65.1	0	–
30	10	0.7	60.7	60.7	60.3	60.3	60.3	58.9	72	77.0
30	20	1.3	43.3	43.3	43.5	43.5	46.4	71.0	344	51.4
30	50	3.2	16.5	16.5	16.3	16.3	25.1	67.3	1507	41.9
100	1	0.2	80.0	80.0	80.0	80.0	80.0	65.0	0	–
100	2	0.4	84.0	84.0	84.0	84.0	84.0	71.0	0	–
100	5	1.1	76.1	76.1	75.8	75.8	75.8	70.3	33	87.9
100	10	2.2	50.7	50.7	51.5	51.5	56.5	68.1	404	55.2
100	20	4.3	32.4	32.4	33.3	33.3	38.5	66.9	1597	44.2
100	50	10	18.5	18.5	18.7	18.7	24.2	67.2	5132	31.6
300	1	0.7	78.6	78.6	78.6	78.6	78.6	67.1	0	–
300	2	1.3	73.6	73.6	73.6	73.6	73.6	64.7	0	–
300	5	3.2	58.9	58.9	58.7	58.7	62.2	64.6	402	49.7
300	10	6.2	42.3	42.3	42.8	42.8	47.9	66.8	1751	38.0
300	20	12	29.7	29.7	29.9	29.9	34.2	65.7	5348	32.2
300	50	25	19.3	19.6	19.6	19.6	22.1	66.9	14736	19.1
980	1	2.1	73.1	73.1	72.9	72.9	72.9	65.9	33	84.7
980	2	4.2	56.8	56.8	56.5	56.5	62.4	66.1	522	47.5
980	5	9.8	43.1	43.1	42.7	42.7	46.7	66.6	3381	36.1
980	10	18	32.8	32.8	32.6	32.6	35.5	66.7	9372	31.0
980	20	30	26.2	26.1	26.1	26.1	27.8	66.8	17485	16.7
980	50	52	22.6	22.2	21.5	22.2	23.4	66.6	40958	6.6

半は $\{5, 10\}$ として部分的に成立（付録 A.10）．**H6**（中心化で CLIP の静的 p は DINO 系の範囲（near 70%未満，far 40%未満）に入り，DINO 系の変化は 10 ポイント以内）：前半は否定（near 91.41%，far 78.46%），後半は静的 p で成立（最大 8.97 ポイント），kNN では DINO (v1) の far-OOD で 10.92 ポイント動く．